Associação entre duas variáveis categóricas

Aula 16 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

06/10/2026

escuro (d)

Análises que vamos fazer nas próximas aulas

TIPOS DE VARIÁVEIS	PERGUNTA TÍPICA	VISUALIZAÇÃO	MÉTODO
duas categóricas	as variáveis são estatisticamente independentes?	barras empilhadas com a proporção dentro de cada grupo	**qui-quadrado**
duas binárias	a proporção é a mesma nos dois grupos?	barras com a proporção de cada grupo	**duas proporções**
numérica e categórica (2 grupos)	a média é a mesma nos dois grupos?	boxplot por grupo	teste t
numérica e categórica (3 ou mais)	as médias são todas iguais?	boxplot por grupo	ANOVA
duas numéricas	existe relação linear entre elas?	gráfico de dispersão	correlação e regressão

As duas primeiras linhas são as de hoje. As outras chegam nas aulas 17 e 18. Em todas, a variável que vamos testar é construída a partir dos documentos dos processos, e não recebida pronta.

PARTE 1

Construção das bases de dados

A base de processos do BTG

A PLANILHA DO BANCO

30 mil contratos de financiamento de veículo que viraram processo, com o número CNJ, a situação do contrato, o valor financiado, a taxa e **o valor que o banco pagou** no processo, quando pagou.

OS DOCUMENTOS

47 mil PDFs em nove arquivos compactados, 89 GB. Cada processo tem dois ou três: a **petição inicial** do autor, a **contestação** do banco e, às vezes, um **e-mail** do escritório ou o **acordo**.

A AMOSTRA DAS AULAS

800 processos sorteados entre os 21 mil que têm PDF. Em **11,6%** deles o banco pagou alguma coisa.

Dados disponíveis e dados necessários

O QUE TEMOS

- uma planilha com **um contrato por linha**
- PDFs com nomes como `1530842_20210916135114.pdf`
- o número CNJ de cada processo
- texto corrido, às vezes **uma letra por linha**

O QUE QUEREMOS

- uma tabela com **um processo por linha**
- o tribunal de cada processo
- o tipo de cada documento
- o que o autor pediu e se o banco pagou

A ponte entre a planilha e os PDFs é o número no nome do arquivo: ele é o mesmo que aparece depois do “CV” na coluna `pasta` (`CV1530842_4093` corresponde a `1530842_….pdf`).

Duas formas de estruturar dados de textos judiciais

FERRAMENTA	O QUE FAZ	EXEMPLO NESTA BASE	VALE A PENA QUANDO
expressão regular	encontra trechos que têm sempre a mesma forma	tribunal no número CNJ; “valor da causa R$ 21.593,82”; “CONTESTAÇÃO” no começo do PDF	o campo tem formato padronizado e o volume é grande
modelo de linguagem	lê o texto e responde perguntas sobre ele	a tese principal da inicial; se o autor pede dano moral	a informação está no sentido do texto, e há como conferir uma amostra

O CRITÉRIO

A escolha depende da natureza do campo. Usar modelo para extrair um número de processo é pagar caro por algo exato e gratuito. Usar regex para decidir a tese é pedir a um padrão de caracteres que interprete.

Tribunal e ano a partir do número CNJ

TEXTO DE ORIGEM (FICTÍCIO)

“EXCELENTÍSSIMO SENHOR DOUTOR JUIZ DE DIREITO DA 3ª VARA CÍVEL DA COMARCA DE CAMPINAS/SP. Processo nº 1004521-33.2023.8.26.0114. JOÃO PEREIRA, já qualificado nos autos da ação revisional...”

Run Code

```python
import re

texto = "Processo nº 1004521-33.2023.8.26.0114. JOÃO PEREIRA, já qualificado"
CNJ = re.compile(r"\d{7}-\d{2}\.(\d{4})\.8\.(\d{2})\.\d{4}")

m = CNJ.search(texto)
print("número:", m.group(0))
print("ano do ajuizamento:", m.group(1), "| código do tribunal:", m.group(2))
```

O número CNJ tem forma fixa, `NNNNNNN-DD.AAAA.J.TR.OOOO`: o `J` igual a 8 é a Justiça Estadual e o `TR` 26 é São Paulo. Por isso o tribunal sai em 100% dos processos.

Tipo de peça a partir do começo do documento

Run Code

```python
import re

CONTESTACAO = re.compile(r"CONTESTA[ÇC][ÃA]O", re.I)
INICIAL = re.compile(r"(PROPOR|AJUIZAR|PROMOVER)\b.{0,150}\bA[ÇC][ÃA]O", re.I | re.S)

def tipo_de_peca(texto):
    if CONTESTACAO.search(texto):
        return "contestação"
    if INICIAL.search(texto):
        return "petição inicial"
    return "outra"

print(tipo_de_peca("O BANCO RÉU vem, respeitosamente, apresentar CONTESTAÇÃO à ação"))
print(tipo_de_peca("MARIA SOUZA, brasileira, vem propor a presente AÇÃO REVISIONAL"))
```

Os dois textos são fictícios, no formato das peças reais: a contestação se anuncia no primeiro parágrafo, e a inicial diz que “vem propor a ação”.

Valor da causa a partir do fecho da petição

PETIÇÃO A (FICTÍCIA)

"...Dá-se à causa o valor de R$ 21.593,82. Termos em que pede deferimento."

PETIÇÃO B (FICTÍCIA)

"...Atribui-se à demanda o montante de R$ 18.000,00. Nestes termos, pede deferimento."

Run Code

```python
import re

VALOR_CAUSA = re.compile(
    r"(?:valor\s+da\s+causa|d[áa]-se\s+[àa]\s+causa).{0,60}?R\$\s*([\d.]{1,12},\d{2})", re.I)

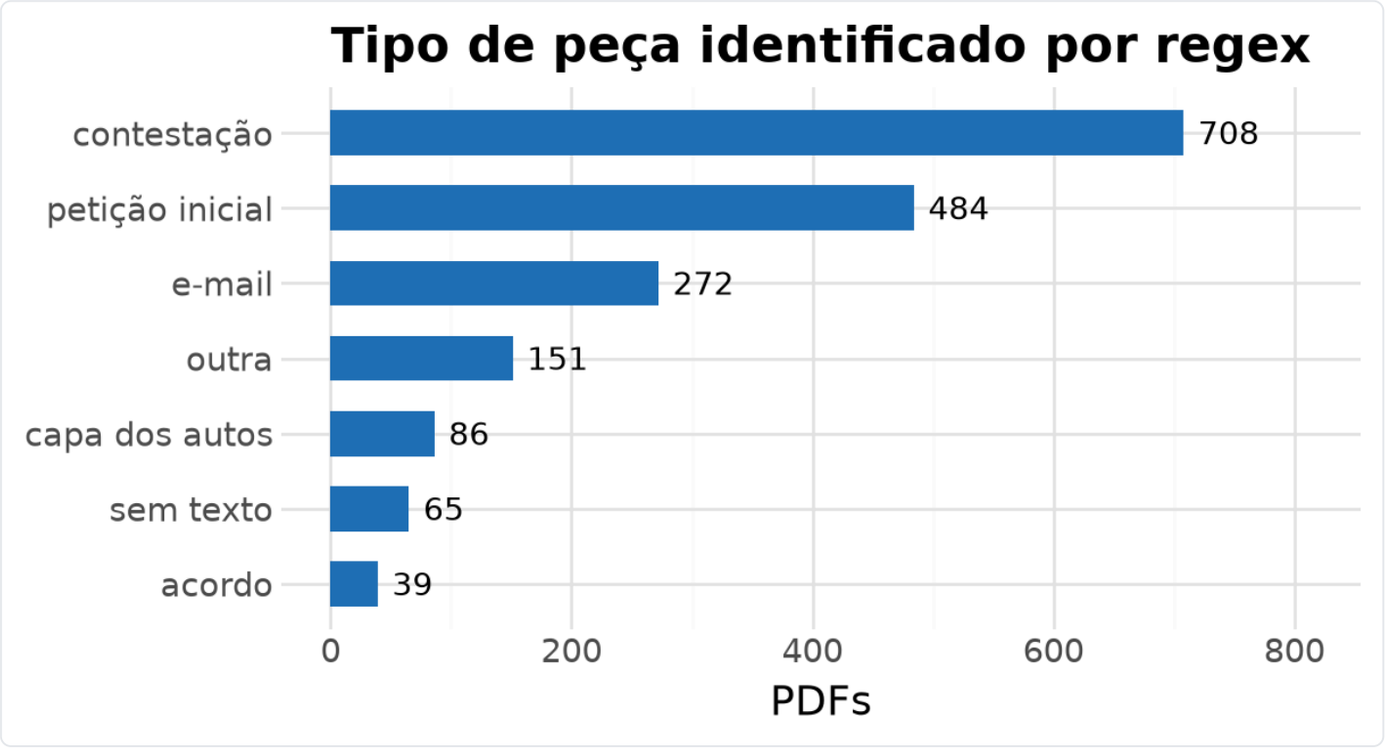
m = VALOR_CAUSA.search("Dá-se à causa o valor de R$ 21.593,82. Termos em que pede deferimento.")
print("petição A:", m.group(1))

m = VALOR_CAUSA.search("Atribui-se à demanda o montante de R$ 18.000,00. Nestes termos...")
print("petição B:", m)
```

Na petição B o padrão não acha nada (`None`): ela diz o mesmo com outras palavras. Na amostra, o valor da causa aparece em cerca de metade das iniciais.

Tipos de documento identificados na amostra

Gráfico | Código



Os 1.805 PDFs dos 800 processos. “Sem texto” são PDFs escaneados, só imagem.

PARTE 2

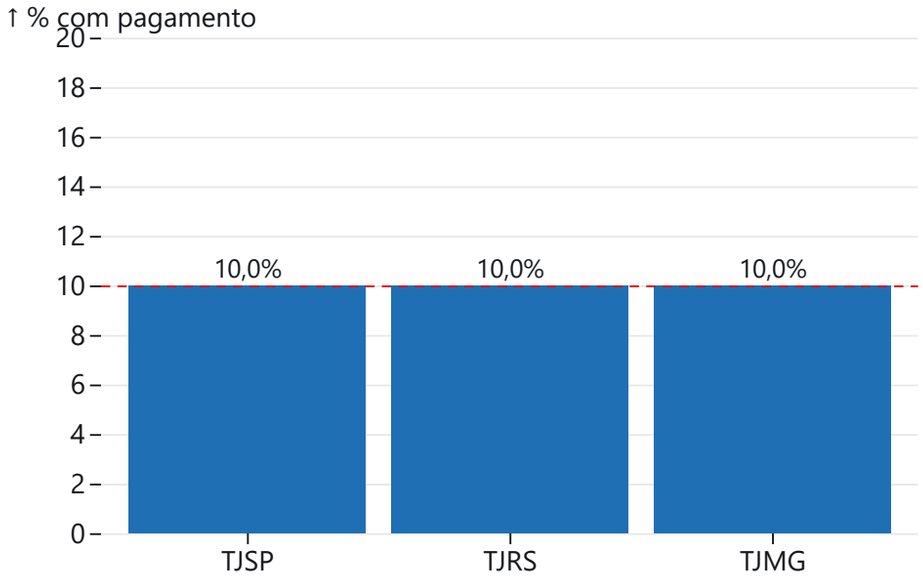
Associação entre duas variáveis categóricas

Tabela de dupla entrada, revisitada

AFASTAMENTO DA INDEPENDÊNCIA

0

TRIBUNAL	PAGOU	NÃO PAGOU	TOTAL	%
TJSP	**30**	**270**	300	
TJRS	**15**	**135**	150	
TJMG	**15**	**135**	150	
total	**60**	**540**	**600**	



PARA A SALA

As variáveis são independentes?

Contagens esperadas sob independência

$$E_{ij} = \frac{(\text{total da linha } i) \times (\text{total da coluna } j)}{n}$$

NA LOUSA

Célula TJSP e pagou: $\frac{300 \times 60}{600} = 30$. As seis esperadas são **30 e 270** no TJSP, **15 e 135** no TJRS e **15 e 135** no TJMG.

Mover o controle não muda os totais de linha nem de coluna, então as contagens esperadas são **sempre as mesmas**. No zero, a tabela observada é exatamente a esperada.

Estatística qui-quadrado

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

COM O CONTROLE EM 3, CÉLULA A CÉLULA

$$\underbrace{\frac{(33-30)^2}{30} + \frac{(267-270)^2}{270}}_{\text{TJSP}} + \underbrace{0 + 0}_{\text{TJRS}} + \underbrace{\frac{(12-15)^2}{15} + \frac{(138-135)^2}{135}}_{\text{TJMG}} = 0{,}30 + 0{,}03 + 0{,}60 + 0{,}07 = 1{,}0$$

O quadrado impede que sobra e falta se cancelem. A divisão por E faz uma diferença de 3 numa célula de 15 pesar mais do que a mesma diferença numa célula de 270.

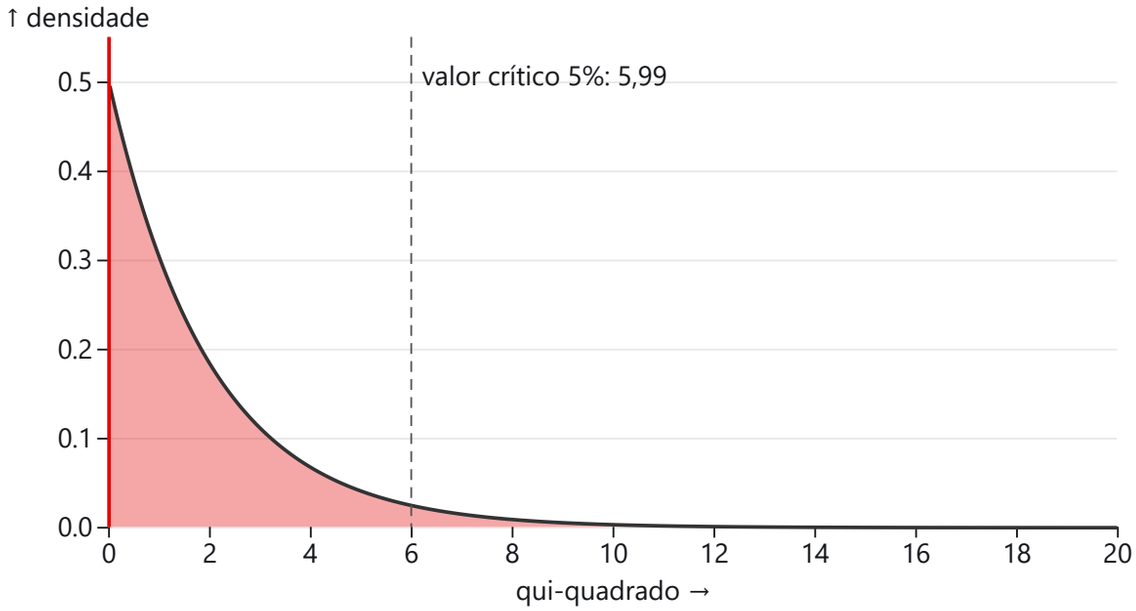
Distribuição qui-quadrado e valor-p

AFASTAMENTO DA INDEPENDÊNCIA

0

	PAGOU	NÃO PAGOU
TJSP	30	270
TJRS	15	135
TJMG	15	135

qui-quadrado = **0,00**
graus de liberdade = **2**
valor-p = **1,000**



Se as variáveis fossem independentes, o qui-quadrado seguiria essa curva. O valor-p é a **área pintada**, à direita do valor observado. Quando o valor observado passa da linha pontilhada, o valor-p fica abaixo de 5%.

Graus de liberdade

LINHAS

3

COLUNAS

2

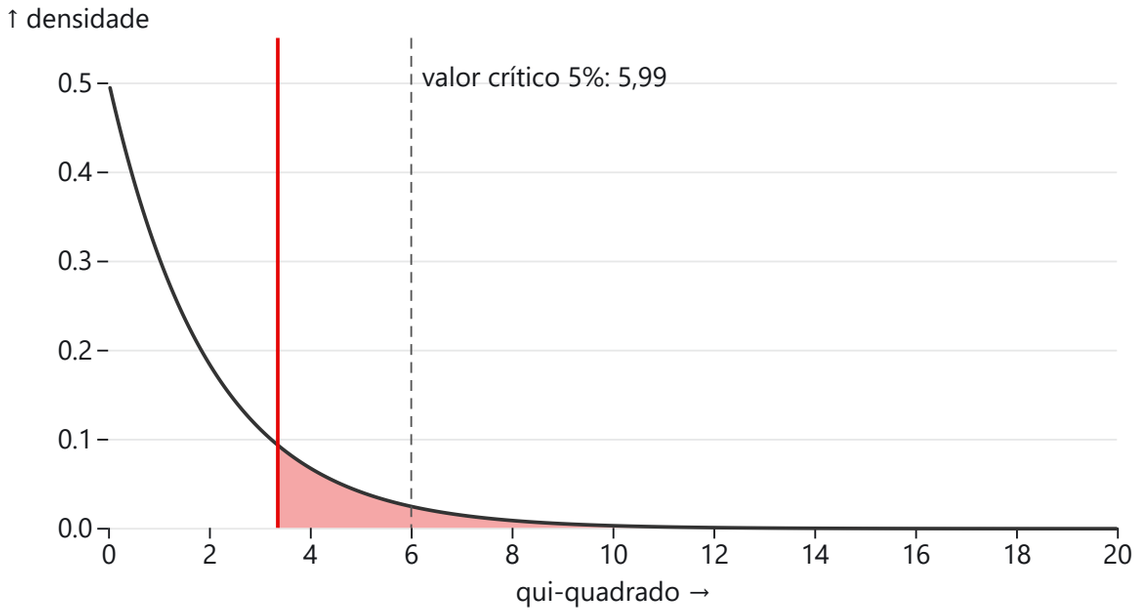
	CATEGORIA A	CATEGORIA B
grupo 1	33	40
grupo 2	38	42
grupo 3	46	32

graus de liberdade = (3 − 1) × (2 − 1) = **2**

qui-quadrado = **3,35**

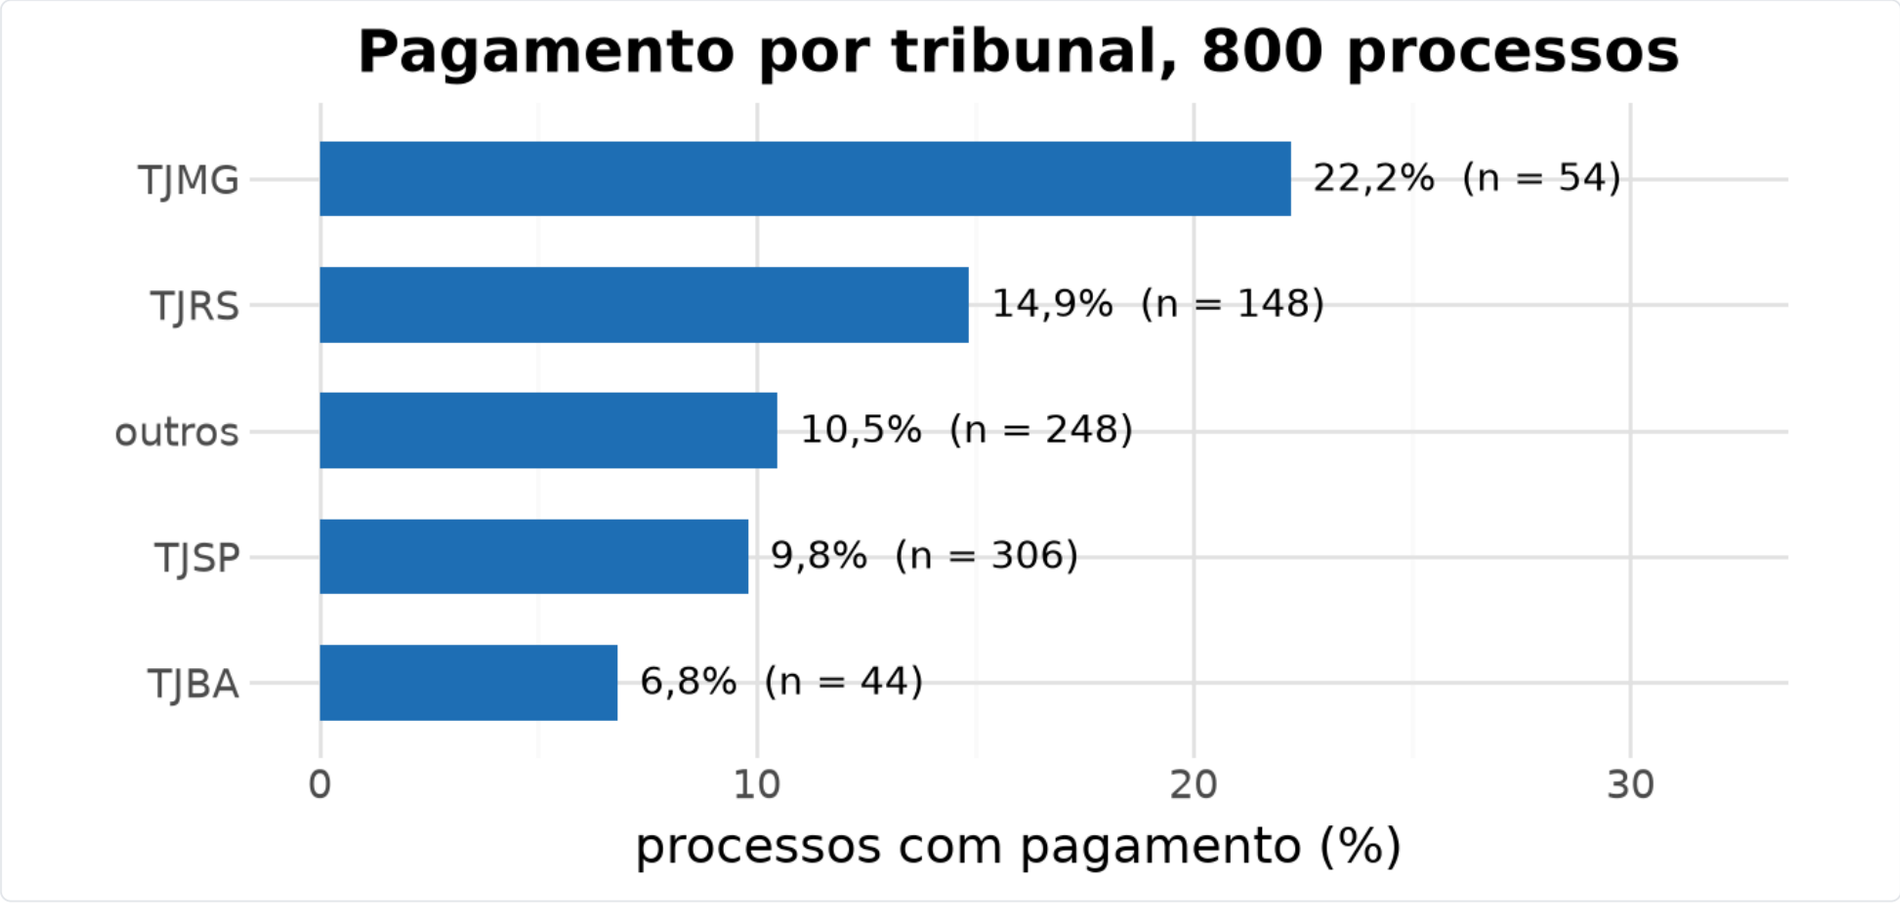
valor crítico 5% = **5,99**

valor-p = **0,188**



Graus de liberdade são quantas células da tabela podem variar livremente depois de fixados os totais: $(\text{linhas} - 1) \times (\text{colunas} - 1)$. Tabelas maiores têm curva mais deslocada para a direita e valor crítico maior.

Tribunal e pagamento na base do BTG



Tribunais com menos de 40 processos na amostra foram agrupados em “outros”. Sem esse agrupamento há células com contagem esperada próxima de zero, e o teste não vale.

Teste qui-quadrado no Python

```
from scipy.stats import chi2_contingency

# tribunais com menos de 40 processos vão para "outros"
frequentes = processos["tribunal"].value_counts()
processos["tribunal_grupo"] = processos["tribunal"].where(
    processos["tribunal"].isin(frequentes[frequentes >= 40].index), "outros")

tabela = pd.crosstab(processos["tribunal_grupo"], processos["pagou"])
qui, valor_p, gl, esperado = chi2_contingency(tabela)
print(f"qui-quadrado = {qui:.2f}   gl = {gl}   valor-p = {valor_p:.3f}")
```

```
qui-quadrado = 9.71   gl = 4   valor-p = 0.046
```

COMO RELATAR

Tribunal e pagamento **não são independentes** ($\chi^2 = 9{,}71$; gl = 4; valor-p = 0,046): de 6,8% no TJBA a 22,2% no TJMG.

Limitações do valor-p

Não indica que o tribunal **causa** o pagamento. Os tribunais recebem casos diferentes.

Não mede o **tamanho** da diferença, só o quanto ela é difícil de atribuir ao acaso.

Não diz **qual** tribunal destoa. Para isso, compare as proporções de cada linha.

Depende do agrupamento escolhido: outro corte pode dar outro valor-p.

Materiais do exercício

ONDE ESTÃO OS ARQUIVOS

Base: `btg_aulas.csv`, no BlackBoard, em **Materiais e Informações**. É sigilosa: não compartilhe fora da turma nem suba no GitHub.

Notebook: `aula16_duas_categoricas.ipynb`, com link na atividade **Aula 16** do BlackBoard. O link abre no GitHub ou direto no Colab.

COMO ABRIR

No Colab: abra o notebook pelo link "abrir no Colab", clique no ícone de pasta, à esquerda, e arraste `btg_aulas.csv` para lá.

No Jupyter (VS Code ou Anaconda): baixe o notebook e deixe `btg_aulas.csv` na mesma pasta dele.

O notebook lê a base com `pd.read_csv("btg_aulas.csv")`. Se aparecer `FileNotFoundError`, o arquivo não está na mesma pasta do notebook.

Exercício, parte a: teste qui-quadrado

O status do contrato está associado ao pagamento? Em duplas, complete as lacunas ____ da parte a do notebook: a tabela de dupla entrada, a proporção dentro de cada status, as contagens esperadas e o teste depois de juntar “EM DIA” com “LIQUIDADO”.

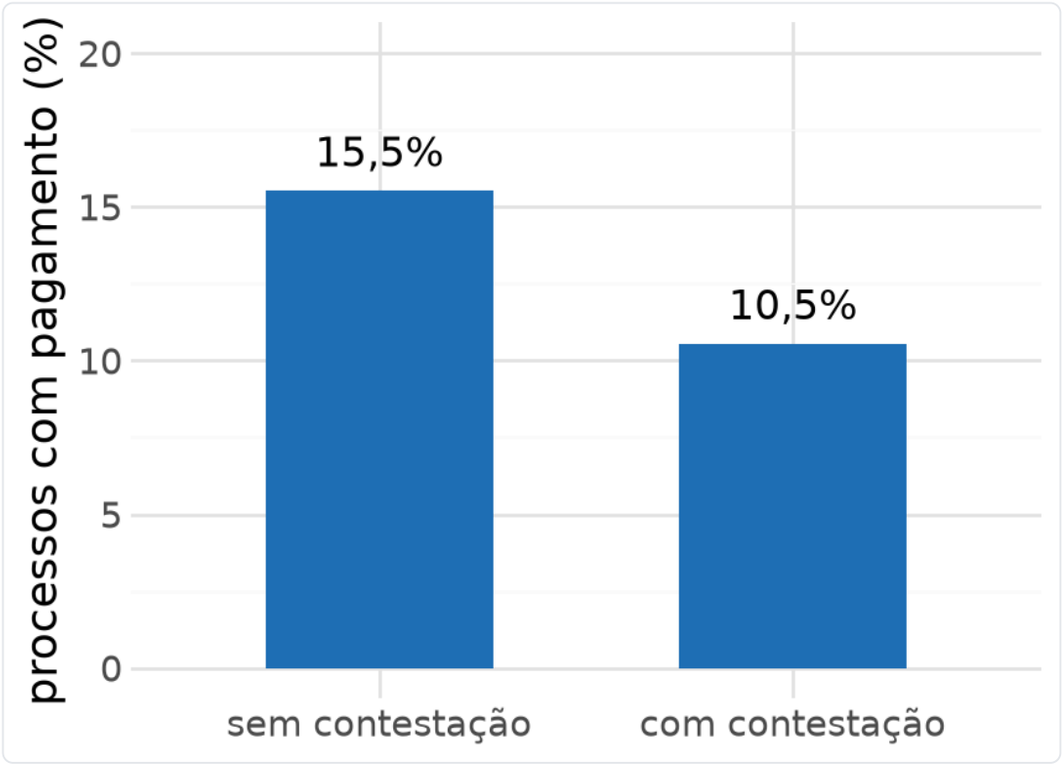
> **PARA ENTREGAR**
>
> Escreva o resultado em **uma frase**, com o qui-quadrado, os graus de liberdade e o valor-p.

PARTE 3

Comparação de duas proporções

Contestação e pagamento

	PAGOU	TOTAL	PROPORÇÃO
sem contestação	27	174	**15,5%**
com contestação	66	626	**10,5%**



“Tem contestação” é se entre os PDFs do processo há um classificado como contestação pela expressão regular. As duas variáveis são binárias, então dá para comparar diretamente as duas proporções.

Duas proporções e qui-quadrado dão o mesmo valor-p

Duas proporções | Qui-quadrado

Run Code

```python
from statsmodels.stats.proportion import proportions_ztest, confint_proportions_2indep

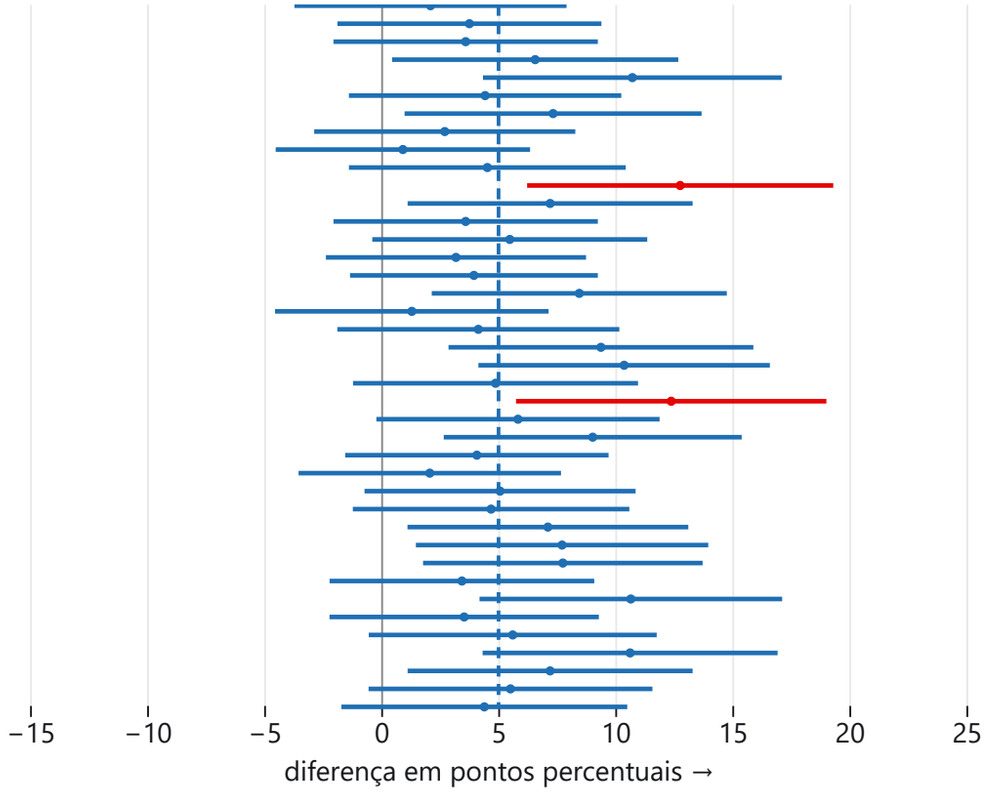
z, valor_p = proportions_ztest([27, 66], [174, 626])
baixo, alto = confint_proportions_2indep(27, 174, 66, 626, method="wald")

print(f"z = {z:.2f}   valor-p = {valor_p:.4f}")
print(f"diferença: {(27/174 - 66/626)*100:.1f} pontos, IC 95% de {baixo*100:.1f} a {alto*100:.1f}")
```

Numa tabela 2×2 sem correção de continuidade, $\chi^2 = z^2$ ($1{,}81^2 \approx 3{,}28$) e o valor-p é o mesmo. A vantagem das duas proporções é o **intervalo da diferença**.

Interpretação frequentista do intervalo de confiança

sortear 40 novas amostras



38 de 40 intervalos contêm a diferença verdadeira (linha tracejada)

16 de 40 excluem o zero, ou seja, teriam valor-p < 0,05

O QUE SIGNIFICA 95%

Repetindo a amostragem muitas vezes, **95% dos intervalos** conteriam a diferença verdadeira. A confiança é no método.

LIGAÇÃO COM O VALOR-P

Intervalo **contém o zero** quando o valor-p **passa de 0,05**. Aqui: de -0,9 a 10,9, valor-p de 0,07.

Relato de um valor-p de 0,07

O QUE NÃO ESCREVER

“Não há diferença entre processos com e sem contestação.”

O QUE ESCREVER

A diferença estimada é de **5 pontos percentuais**, e o intervalo de 95% vai de -0,9 a 10,9 pontos. **Estes dados não mostram diferença** ao nível de 5%, mas são compatíveis tanto com nenhuma diferença quanto com uma diferença de 10 pontos.

0,07 e 0,04 descrevem evidências parecidas. Relatar a estimativa e o intervalo evita transformar uma régua contínua num carimbo de sim ou não.

Exercício, parte b: teste de duas proporções

A proporção de pagamento é a mesma nos processos com e sem petição inicial entre os documentos do banco?

```
com = processos[processos["tem_inicial"]]["pagou"]
sem = processos[~processos["____"]]["pagou"]

z, valor_p = proportions_ztest([sem.sum(), com.sum()], [len(sem), len(____)])
baixo, alto = confint_proportions_2indep(sem.sum(), len(sem), com.sum(), len(com),
                                         method="wald")
```

PARA ENTREGAR

Escreva a diferença, o intervalo de 95% e o valor-p em **uma frase**. Cuidado: o teste mostra associação. Não escreva que ter a inicial no dossiê **causa** alguma coisa.

Resumo

HOJE

- Regex estrutura o que tem forma fixa, e a cobertura dele é um resultado.
- Independência: a mesma proporção em todos os grupos.
- O qui-quadrado mede o afastamento da tabela esperada; o valor-p é a área à direita na distribuição.
- Graus de liberdade: $(\text{linhas} - 1) \times (\text{colunas} - 1)$.
- O intervalo de 95% contém o zero quando o valor-p passa de 0,05.

QUINTA-FEIRA, 08/10

Uma variável **numérica** e uma **categórica**: teste t e ANOVA.

E as variáveis que só um modelo de linguagem consegue construir, porque exigem ler a petição.