Associação entre uma variável numérica e uma categórica

Aula 17 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

08/10/2026

Métodos de análise por tipo de variável

TIPOS DE VARIÁVEIS	PERGUNTA TÍPICA	VISUALIZAÇÃO	MÉTODO
duas categóricas	as variáveis são estatisticamente independentes?	barras empilhadas	qui-quadrado
duas binárias	a proporção é a mesma nos dois grupos?	barras com as proporções	duas proporções
numérica e categórica (2 grupos)	**a média é a mesma nos dois grupos?**	**boxplot por grupo**	**teste t**
numérica e categórica (3 ou mais)	**as médias são todas iguais?**	**boxplot por grupo**	**ANOVA e Tukey**
duas numéricas	existe relação linear entre elas?	gráfico de dispersão	correlação e regressão

As duas primeiras linhas foram a aula 16. Hoje são a terceira e a quarta, e as variáveis categóricas vêm de um modelo de linguagem que leu as petições.

PARTE 1

Construção de variáveis com modelos de linguagem

Especificação das categorias com `Literal`

```
from typing import Literal

Tese = Literal["juros abusivos", "tarifas e encargos", "seguro embutido",
               "capitalização de juros", "outra"]
```

CONJUNTO FECHADO DE RESPOSTAS

O `Literal` define as únicas respostas aceitas. O modelo não pode criar uma categoria nova, nem escrever a mesma coisa de três jeitos diferentes. Uma resposta fora da lista é rejeitada antes de entrar na tabela.

Decidir quais são as categorias é trabalho jurídico. É nessa lista que a pesquisa decide o que consegue enxergar.

Descrição dos campos com `pydantic`

```
from pydantic import BaseModel, Field

class Inicial(BaseModel):
    tese_principal: Tese = Field(
        description="O principal ponto do contrato que o autor ataca. Se houver "
                    "mais de um, o que ocupa mais espaço na petição.")
    pede_dano_moral: bool = Field(
        description="O autor pede indenização por dano moral?")
    qtd_pedidos: int = Field(
        ge=1, le=15,
        description="Quantos pedidos de mérito distintos o autor faz, sem contar "
                    "gratuidade, citação e honorários.")
```

A DESCRIÇÃO É O ENUNCIADO

A `description` não é comentário: é a pergunta que o modelo recebe sobre cada campo. Uma descrição vaga é a causa mais comum de extração ruim.

Chamada ao modelo de linguagem

```
from pydantic_ai import Agent

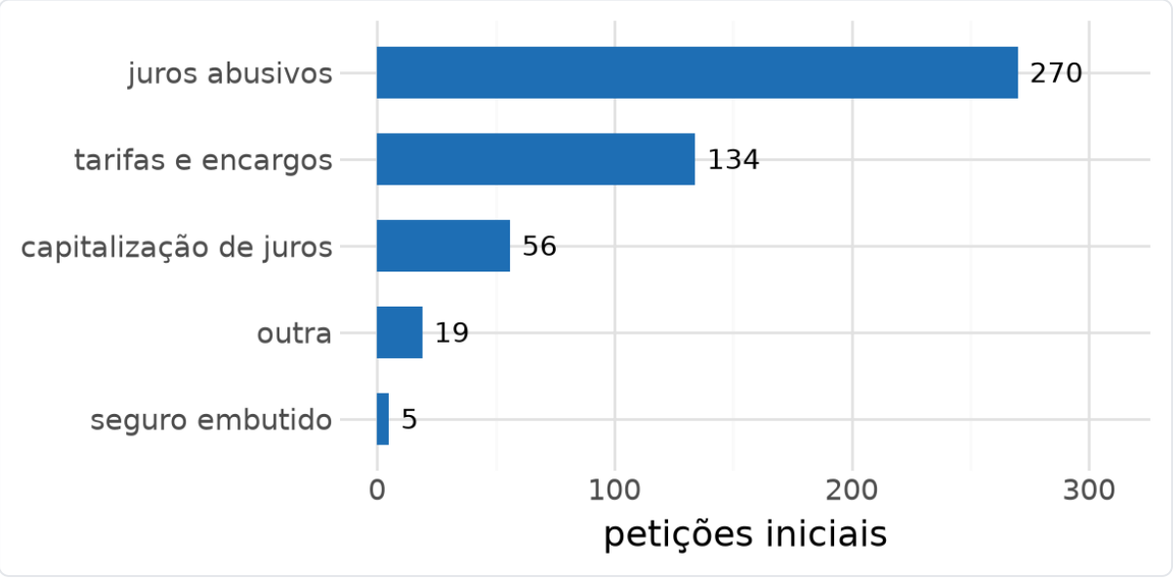
agente = Agent("openai:gpt-6-luna", output_type=Inicial,
               system_prompt="Você lê petições iniciais contra o Banco PAN sobre "
                             "financiamento de veículo e preenche os campos pedidos.")

resposta = agente.run_sync(texto_da_peticao).output
resposta.tese_principal, resposta.qtd_pedidos
```

NA BASE DO BTG

484 petições iniciais lidas, cerca de 7 segundos cada, dez de cada vez: pouco mais de dez minutos. O modelo recebe o começo da petição e a seção de pedidos, que uma expressão regular separou antes (“Ante o exposto… Termos em que pede deferimento”).

Variáveis produzidas pelo modelo



PEDIDO	PETIÇÕES
tarifas	75,8%
repetição em dobro	53,3%
seguro	48,3%
dano moral	7,2%

Quase metade das petições contesta o seguro, mas só 5 têm o seguro como tese principal. As duas perguntas são diferentes, e é por isso que viraram campos diferentes.

Conferência humana de uma amostra

OBRIGATÓRIA

Antes de usar as colunas, sorteie algumas petições, leia os pedidos e compare com o que o modelo respondeu. Se ninguém confere, o erro vira dado, o dado vira gráfico e o gráfico vira conclusão.

```
amostra = iniciais.dropna(subset=["texto_pedidos"]).sample(5, random_state=17)

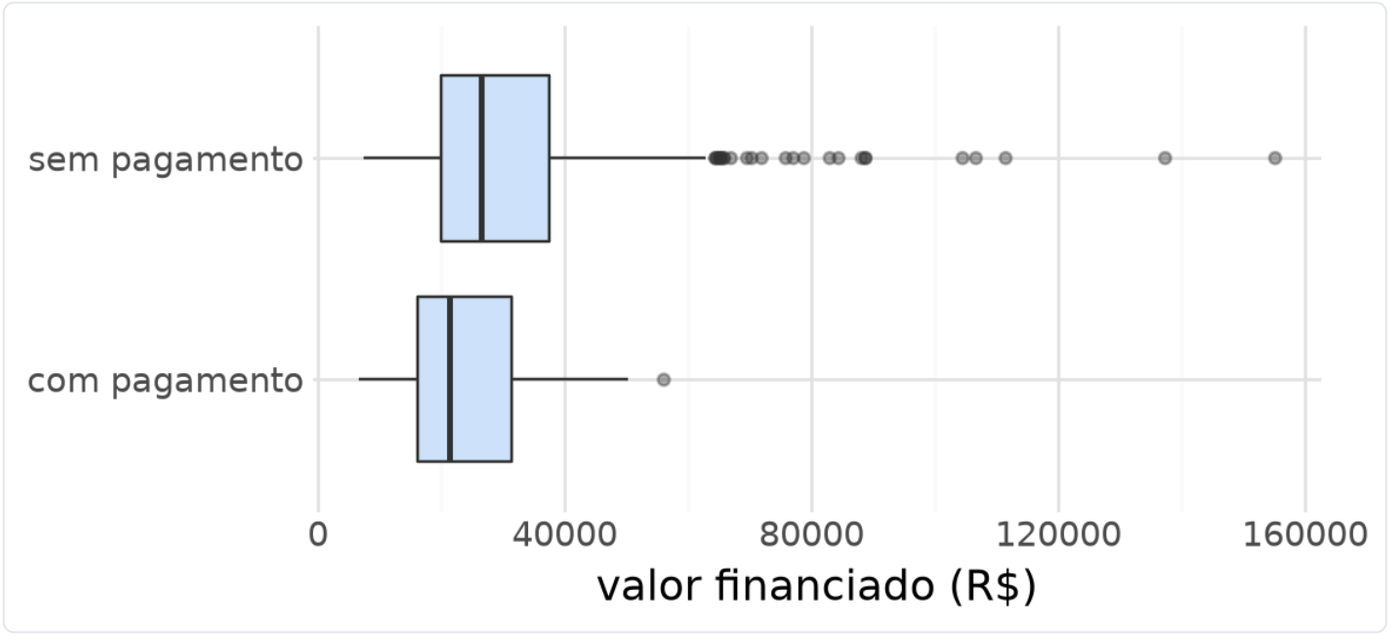
for _, linha in amostra.iterrows():
    print(linha["texto_pedidos"][:900])
    print("-> modelo:", linha["tese_principal"], "| pedidos:", int(linha["qtd_pedidos"]))
```

Com cinco casos não se mede a taxa de erro. O objetivo é ver, com os próprios olhos, que tipo de erro o modelo comete.

PARTE 2

Teste t para dois grupos

Valor financiado e pagamento



	N	MÉDIA	MEDIANA
com pagamento	90	R$ 24.276	R$ 21.216
sem pagamento	698	R$ 30.413	R$ 26.463

Uma numérica e uma binária. Antes de qualquer teste, o boxplot: a caixa dos processos com pagamento está toda um pouco à esquerda.

Hipóteses do teste t

EM PALAVRAS

H0: o valor financiado médio é **o mesmo** nos processos com e sem pagamento.

H1: o valor financiado médio é **diferente** nos dois grupos.

FORMALIZADAS

$$H_0 : \mu_{\text{com}} = \mu_{\text{sem}}$$

$$H_1 : \mu_{\text{com}} \neq \mu_{\text{sem}}$$

μ_{com} e μ_{sem} são os valores financiados médios de **todos** os processos com e sem pagamento, e não só dos 788 da amostra. São parâmetros: o teste usa as médias da amostra para dizer algo sobre eles.

Estatística t, valor-p e intervalo

$$t = \frac{\bar{x}_{\text{com}} - \bar{x}_{\text{sem}}}{\text{erro-padrão da diferença}}, \text{ com erro-padrão} = \sqrt{s_1^2/n_1 + s_2^2/n_2}$$

DIFERENÇA ENTRE AS MÉDIAS (R$ MIL)

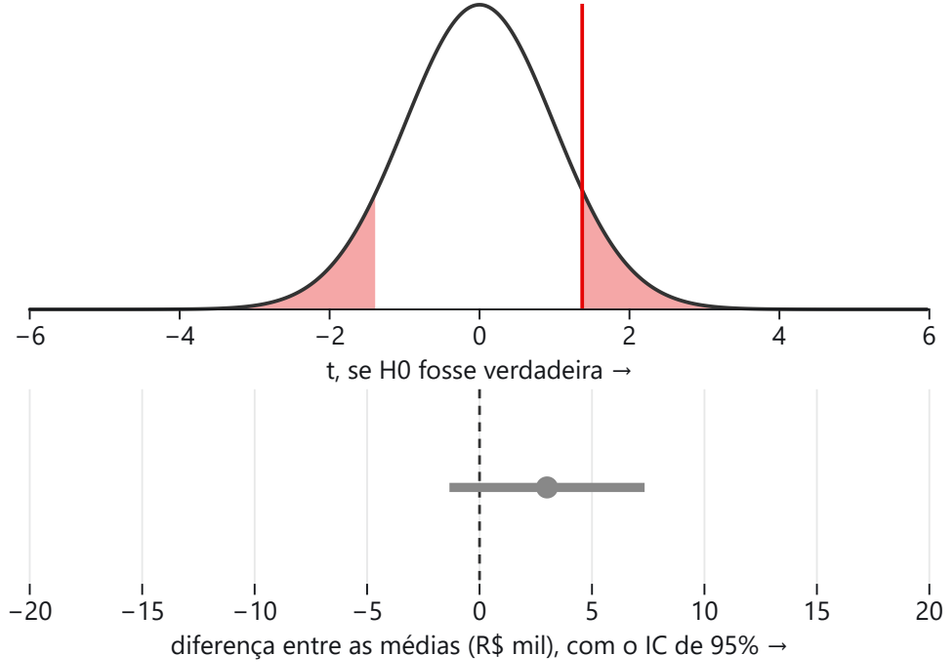
3

DESVIO-PADRÃO EM CADA GRUPO (R$ MIL)

12

PROCESSOS EM CADA GRUPO

60



erro-padrão = **2,19** mil
t = **1,37** (118 graus de liberdade)
valor-p = **0,174**
IC 95%: de **-1,3** a **7,3** mil

O intervalo contém o zero, e o valor-p passa de 0,05: os dados não mostram diferença.

Teste t no Python

```
from scipy.stats import ttest_ind

pagou = processos.loc[processos["pagou"], "valor_financiado"].dropna()
nao_pagou = processos.loc[~processos["pagou"], "valor_financiado"].dropna()

t, valor_p = ttest_ind(pagou, nao_pagou, equal_var=False)
print(f"t = {t:.2f}   valor-p = {valor_p:.6f}")
```

```
t = -4.76   valor-p = 0.000005
diferença: R$ -6,137, de R$ -8,700 a R$ -3,573 (IC 95%)
```

Interpretação do teste t

COMO RELATAR

Nos processos em que o banco pagou, o valor financiado médio é **R$ 6,1 mil menor** que nos demais (t = -4,76; valor-p < 0,001). O intervalo de 95% para a diferença vai de R$ 3,6 mil a R$ 8,7 mil.

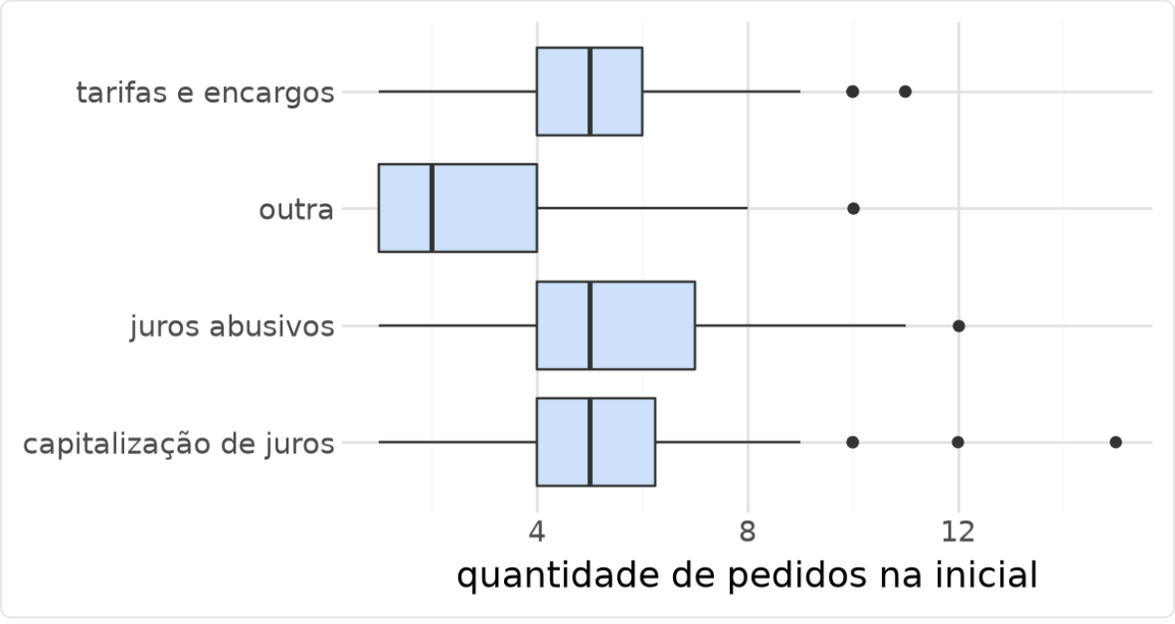
ASSOCIAÇÃO NÃO É MOTIVO

Uma explicação plausível é que fazer acordo em contrato pequeno custa pouco ao banco. Plausível não é demonstrado: o teste mostra que as médias diferem, não por quê.

PARTE 3

ANOVA para três ou mais grupos

Quantidade de pedidos por tese principal



TESE	N	MÉDIA
juros abusivos	270	5,56
capitalização	56	5,21
tarifas e encargos	134	5,19
outra	19	3,00

As duas variáveis foram construídas pelo modelo. “Seguro embutido” ficou de fora por ter só 5 petições: o mesmo critério de agrupar ou excluir categorias raras da aula 16.

ANOVA: alguma média é diferente?

HIPÓTESES

H0: a quantidade média de pedidos é a mesma nas quatro teses.

H1: pelo menos uma tese tem média diferente.

$$H_0 : \mu_{\text{juros}} = \mu_{\text{capit}} = \mu_{\text{tarifas}} = \mu_{\text{outra}}$$

```
from scipy.stats import f_oneway

grupos = [g["qtd_pedidos"].to_numpy()
          for _, g in base.groupby("tese_principal
F, valor_p = f_oneway(*grupos)
```

```
F = 7.26   valor-p = 0.00009
```

Valor-p bem abaixo de 0,05: rejeitamos H0. A ANOVA diz que **há** diferença entre as teses, mas não diz entre quais. Para isso, o próximo passo.

Tukey: entre quais teses está a diferença?

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd
print(pairwise_tukeyhsd(base["qtd_pedidos"], base["tese_principal"]))
```

PAR	DIFERENÇA	VALOR-P AJUSTADO	DIFERE?
juros abusivos e outra	-2,56	< 0,001	sim
tarifas e encargos e outra	2,19	0,001	sim
capitalização e outra	-2,21	0,002	sim
juros abusivos e tarifas	-0,36	0,46	não
capitalização e juros abusivos	0,34	0,76	não
capitalização e tarifas	-0,02	1,00	não

O Tukey compara todos os pares de uma vez, com o valor-p **ajustado** para o número de comparações. Aqui a diferença está toda no grupo “outra”.

Regra de uso da ANOVA e do Tukey

ANOVA DEU DIFERENÇA (VALOR-P < 0,05)

Use o **Tukey** para saber entre quais grupos ela está.

ANOVA NÃO DEU DIFERENÇA

Pare aí. Relate que os dados não mostram diferença entre as médias. Não rode o Tukey atrás de algum par que "dê significativo": isso é procurar até achar.

O TUKEY PODE PARECER INCONSISTENTE

- ANOVA rejeita H0, mas o Tukey não aponta **nenhum** par.
- A não difere de B, B não difere de C, mas **A difere de C**.

Não é contradição: é falta de precisão para dizer onde está a diferença.

Isso é mais comum quando os grupos têm **tamanhos muito diferentes**, como aqui (270 petições de juros contra 19 de "outra"): o planejamento da amostra decide quanta precisão cada comparação tem.

Interpretação da ANOVA e do teste de Tukey

COMO RELATAR

A quantidade de pedidos difere entre as teses (F = 7,26; valor-p < 0,001). O teste de Tukey localiza a diferença no grupo “outra”, com 3 pedidos em média contra 5 a 6 nos demais. Entre juros, capitalização e tarifas, **os dados não mostram diferença**.

As duas variáveis vieram do modelo de linguagem, então o resultado vale tanto quanto a conferência que foi feita.

PARTE 4

Exercício no notebook

Ausência de evidência e evidência de ausência

O QUE NÃO ESCREVER

"A taxa de juros **é igual** em todas as teses."

"**Não existe** relação entre a tese e a taxa."

O QUE ESCREVER

"**Estes dados não mostram** diferença na taxa de juros entre as teses."

E, se possível, o intervalo, que mostra o tamanho de diferença que ainda caberia nos dados.

Resumo

HOJE

- Regex para a forma, modelo para o sentido, e conferência sempre.
- `Literal` fecha as categorias; a `description` é o enunciado.
- Dois grupos: teste t, com o intervalo da diferença.
- Três ou mais: ANOVA, e Tukey para saber entre quem.
- Resultado nulo tem redação própria.

TERÇA-FEIRA, 13/10

Duas variáveis **numéricas**: correlação e regressão linear simples.

E o **Projeto 05**, com os quatro métodos.