Associação entre duas variáveis numéricas

Aula 18 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

13/10/2026

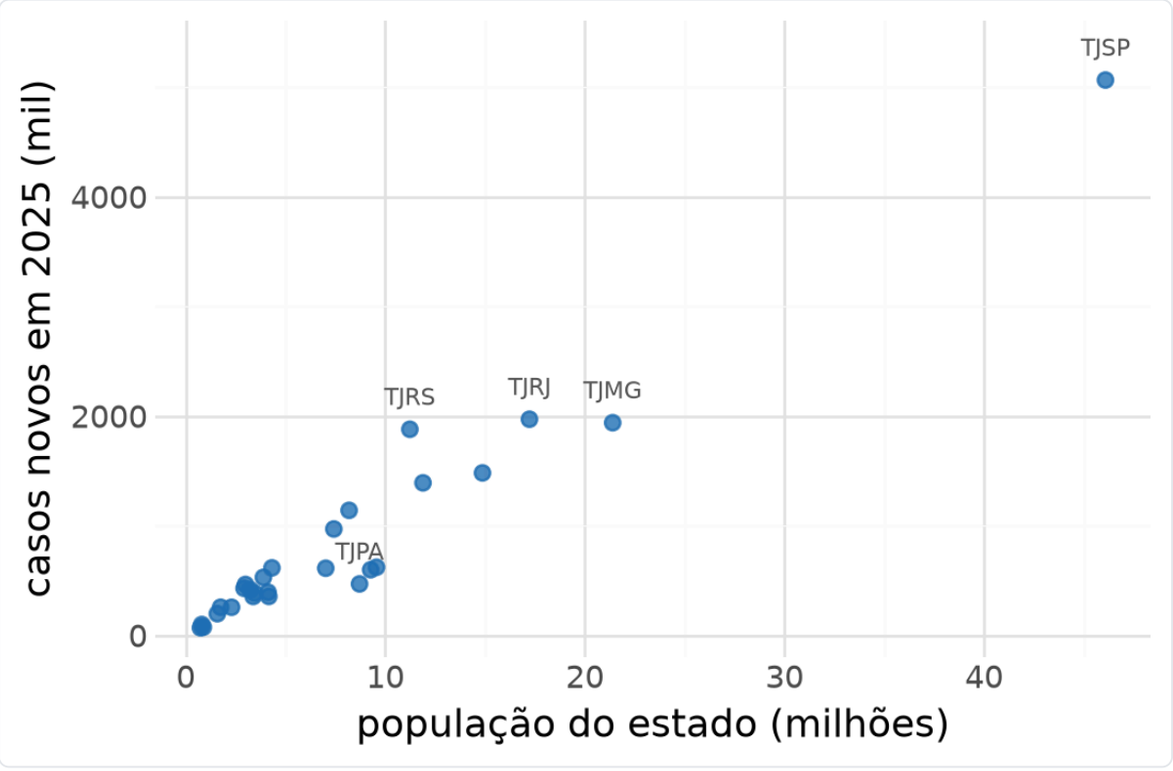
Métodos de análise por tipo de variável

TIPOS DE VARIÁVEIS	PERGUNTA TÍPICA	VISUALIZAÇÃO	MÉTODO	AULA
duas categóricas	as variáveis são estatisticamente independentes?	barras empilhadas	qui-quadrado	16
duas binárias	a proporção é a mesma nos dois grupos?	barras com as proporções	duas proporções	16
numérica e categórica (2 grupos)	a média é a mesma nos dois grupos?	boxplot por grupo	teste t	17
numérica e categórica (3 ou mais)	as médias são todas iguais?	boxplot por grupo	ANOVA e Tukey	17
duas numéricas	**existe relação linear entre elas?**	**gráfico de dispersão**	**correlação e regressão**	**18**

PARTE 1

Correlação

Casos novos e população dos estados



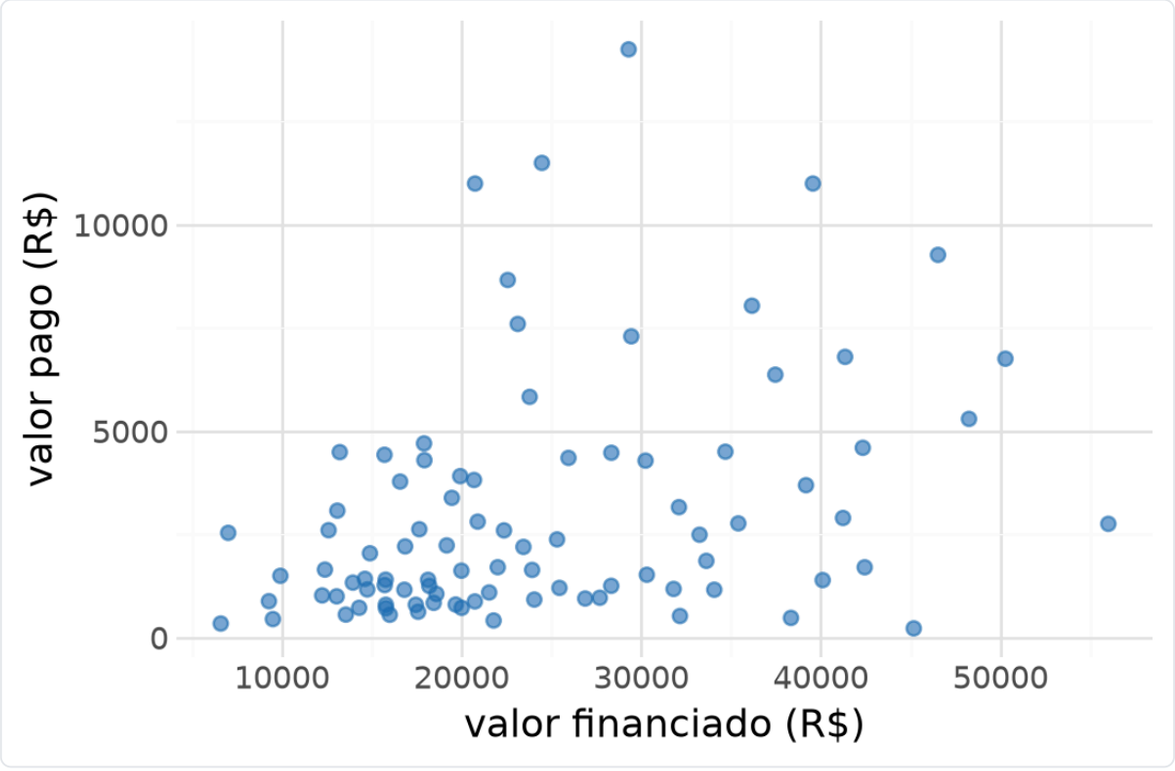
A PERGUNTA

Dá para **prever quantos casos novos** um tribunal de justiça recebe por ano a partir da **população do estado**?

Um ponto por tribunal, os 27 TJs. Casos novos de 2025 do Justiça em Números (CNJ) e população estimada de 2025 (IBGE).

CORRELAÇÃO

Valor pago e valor financiado



A PERGUNTA

Nos **90 processos** em que o banco pagou, dá para **prever quanto ele pagou** a partir do valor financiado do contrato?

As duas variáveis vêm da planilha do banco. Um ponto por processo.

Coeficiente de correlação de Pearson

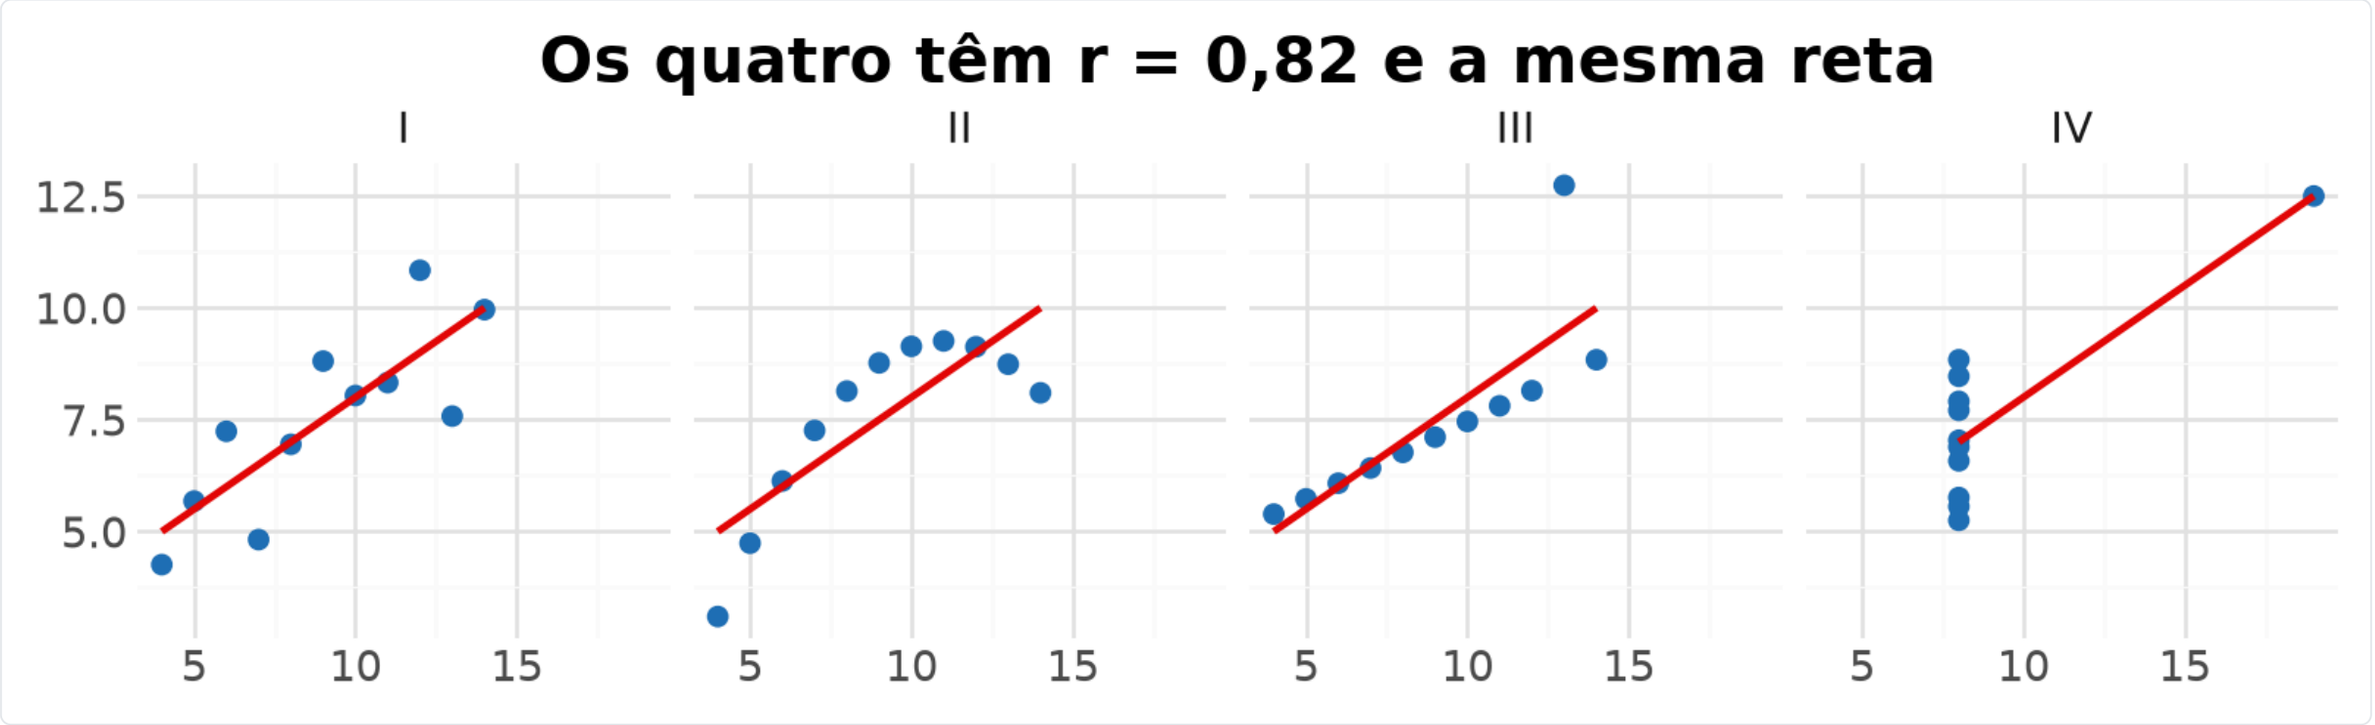
DEFINIÇÃO

O coeficiente r mede o quanto duas variáveis numéricas variam juntas **em linha reta**, numa escala de -1 a 1. Ele não tem unidade: trocar reais por milhares de reais não muda o r.

```
tribunais["populacao_mi"].corr(tribunais["casos_novos_mil"])  # 0.974
pagos["valor_financiado"].corr(pagos["valor_pago"])           # 0.342
```

$r = 0{,}97$ nos tribunais: os pontos quase formam uma reta. $r = 0{,}34$ no banco: a nuvem sobe, mas é larga.

Quarteto de Anscombe



MESMA CORRELAÇÃO, FORMATOS DIFERENTES

Os quatro conjuntos têm a mesma média, a mesma correlação e a mesma reta. Só no primeiro a reta descreve bem os dados. No segundo a relação é curva; no terceiro, um ponto fora puxa a reta; no quarto, uma única observação cria a correlação inteira.

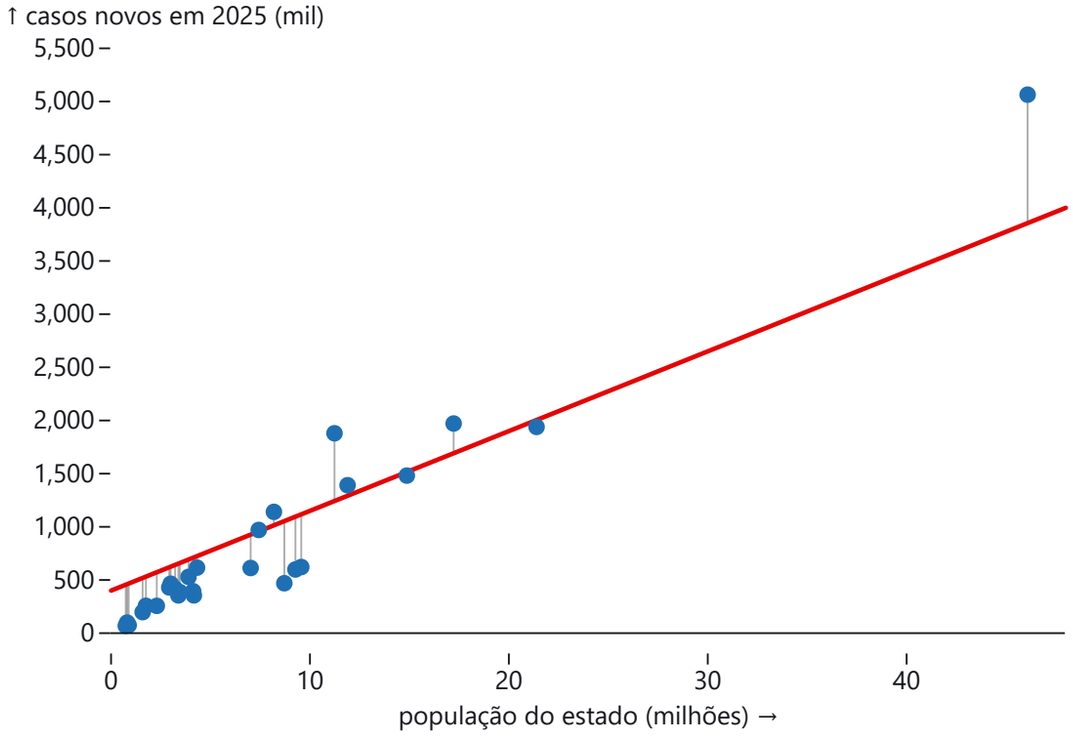
Por isso o gráfico de dispersão vem antes do coeficiente, sempre.

PARTE 2

Regressão linear simples

Reta de mínimos quadrados

$$\text{casos novos} = a + b \times \text{população} + \text{erro}$$



A (INTERCEPTO, MIL)

400

B (INCLINAÇÃO, MIL POR MILHÃO)

75

soma dos quadrados dos erros = **4.159.084**

a menor possível = **1.383.165**, com a = 9,8 e b = 106,7

b é **quanto y muda, em média, quando x aumenta uma unidade**; a é o valor de y quando x vale zero. Os traços cinza são os **erros**, a parte de y que a reta não explica. A reta de mínimos quadrados é a que torna a **soma dos quadrados dos erros** a menor possível.

Regressão no Python

```
import statsmodels.formula.api as smf

modelo = smf.ols("casos_novos_mil ~ populacao_mi", data=tribunais).fit()
print(modelo.summary().tables[1])
```

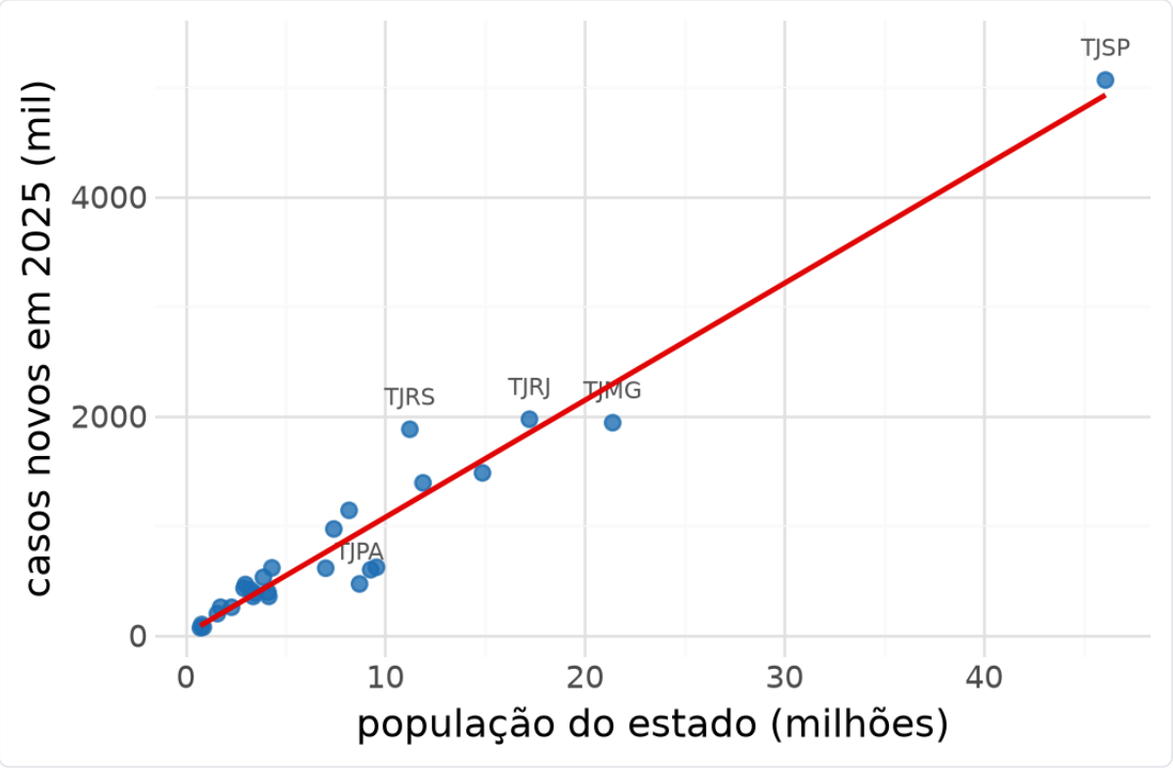
```
                 coef    std err          t      P>|t|      [0.025      0.975]
Intercept        9.8121     59.956      0.164      0.871    -113.671     133.295
populacao_mi   106.7254      4.974     21.458      0.000      96.482     116.969

R² = 0.949
```

```
import pandas as pd

modelo.predict(pd.DataFrame({"populacao_mi": [5]}))  # previsão para 5 milhões: 543.4
modelo.resid.std()                                    # erro típico da previsão: 230.6
```

Previsão com a reta



O COEFICIENTE

Cada **1 milhão de habitantes** a mais está associado a cerca de **107 mil casos novos** a mais por ano.

A PREVISÃO

Um estado de **5 milhões** de habitantes: cerca de **543 mil casos novos** por ano, errando tipicamente uns 230 mil para mais ou para menos.

Regressão no Python com correlação baixa

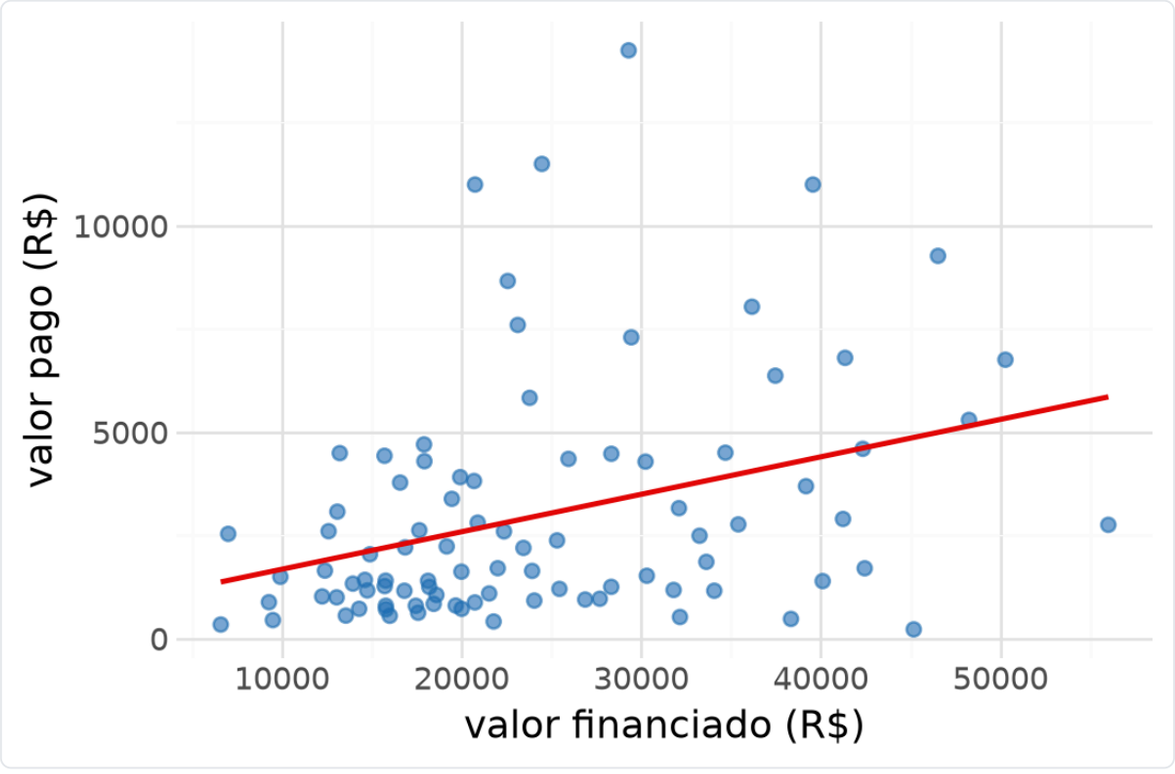
```
modelo = smf.ols("valor_pago ~ valor_financiado", data=pagos).fit()
print(modelo.summary().tables[1])
```

```
                    coef    std err          t      P>|t|      [0.025      0.975]
Intercept         776.8099    705.084      1.102      0.274    -624.396    2178.015
valor_financiado    0.0907      0.027      3.414      0.001       0.038       0.144

R² = 0.117
```

```
modelo.predict(pd.DataFrame({"valor_financiado": [30_000]}))  # previsão para R$ 30 mil: 3498.6
modelo.resid.std()                                              # erro típico da previsão: 2683.3
```

Previsão com correlação baixa



A RETA

$\text{pago} = 777 + 0{,}091 \times \text{financiado}$, com $R^2 = 0{,}12$. Cada R$ 1.000 a mais financiados está associado a uns R$ 91 a mais pagos.

A PREVISÃO

Um contrato de **R$ 30 mil**: o banco pagaria cerca de **R$ 3.500**, errando tipicamente uns **R$ 2.700**. A reta existe, mas prevê mal.

O R^2 e a qualidade da previsão

	TRIBUNAIS	BANCO
correlação r	0,97	0,34
R^2	0,95	0,12
previsão	543 mil casos novos (5 milhões de habitantes)	R$ 3.500 (R$ 30 mil financiados)
erro típico	230 mil, 42% da previsão	R$ 2.700, 77% da previsão

O R^2

O R^2 é a fração da variação de y que a reta explica. Com uma única variável explicativa, ele é o quadrado do r: $0{,}97^2 \approx 0{,}95$ e $0{,}34^2 \approx 0{,}12$.

Coeficiente sem unidade e com unidade

SEM UNIDADE

"O coeficiente deu 106,7."

106,7 de quê? Em relação a quê?

COM UNIDADE

"Cerca de 107 mil casos novos a mais por ano para cada milhão de habitantes a mais."

Agora é uma afirmação que alguém pode verificar e contestar.

Escolher a unidade de x (habitantes ou milhões de habitantes) não muda o modelo, mas muda o quanto a frase é legível. Escolha a que o leitor entende.

Resumo das três aulas

O QUE FICA

- A primeira pergunta é **que tipos de variáveis eu tenho**.
- Os dados não vêm prontos: regex para a forma, modelo para o sentido, e conferência humana.
- O gráfico vem antes do teste.
- Estimativa com intervalo, e não só o valor-p.
- Associação não é causa, em nenhum dos cinco métodos.

20/10

Regressão múltipla: mais de uma variável explicativa ao mesmo tempo.

E o teste t e a ANOVA aparecem como **casos particulares** da regressão.