Regressão linear múltipla

Aula 19 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

20/10/2026

Objetivos de aprendizagem

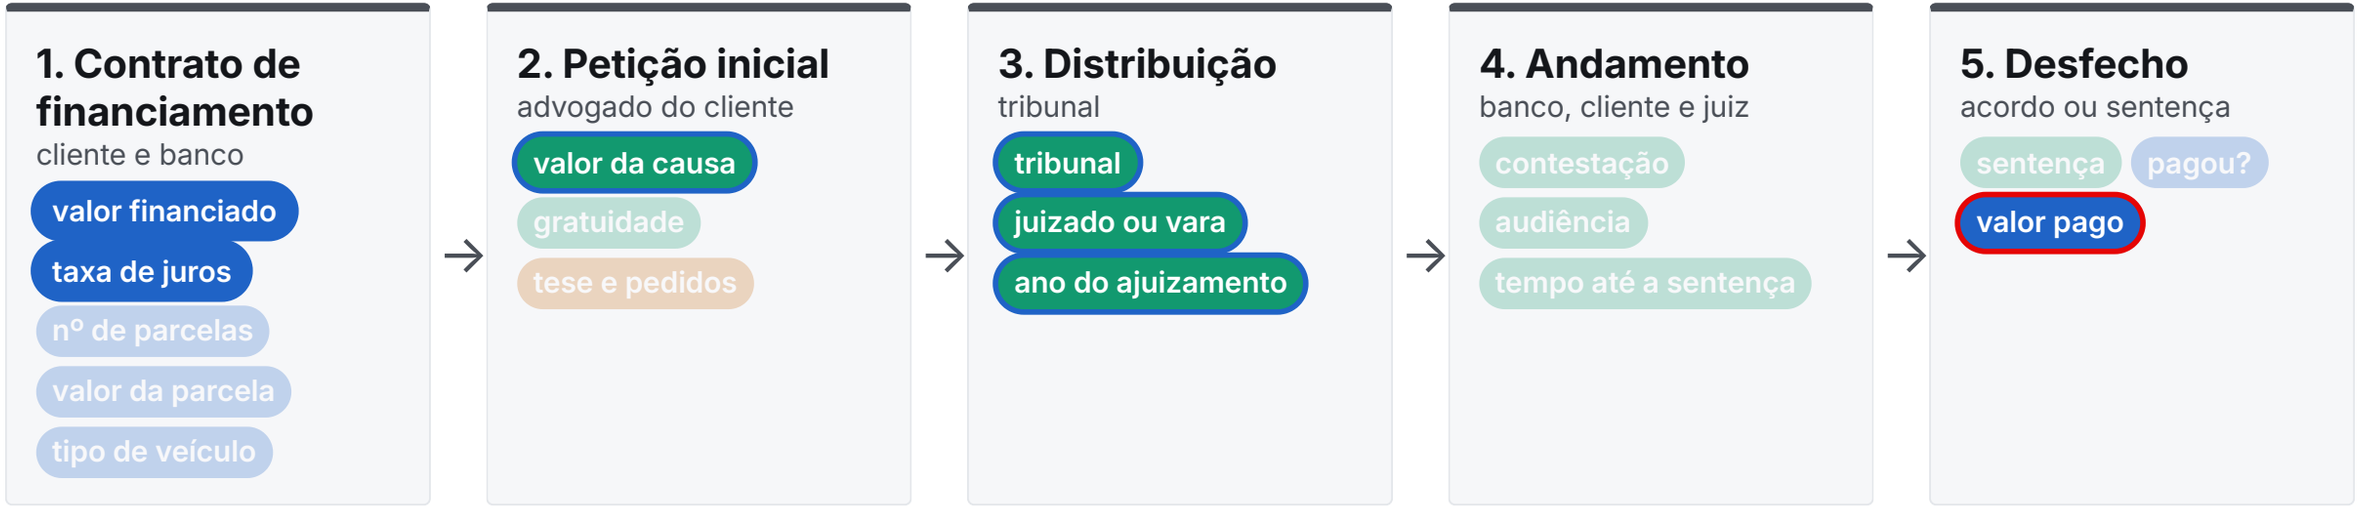
Ao final da aula, vocês devem ser capazes de:

1. **dizer** de que etapa do processo vem cada variável da base, e quais delas podem explicar o valor pago pelo banco;
2. **interpretar** o intercepto, o coeficiente angular, o intervalo e o R^2 de uma regressão simples a partir da saída do `statsmodels`;
3. **interpretar** cada coeficiente de uma regressão múltipla "mantidas as demais variáveis", e usar a correlação entre as explicativas para entender por que ele muda quando uma variável entra ou sai;
4. **reconhecer** o teste t e a ANOVA como regressões com variáveis dummy, e ler cada coeficiente em relação à categoria de referência.

PARTE 1

Do contrato ao pagamento

Do contrato ao pagamento: de onde vem cada variável



planilha do banco · registro público do processo (PDPJ e número CNJ) · PDFs do processo

PERGUNTA DA AULA: O QUE ESTÁ ASSOCIADO AO VALOR PAGO PELO BANCO?

Podem explicar o valor pago as variáveis que existem **antes** do desfecho (em destaque). O tempo até a sentença e a própria sentença fazem parte do desfecho, e não servem para explicá-lo.

A base: um processo por linha

TRIBUNAL	ANO	JUIZADO OU VARA	FINANCIADO	JUROS (A.M.)	VALOR DA CAUSA	SENTENÇA	VALOR PAGO
TJRS	2023	vara	39.700	4,00%	75.500		0
TJSP	2019	vara	32.300	1,69%	11.900	improcedente	0
TJSP	2019	vara	10.300	3,08%	10.600	parcialmente procedente	1.060
TJSP	2023	vara	36.900	1,97%	18.400	improcedente	0
TJSP	2020	vara	26.300	1,73%	14.200	improcedente	1.260
TJBA	2019	juizado	53.300	2,46%	18.000	parcialmente procedente	1.340
TJRS	2024	vara	15.800	3,50%	15.800	parcialmente procedente	800
TJSP	2023	vara	35.800	2,05%	16.000	parcialmente procedente	750

A PLANILHA DO BANCO E O REGISTRO PÚBLICO DO PROCESSO

30.000 processos; em 3.630 o banco pagou, por acordo ou condenação. Em 3.154 deles, o PDPJ deu valor da causa, juizado ou vara, sentença e datas.

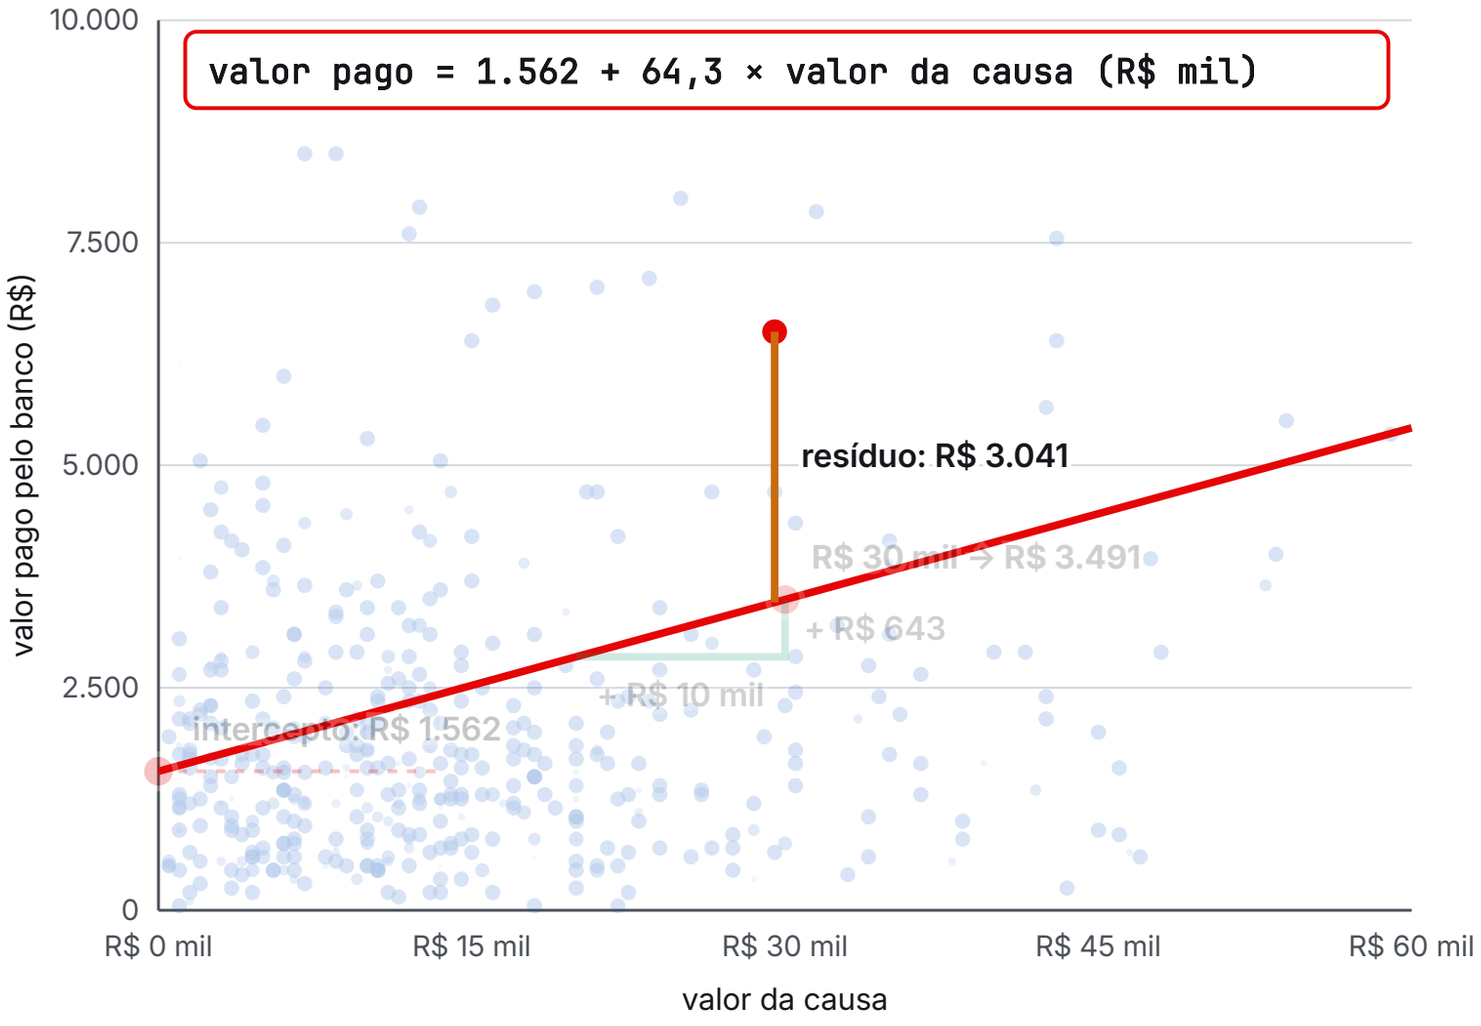
SOB SIGILO

Valores arredondados aqui e nenhum dado pessoal. A base vai para vocês pelo BlackBoard, sem número de processo, e não pode sair da turma.

PARTE 2

Regressão linear simples

Valor pago e valor da causa nos processos com pagamento



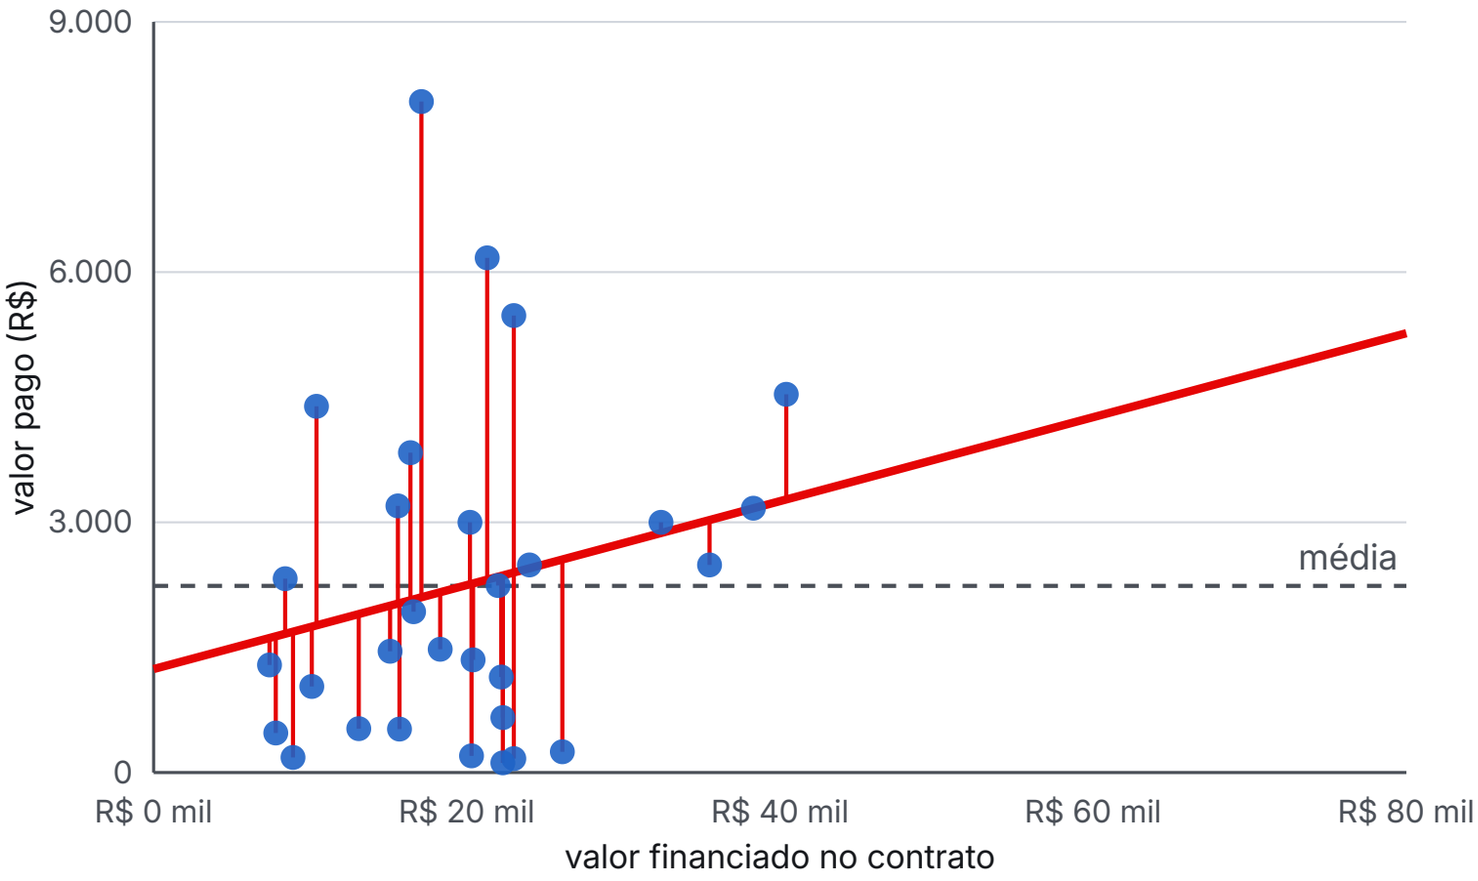
Resíduo: a distância vertical entre o processo e a reta. É a parte do valor pago que o valor da causa **não explica**.

Ajuste no statsmodels e leitura da saída

```
import statsmodels.formula.api as smf
pagos = contratos[contratos["pagou"]]
modelo = smf.ols("valor_pago ~ causa_mil",
                 data=pagos).fit()
```

R-squared = 0,088: a reta explica 8,8% da variação do valor pago.
No. Observations: 3.154 processos.

R^2: quanto da variação a reta explica



Mesmo valor pago, outra explicativa: o valor financiado no contrato. Os pontos andam só na horizontal, e o R^2 cai de cerca de 0,09 para 0,05. O pedido explica mais do que o contrato.



R^2 = 1 − sobra / total = **0,048**

Como relatar a regressão simples, e o que ela não diz

COMO RELATAR O COEFICIENTE

"Nos 3.154 processos com pagamento, cada R$ 1.000 a mais no valor da causa estão **associados** a cerca de **R$ 64 a mais pagos** (IC 95%: R$ 57 a R$ 72)."

Unidade das duas variáveis, a palavra "associados", e o intervalo.

LIMITAÇÕES

- **Uma variável só**: o valor da causa anda junto com o tamanho do contrato, e a reta mistura os dois.
- **R^2 de 8,8%**: o valor pago depende sobretudo do que não está na base, como a decisão do juiz e a negociação.
- **Associação, não efeito**: pedir mais não "causa" receber mais.
- Só processos **com pagamento**: nada diz sobre a chance de pagar.

PARTE 3

Regressão múltipla

Correlação entre as variáveis explicativas

	valor pago	valor da causa	financiado	valor da parcela	juros	ano
valor pago	1	0,30	0,21	0,26	0,13	0,19
valor da causa	0,30	1	0,42	0,48	0,26	0,22
financiado	0,21	0,42	1	0,94	-0,06	0,18
valor da parcela	0,26	0,48	0,94	1	0,21	0,31
juros	0,13	0,26	-0,06	0,21	1	0,48
ano	0,19	0,22	0,18	0,31	0,48	1

Financiado e valor da parcela: 0,94. Quase a mesma informação: as duas juntas no modelo deixam os coeficientes instáveis, e por isso a parcela fica de fora.

O coeficiente do valor da causa muda conforme o modelo

	modelo 1 `valor pago ~ causa`	modelo 2 `valor pago ~ causa + financiado`	modelo 3 `valor pago ~ causa + financiado + juros + ano`
intercepto	1.569	1.066	758
valor da causa (por R$ mil)	**58,4** 52 a 65	**49,9** 43 a 57	**44,1** 37 a 52
financiado (por R$ mil)		25,9	24,8
juros (por ponto % ao mês)			156
ano (desde 2020)			155
R^2	0,091	0,100	0,115

Variáveis da base: `valor_pago` (resposta), `valor_causa` (PDPJ, em R$ mil), `valor_financiado` (em R$ mil) e `taxa_juros` (% ao mês) da planilha, e `ano_ajuizamento` (do número CNJ, em anos desde 2020). Abaixo do coeficiente da causa, o intervalo de 95%.

Com juros e ano: R$ 44,1, mantidos o financiado, os juros e o ano. Cada coeficiente depende de **quais outras variáveis** estão no modelo.

Interpretação: mantidas as demais variáveis

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	757.5	294.5	2.57	0.010	180.1	1335.0
causa_mil	44.1	3.9	11.42	0.000	36.6	51.7
financiado_mil	24.8	4.8	5.13	0.000	15.3	34.3
taxa_juros	156.3	106.5	1.47	0.142	-52.5	365.0
anos_desde_2020	155.0	29.3	5.30	0.000	97.7	212.4

$R^2 = 0.115$ R^2 ajustado $= 0.113$ $n = 2989$

FRASE INCOMPLETA

"Cada R$ 1.000 a mais na causa aumentam o pagamento em R$ 44."

Falta o "mantidos", e "aumentam" afirma uma causa.

FRASE COMPLETA

"**Entre processos com o mesmo valor financiado, a mesma taxa de juros e o mesmo ano**, cada R$ 1.000 a mais no valor da causa estão **associados** a cerca de **R$ 44 a mais pagos** (IC 95%: R$ 37 a R$ 52)."

R^2 na regressão múltipla

MODELO	R^2	R^2 AJUSTADO
causa	0,091	0,091
causa + financiado	0,100	0,100
causa + financiado + juros + ano	0,115	0,113

O R^2 ajustado desconta o número de variáveis: só sobe quando a variável nova ajuda mais do que o acaso ajudaria.

COMO LER

O R^2 **nunca cai** quando uma variável entra, mesmo que ela seja ruído. Para comparar modelos de tamanhos diferentes, olhem o ajustado.

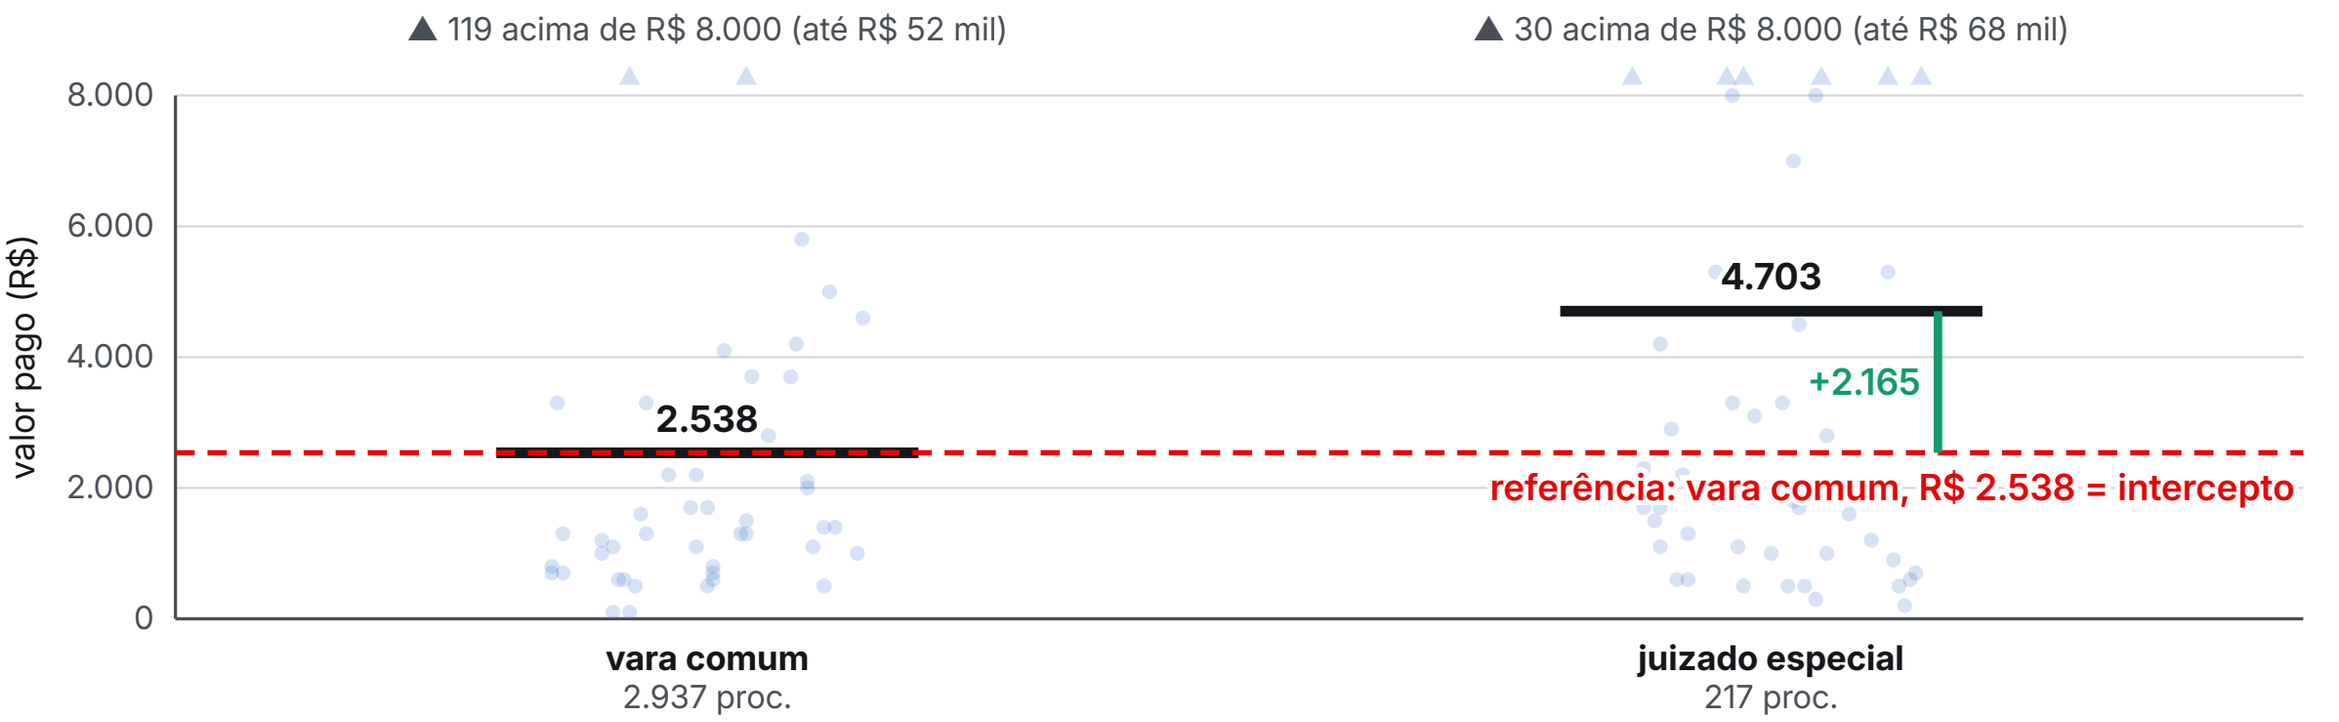
O QUE O R² NÃO DIZ

Baixo não quer dizer coeficiente inútil: a causa tem associação clara com o valor pago, mesmo com R^2 baixo. **Alto** não quer dizer causa: a parcela pelo financiado, prazo e juros dá R^2 de 0,97 porque é a fórmula da parcela.

PARTE 4

Variáveis categóricas: teste t e ANOVA

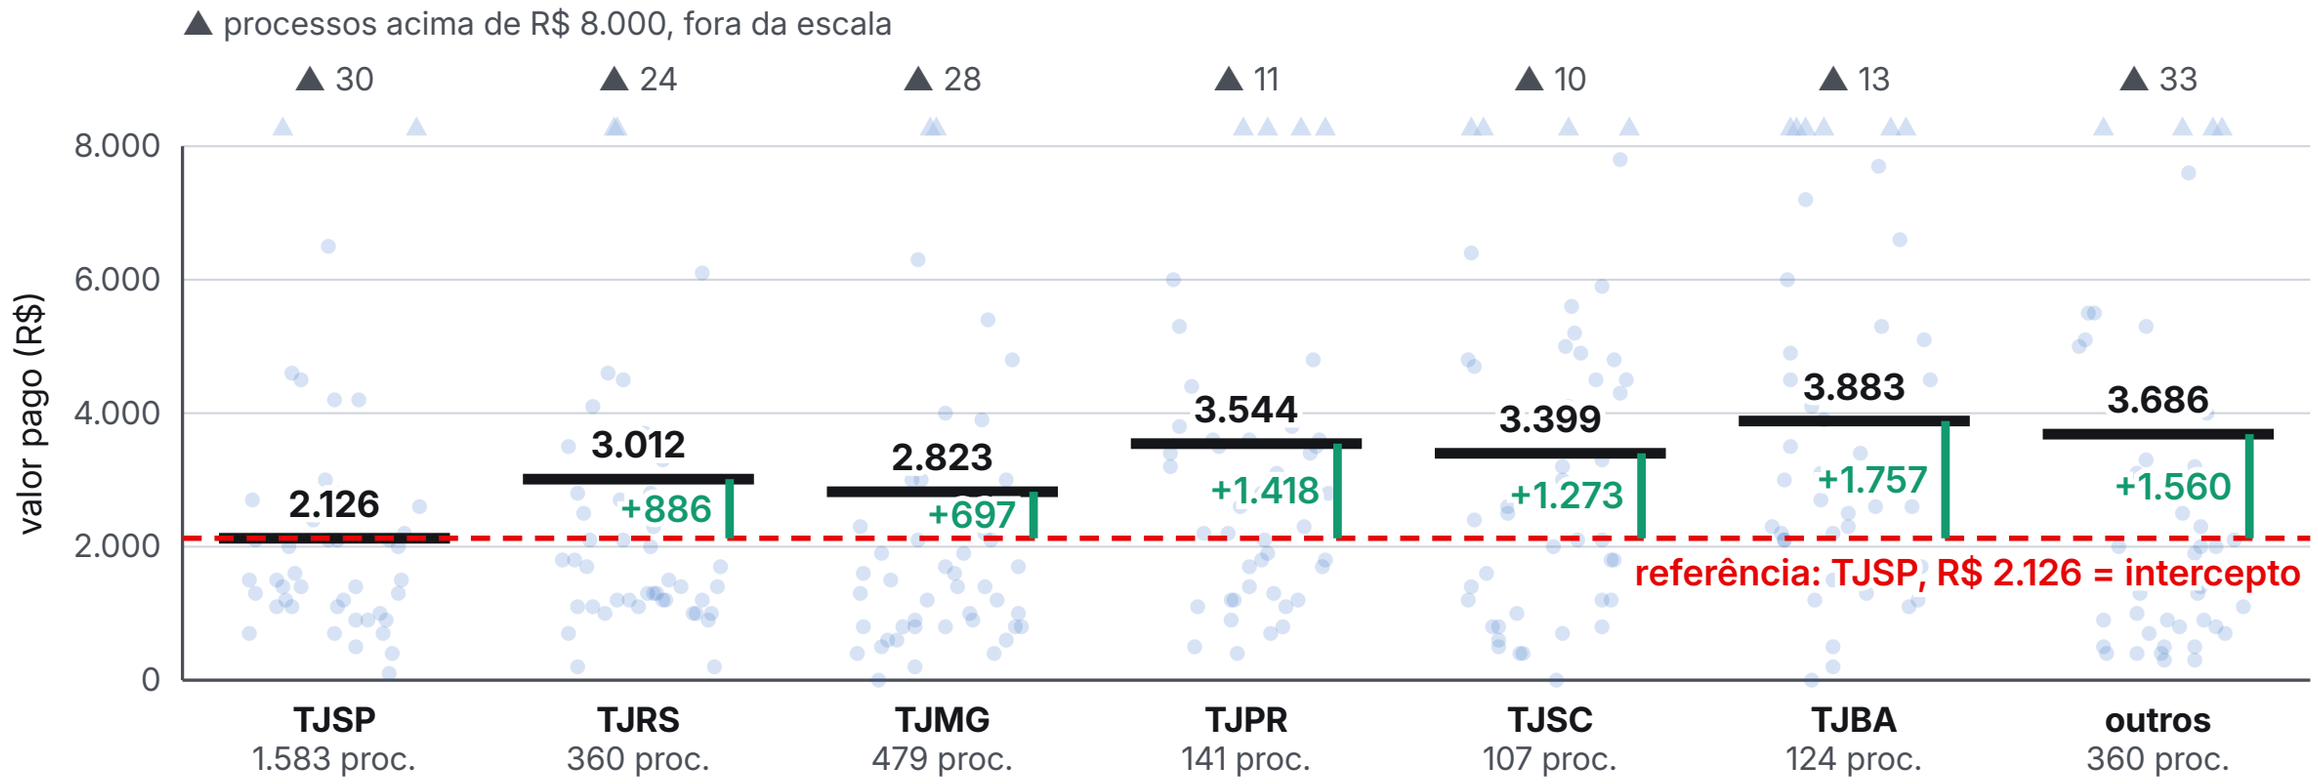
Teste t como regressão: juizado especial e vara comum



	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	2537.59	67.76	37.45	0.000	2404.74	2670.45
juizado especial	2165.66	258.33	8.38	0.000	1659.15	2672.16

O t da dummy (8,38) é o do **teste t com variâncias iguais**. Teste t = regressão com uma dummy.

ANOVA como regressão: valor pago por tribunal



	sum_sq (milhões)	df	F	PR(>F)
tribunal	1240.4	6	15.41	1.7e-17
resíduo	42211.1	3147		

A tabela da ANOVA (`anova_lm`) testa se **todas** essas diferenças são zero ao mesmo tempo: F = 15,41, valor-p < 0,001. ANOVA = regressão com várias dummies.

Dummies: cada tribunal vira uma coluna de 0 e 1

processo	tribunal	TJRS	TJMG	TJPR	TJSC	TJBA	outros
A	TJSP	0	0	0	0	0	0
B	TJRS	**1**	0	0	0	0	0
C	TJBA	0	0	0	0	**1**	0
D	TJMG	0	**1**	0	0	0	0
E	TJGO	0	0	0	0	0	**1**

```
ref = 'C(tribunal, Treatment("TJSP"))
smf.ols(f"valor_pago ~ {ref}", pagos)
```

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	2125.66	92.05	23.09	0.000	1945.18	2306.15
TJRS	886.50	213.85	4.15	0.000	467.20	1305.80
TJMG	697.47	190.99	3.65	0.000	323.00	1071.94
TJPR	1417.97	321.87	4.41	0.000	786.87	2049.07
TJSC	1272.93	365.83	3.48	0.001	555.65	1990.22
TJBA	1757.31	341.53	5.15	0.000	1087.67	2426.96
outros	1560.82	213.85	7.30	0.000	1141.52	1980.12

Na regressão, **cada coluna vira um coeficiente**. O intercepto, R$ 2.126, é a média do TJSP. Um processo do TJBA tem 1 só na coluna TJBA: em média, R$ 1.757 a mais que o TJSP.

PARTE 5

Exercícios no notebook

Exercícios de interpretação no notebook

NOTEBOOK `aula19_aluno.ipynb`, EM DUPLAS · 35 MINUTOS

1. **Ler saídas prontas**: expectativa de vida e renda dos países; casos novos, população e magistrados dos tribunais.
2. **Acrescentar e retirar variáveis**: o que muda em cada coeficiente e no R^2.
3. **Duas variáveis quase iguais**: o que acontece com os coeficientes.
4. **Dummies**: trocar a referência.
5. **ANOVA da aula 17** refeita como regressão.

O QUE CADA EXERCÍCIO PEDE

Uma frase por coeficiente, com **unidade**, **"mantidas as demais"** e **intervalo**. Nas mudanças de coeficiente, a explicação pela correlação entre as variáveis.

Bases: `btg_contratos.csv` (BlackBoard, sob sigilo), `paises_2022.csv` (Our World in Data), `tribunais_2025.csv` (CNJ e IBGE) e `btg_aulas.csv`.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- Intercepto: a previsão com as explicativas em zero (às vezes sem leitura). Coeficiente: a mudança média por unidade.
- R^2: a fração da variação explicada. Baixo não é inútil; alto não é causa.
- Na múltipla, cada coeficiente vale **mantidas as demais variáveis do modelo**, e muda quando entra uma variável correlacionada.
- Teste t e ANOVA são regressões com dummies; cada coeficiente é a diferença para a **referência**.

PRÓXIMA AULA, 22/10: REGRESSÃO LOGÍSTICA

E quando o desfecho é **sim ou não**, como ter havido pagamento?

Regressão logística, e uma análise completa de base jurídica, da pergunta à limitação.