Regressão linear múltipla e regressão logística

Aula 20 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

22/10/2026

A base desta aula é simulada

Primeiras linhas | Variáveis

```
processos = pd.read_csv(URL)
processos.head()
```

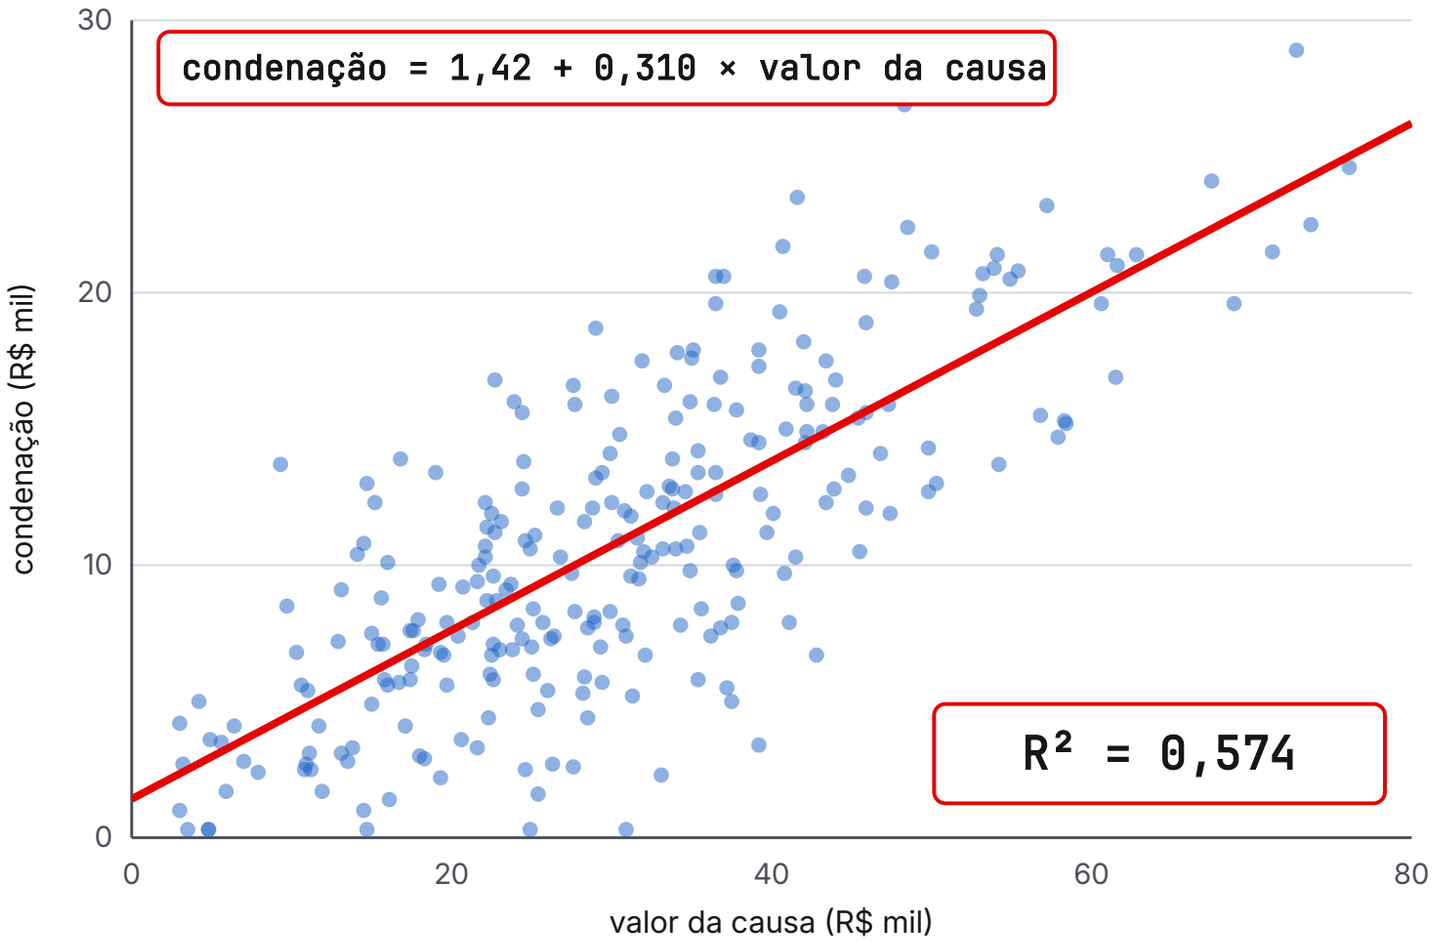
	processo	tribunal	juizado	escritorio_massa	idade_autor	valor_financiado	taxa_juros	valor_causa	pericia	sentenca_favoravel	valor_condenacao	custas
0	P0001	TJMG	0	0	49	69.1	2.15	38.2	0	0	NaN	0.40
1	P0002	TJMG	1	1	54	23.2	1.93	18.3	1	1	6.9	1.90
2	P0003	TJPR	0	0	59	73.4	1.59	25	0	1	13.3	2.62
3	P0004	TJRS	0	1	50	35.5	1.99	39.7	0	1	11.2	1.46
4	P0005	TJSP	0	1	30	24	1.71	23.7	0	0	NaN	1.50

1.000 processos julgados, **sorteados** para a aula: imitam as revisionais de veículo do BTG, mas não dizem nada sobre processos reais.

PARTE 1

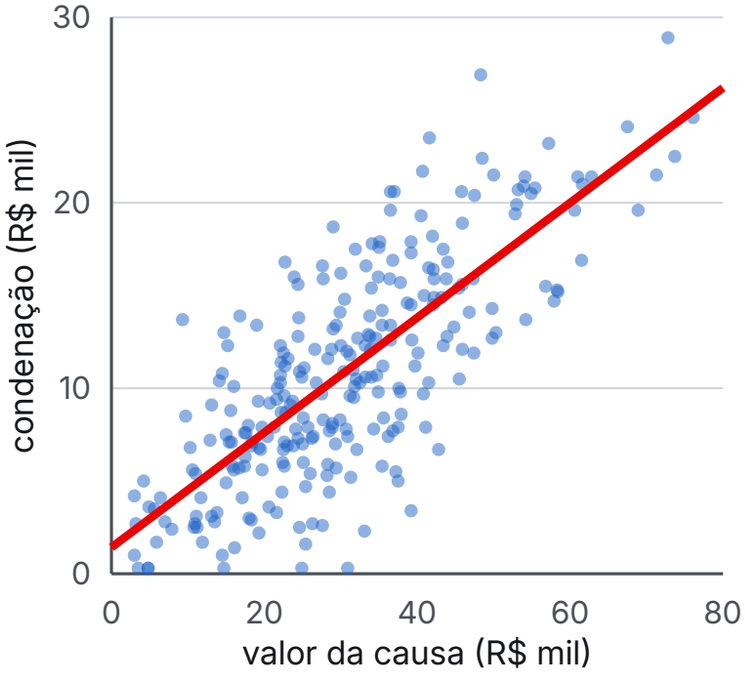
Regressão linear: revisão da aula 19

Regressão simples: condenação e valor da causa



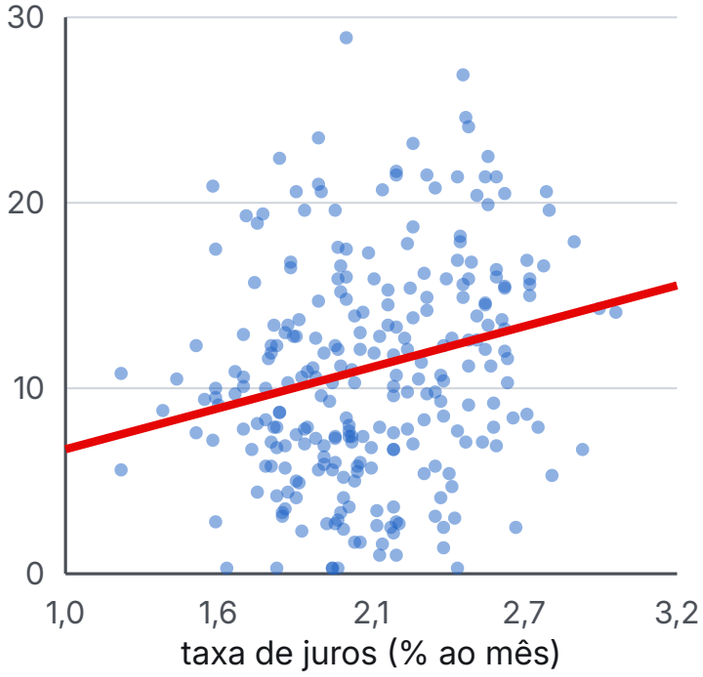
R^2 **= 0,574**: a reta explica 57% da variação da condenação entre os processos.

Valor-p e R^2 respondem perguntas diferentes



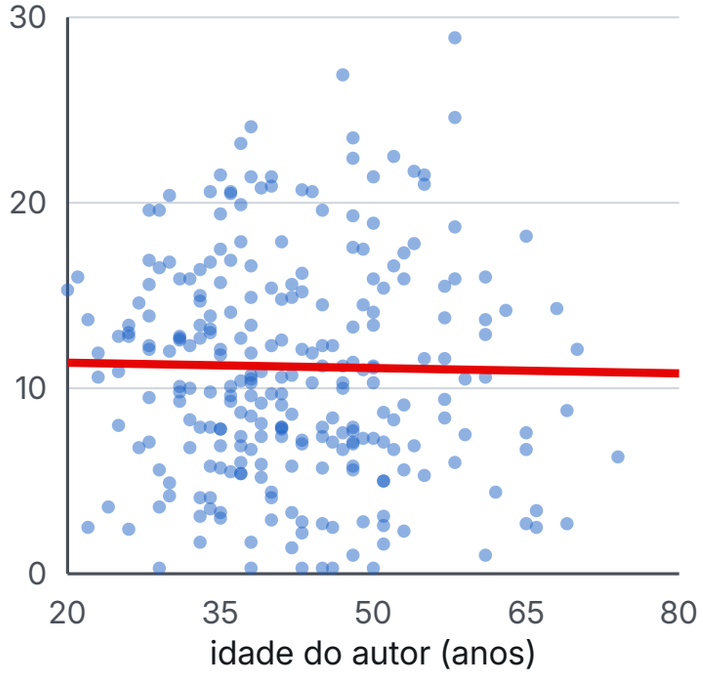
valor-p < 0,001 **há associação**

R^2 = 0,574



valor-p < 0,001 **há associação**

R^2 = 0,053



valor-p = 0,68 **sem evidência**

R^2 = 0,000

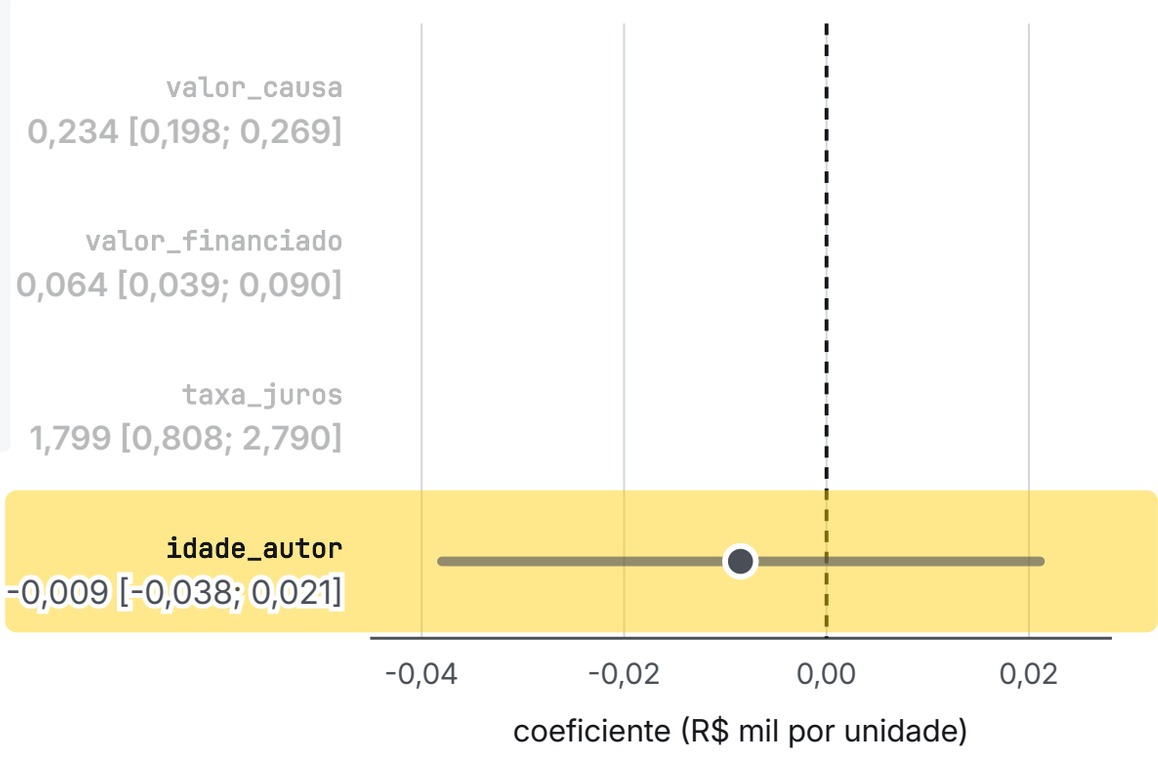
R^2: quanto explica? A causa, muito. Os juros têm associação clara, mas explicam **pouco**. R^2 baixo não quer dizer coeficiente inútil.

Regressão múltipla: o modelo completo

```
modelo3 = smf.ols("valor_condenacao ~ valor_causa + valor_financiado + taxa_juros + idade_autor",
                  data=processos).fit()
```

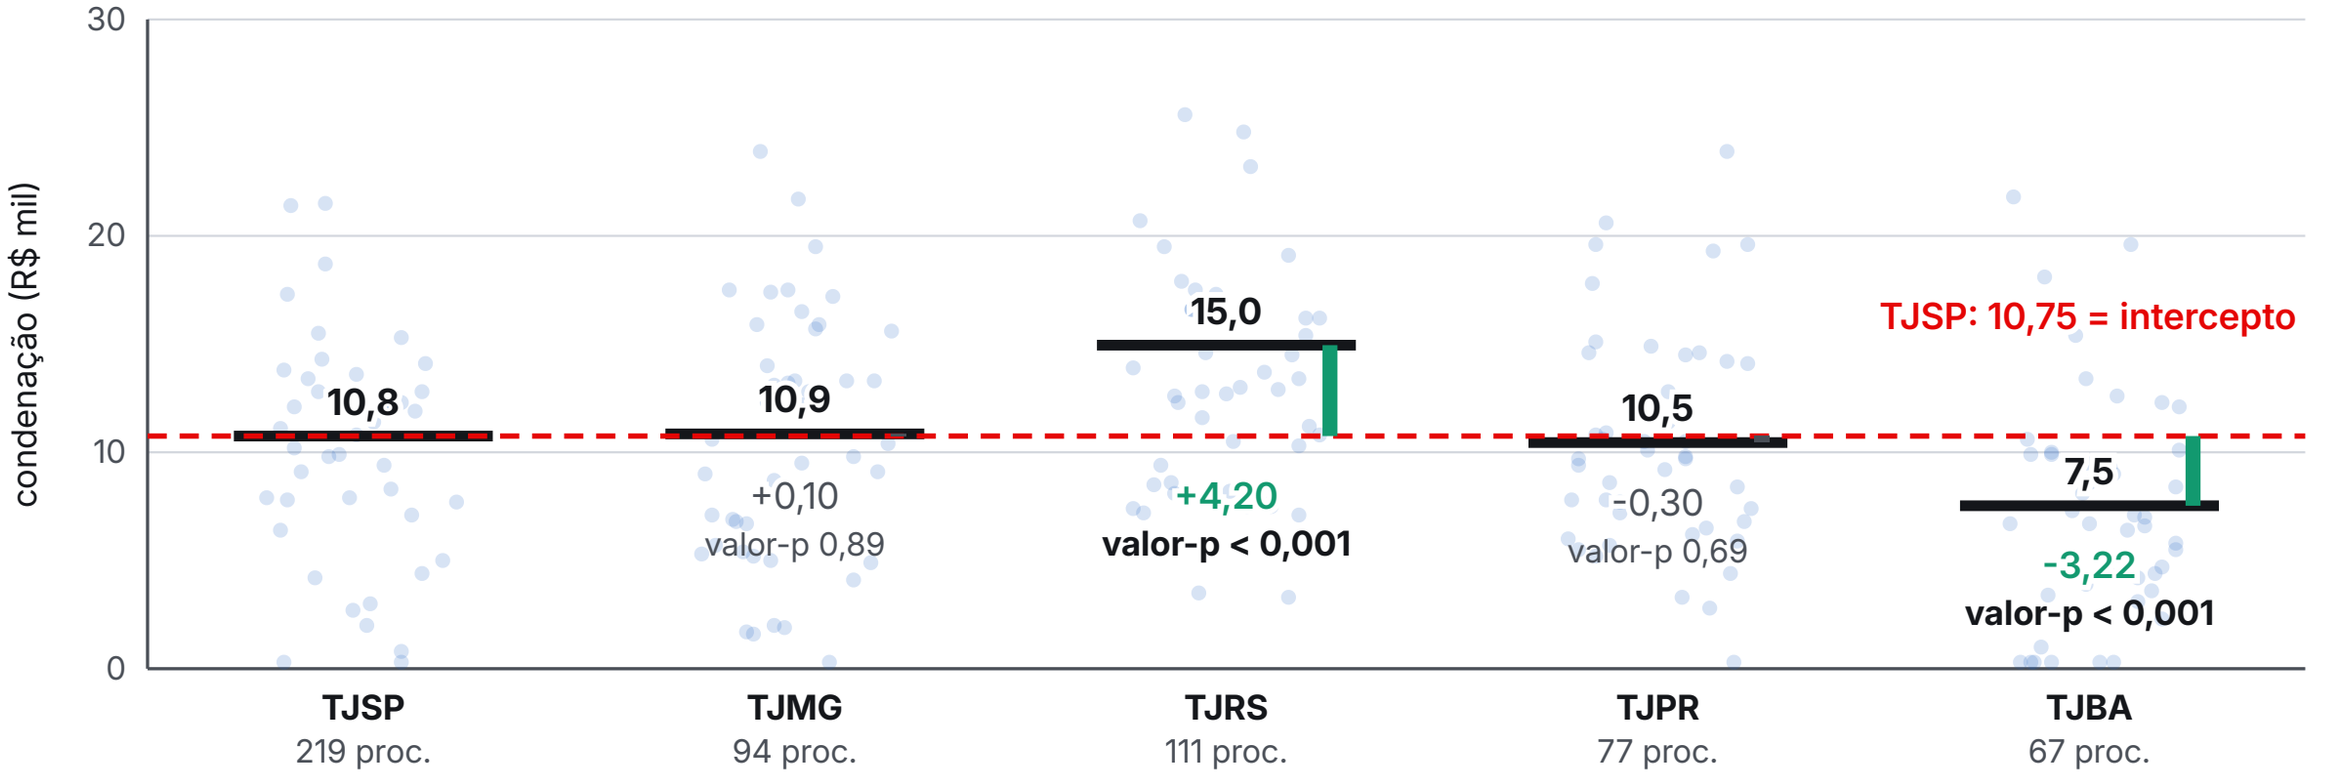
	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	-2.4116	1.257	-1.920	0.056	-4.881	0.058
valor_causa	0.2336	0.018	12.810	0.000	0.198	0.269
valor_financiado	0.0640	0.013	4.920	0.000	0.038	0.090
taxa_juros	1.7993	0.504	3.570	0.000	0.808	2.790
idade_autor	-0.0085	0.015	-0.560	0.574	-0.038	0.021

R-squared: 0.595 No. Observations: 568



> **Idade:** valor-p 0,57 e intervalo que **cruza o zero**: sem evidência de associação.

Tribunal: cinco categorias, quatro dummies




```
smf.ols('valor_condenacao ~ C(tribunal, Treatment("TJSP"))',
        data=processos).fit()
```

Cada coeficiente é a **diferença para o TJSP**. O TJRS condena mais, o TJBA menos. TJMG e TJPR **não se distinguem** do TJSP.

Exercício no notebook: as custas do processo

PARTE 6 DO NOTEBOOK · EM DUPLAS

A resposta agora é `custas`, nos 1.000 processos.

1. Só com o valor da causa: há associação? Quanto explica?
2. Com juizado, perícia e tribunal: a frase do coeficiente da perícia e a do juizado.
3. Qual tribunal tem as custas mais altas? Algum não se distingue do TJSP?
4. Compare os dois R^2.

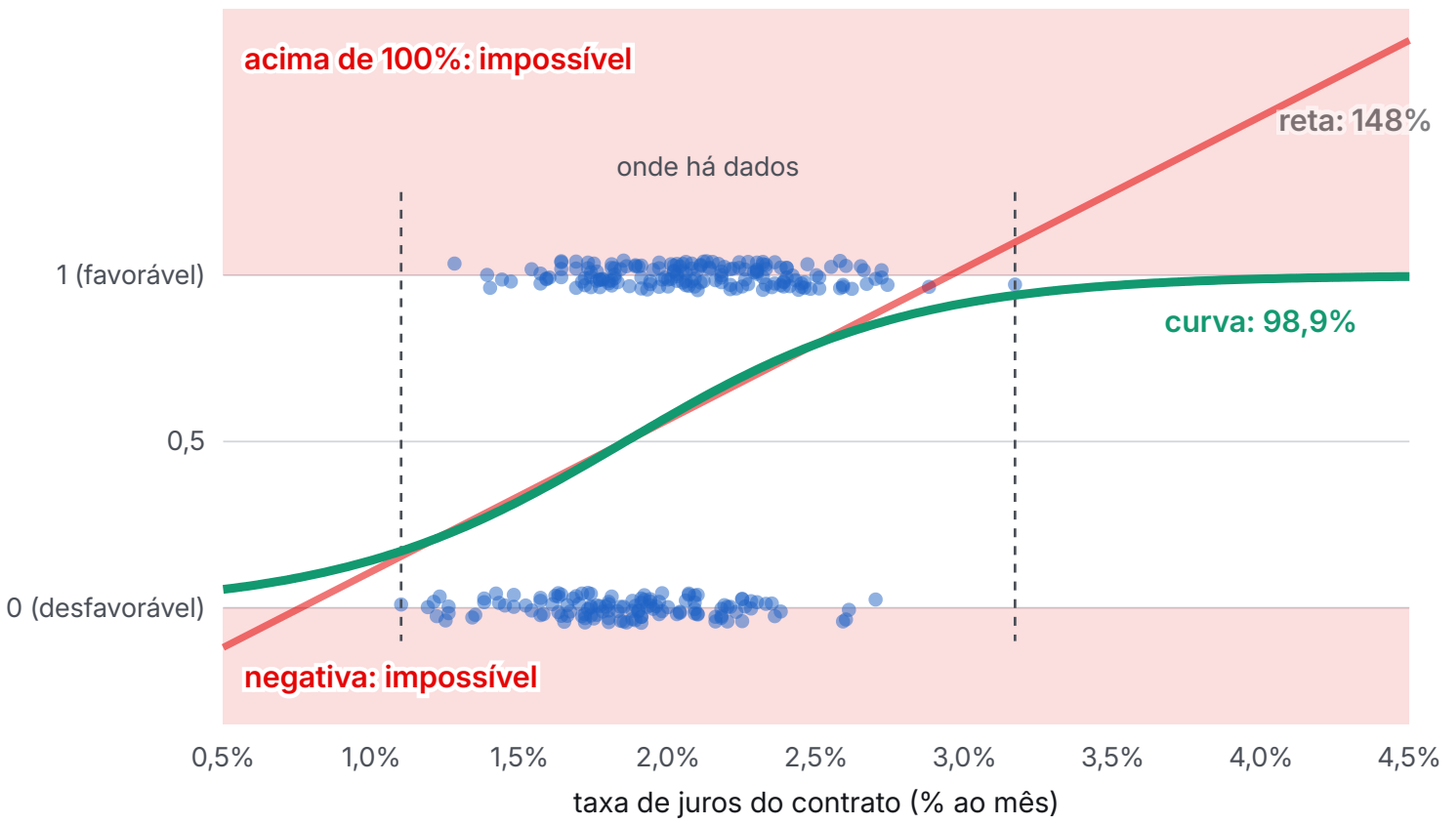
O QUE OBSERVAR

Um modelo com R^2 **baixo** e um com R^2 **alto** para a mesma resposta; coeficientes com e sem evidência; e o "mantidas as demais" em cada frase.

PARTE 2

Regressão logística

Desfecho de sim ou não: a reta não serve



A **curva logística** fica sempre entre 0 e 1. Ela modela a **chance**, e não a probabilidade diretamente.

Probabilidade e chance

$$\text{chance} = \frac{p}{1 - p}$$

probabilidade **80%**



chance = 0,80 / 0,20 = **4,00** (4,00 para 1)

PROBABILIDADE	CHANCE	EM PALAVRAS
50%	1	1 para 1
80%	4	4 para 1
20%	0,25	1 para 4
10%	0,11	1 para 9

PARTE 8 DO NOTEBOOK · EM GRUPOS · 10 MINUTOS

Ida e volta entre probabilidade e chance, a tabela 2×2 do próximo slide, e quatro afirmações de certo ou errado.

Razão de chances numa tabela 2x2

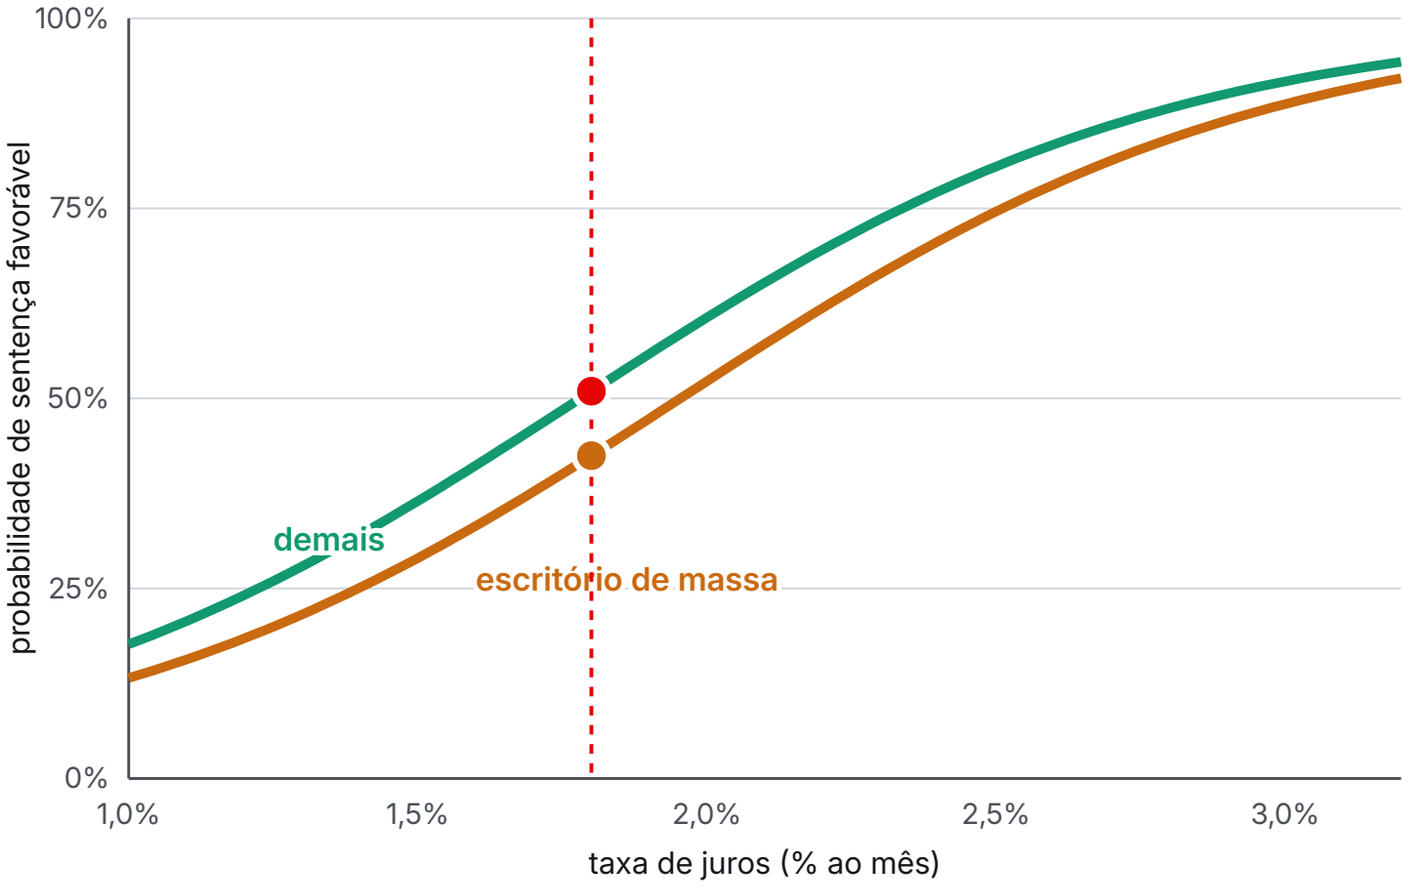
	favorável	desfavorável	probabilidade	chance
escritório de massa	162	189	46%	162 / 189 = **0,86**
demais	406	243	63%	406 / 243 = **1,67**

razão de chances = 0,86 / 1,67 = **0,51**

Razão de chances: com escritório de massa, a chance é 0,51 vezes a dos demais, mais ou menos a **metade**. Razão igual a 1 seria "nenhuma diferença".

O modelo de regressão logística

$$\log\left(\frac{p}{1-p}\right) = a + b_1 x_1 + b_2 x_2 + \ldots \quad \Longrightarrow \quad e^b = \text{razão de chances}$$



taxa de juros: **1,80% ao mês**

	probabilidade	chance
escritório de massa	42%	0,74
demais	51%	1,04
massa ÷ demais	diferença: -8 pontos	**0,71**

Arraste os juros: a **diferença de probabilidade** muda, mas a **razão de chances** fica sempre a mesma. É isso que o coeficiente resume.

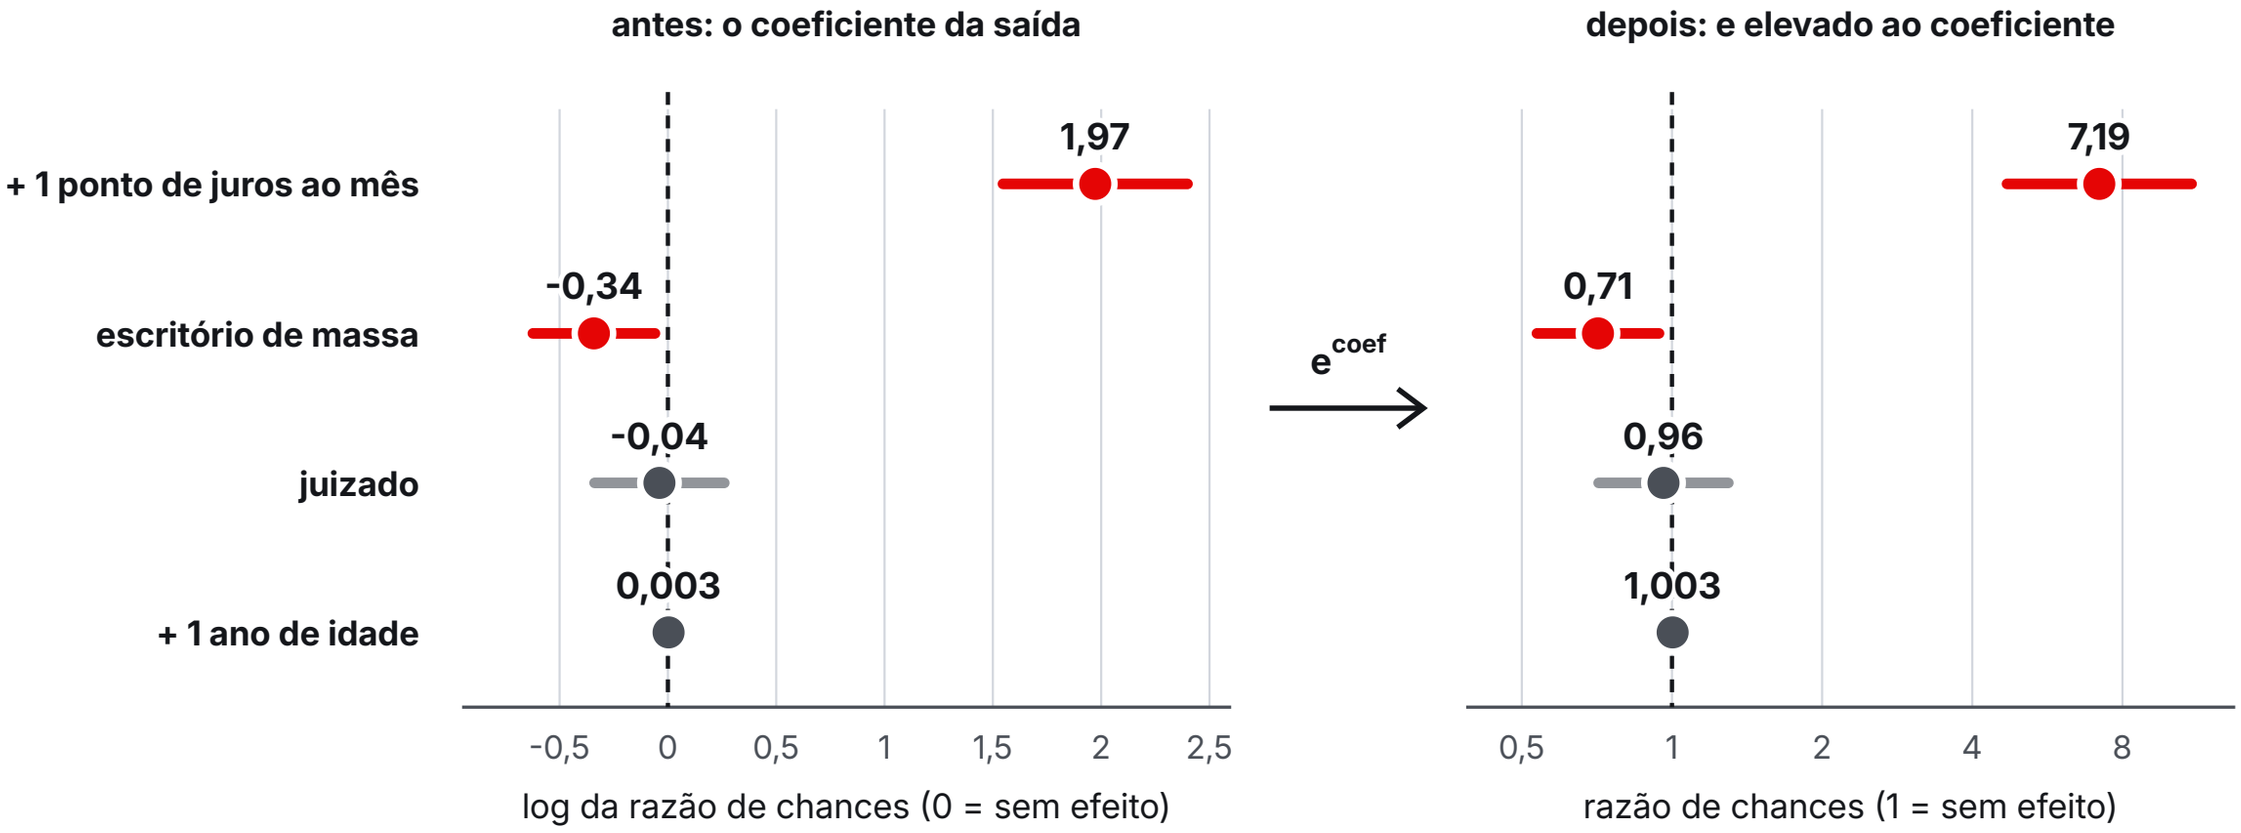
A saída do statsmodels

```
logit2 = smf.logit("sentenca_favoravel ~ taxa_juros + escritorio_massa + juizado + idade_autor",
                   data=processos).fit()
np.exp(logit2.params)          # razões de chances
```

	coef	std err	z	P>|z|	[0.025	0.975]	e^{coef}	IC 95%
Intercept	-3.6426	0.5284	-6.89	0.000	-4.678	-2.607	**0.026**	0.01 a 0.07
taxa_juros	1.9725	0.2174	9.07	0.000	1.546	2.398	**7.189**	4.70 a 11.01
escritorio_massa	-0.3416	0.1438	-2.38	0.018	-0.623	-0.060	**0.711**	0.54 a 0.94
juizado	-0.0391	0.1528	-0.26	0.798	-0.339	0.260	**0.962**	0.71 a 1.30
idade_autor	0.0031	0.0062	0.50	0.617	-0.009	0.015	**1.003**	0.99 a 1.02

> **Idade:** razão de 1,003, valor-p 0,62: também **sem evidência**.

Do coeficiente à razão de chances

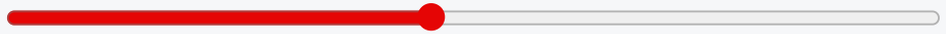


Acima de 1, **multiplica** a chance (juros); abaixo de 1, **diminui** (escritório de massa, 0,71). Intervalo que cruza o 1: **sem evidência** (juizado e idade).

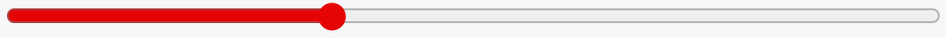
Probabilidade prevista para um perfil

☑ escritório de massa ☐ juizado

taxa de juros: **2,00% ao mês**



idade do autor: **40 anos**



probabilidade prevista de sentença favorável

52%



log da chance = -3,64 + 1,97×**2,00** - 0,34×**1** - 0,04×**0** + 0,003×**40** = 0,08

chance = $e^{0,08}$ = 1,09 → probabilidade = chance / (1 + chance) = **52%**

```
perfis = pd.DataFrame({"taxa_juros": [2], "escritorio_massa": [1],
                       "juizado": [0], "idade_autor": [40]})
logit2.predict(perfis)
```

Na aula 21, a probabilidade prevista vira decisão: escolhemos um **ponto de corte** e contamos os erros de cada lado.

Exercício: a perícia contábil ajuda o autor?

PARTE 11 DO NOTEBOOK · EM DUPLAS

0. **Unidade:** o que é cada linha, e quem ficou de fora.
1. **Exploratória:** proporção de sentenças favoráveis com e sem perícia.
2. **Modelo:** logística com perícia, juros, escritório de massa, juizado e tribunal.
3. **Previsão:** vara do TJSP, juros de 2% ao mês, sem escritório de massa, com e sem perícia.
4. **Relatório**, em três frases.

AS TRÊS FRASES DO RELATÓRIO

1. A **pergunta**.
2. O **resultado**: razão de chances, intervalo e “mantidos...”.
3. **Uma limitação**: o que o modelo não permite concluir.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- **Valor-p**: existe associação? R^2: quanto explica? São perguntas diferentes.
- Na múltipla, cada coeficiente vale **mantidas as demais**, e muda quando entra uma variável correlacionada.
- Desfecho de sim ou não pede **regressão logística**; e^b é a **razão de chances**.
- Razão de chances acima de 1 aumenta a chance; abaixo de 1, diminui.

PRÓXIMA AULA, 27/10: PONTO DE CORTE E PROJETO 06

A probabilidade prevista vira decisão quando se escolhe um **ponto de corte**. Matriz de confusão, precisão e revocação, e o **Projeto 06**: qual erro é mais grave?