Discussão do Projeto 06 e exercícios de revisão

Aula 22 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

29/10/2026

Objetivos de aprendizagem

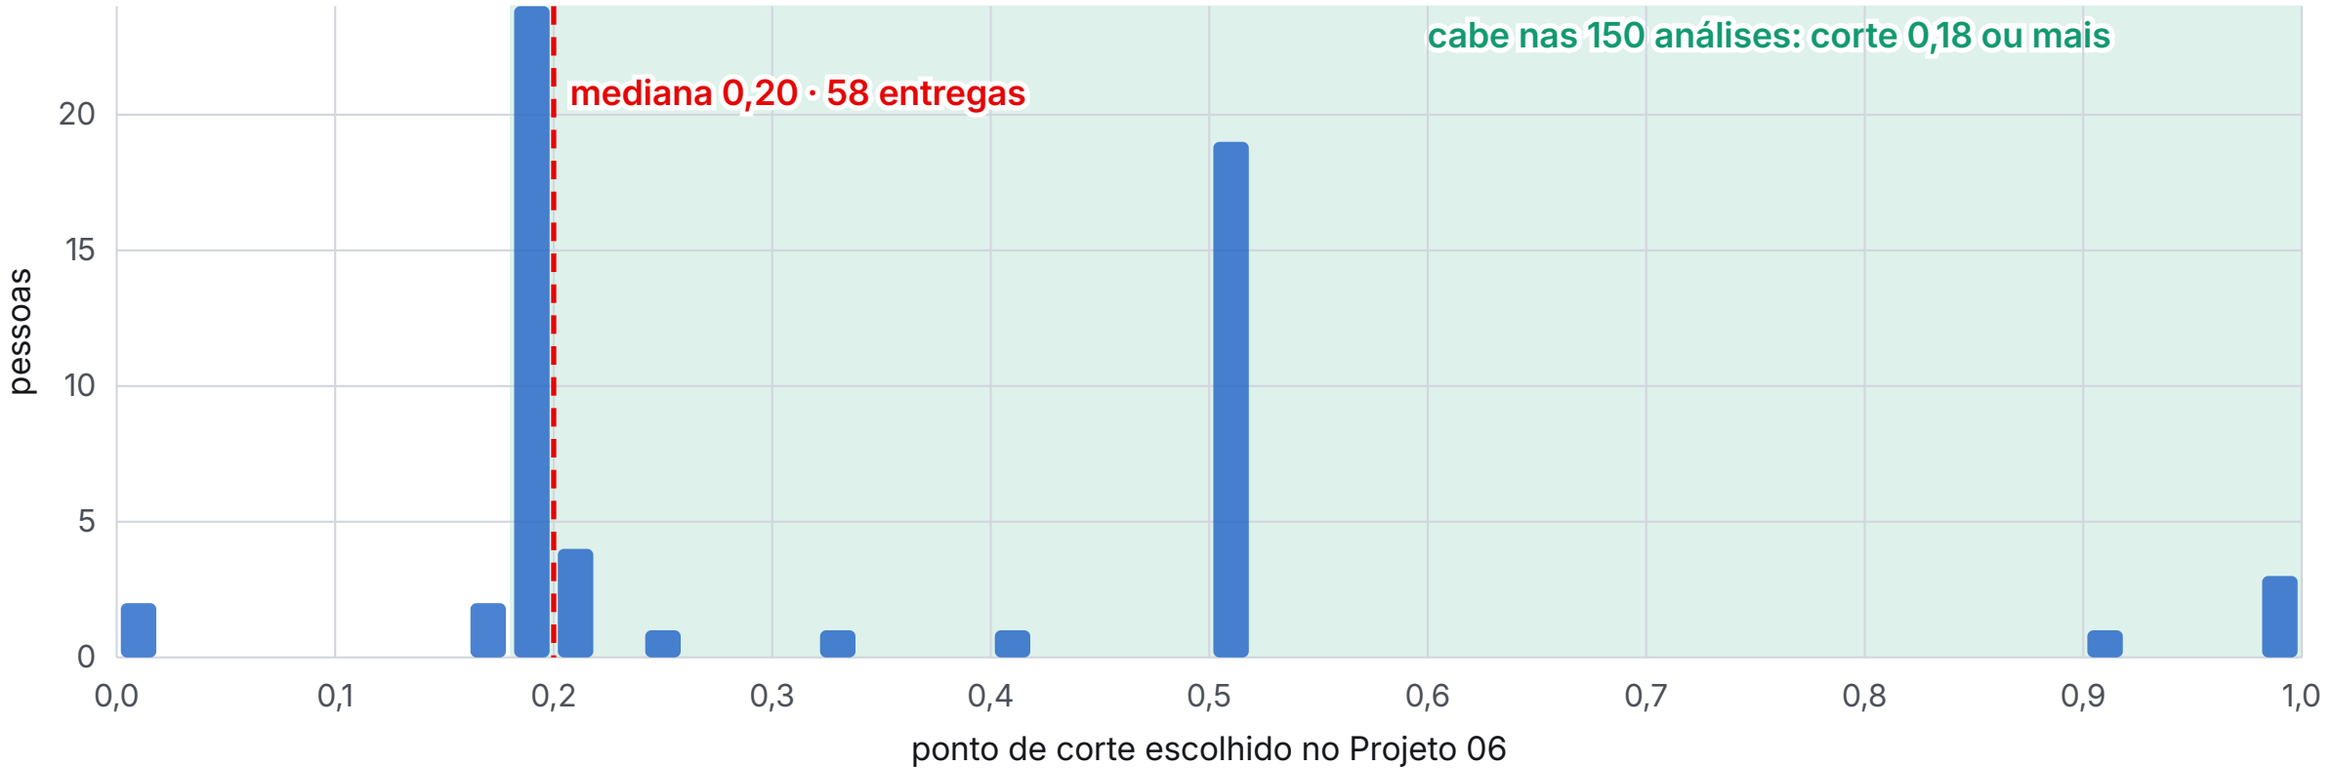
Ao final da aula, vocês devem ser capazes de:

1. **comparar** pontos de corte diferentes sobre a mesma curva de precisão e sensibilidade, e justificar a diferença pelo papel de quem decide;
2. **ler** uma curva ROC e interpretar a AUC como medida que não depende do corte;
3. **calcular** as medidas de erro a partir da matriz de confusão e **escolher** a que mais importa em cada problema, com evento comum e raro;
4. **interpretar** a saída de uma regressão logística, com variável categórica, e explicar por que um coeficiente muda quando entra outra variável;
5. **reconhecer** sobreajuste comparando o erro no treino e no teste.

PARTE 1

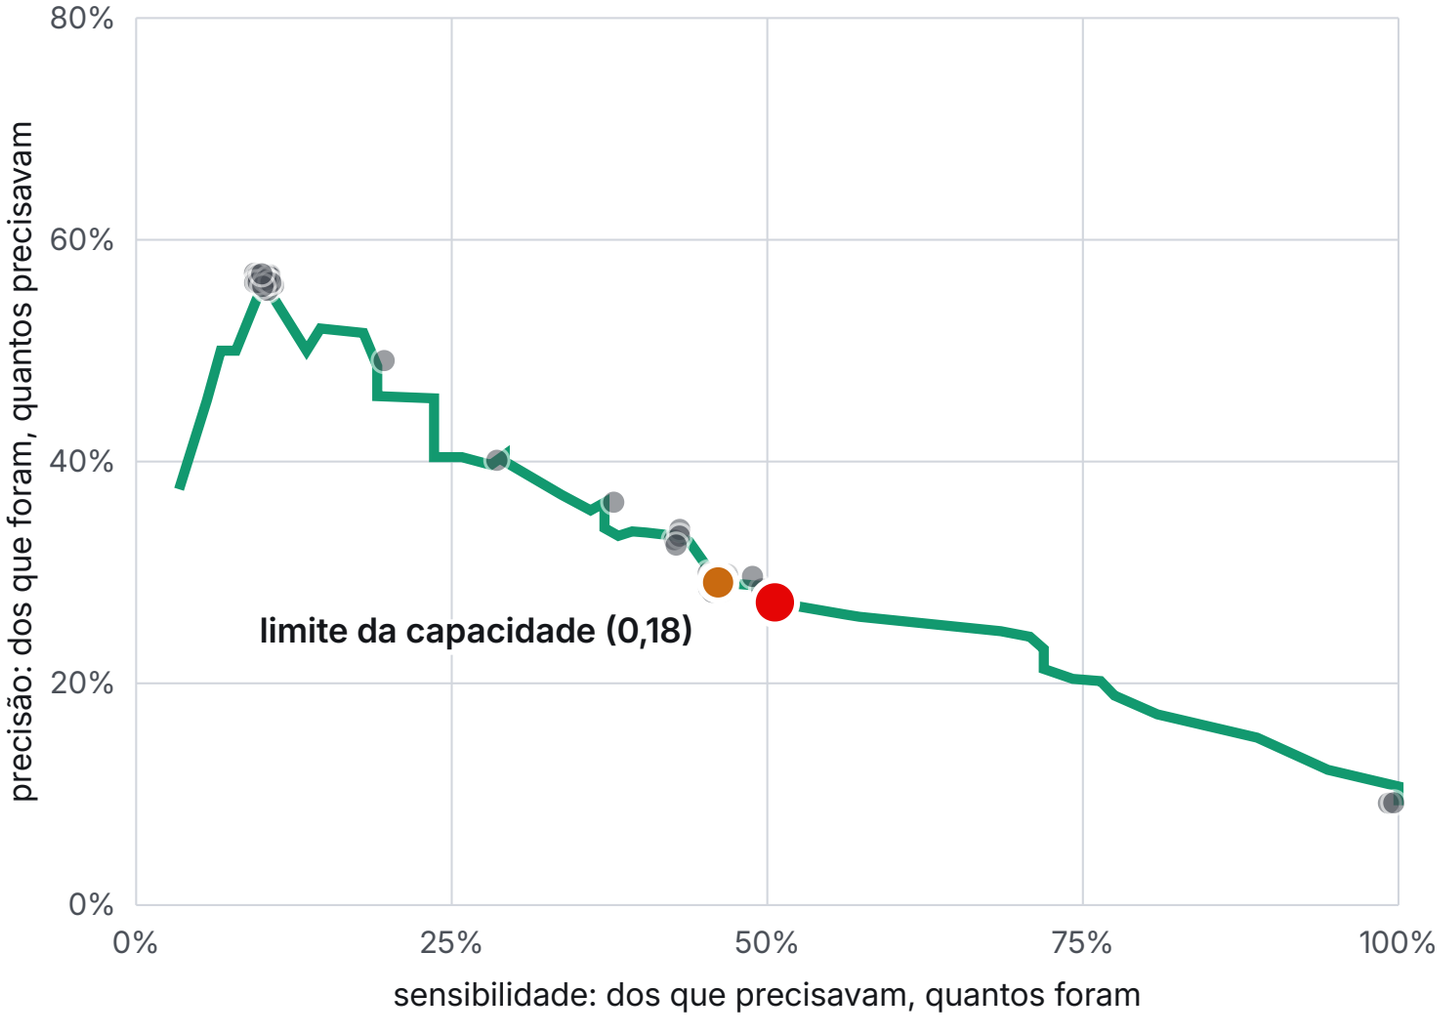
Discussão do Projeto 06

Os cortes escolhidos pela turma



Em verde, os cortes que **cabem** nas 150 análises aprofundadas por mês. Abaixo deles, o especialista recebe mais processos do que consegue analisar.

Mesmo modelo, cortes diferentes



ponto de corte: **0,15**

ao especialista **165**

não cabe

precisão **27%**

sensibilidade **51%**

ficaram sem análise (FN) **44**

COMO LER

Cada ponto cinza é o corte de uma pessoa da turma, sobre a **mesma curva**. Mais à direita, pega mais casos que precisam do especialista e manda mais casos sem necessidade. Ninguém escapa da curva: o modelo é o mesmo.

Discussão em plenário

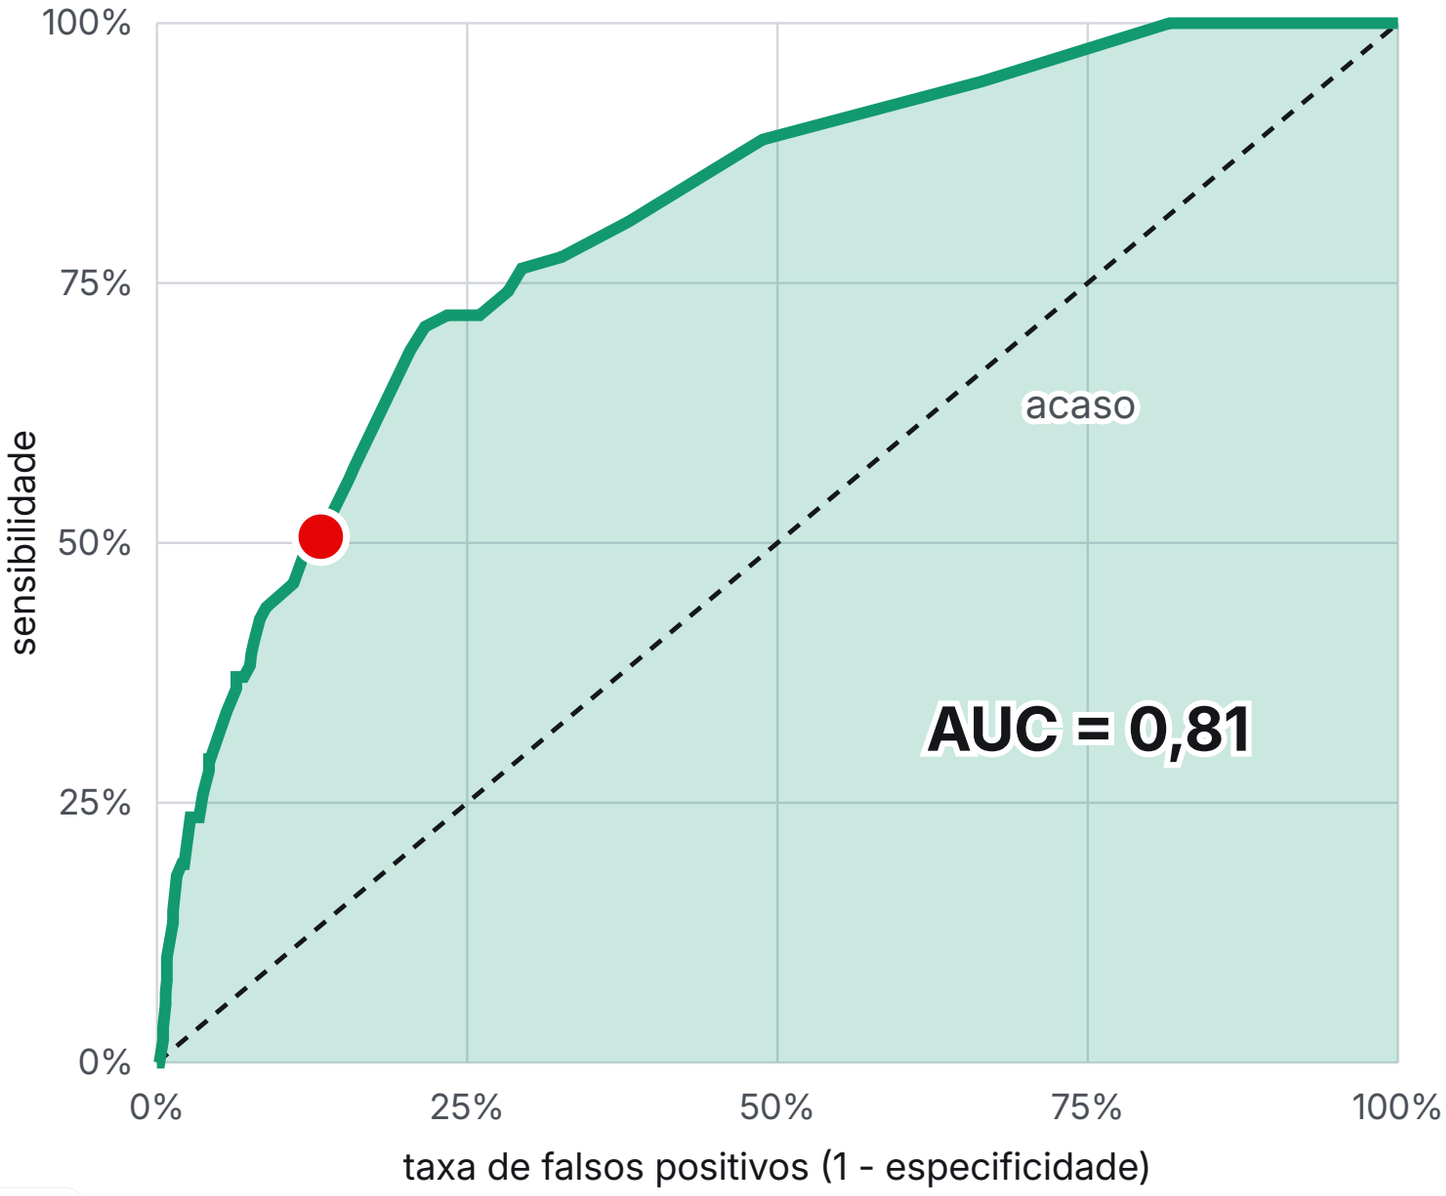
EM PLENÁRIO · 15 MINUTOS

1. Quem escolheu **corte baixo**: qual erro considerou mais grave, e quem paga por ele?
2. Quem escolheu **corte alto**: o que ganhou, e quem fica sem a análise aprofundada?
3. O **modelo trivial** acerta 91%. Por que ninguém o usaria?
4. O que a matriz de confusão **não mostra**: gravidade do caso, custo do tratamento, quem ficou com o parecer padronizado?

O QUE OBSERVAR

- A técnica dá a **curva**; o **ponto na curva** é uma escolha, e precisa de justificativa.
- A capacidade de 150 análises é um limite **institucional**: mudar a capacidade muda o corte possível.
- Duas pessoas com o mesmo corte podem ter razões diferentes.

Curva ROC: todos os cortes num gráfico só



ponto de corte: **0,15**

sensibilidade **51%** falsos positivos **13%**

A **área sob a curva** (AUC) é 0,81. Quanto mais a curva se afasta da diagonal para cima, melhor o modelo **ordena** os casos.

AUC: uma medida que não depende do corte

COMO INTERPRETAR A AUC

Sorteie um caso que **precisava** de análise e um que **não precisava**. A AUC é a probabilidade de o modelo dar ao primeiro uma probabilidade maior que ao segundo.

- **0,5:** o modelo ordena como uma moeda.
- **1:** ordena perfeitamente.
- **NatJus: 0,81.** Em 81% dos pares, o caso que precisava fica na frente.

O QUE A AUC NÃO DIZ

- Não escolhe o corte: a mesma AUC serve para qualquer ponto da curva.
- Não diz se a **capacidade** comporta o corte, nem qual erro é mais grave.

No **Projeto 08**, a competição preditiva, a nota de cada modelo é a **AUC** calculada no servidor, sobre rótulos que vocês não têm.

Exercícios no notebook: até 4 pontos extras no Projeto 06

NOTEBOOK DE EXERCÍCIOS DA AULA 22 · INDIVIDUAL · ATÉ 18:20

1. **Trabalhista:** medidas da matriz de confusão, evento comum.
2. **Previdenciário:** fraude rara, modelo trivial e corte pela capacidade.
3. **Consumidor:** saída da logística, variável categórica e coeficiente que muda.
4. **Juizado:** e se o modelo souber quem é o juiz?

COMO FUNCIONA

- **Nenhum código de modelo:** as células estão prontas. As contas usam o Python como calculadora.
- **1 ponto por exercício**, somado à nota do Projeto 06.
- Pode conversar, mas escreva **com as suas palavras**.
- **Entrega:** baixe o `.ipynb` e envie no BlackBoard, no item **Exercícios da aula 22**.

Abrir o notebook no Colab

PARTE 2

Introdução a machine learning

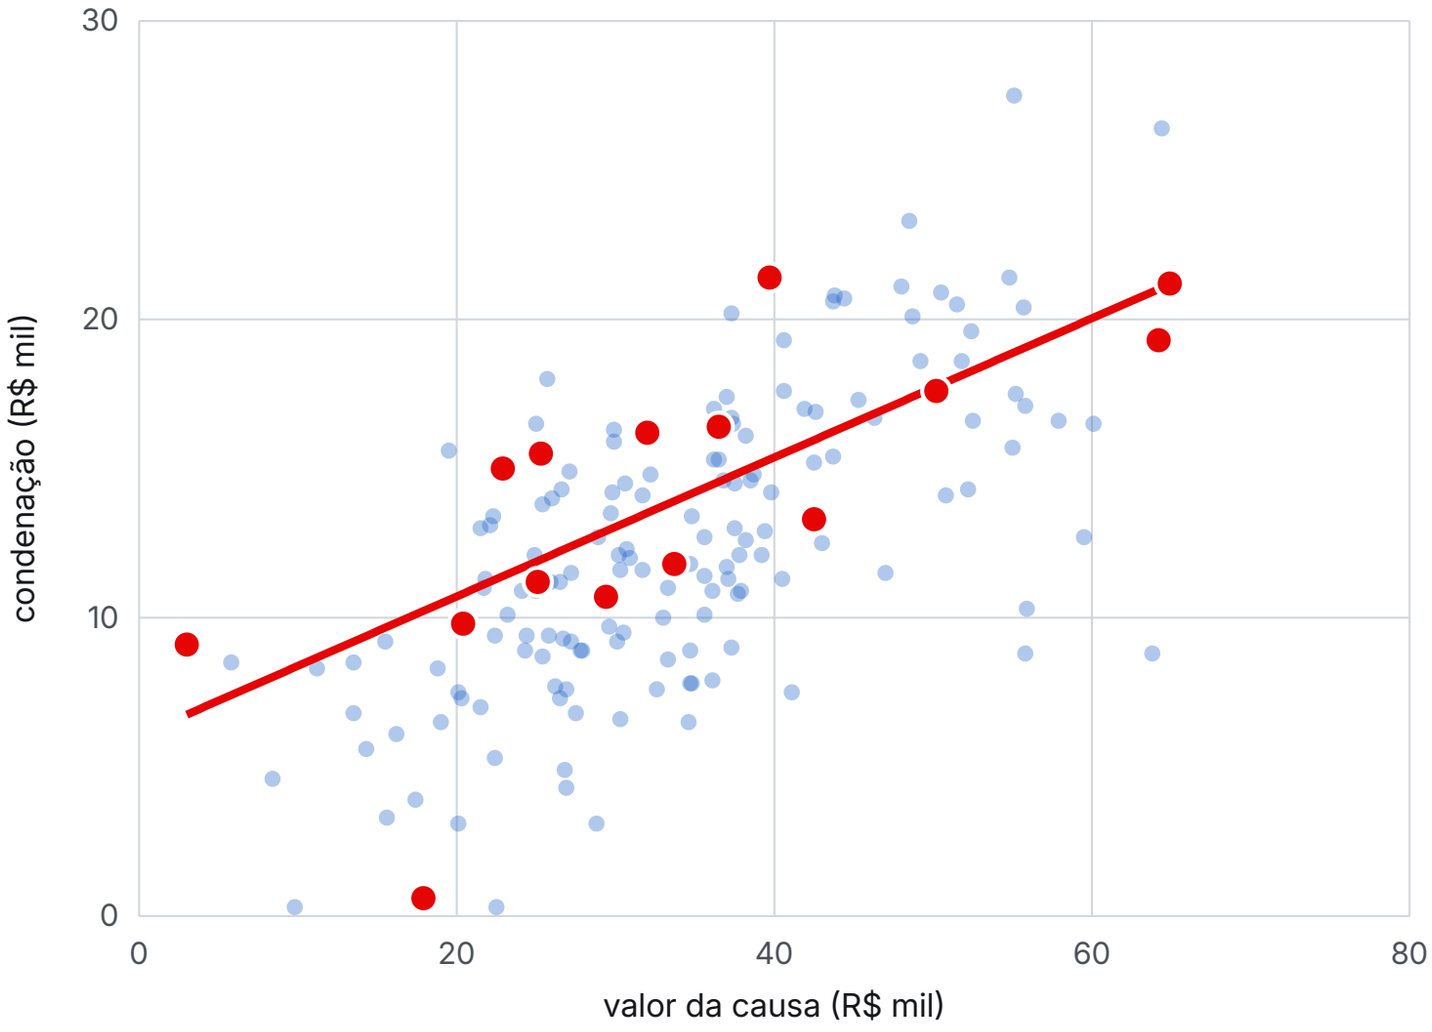
Explicar e prever são objetivos diferentes

	explicar (aulas 16 a 21)	prever (a partir de hoje)
pergunta	o que está associado à sentença?	qual a probabilidade neste processo novo?
o que importa	coeficientes, intervalos, valor-p	o erro em casos que o modelo **não viu**
variáveis	escolhidas pela pergunta, interpretáveis	qualquer uma que ajude a prever, sem olhar o futuro
avaliação	o modelo faz sentido?	treino, validação e teste

MACHINE LEARNING

Métodos que **aprendem uma regra a partir de exemplos** para aplicá-la a casos novos. A regressão logística da aula 20 já é um deles: o que muda é o objetivo e o jeito de avaliar.

Sobreajuste e subajuste



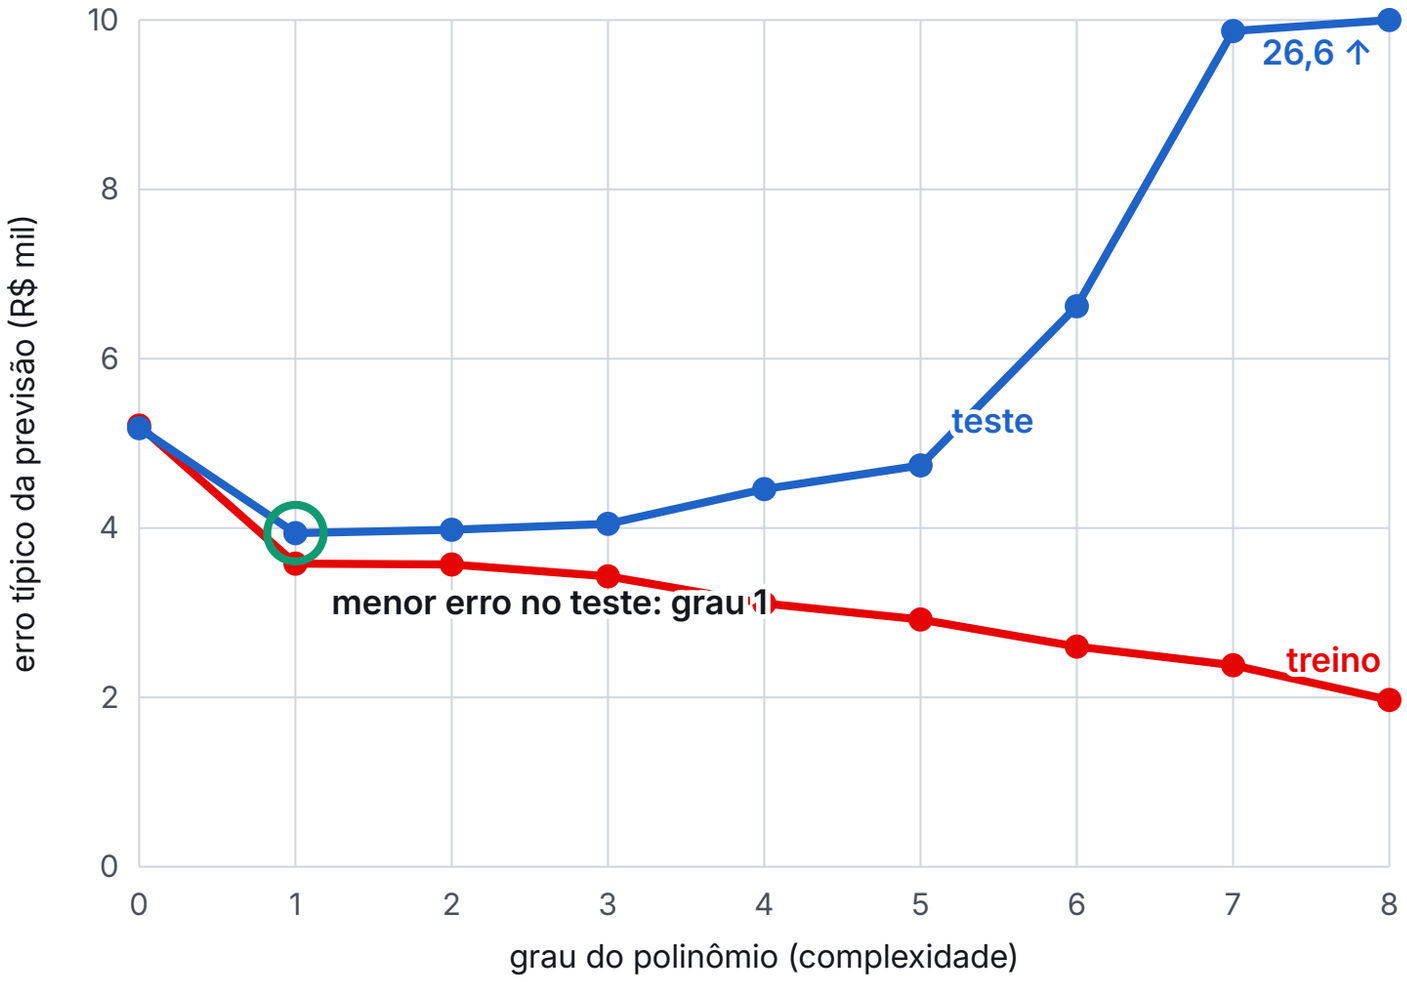
complexidade (grau do polinômio): **1**

erro no treino **3,6** erro no teste **3,9**

equilibrado

Agora os **processos de teste**, que o modelo não viu. A curva de grau 8, que acertava o treino, erra muito nos novos: ela aprendeu o **ruído** daqueles 15 processos, e não a regra.

Erro no treino e erro no teste



O melhor grau é o de **menor erro em casos novos**, e não no treino. Mas o teste não pode ser usado para escolher: ele ficaria otimista. Quem escolhe é a **validação**.

Resumo da aula e próximas aulas

PONTOS PRINCIPAIS DA AULA

- O modelo dá a **curva**; o corte é uma **escolha**.
- A **AUC** não depende do corte.
- Evento **raro**: a acurácia engana; compare com o **trivial**.
- Um coeficiente **muda** quando entra outra variável.
- **Sobreajuste:** acerta o treino, erra os casos novos.

PRÓXIMAS AULAS

- **03/11:** regressão logística no **scikit-learn**, com treino e teste, **validação cruzada** e **regularização**, e comparação de modelos.
- **05/11:** árvores e florestas aleatórias, **Projeto 07** (provinha de machine learning) e lançamento do **Projeto 08** (competição, nota pela AUC).