Árvores de decisão e florestas aleatórias

Aula 24 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

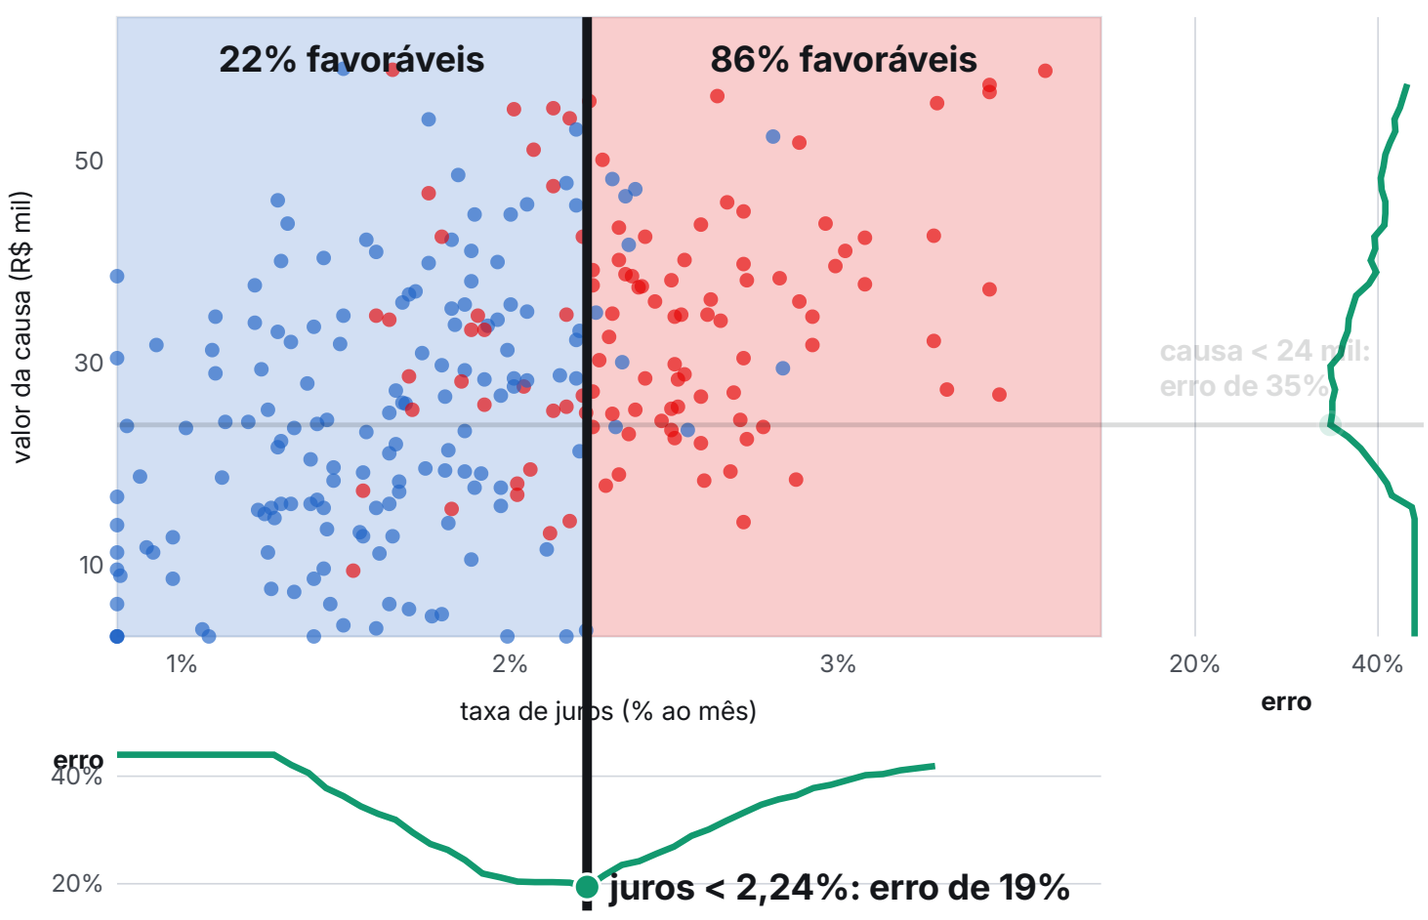
05/11/2026

Objetivos de aprendizagem

Ao final da aula, você será capaz de:

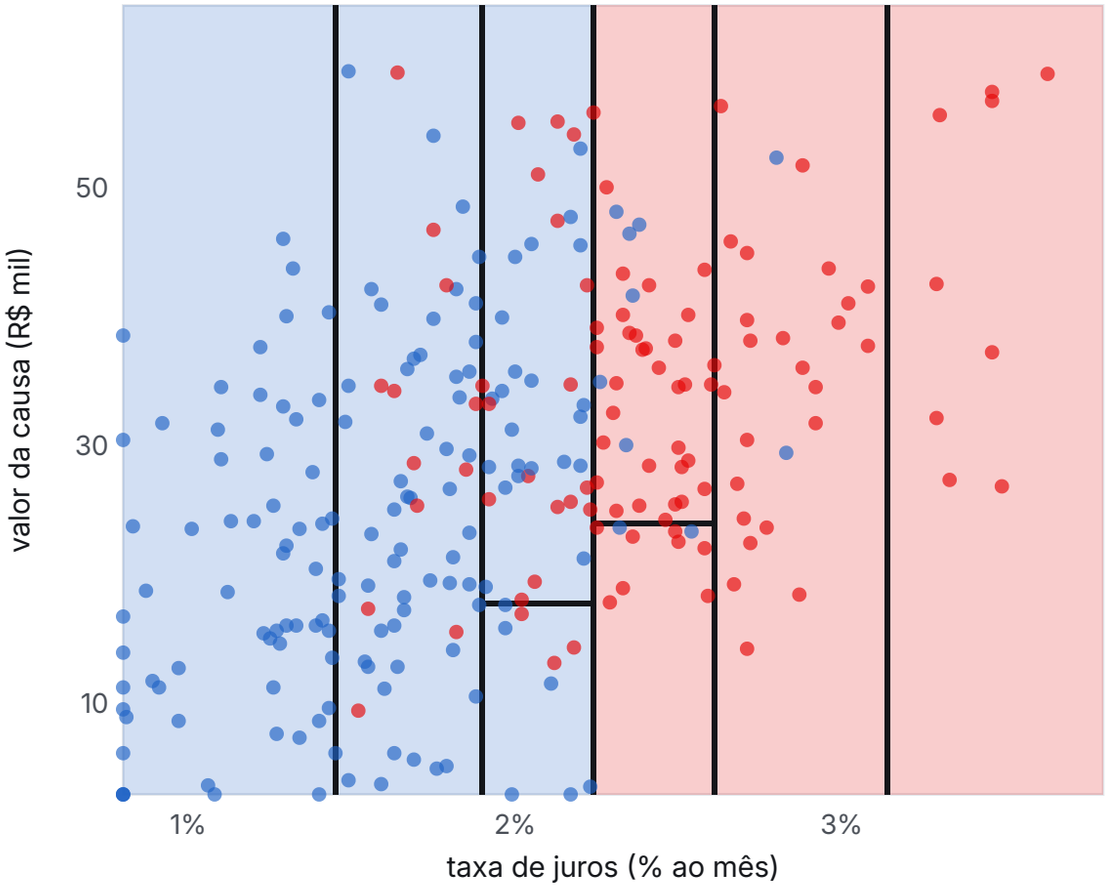
1. **explicar** como uma árvore de decisão escolhe cada pergunta e parte os dados;
2. **usar** uma árvore para prever um processo novo;
3. **controlar** o sobreajuste de uma árvore pela profundidade;
4. **explicar** por que uma floresta aleatória costuma superar uma árvore só;
5. **identificar** vazamento, a variável que só existe depois do desfecho;
6. **gerar** um arquivo de predições para o Projeto 08.

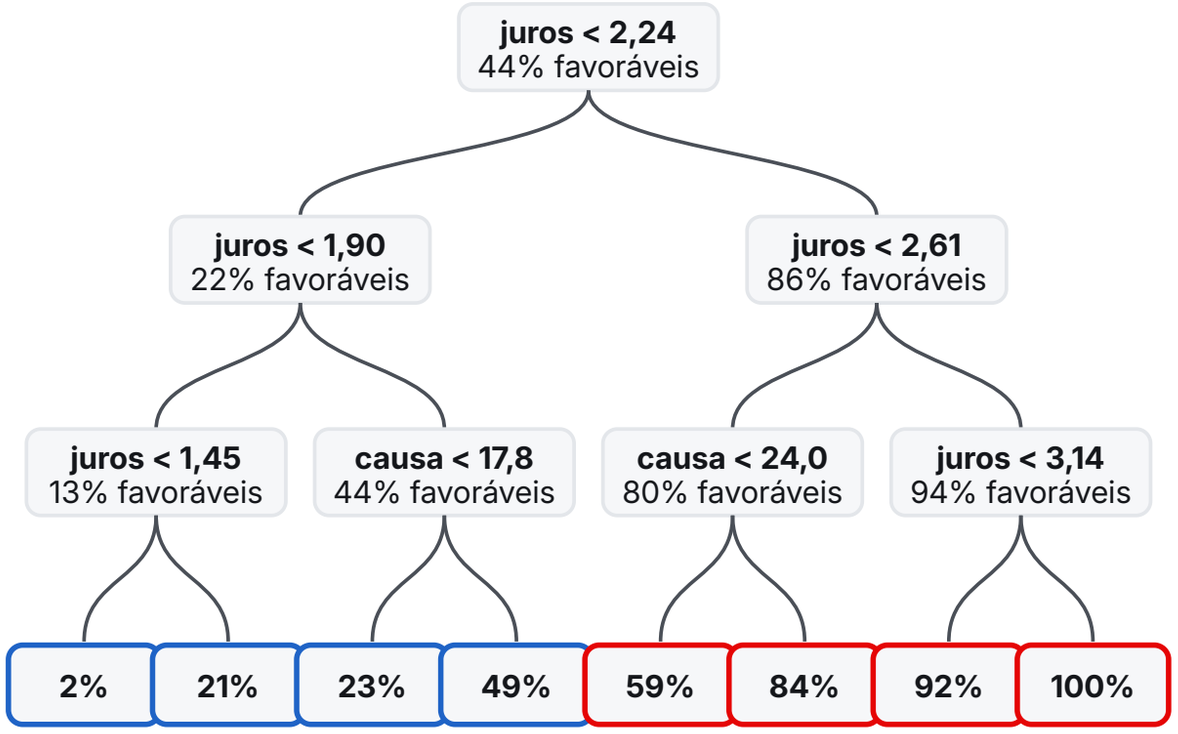
Como a árvore escolhe a primeira pergunta



Vence o corte com **menor erro**: juros abaixo de 2,24%. A árvore faz o mesmo dentro de cada lado, de novo e de novo.

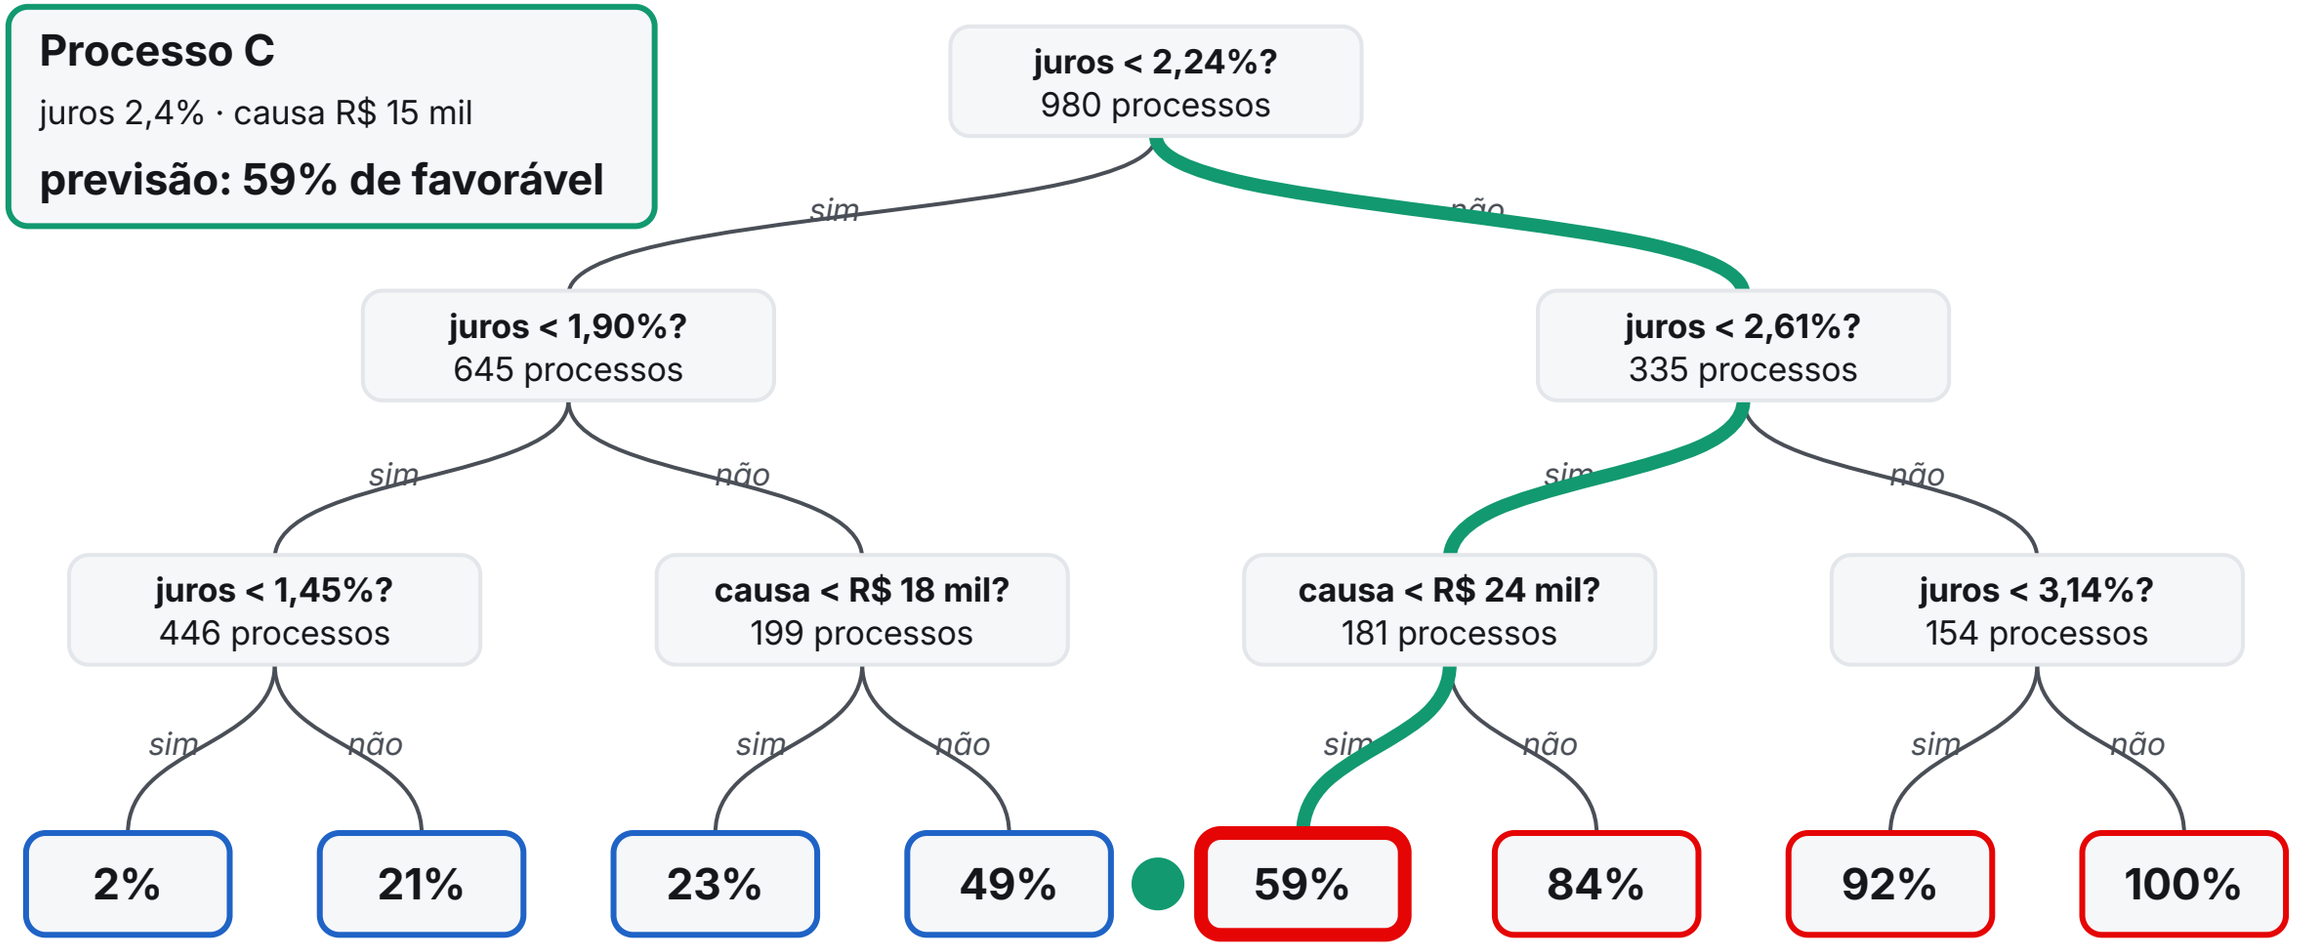
Pergunta após pergunta, a árvore parte os dados





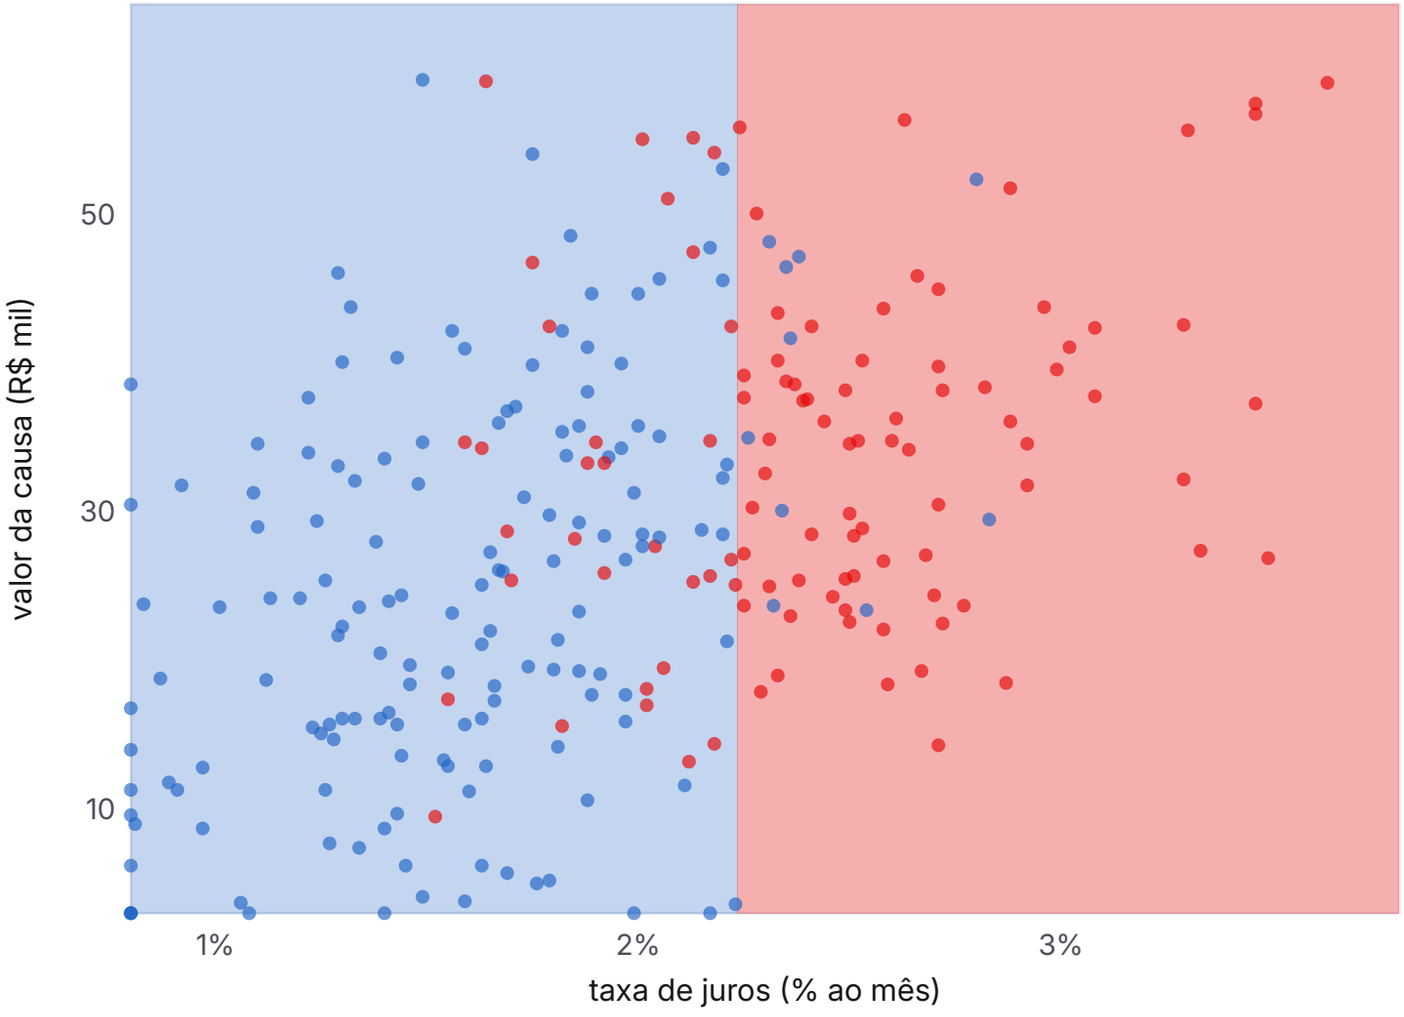
Cada **folha** é uma regra, e a probabilidade é a proporção de favoráveis ali. A causa só entra em parte dos juros: a árvore acha **interações** sozinha.

Um processo novo desce a árvore



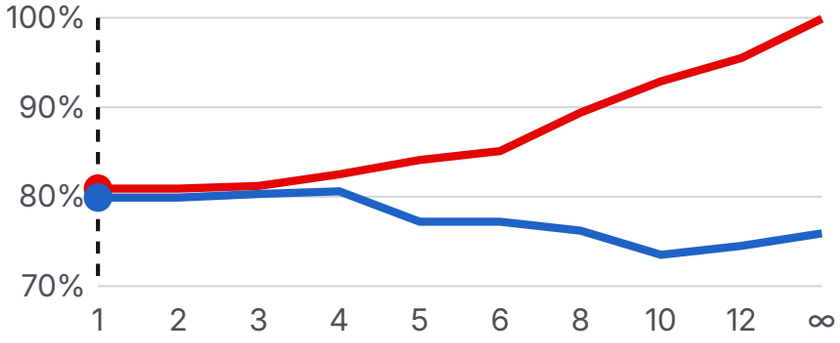
Juros de 2,4% e causa de R$ 15 mil: aqui a **causa** decide.

Árvores de diferentes profundidades



profundidade máxima: **1**

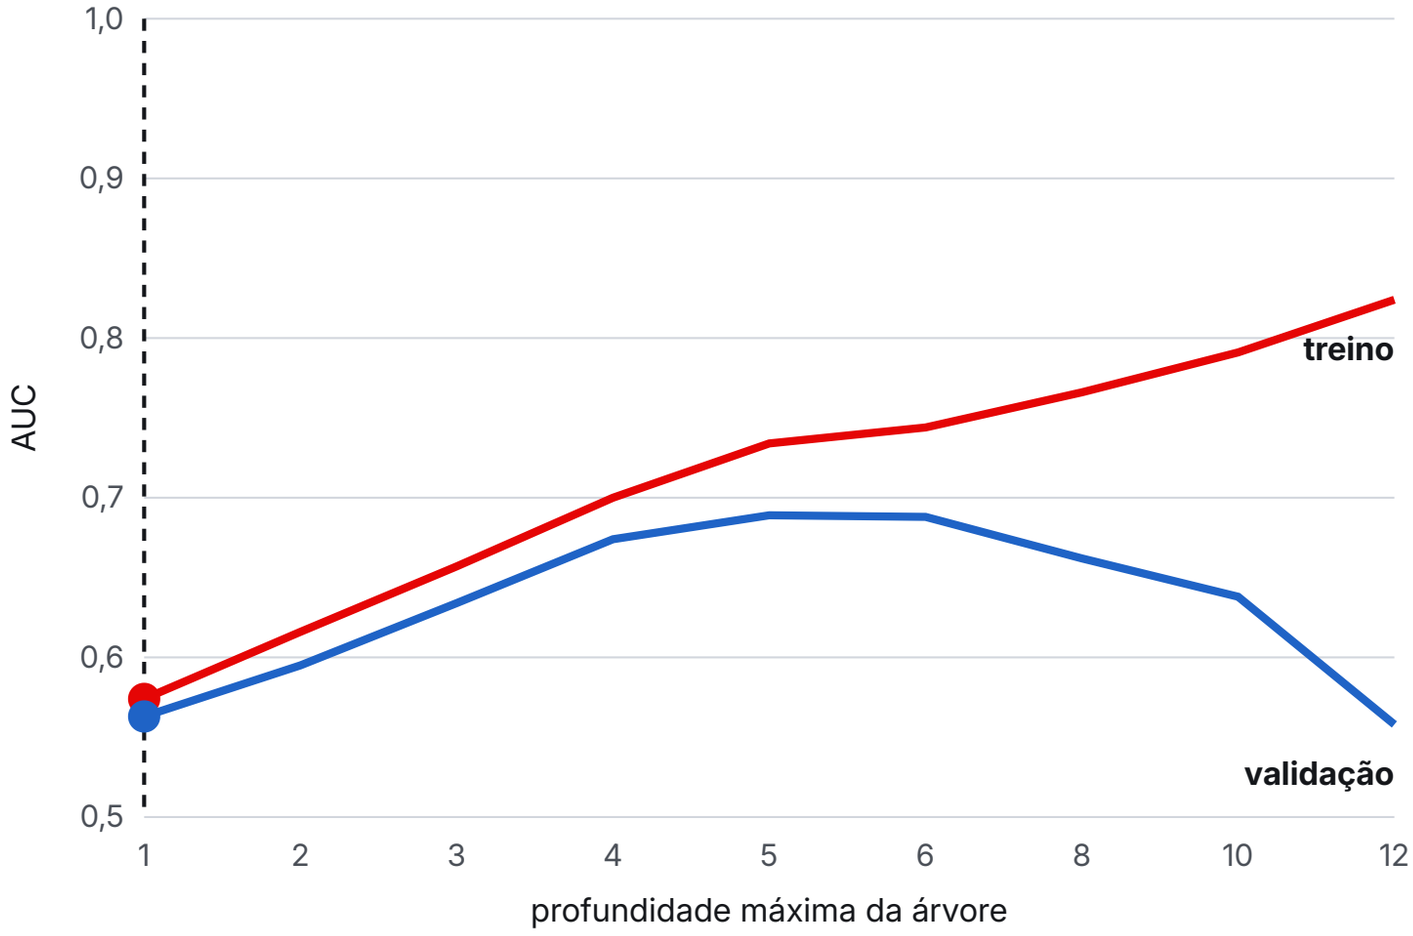
folhas	acerto no treino	acerto no teste
2	**81%**	**80%**



PROFUNDIDADE É COMPLEXIDADE

Cada nível divide as folhas de novo. Sem limite, quase uma folha por processo: a árvore **decorou** o treino.

Na base real: profundidade e sobreajuste



profundidade máxima: **1**

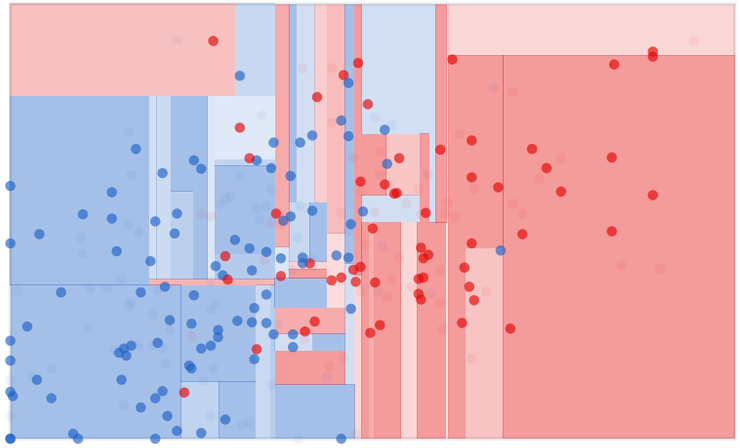
treino	validação
0,57	**0,56**

COMO LER O GRÁFICO

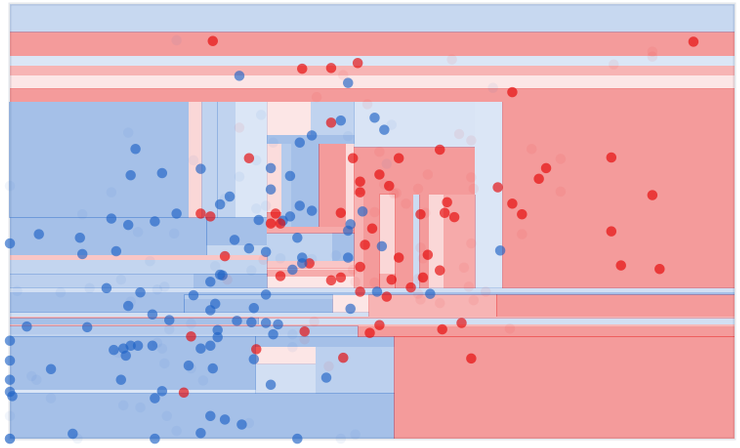
Base real do Projeto 08, com a pergunta da aula 23: houve voto divergente? Sem limite, a árvore tem AUC de **1,00** no treino e **0,53** na validação: decorou. A profundidade é um **hiperparâmetro**, e a melhor na validação é **5**.

Floresta: cada árvore vê uma amostra diferente

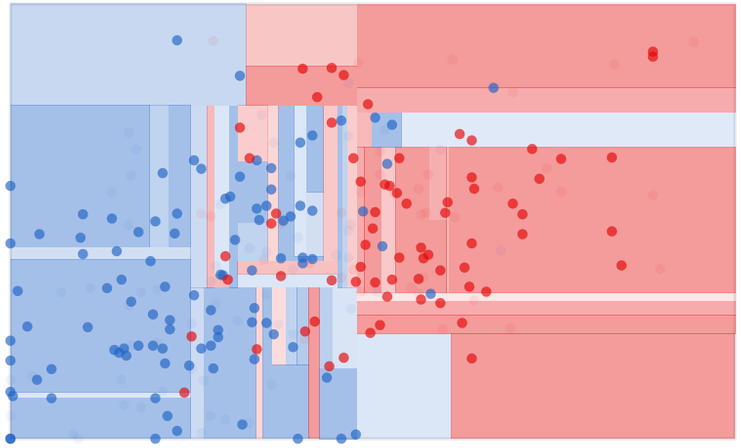
árvore 1



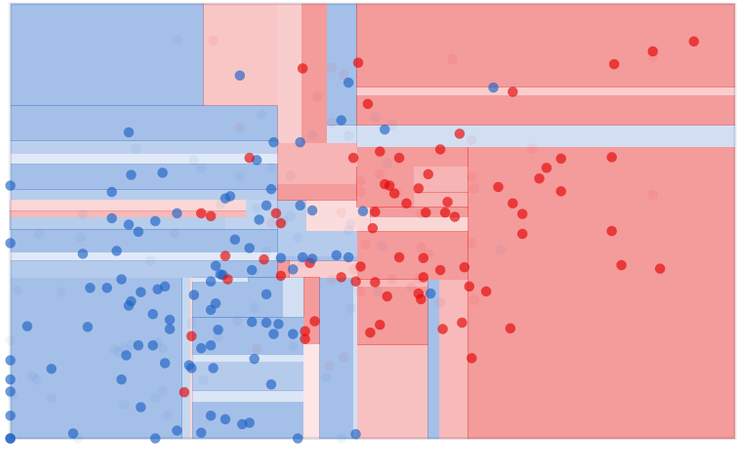
árvore 2



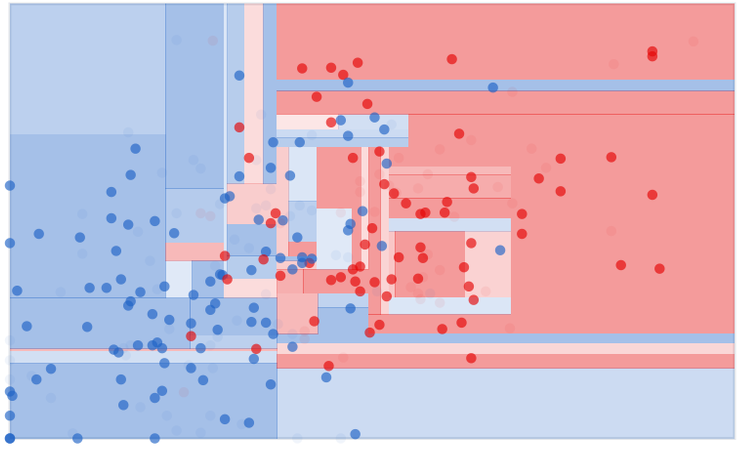
árvore 3



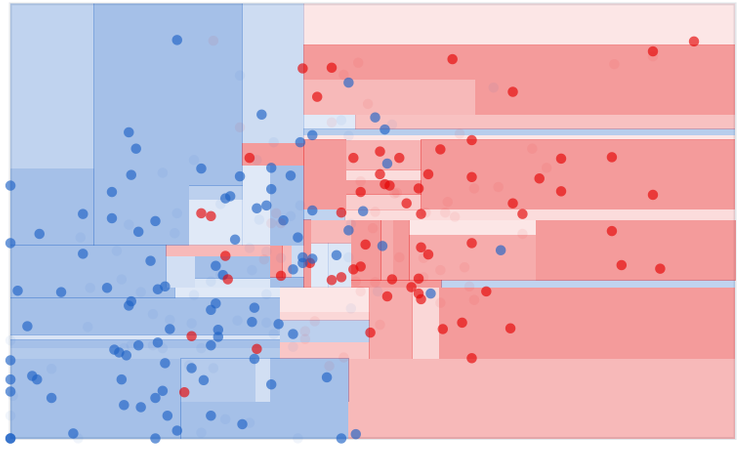
árvore 4



árvore 5

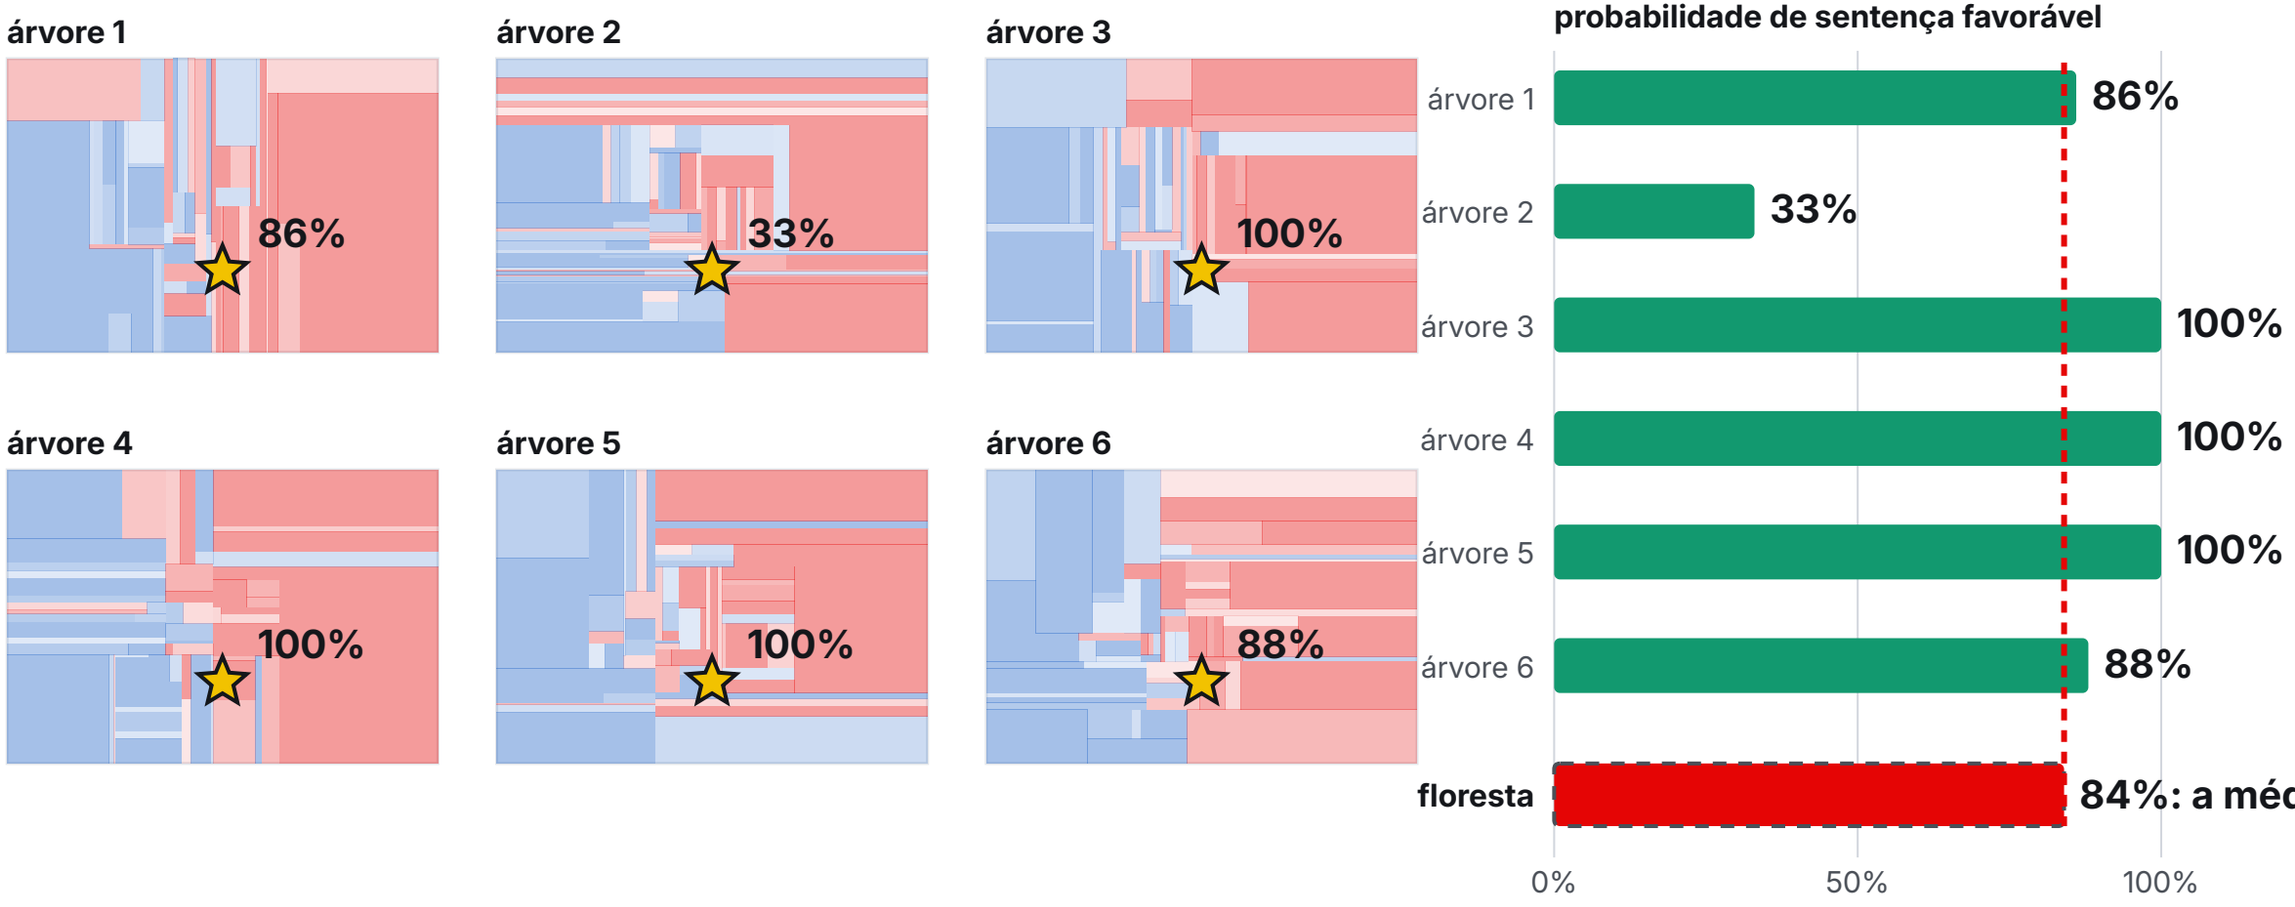


árvore 6



Seis sorteios, seis árvores, **seis partições diferentes**. Todas sem limite de profundidade.

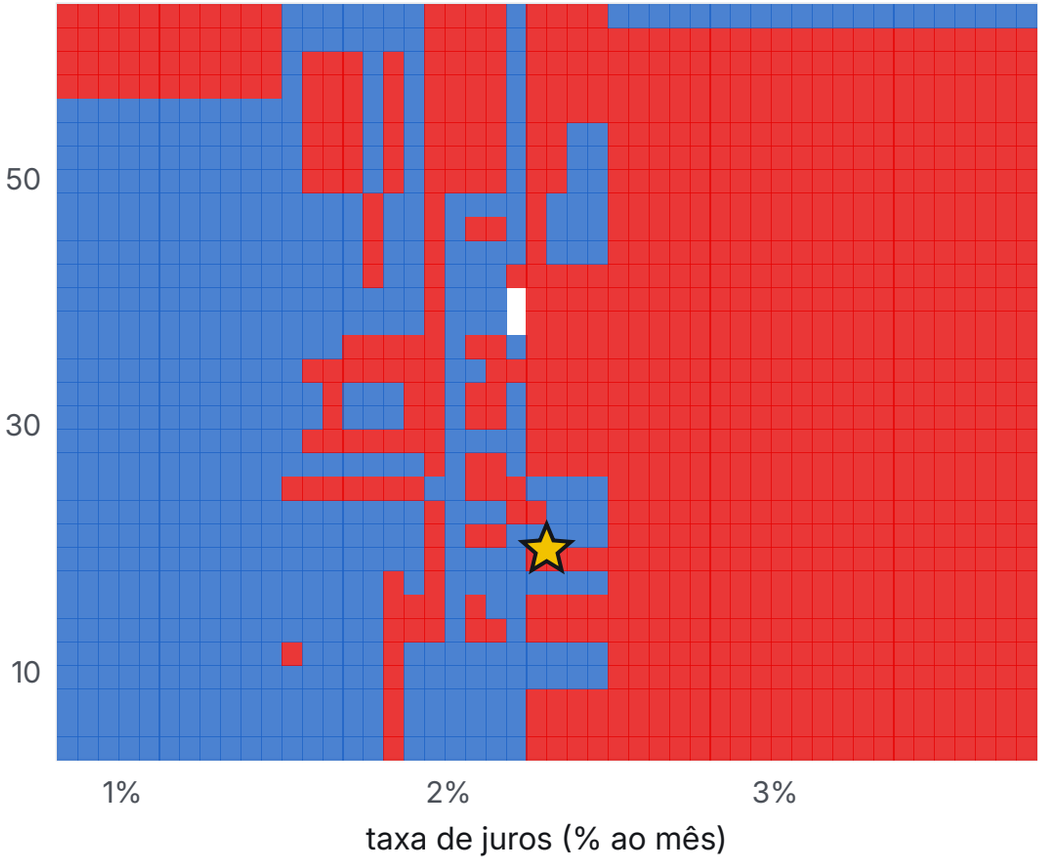
Floresta: as árvores votam, e vale a média



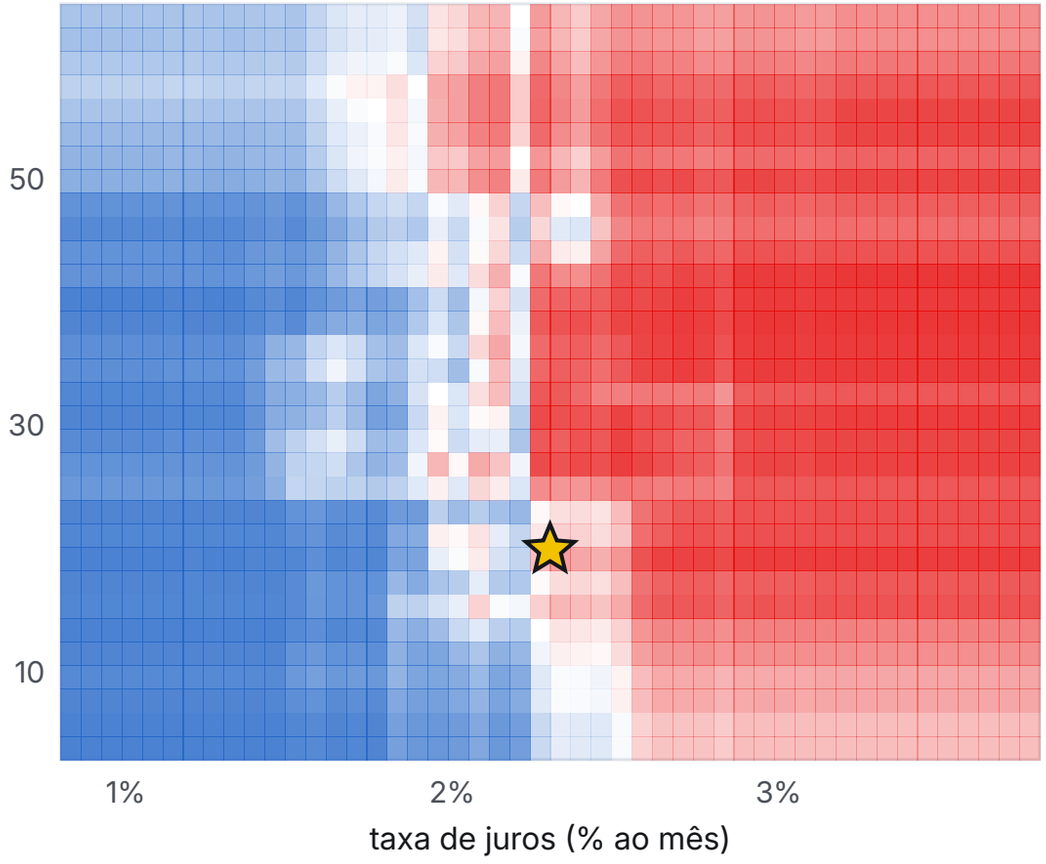
A floresta faz a **média**. Os erros de cada árvore se compensam, e a previsão muda menos de uma amostra para outra.

Uma árvore funda e uma floresta

uma árvore sem limite de profundidade

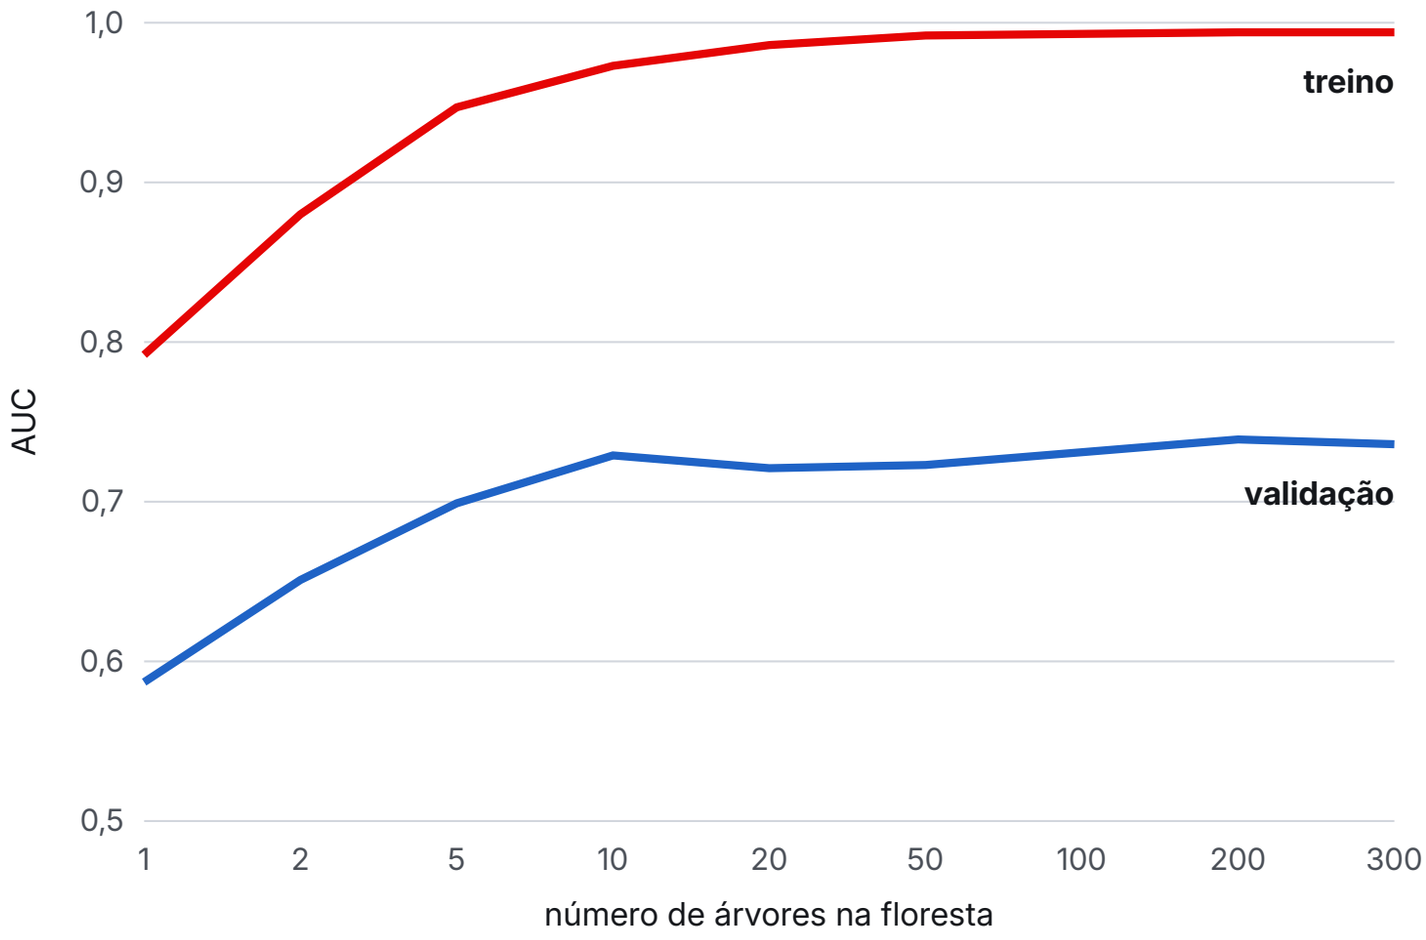


floresta de 300 árvores



A floresta de 300 árvores: a mesma regra geral, com fronteiras suaves. As ilhas somem na média.

Mais árvores na floresta, sem sobreajuste novo

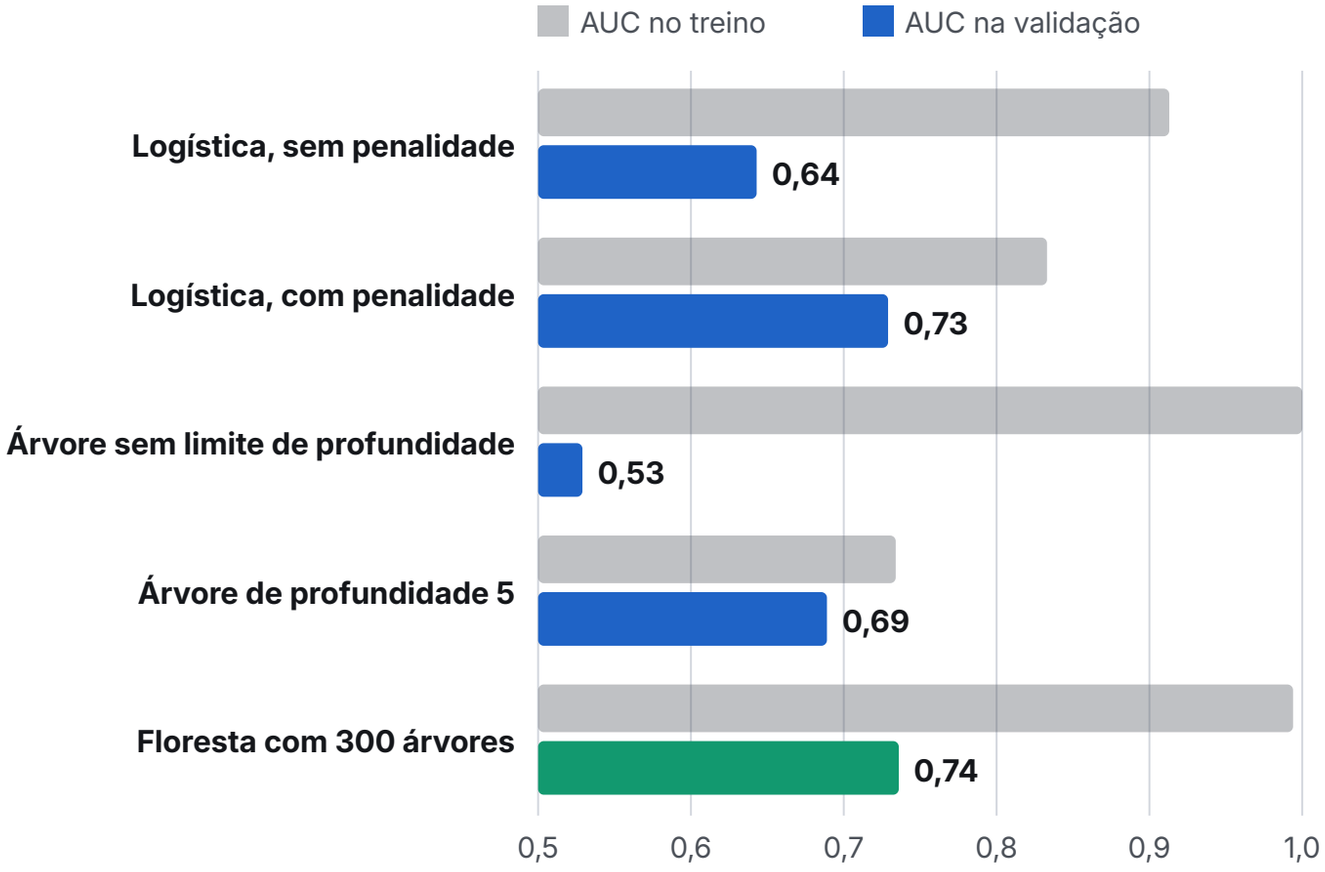


COMO LER O GRÁFICO

Aumentar o número de árvores **não piora** a validação: ela sobe e estabiliza, por volta de 100 a 200 árvores. Mais árvores custam tempo de computador, e não acerto.

O treino perto de 1 é normal numa floresta. O número que vale é o da **validação**.

Comparação entre os modelos na base real



QUANDO USAR CADA UM

- **Logística:** os coeficientes precisam ser explicados, ou há muitas categorias e poucos dados.
- **Árvore:** a regra precisa ser lida por uma pessoa.
- **Floresta:** o que importa é ordenar bem os casos novos.

Vazamento: a variável que só existe depois do desfecho

O QUE É VAZAMENTO

Uma variável que carrega a resposta, mas **não estaria disponível** no momento da previsão. A AUC fica ótima no papel, e o modelo é inútil na prática.

A pergunta a fazer para cada coluna: **no dia em que eu vou prever, eu já sei isto?**

EXEMPLOS PARA PREVER A SENTENÇA

- `data_do_transito_em_julgado`: só existe depois da sentença.
- `valor_da_condenacao`: só existe se houver condenação.
- `tipo_de_acao`: conhecida na distribuição, pode entrar.
- `resultado_de_outro_modelo`: depende do que ele usou.

Quiz



Esta variável pode entrar no modelo?

`jtrecenti.github.io/cdad2-202662/quiz`

Exercício no notebook: do modelo ao arquivo de predições

NOTEBOOK DA AULA 24 · INDIVIDUAL · ATÉ 18:00

Continua a pergunta da aula 23, na mesma base.

1. Ajustar e ler uma árvore.
2. Escolher a profundidade por validação cruzada.
3. Ajustar a floresta e ver as variáveis importantes.
4. Comparar os três modelos.
5. Gerar o arquivo de predições.

Abrir o notebook no Colab

POR QUE ESTE NOTEBOOK IMPORTA

A parte 5 é a **receita do Projeto 08**: o projeto usa as mesmas colunas, com outra resposta. Trocando o alvo, o notebook vira o seu ponto de partida.

Projeto 08: competição de modelos

PROJETO 08 · INDIVIDUAL · EM CASA · ATÉ 24/11, 12:00

Prever se o recurso criminal será integralmente negado, em acórdãos reais do TJSP.

- `treino.csv`: 5.953 acórdãos, com `negou`.
- `teste.csv`: 2.552 acórdãos, sem a resposta.
- **Entrega:** CSV com `id` e `prob`, no portal.
- **Nota pela AUC**, em **3 submissões**: vale a melhor. Pode usar IA.

COMO CHEGAR AO MODELO

1. Rode a receita da aula e **supere o baseline** do portal.
2. Melhore com **validação cruzada no treino**: variáveis, `C`, profundidade.
3. Use as submissões para **confirmar**, e não para escolher: é o erro do teste fora da gaveta.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- A árvore escolhe, a cada passo, a **pergunta que menos erra**.
- Para prever, o processo **desce a árvore** até uma folha.
- Árvore funda **decora**: a profundidade é o hiperparâmetro.
- A floresta faz a **média** de árvores diferentes, e erra menos em casos novos.
- **Vazamento:** no dia da previsão, eu já sei isto?

PROJETO 07 · TERÇA, 10/11, NO INÍCIO DA AULA

5 questões de múltipla escolha sobre as aulas 22 a 24, em **15 minutos**, no portal. Individual, sem consulta e sem IA, em tela cheia.

Estude: sobreajuste, validação cruzada, o `C` da regressão logística, árvores e florestas, e vazamento.