Interpretabilidade, justiça algorítmica e LGPD

Aula 25 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

10/11/2026

Objetivos de aprendizagem

Ao final da aula, você será capaz de:

1. **explicar** a previsão de um processo com valores de Shapley (SHAP), e por que uma floresta precisa deles;
2. **medir** se um modelo erra de forma diferente entre grupos de pessoas, e explicar por que os critérios de justiça entram em conflito;
3. **discutir** o uso de variáveis como sexo e raça e o que a LGPD exige de decisões automatizadas.

Regressão logística e árvore se leem; a floresta, não

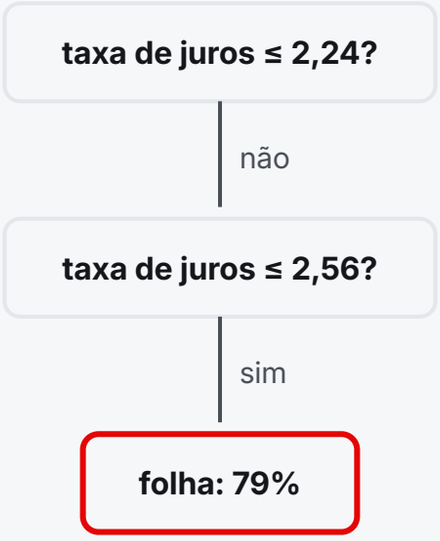
regressão logística

ponto de partida	-8,11
juros: 3,47 × 2,3	+7,98
valor da causa: 0,027 × 30	+0,81

cada variável soma um pedaço fixo

previsão: 66%

árvore de decisão



previsão: 79%

floresta de 300 árvores

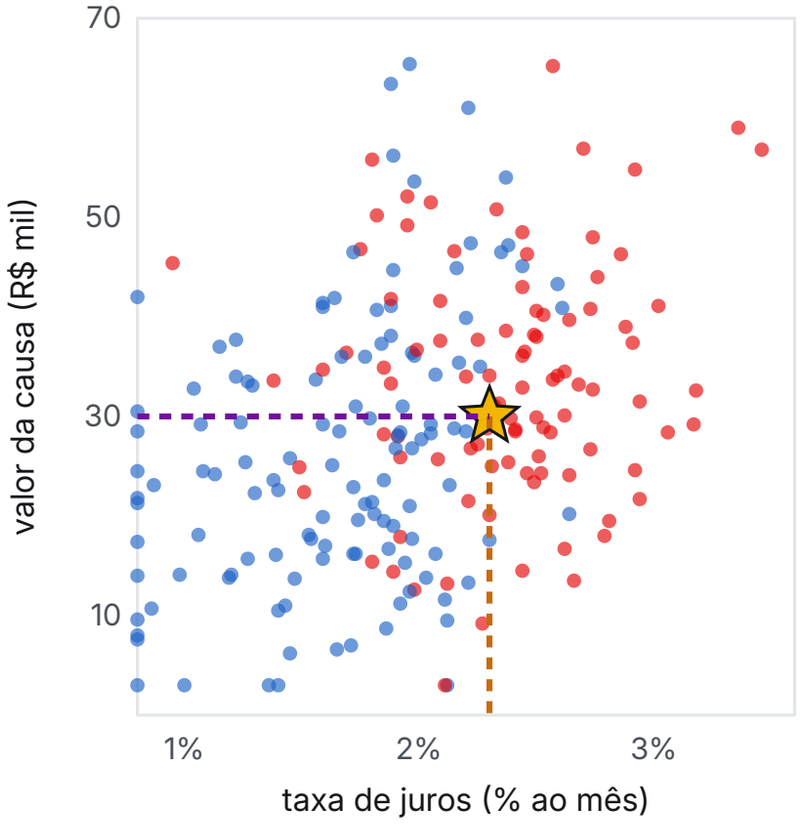


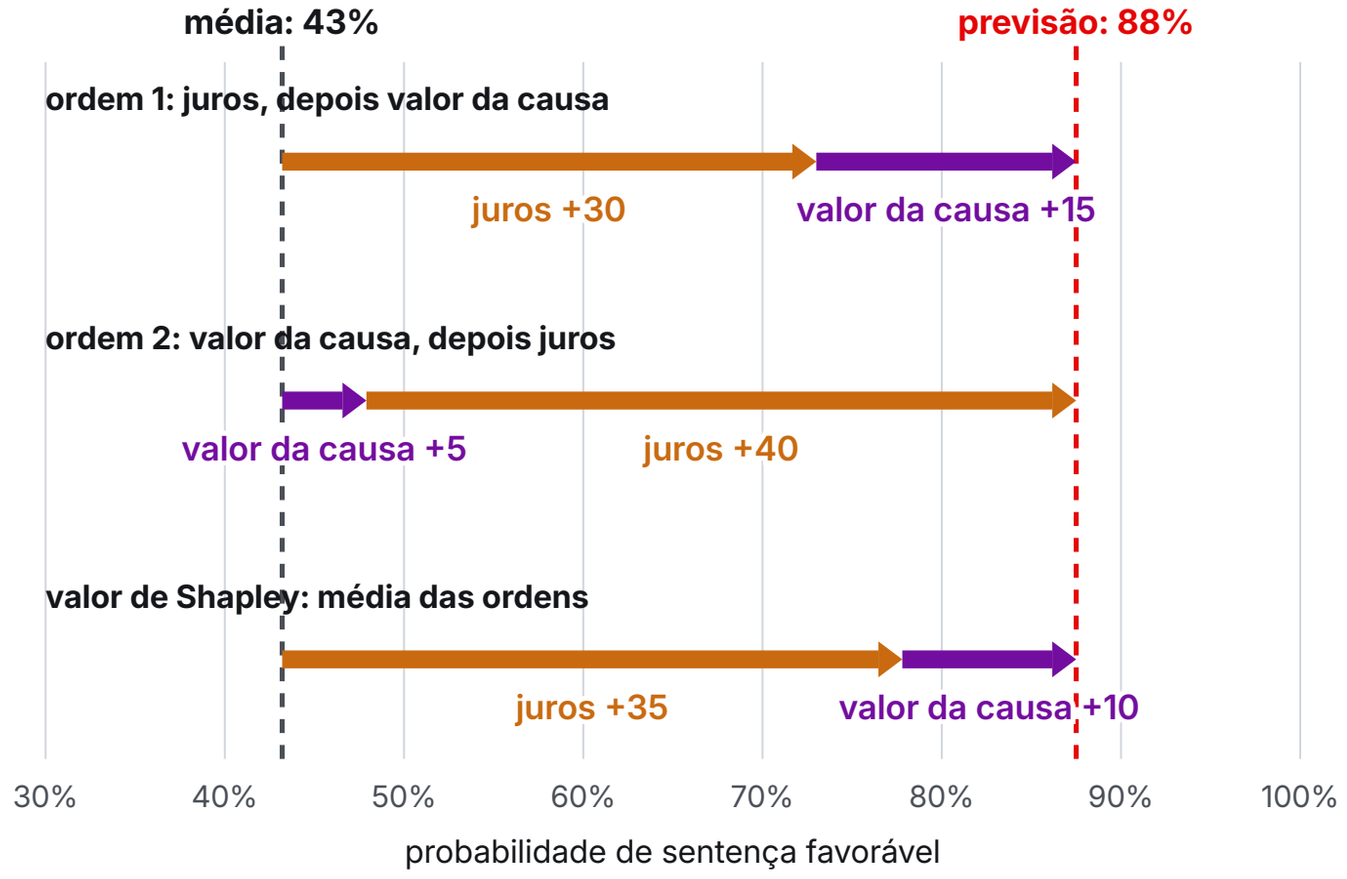
... e mais 260; a previsão é a média

previsão: 88%

Floresta: 300 árvores, cada uma com as suas perguntas, e a previsão é a **média**. Ninguém lê 300 caminhos. Para saber o que pesou, é preciso outra ferramenta: o **SHAP**.

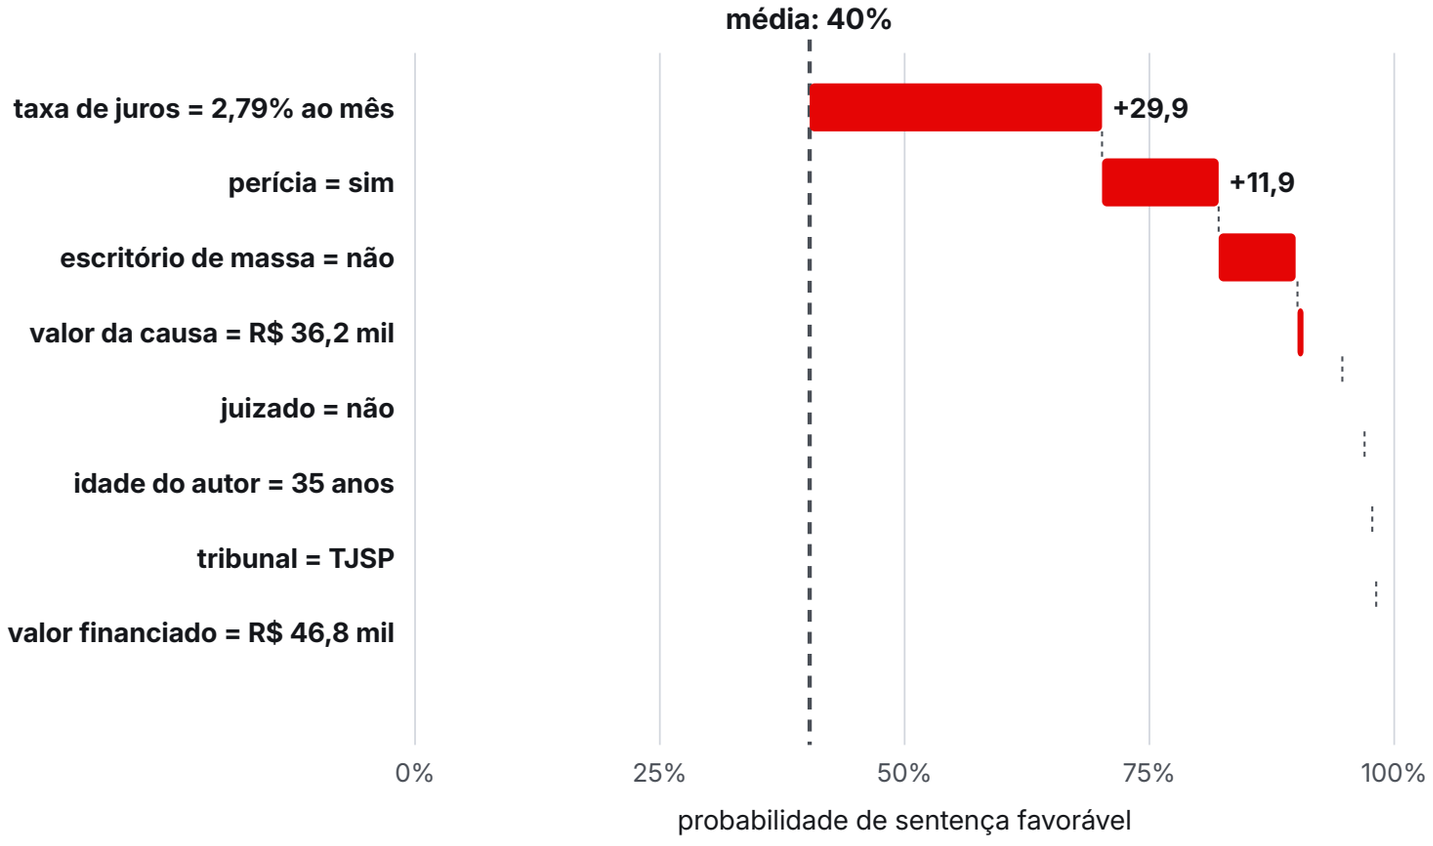
Valor de Shapley: a contribuição de cada variável





Para não depender da ordem, tiro a **média** das duas: juros **+35** e valor da causa **+10**. É o **valor de Shapley**, e a soma fecha: 43 + 35 + 10 = 88. O **SHAP** faz essa conta com todas as variáveis.

Gráfico em cascata: a explicação de um processo

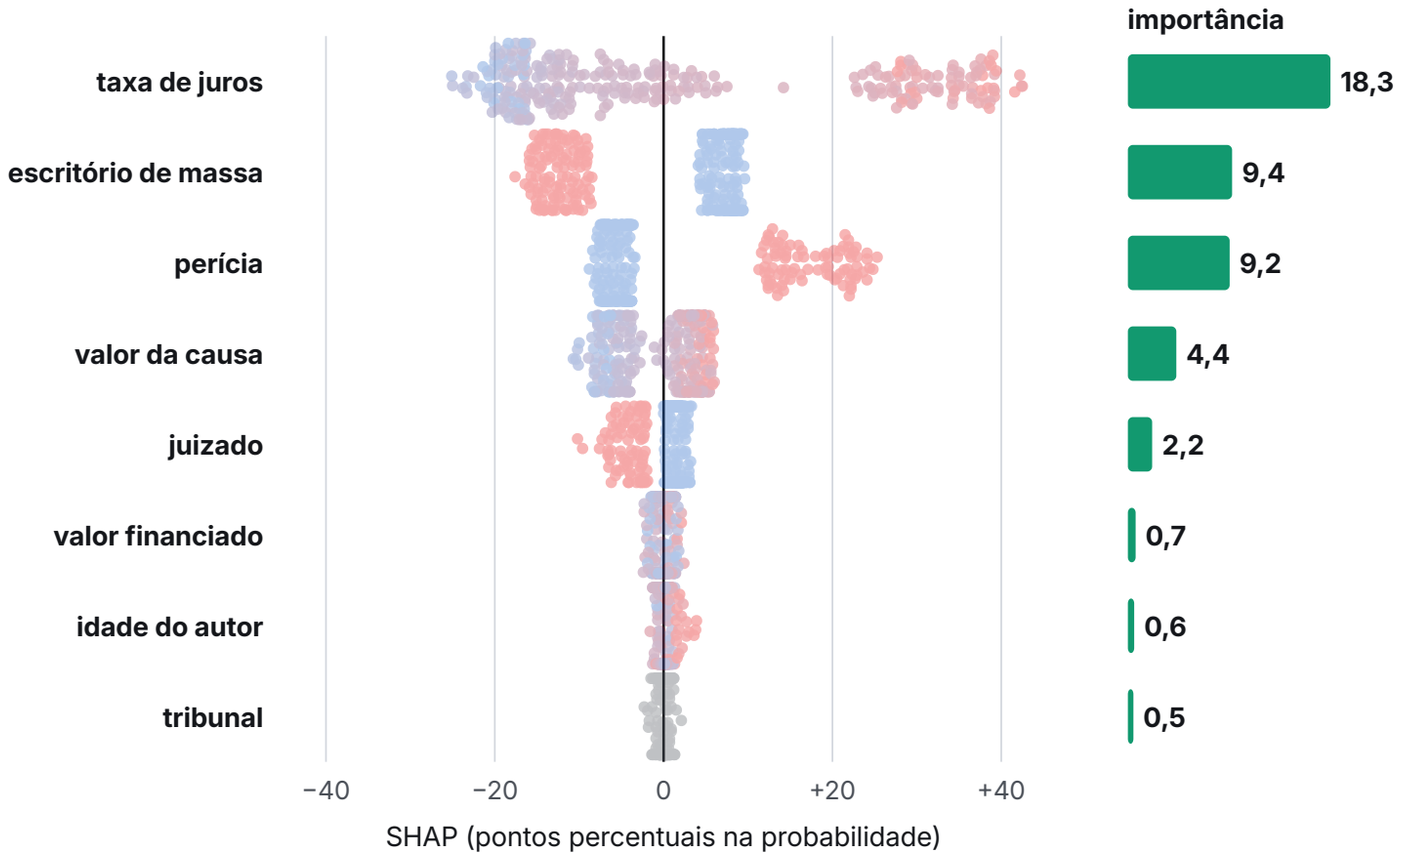


processo A | processo B | processo C

COMO LER A CASCATA

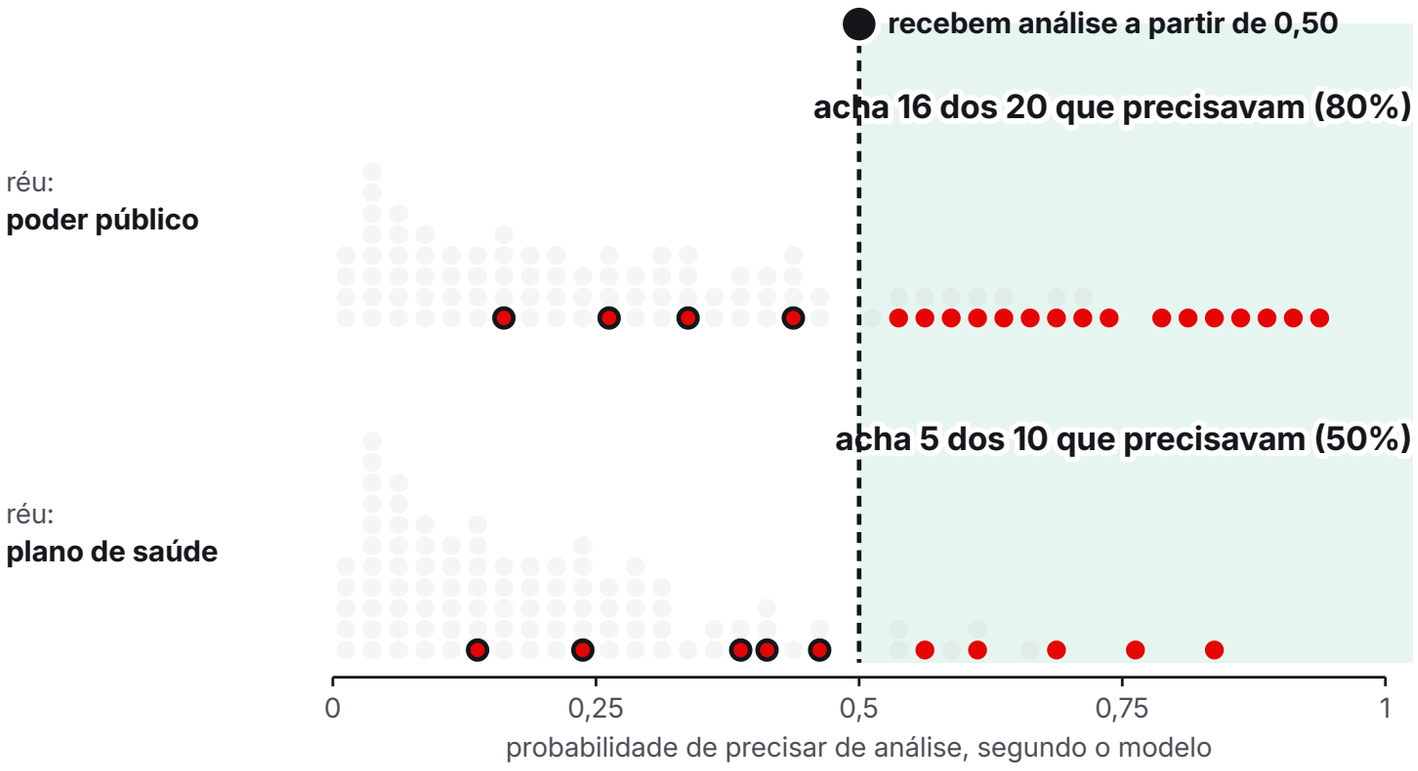
Começa na **média** da floresta (40%) e soma uma variável por vez. Barra **vermelha** empurra para a sentença favorável; **azul**, contra. O fim é a previsão do processo.

Gráfico de enxame: as explicações de muitos processos



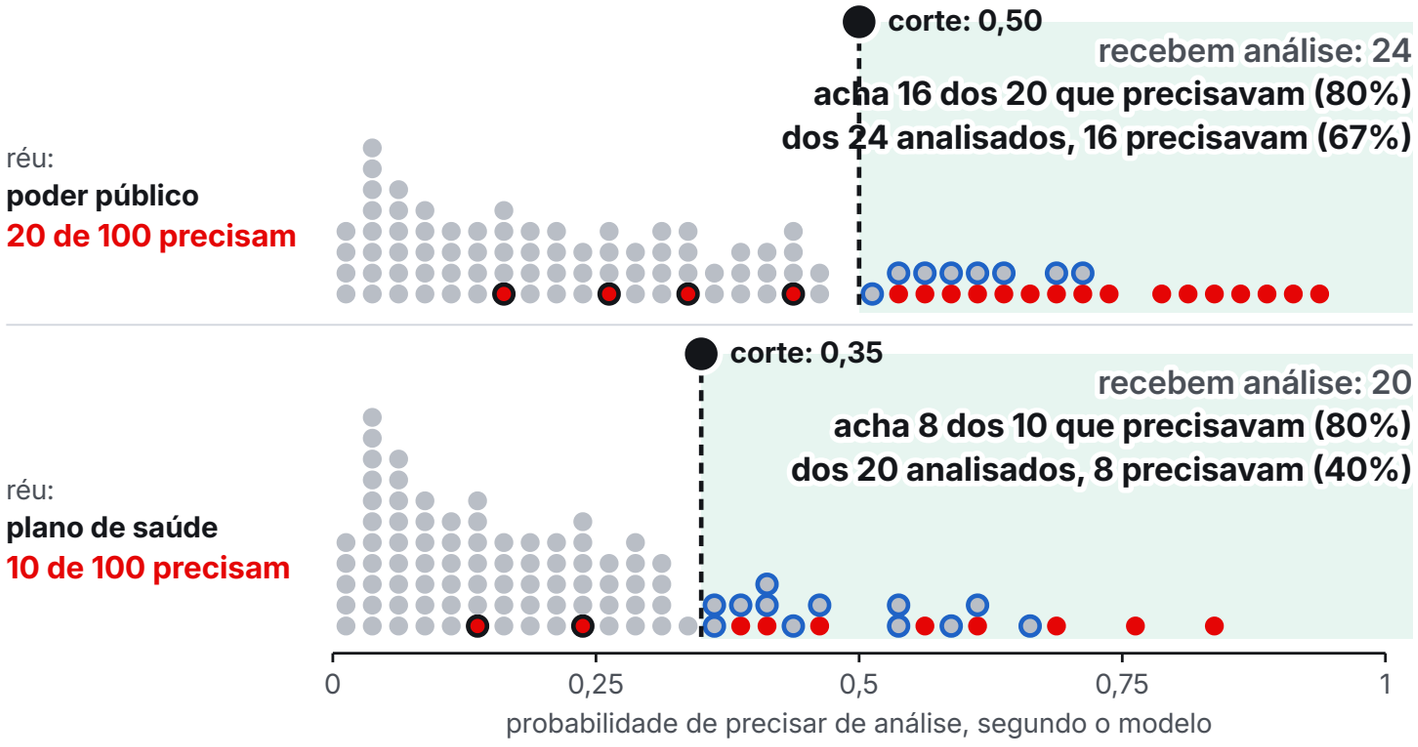
A média do tamanho dos pontos (sem o sinal) é a **importância geral**: a mesma ideia da aula 24, agora com o lado para o qual cada variável empurra.

Justiça algorítmica: o modelo erra igual com todos?



Por quê? Nos planos, os casos que precisavam ganharam probabilidades mais baixas: o modelo os reconhece pior. **Para a turma:** isso é aceitável? O que vocês fariam? (Dá para arrastar o corte.)

Igualar um erro desiguala outro

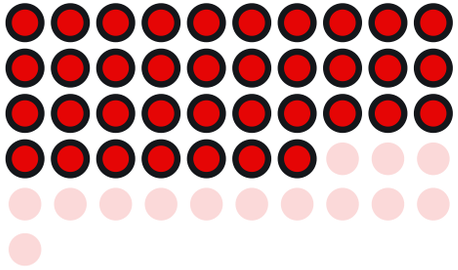


Cada corte iguala **uma** medida, não as duas. No fundo, os grupos são diferentes: precisam **20 de 100** contra **10 de 100**. Com proporções diferentes, um modelo que erra não consegue ter erros e precisão iguais ao mesmo tempo. **Qual igualdade importa é uma decisão normativa.**

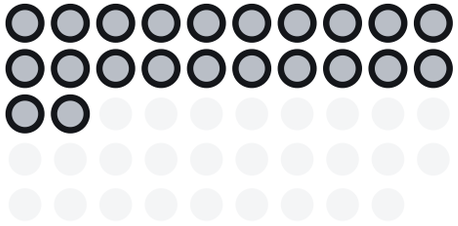
O mesmo dilema num caso real: o COMPAS

réus negros

voltaram a ser presos: 51



não voltaram: 49

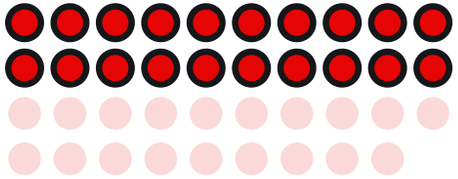


63%

37 voltaram entre os 59 de alto risco

réus brancos

voltaram a ser presos: 39



não voltaram: 61

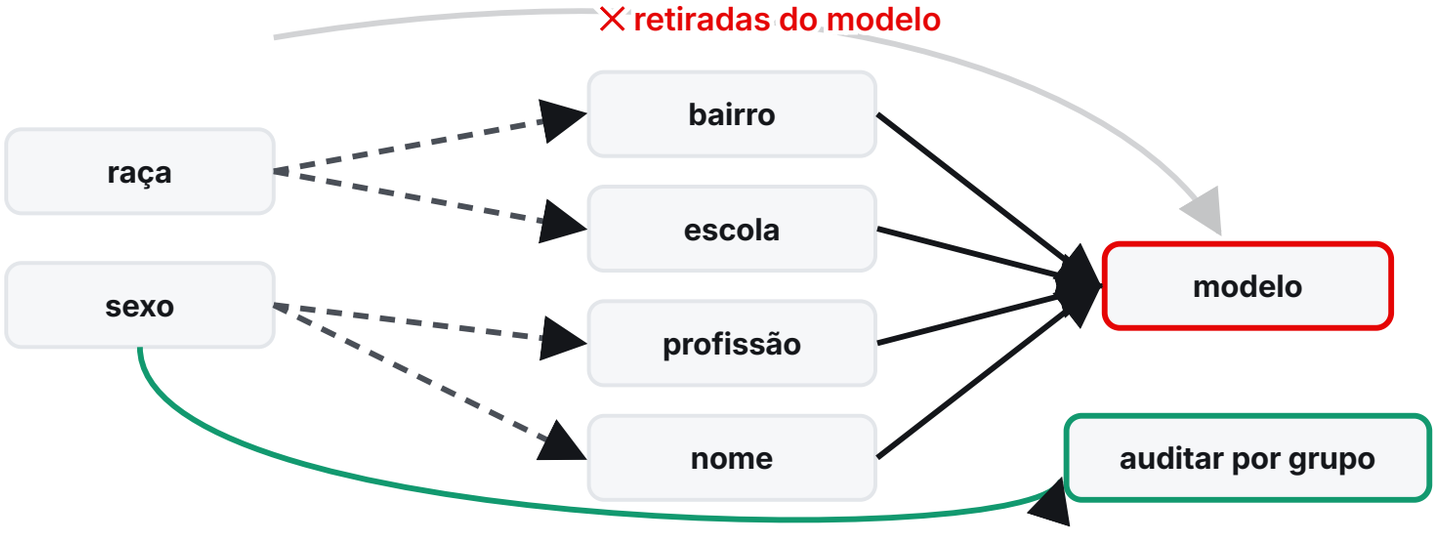


59%

20 voltaram entre os 34 de alto risco

A empresa respondeu olhando a **precisão**: dos marcados de alto risco, voltaram **63%** dos negros e **59%** dos brancos, quase o mesmo. As duas análises estão certas, e não dá para igualar as duas coisas: é o slide anterior.

Sexo, raça e as variáveis que fazem as vezes delas



E sem a variável não dá para **auditar**: para medir a sensibilidade por grupo, como nos slides anteriores, é preciso saber o grupo de cada pessoa.

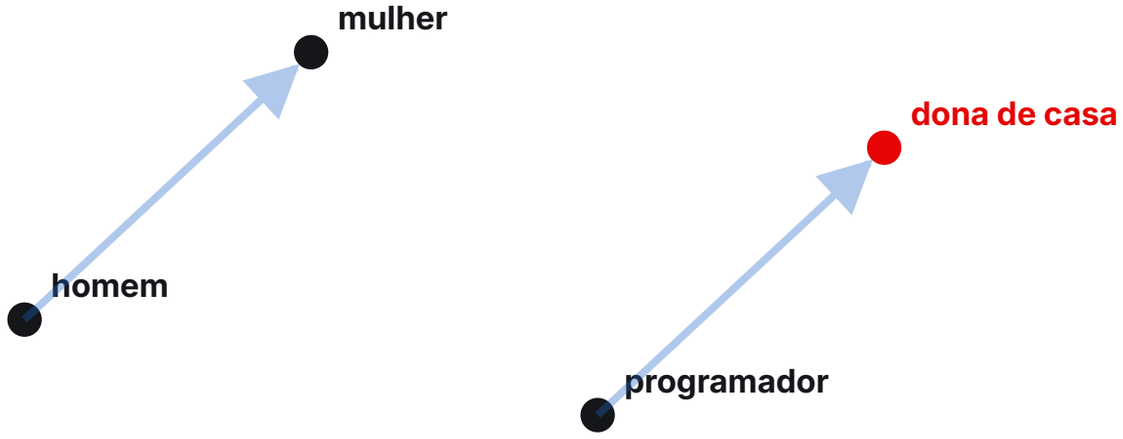
PARA DEBATER

Um tribunal quer um modelo de risco para as **audiências de custódia**. Ele pode usar **raça**? E o **bairro**? E o **sexo**, se na base os homens reincidem mais?

BASE NORMATIVA

Constituição, arts. 3º, IV, e 5º, I. Na LGPD, origem racial é **dado sensível** (art. 5º, II); sexo não está na lista, mas vale a **não discriminação** (art. 6º, IX).

Viés em modelos de linguagem



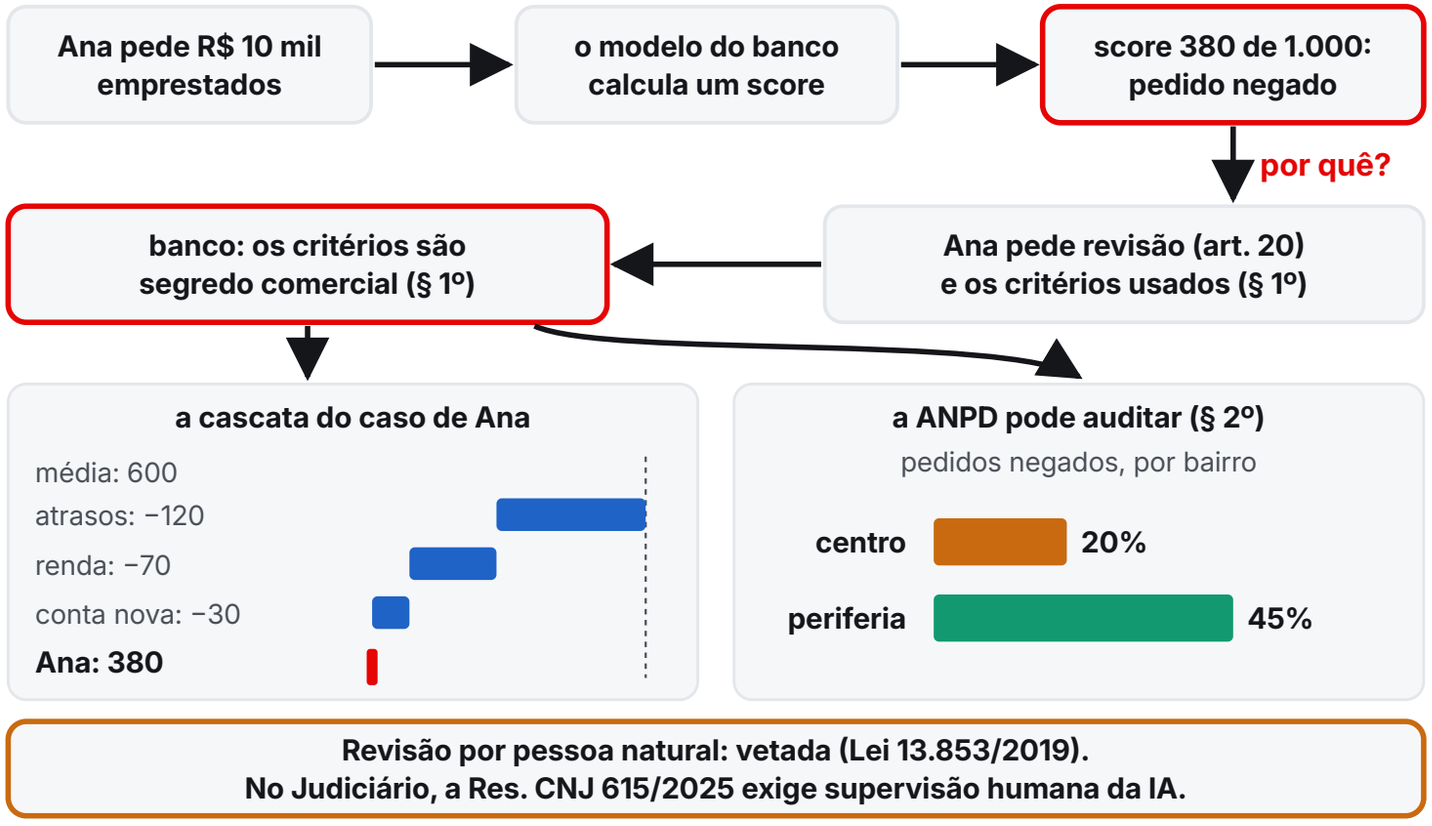
Esquema: os vetores reais têm centenas de dimensões.

O mesmo vale para textos jurídicos: um modelo treinado em **decisões passadas** aprende os padrões delas, **inclusive os injustos**, e os repete em escala.

OUTROS EXEMPLOS DOCUMENTADOS

- Tradução de pronome neutro como “ele é médico” e “ela é enfermeira” (Caliskan e coautores, 2017).
- Jurisprudência **inventada** por chatbot numa peça (Mata v. Avianca, Nova York, 2023).

O que a LGPD garante num caso de crédito



Dois limites. A revisão **por pessoa natural** foi vetada em 2019: ela pode ser feita por outro sistema. No **Judiciário**, a Resolução CNJ 615/2025 exige supervisão humana e classificação de risco das soluções de IA.

Exercício no notebook: explicar e auditar um modelo

NOTEBOOK DA AULA 25 · INDIVIDUAL · O QUE FALTAR FICA PARA CASA

1. Ajustar a floresta e calcular o SHAP.
2. Ler a cascata de um processo.
3. Ler o enxame e comparar com a importância da aula 24.
4. Medir a sensibilidade por grupo na triagem do NatJus.
5. Responder: a explicação basta para o art. 20 da LGPD?

Abrir o notebook no Colab

PARA O PROJETO 08

O SHAP funciona com qualquer modelo do scikit-learn. Rode-o no seu modelo do projeto: se uma variável pesa muito mais do que você esperava, desconfie de **vazamento** antes de comemorar a AUC.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- A logística e a árvore se leem; a floresta precisa do **SHAP**, que reparte a previsão entre as variáveis.
- A **cascata** explica um caso; o **enxame**, muitos casos.
- O mesmo modelo pode **errar diferente** entre grupos, e os critérios de justiça não cabem todos juntos.
- Tirar sexo e raça **não basta**: outras variáveis fazem as vezes delas.
- A **LGPD** garante revisão e informação sobre os critérios.

PRÓXIMOS PASSOS

- **Quinta, 12/11 (aula 26):** redes neurais e embeddings, com aplicações a textos jurídicos.
- **Sábado, 14/11:** relatório da Pesquisa de Campo.
- **Projeto 08:** até 24/11, 12:00. Meta para esta semana: a primeira submissão acima do baseline.

Para consultar depois

INTERPRETABILIDADE

- Interpretable Machine Learning, de Christoph Molnar: livro gratuito, com SHAP explicado sem fórmulas.
- Documentação do SHAP: exemplos de cascata e enxame com o scikit-learn.

JUSTIÇA ALGORÍTMICA

- Machine Bias, a reportagem da ProPublica sobre o COMPAS (2016).
- Fairness and Machine Learning, de Barocas, Hardt e Narayanan: livro gratuito sobre os critérios e os seus conflitos.

NORMAS

- LGPD, Lei 13.709/2018, no Planalto.
- Resolução CNJ 615/2025, sobre IA no Judiciário.