Interpretabilidade, justiça algorítmica e LGPD

Aula 25 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

10/11/2026

Objetivos de aprendizagem

Ao final da aula, você será capaz de:

1. **explicar** a previsão de um processo com valores de Shapley (SHAP);
2. **ler** um gráfico em cascata e um gráfico de enxame;
3. **distinguir** a explicação de um modelo de uma relação causal;
4. **medir** se um modelo erra de forma diferente entre grupos;
5. **explicar** por que critérios de justiça entram em conflito;
6. **relacionar** decisões automatizadas com a LGPD e com a regulação do CNJ.

Importância geral e explicação de um caso

O QUE A AULA 24 MOSTROU

A importância da floresta diz **quais variáveis** o modelo mais usa, somando todos os processos.

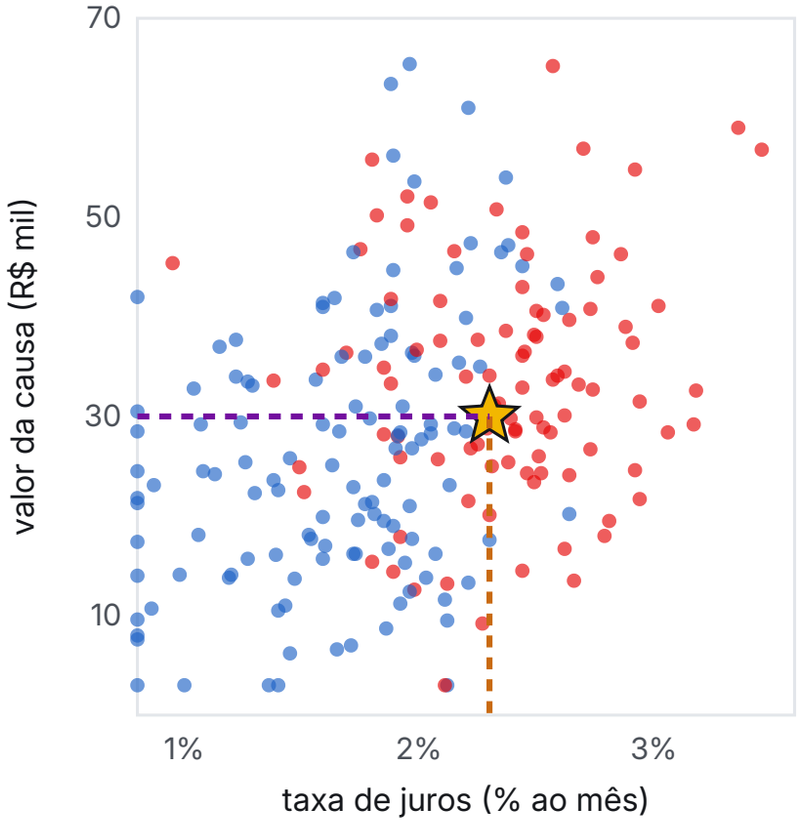
Ela não diz **para que lado** cada variável empurra, nem **por que um processo específico** recebeu a probabilidade que recebeu.

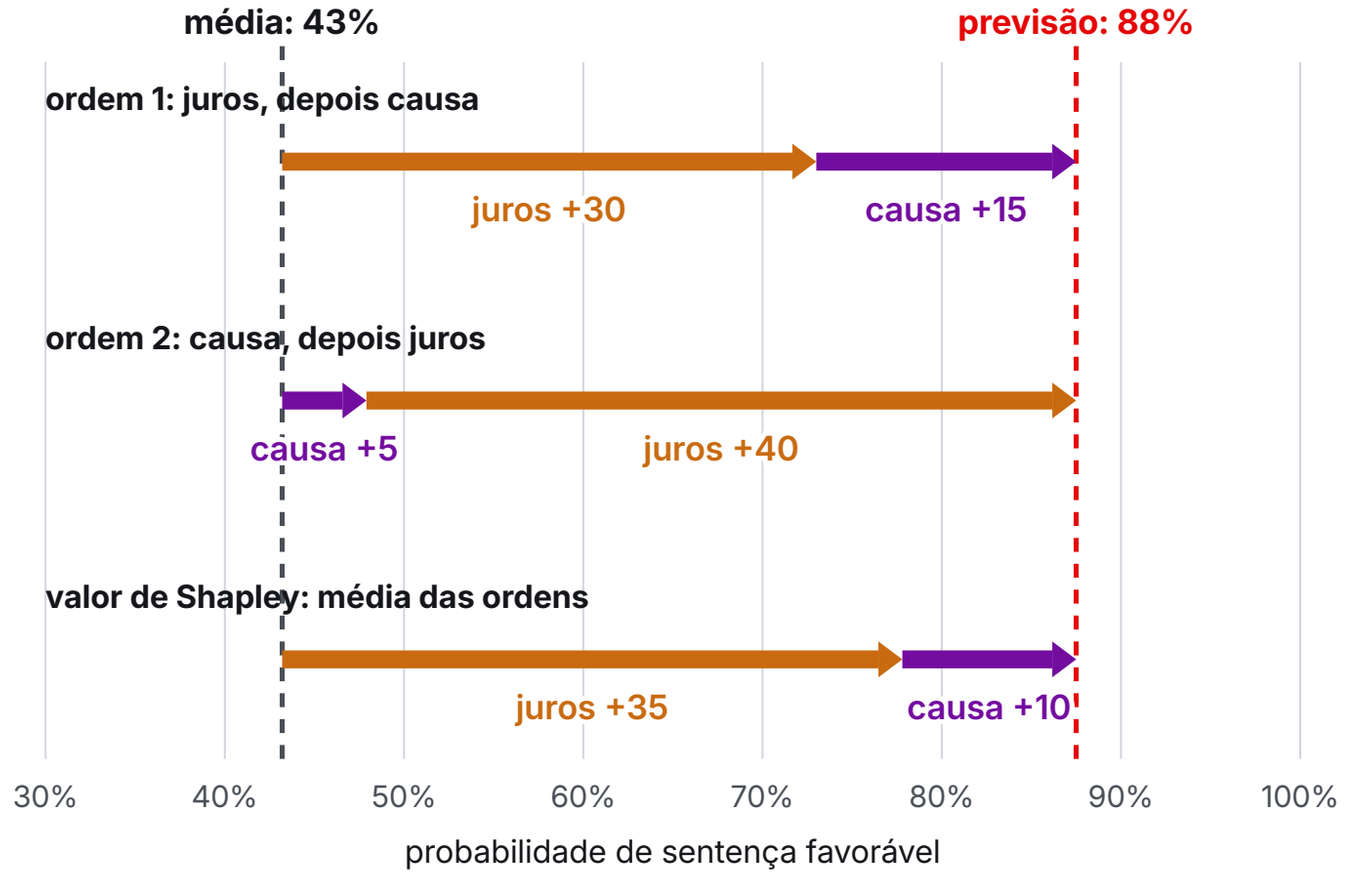
A PERGUNTA DE QUEM É AFETADO

"O modelo deu **88%** para o meu processo. O que, no meu processo, levou a esse número?"

É a pergunta de um advogado, de um juiz que usa a triagem, e do titular dos dados que pede revisão pela **LGPD**. A resposta é uma **explicação local**: a previsão repartida entre as variáveis.

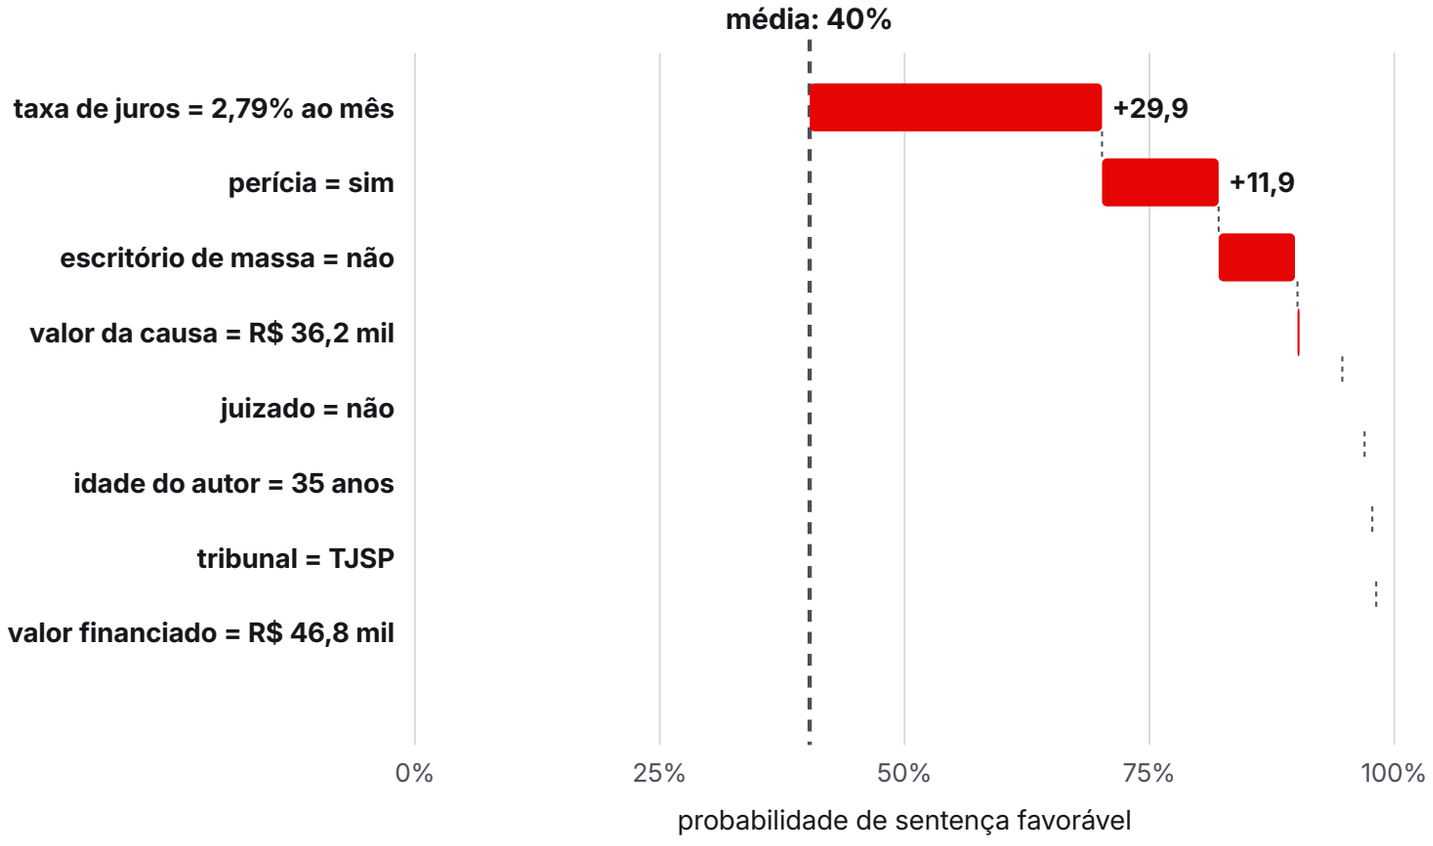
Valor de Shapley: a contribuição de cada variável





O **valor de Shapley** é a média das contribuições em todas as ordens: **juros +34,6** e **causa +9,6** pontos. Somados à média, dão exatamente a previsão. O **SHAP** faz essa conta para muitas variáveis.

Gráfico em cascata: a explicação de um processo

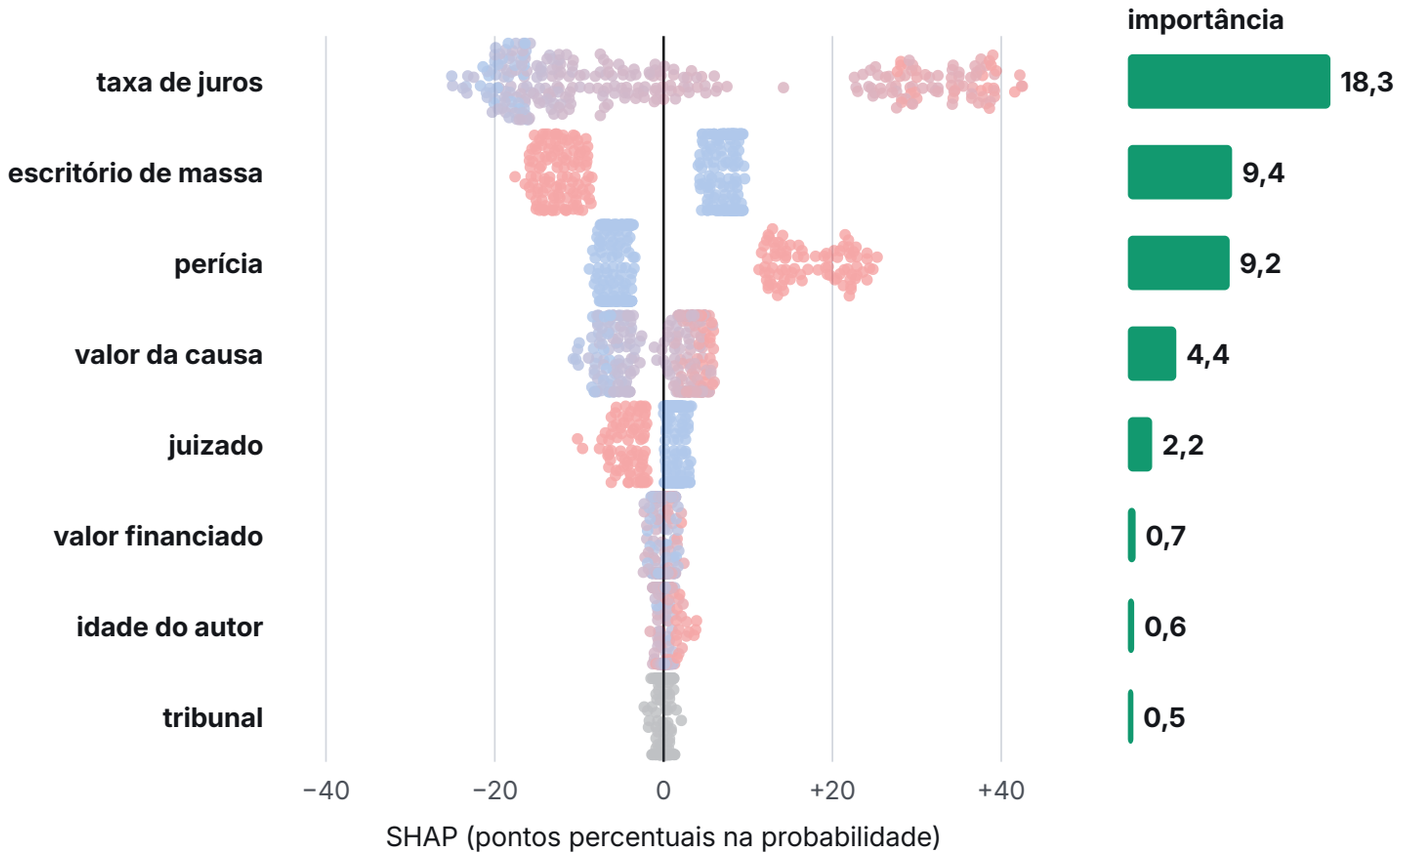


processo A | processo B | processo C

COMO LER A CASCATA

Começa na **média** da floresta (40%) e soma uma variável por vez. Barra **vermelha** empurra para a sentença favorável; **azul**, contra. O fim é a previsão do processo.

Gráfico de enxame: as explicações de muitos processos



A média do tamanho dos pontos (sem o sinal) é a **importância geral**: a mesma ideia da aula 24, agora com o lado para o qual cada variável empurra.

A explicação é do modelo, não do mundo

O QUE O SHAP NÃO DIZ

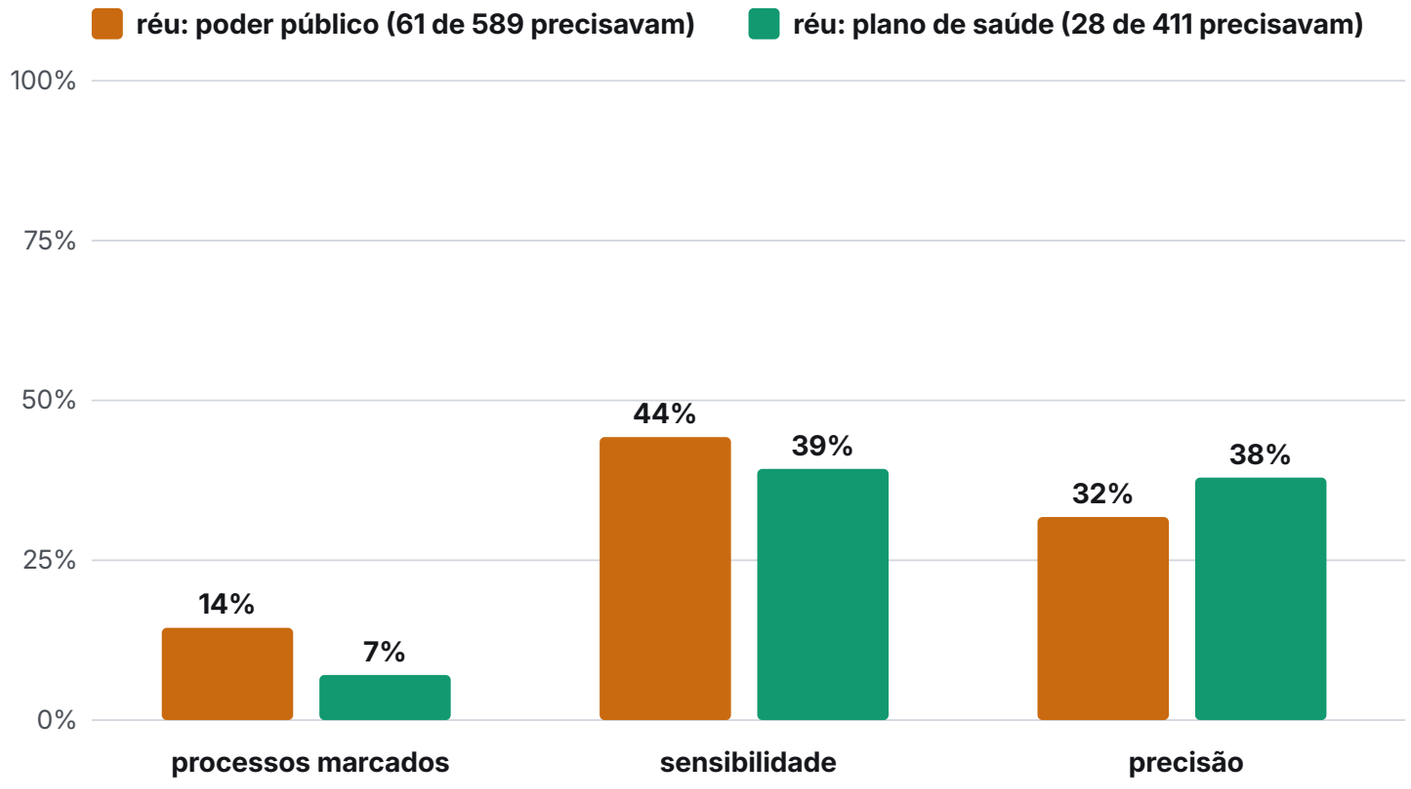
O SHAP explica **como o modelo calcula** a previsão. Se o modelo aprendeu uma associação, o SHAP mostra a associação.

"Escritório de massa empurra para baixo" **não** quer dizer que contratar outro escritório mudaria a sentença. Para efeito causal, é preciso desenho causal (aulas 16 a 18), não um modelo de previsão.

PARA QUE A EXPLICAÇÃO SERVE

- **Conferir** o modelo: uma variável com peso estranho pode ser vazamento.
- **Contestar** um caso: dá a quem foi afetado algo concreto para discutir.
- **Auditar** grupos: se a variável que mais pesa é um traço protegido, ou um substituto dele (CEP, nome, escola), há um problema.

Justiça algorítmica: o mesmo corte, erros diferentes por grupo



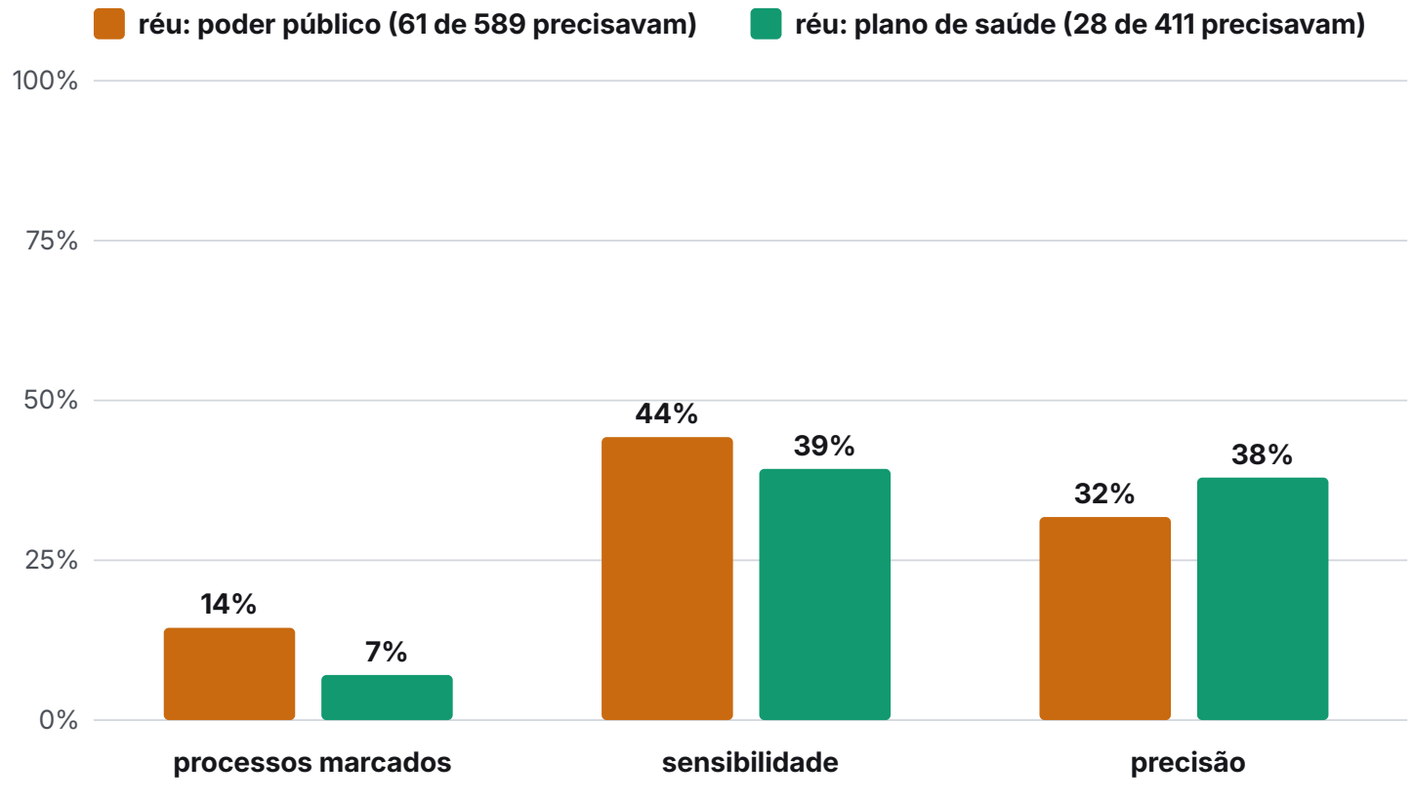
ponto de corte: **0,20**

marcados: **114** de 1.000 (capacidade: 150)

A TRIAGEM DO PROJETO 06

O modelo do NatJus nos 1.000 processos novos, por **réu**: poder público (SUS) ou plano de saúde. No corte da turma (mediana de 0,20), a sensibilidade **muda** de um grupo para o outro.

Critérios de justiça que não cabem juntos



corte, réu poder público: **0,20**

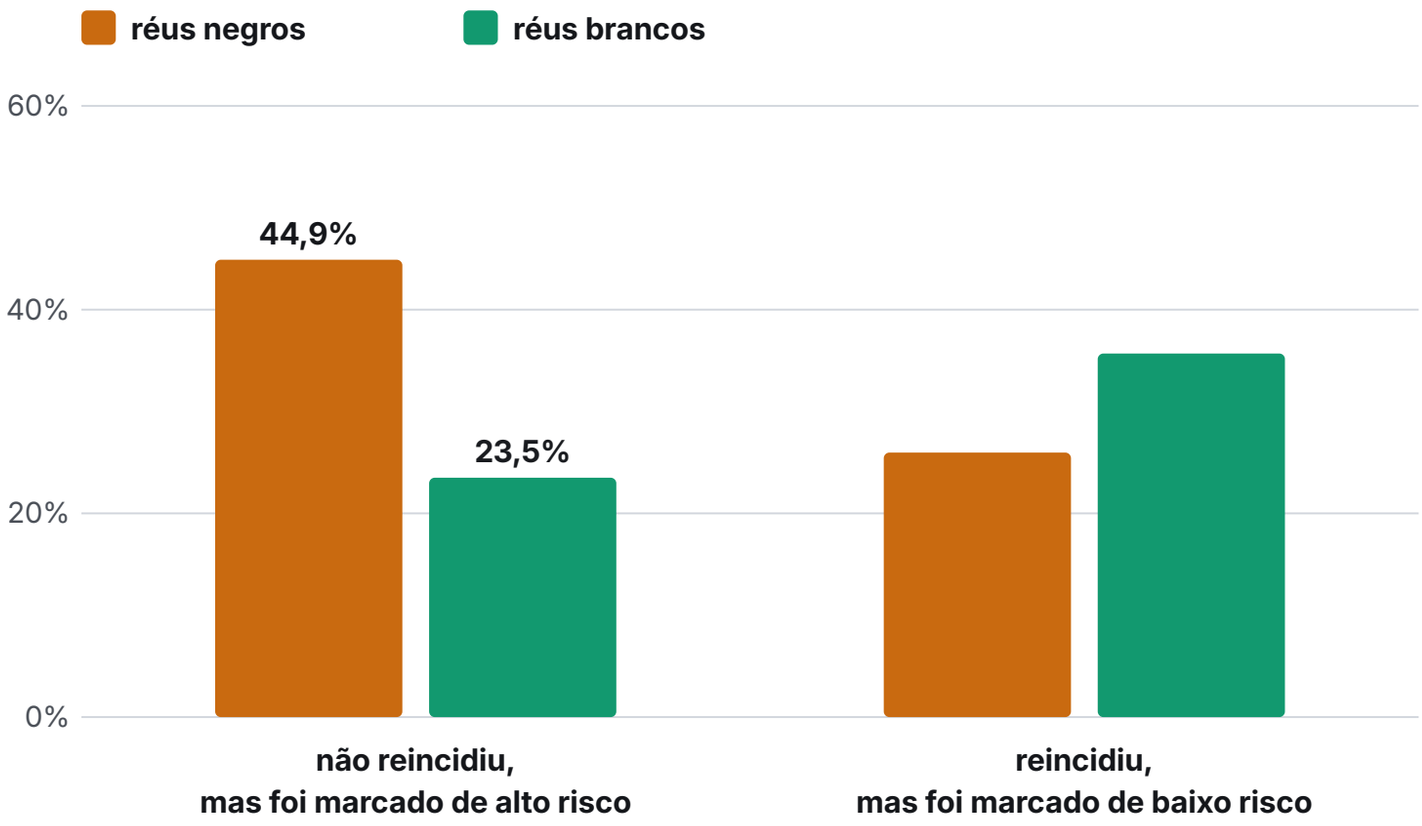
corte, réu plano de saúde: **0,20**

TRÊS CRITÉRIOS, EM LINGUAGEM NATURAL

- **Mesma marcação:** a mesma chance de análise.
- **Mesma sensibilidade:** quem precisa é encontrado na mesma proporção.
- **Mesma precisão:** a marcação vale o mesmo.

Com proporções de casos diferentes, não dá para igualar os três. **Escolher o critério é uma decisão normativa.**

O caso COMPAS: o mesmo modelo, dois diagnósticos



Fonte: ProPublica, Machine Bias (2016).

O QUE ACONTECEU

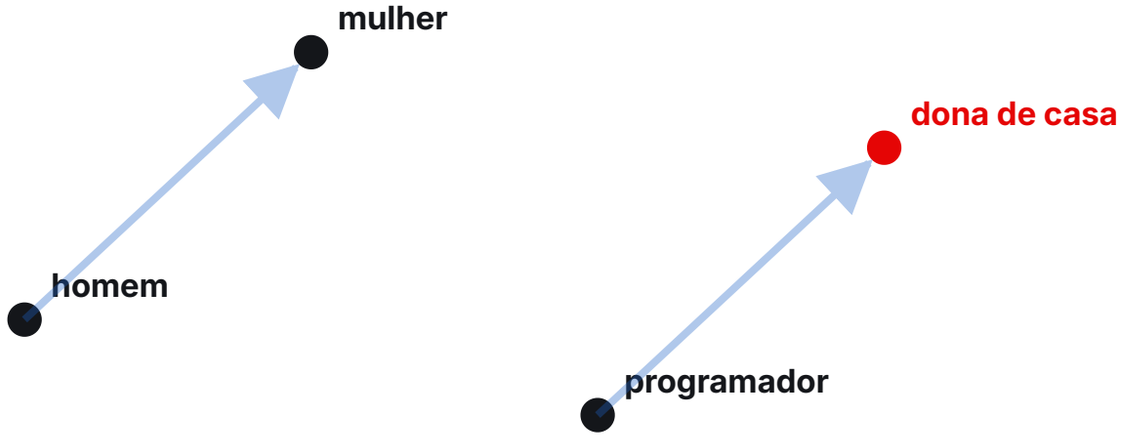
Nota de **risco de reincidência** dada a réus nos EUA, usada em decisões de fiança e pena. A ProPublica analisou cerca de 7 mil réus de um condado da Flórida (2016).

DUAS LEITURAS, OS MESMOS DADOS

- **ProPublica:** entre quem **não** reincidiu, negros foram marcados de alto risco quase **duas vezes** mais.
- **Empresa:** entre os marcados de alto risco, a proporção que reincidiu era **parecida** nos dois grupos.

As duas estavam certas: é o conflito do slide anterior.

Viés em modelos de linguagem



Esquema: os vetores reais têm centenas de dimensões.

O mesmo vale para textos jurídicos: um modelo treinado em **decisões passadas** aprende os padrões delas, **inclusive os injustos**, e os repete em escala.

OUTROS EXEMPLOS DOCUMENTADOS

- Tradução de pronome neutro como “ele é médico” e “ela é enfermeira” (Caliskan e coautores, 2017).
- Jurisprudência **inventada** por chatbot numa peça (Mata v. Avianca, Nova York, 2023).

Decisões automatizadas na LGPD e no Judiciário

LEI 13.709/2018 (LGPD)

- **Art. 20:** direito de pedir **revisão** de decisão tomada **unicamente** por tratamento automatizado que afete seus interesses (perfil, crédito etc.).
- **Art. 20, § 1º:** direito a informação sobre os **critérios e procedimentos**, ressalvados os segredos comercial e industrial.
- **Art. 6º, IX:** princípio da **não discriminação**.
- **Arts. 5º, II, e 11:** regras mais estritas para dados **sensíveis** (origem racial, saúde, religião etc.).

O QUE ISSO PEDE DE UM MODELO

- A revisão “por pessoa natural” foi **vetada** (Lei 13.853/2019): a lei garante a revisão, não que ela seja humana.
- No Judiciário, a **Resolução CNJ 615/2025** (substituiu a 332/2020) exige supervisão humana e classificação de risco das soluções de IA.
- A **cascata** e os **erros por grupo** são as ferramentas para cumprir esses deveres.

Exercício no notebook: explicar e auditar um modelo

NOTEBOOK DA AULA 25 · INDIVIDUAL · O QUE FALTAR FICA PARA CASA

1. Ajustar a floresta e calcular o SHAP.
2. Ler a cascata de um processo.
3. Ler o enxame e comparar com a importância da aula 24.
4. Medir a sensibilidade por grupo na triagem do NatJus.
5. Responder: a explicação basta para o art. 20 da LGPD?

Abrir o notebook no Colab

PARA O PROJETO 08

O SHAP funciona com qualquer modelo do scikit-learn. Rode-o no seu modelo do projeto: se uma variável pesa muito mais do que você esperava, desconfie de **vazamento** antes de comemorar a AUC.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- O **valor de Shapley** reparte uma previsão entre as variáveis, pela média das contribuições em todas as ordens.
- A **cascata** explica um caso; o **enxame**, muitos casos de uma vez.
- A explicação é **do modelo**: não é efeito causal.
- O mesmo modelo pode **errar diferente** entre grupos, e os critérios de justiça não cabem todos juntos.
- A **LGPD** garante revisão e informação sobre os critérios de decisões automatizadas.

PRÓXIMOS PASSOS

- **Quinta, 12/11 (aula 26):** redes neurais e embeddings, com aplicações a textos jurídicos.
- **Sábado, 14/11:** relatório da Pesquisa de Campo.
- **Projeto 08:** até 24/11, 12:00. Meta para esta semana: a primeira submissão acima do baseline.