Interpretabilidade, justiça algorítmica e LGPD

Aula 25 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

10/11/2026

Objetivos de aprendizagem

Ao final da aula, você será capaz de:

1. **explicar** a previsão de um processo com valores de Shapley (SHAP), e por que uma floresta precisa deles;
2. **medir** se um modelo erra de forma diferente entre grupos de pessoas, e explicar por que os critérios de justiça entram em conflito;
3. **discutir** o uso de variáveis como sexo e raça e o que a LGPD exige de decisões automatizadas.

Regressão logística e árvore se leem; a floresta, não

regressão logística

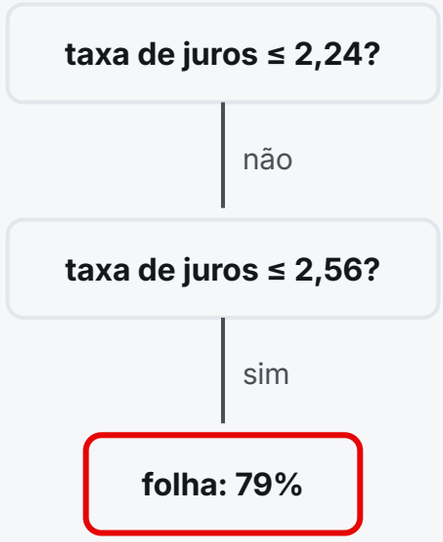
ponto de partida	-8,11
juros: 3,47 × 2,3	+7,98
valor da causa: 0,027 × 30	+0,81



cada variável soma um pedaço fixo

previsão: 66%

árvore de decisão



previsão: 79%

floresta de 300 árvores

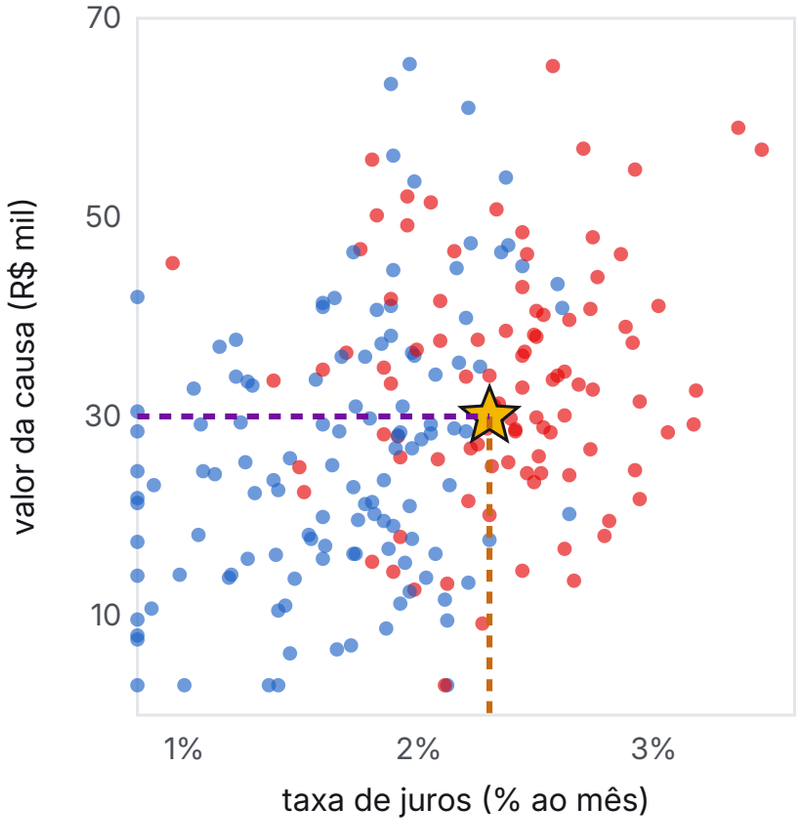


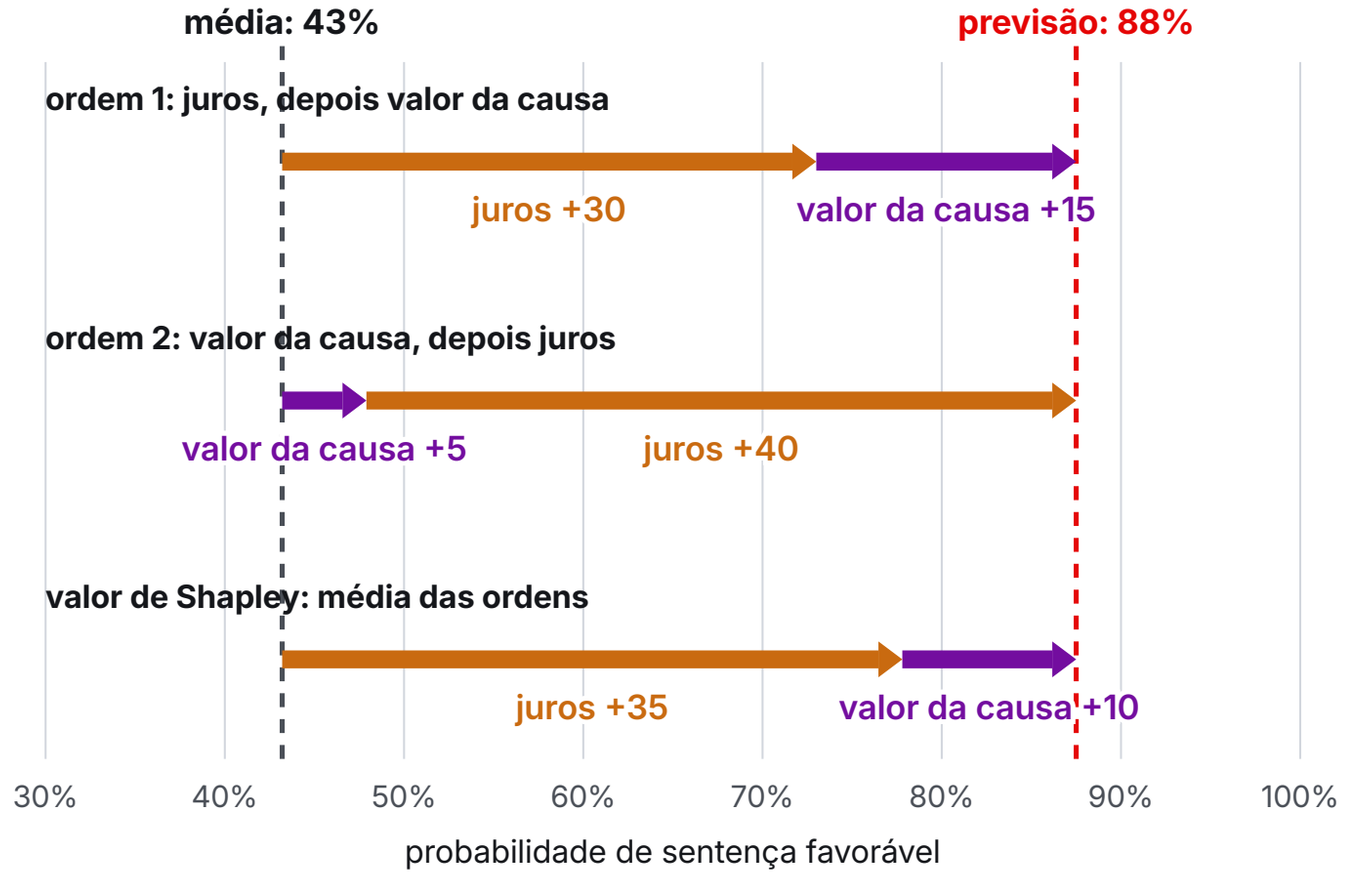
... e mais 260; a previsão é a média

previsão: 88%

Floresta: 300 árvores, cada uma com as suas perguntas, e a previsão é a **média**. Ninguém lê 300 caminhos. Para saber o que pesou, é preciso outra ferramenta: o **SHAP**.

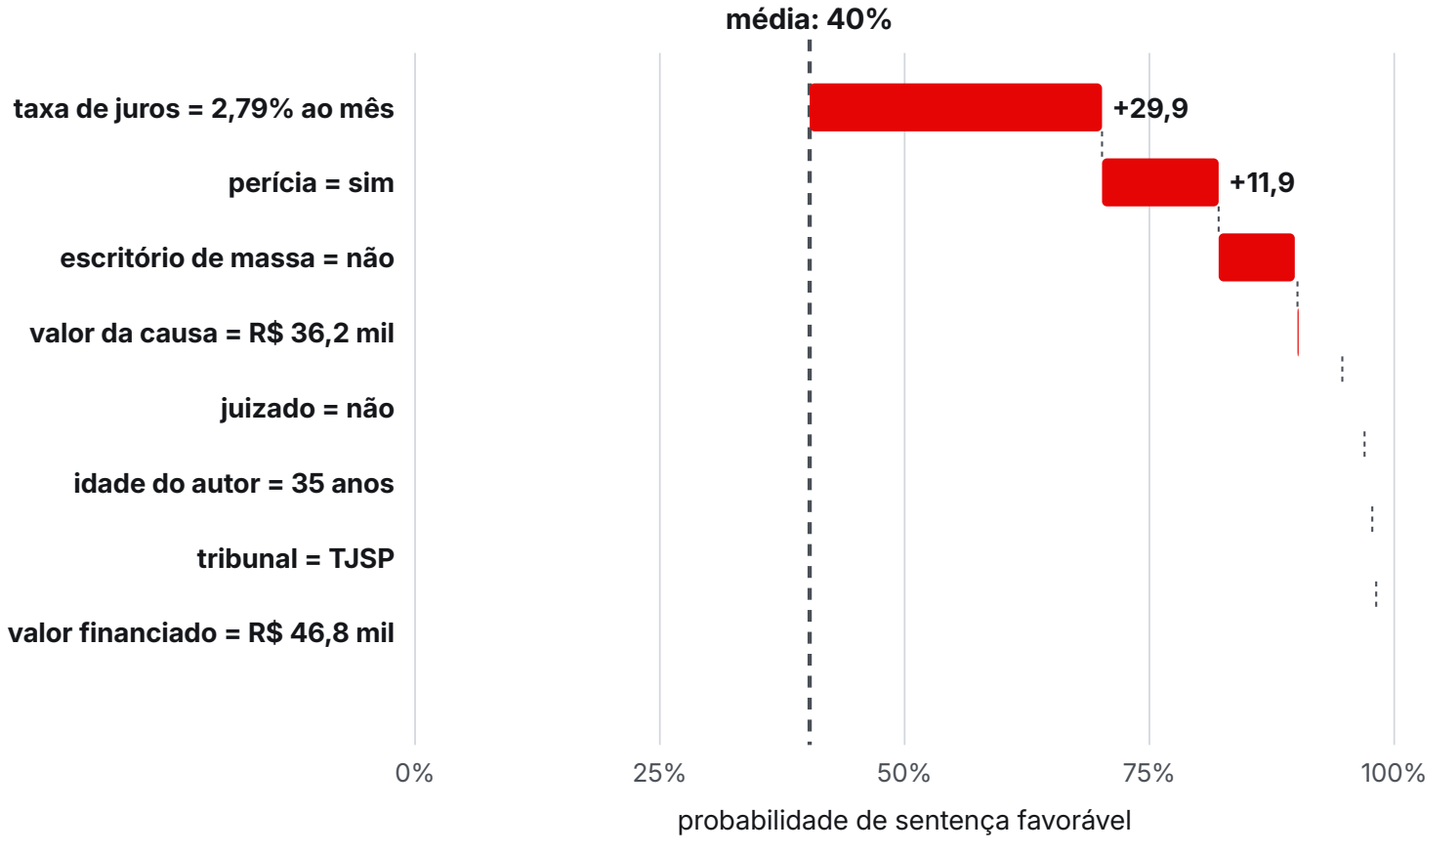
Valor de Shapley: a contribuição de cada variável





Para não depender da ordem, tiro a **média** das duas: juros **+35** e valor da causa **+10**. É o **valor de Shapley**, e a soma fecha: 43 + 35 + 10 = 88. O **SHAP** faz essa conta com todas as variáveis.

Gráfico em cascata: a explicação de um processo

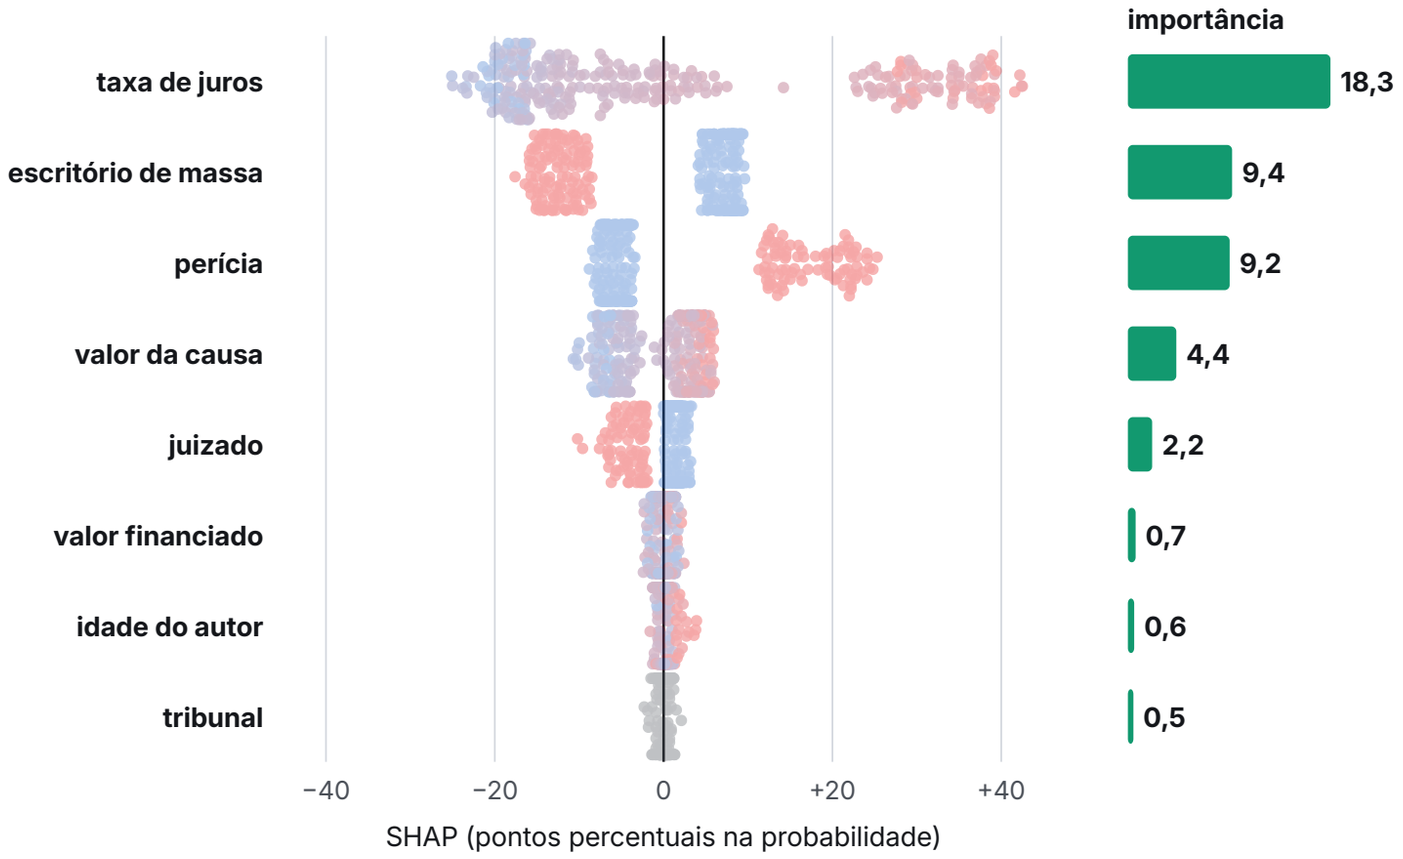


processo A | processo B | processo C

COMO LER A CASCATA

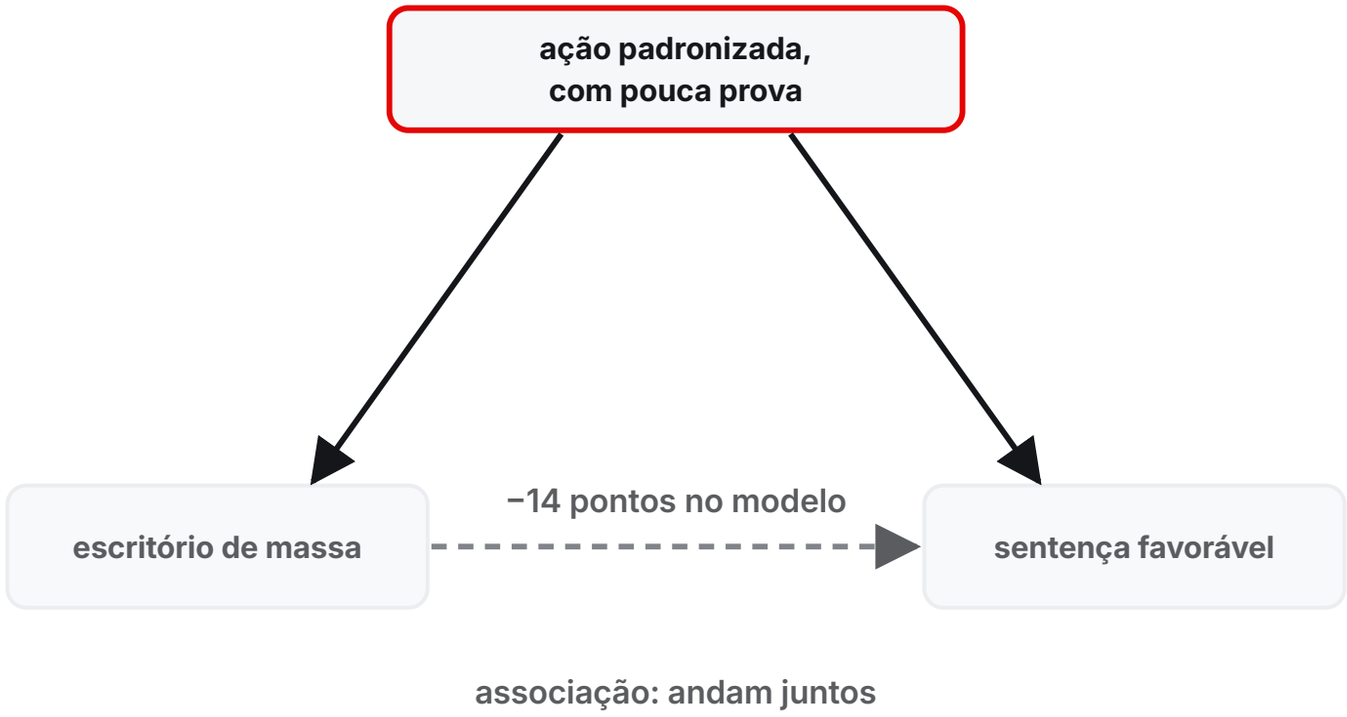
Começa na **média** da floresta (40%) e soma uma variável por vez. Barra **vermelha** empurra para a sentença favorável; **azul**, contra. O fim é a previsão do processo.

Gráfico de enxame: as explicações de muitos processos



A média do tamanho dos pontos (sem o sinal) é a **importância geral**: a mesma ideia da aula 24, agora com o lado para o qual cada variável empurra.

A explicação é do modelo, não do mundo



Para saber o efeito de trocar de escritório, é preciso um **desenho causal** (aulas 16 a 18). O SHAP serve para **conferir** o modelo (uma variável que pesa demais pode ser vazamento), **contestar** um caso e **auditar** grupos.

Justiça algorítmica: o que é e por que importa

RELEMBRANDO O PROJETO 06

O NatJus recebe **1.000 processos de saúde** por mês e consegue fazer **análise aprofundada** em 150. Um modelo dá a cada processo a probabilidade de precisar dessa análise, e o **corte** decide quem recebe.

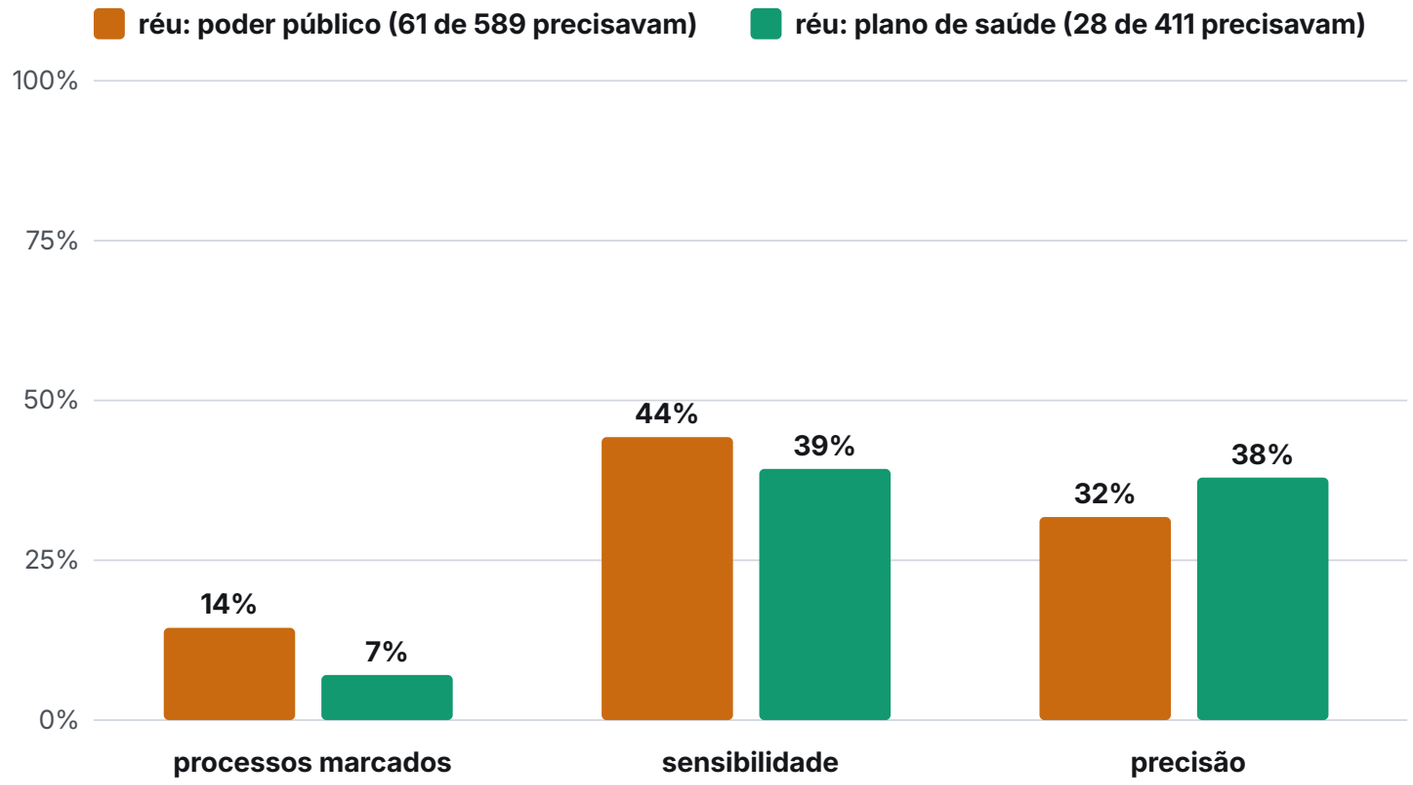
O erro grave é o caso que **precisava** de análise e ficou de fora: um paciente cujo pedido foi decidido sem o parecer de que precisava.

A PERGUNTA DA JUSTIÇA ALGORÍTMICA

Esses erros caem **igualmente** sobre grupos diferentes de pessoas?

Um modelo pode ter boa AUC no geral e, ainda assim, falhar mais com um grupo, **sem usar** nenhuma variável sobre o grupo. Aqui, o grupo é **quem é o réu**: o **poder público**, nos pedidos de pacientes do SUS, ou um **plano de saúde**.

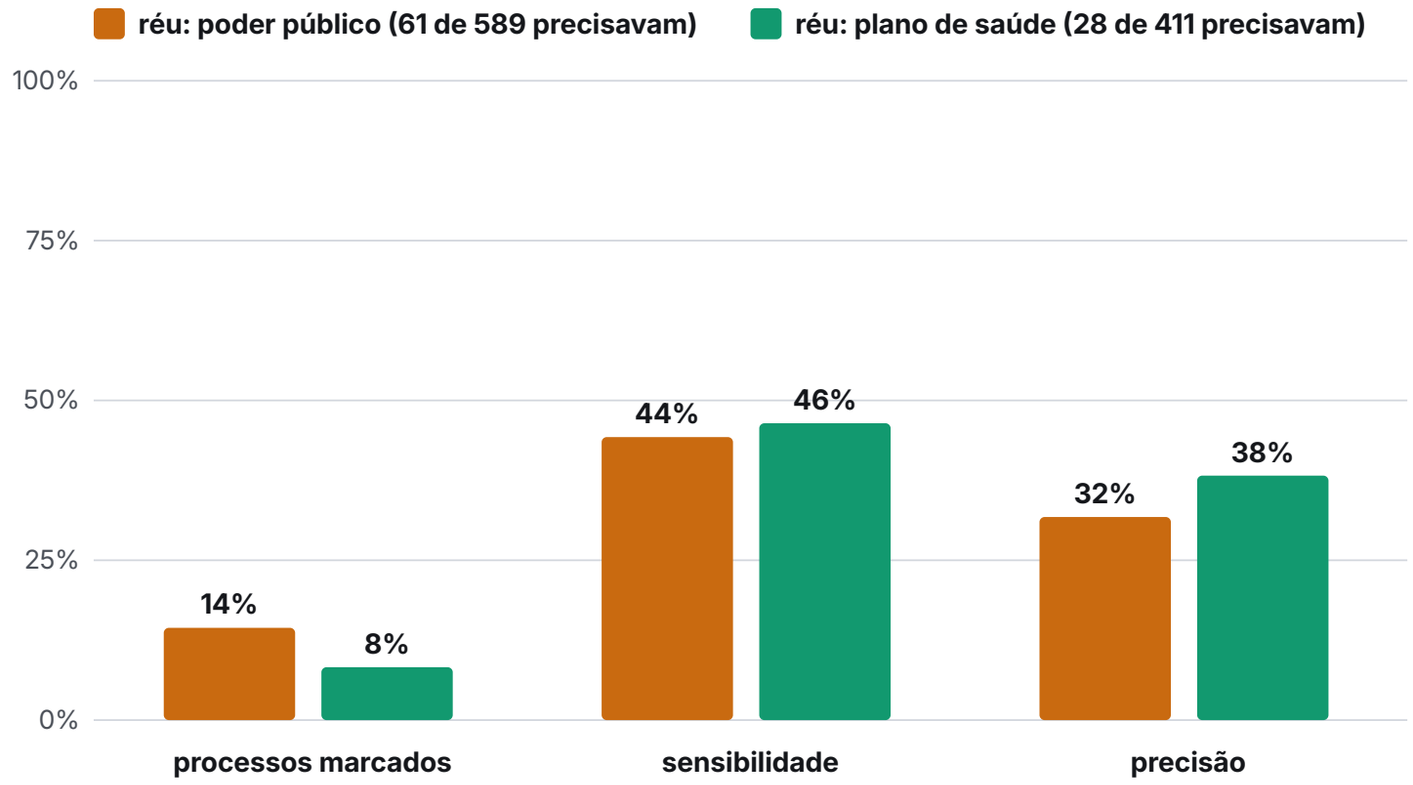
O mesmo corte, erros diferentes por grupo



ponto de corte: **0,20**

Para a turma: e se a sensibilidade fosse **80%** para quem processa o poder público e **50%** para quem processa um plano? Seria aceitável? Arraste o corte.

Critérios de justiça que não cabem juntos

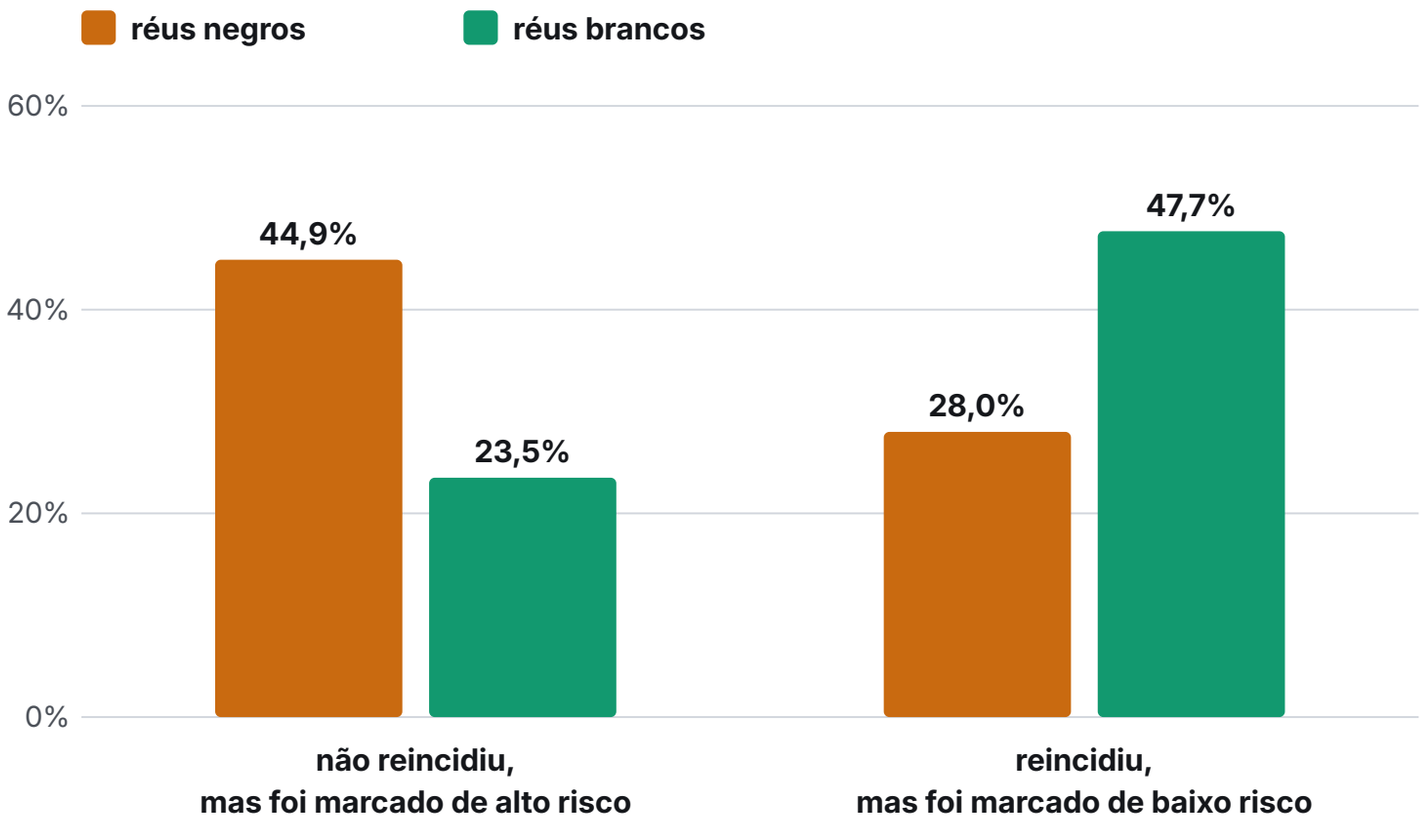


corte, réu poder público: **0,20**

corte, réu plano de saúde: **0,175**

Não existe corte que deixe as três iguais. **Escolher qual igualdade importa é uma decisão normativa**, como a escolha do corte no Projeto 06.

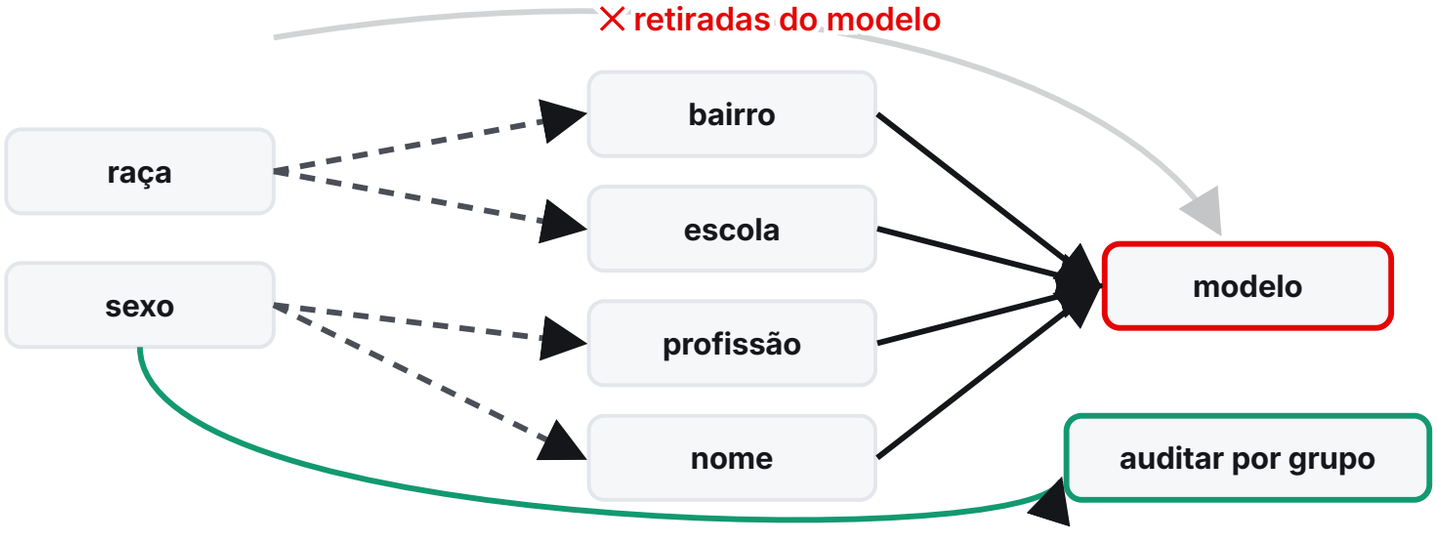
O caso COMPAS: o mesmo modelo, dois diagnósticos



Fonte: ProPublica, Machine Bias (2016).

A empresa respondeu: entre os marcados como alto risco, cerca de **6 em cada 10** reincidiram, nos **dois** grupos, então a nota significa o mesmo para todos. As duas análises estão certas: é o conflito do slide anterior.

Sexo, raça e as variáveis que fazem as vezes delas



E sem a variável não dá para **auditar**: para medir a sensibilidade por grupo, como nos slides anteriores, é preciso saber o grupo de cada pessoa.

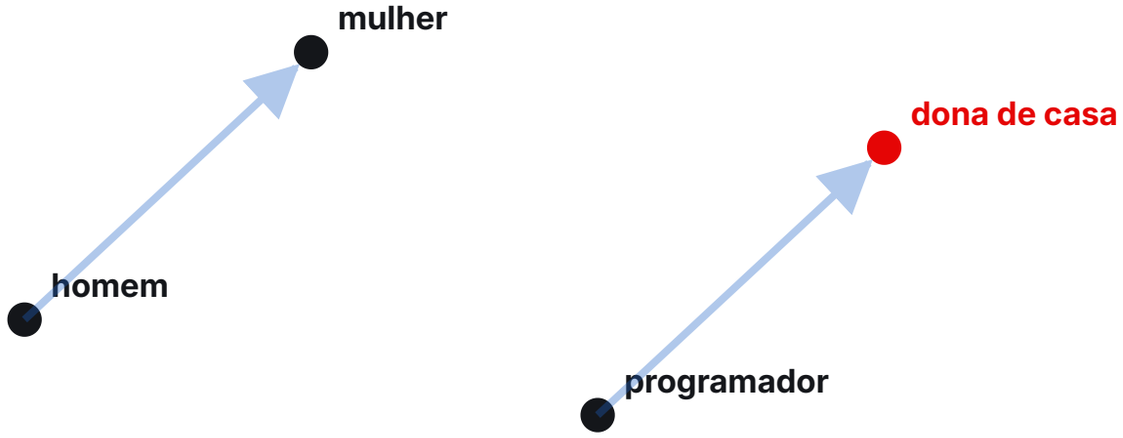
PARA DEBATER

Um tribunal quer um modelo de risco para as **audiências de custódia**. Ele pode usar **raça**? E o **bairro**? E o **sexo**, se na base os homens reincidem mais?

BASE NORMATIVA

Constituição, arts. 3º, IV, e 5º, I. Na LGPD, origem racial é **dado sensível** (art. 5º, II); sexo não está na lista, mas vale a **não discriminação** (art. 6º, IX).

Viés em modelos de linguagem



Esquema: os vetores reais têm centenas de dimensões.

O mesmo vale para textos jurídicos: um modelo treinado em **decisões passadas** aprende os padrões delas, **inclusive os injustos**, e os repete em escala.

OUTROS EXEMPLOS DOCUMENTADOS

- Tradução de pronome neutro como “ele é médico” e “ela é enfermeira” (Caliskan e coautores, 2017).
- Jurisprudência **inventada** por chatbot numa peça (Mata v. Avianca, Nova York, 2023).

Decisões automatizadas na LGPD e no Judiciário

O QUE A LEI GARANTE

- **LGPD, art. 20:** pedir **revisão** de decisão tomada **unicamente** por tratamento automatizado que afete seus interesses (perfil, crédito etc.).
- **Art. 20, § 1º:** saber os **critérios e procedimentos**, ressalvados os segredos comercial e industrial; pelo **§ 2º**, a ANPD pode fazer auditoria.
- A revisão "por pessoa natural" foi **vetada** (Lei 13.853/2019).
- No Judiciário, a **Resolução CNJ 615/2025** exige supervisão humana e classificação de risco das soluções de IA.

EXEMPLO: O SCORE DE CRÉDITO

Um banco nega um empréstimo com base num **score** calculado por um modelo.

- O STJ (**Súmula 550**) admite o score sem consentimento, mas o consumidor pode pedir esclarecimentos sobre os dados pessoais usados e as fontes.
- Pela LGPD, ele pode pedir **revisão** e saber os **critérios**. O banco alega segredo comercial.
- Uma **cascata** do caso dele e a **auditoria por grupo** são formas de explicar sem abrir o código.

Exercício no notebook: explicar e auditar um modelo

NOTEBOOK DA AULA 25 · INDIVIDUAL · O QUE FALTAR FICA PARA CASA

1. Ajustar a floresta e calcular o SHAP.
2. Ler a cascata de um processo.
3. Ler o enxame e comparar com a importância da aula 24.
4. Medir a sensibilidade por grupo na triagem do NatJus.
5. Responder: a explicação basta para o art. 20 da LGPD?

Abrir o notebook no Colab

PARA O PROJETO 08

O SHAP funciona com qualquer modelo do scikit-learn. Rode-o no seu modelo do projeto: se uma variável pesa muito mais do que você esperava, desconfie de **vazamento** antes de comemorar a AUC.

Resumo da aula e próxima aula

PONTOS PRINCIPAIS DA AULA

- A logística e a árvore se leem; a floresta precisa do **SHAP**, que reparte a previsão entre as variáveis.
- A **cascata** explica um caso; o **enxame**, muitos casos. A explicação é do modelo: **não é efeito causal**.
- O mesmo modelo pode **errar diferente** entre grupos, e os critérios de justiça não cabem todos juntos.
- Tirar sexo e raça **não basta**: outras variáveis fazem as vezes delas.
- A **LGPD** garante revisão e informação sobre os critérios.

PRÓXIMOS PASSOS

- **Quinta, 12/11 (aula 26):** redes neurais e embeddings, com aplicações a textos jurídicos.
- **Sábado, 14/11:** relatório da Pesquisa de Campo.
- **Projeto 08:** até 24/11, 12:00. Meta para esta semana: a primeira submissão acima do baseline.

Para consultar depois

INTERPRETABILIDADE

- Interpretable Machine Learning, de Christoph Molnar: livro gratuito, com SHAP explicado sem fórmulas.
- Documentação do SHAP: exemplos de cascata e enxame com o scikit-learn.

JUSTIÇA ALGORÍTMICA

- Machine Bias, a reportagem da ProPublica sobre o COMPAS (2016).
- Fairness and Machine Learning, de Barocas, Hardt e Narayanan: livro gratuito sobre os critérios e os seus conflitos.

NORMAS

- LGPD, Lei 13.709/2018, no Planalto.
- Resolução CNJ 615/2025, sobre IA no Judiciário.