Redes neurais e embeddings

Aula 26 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

12/11/2026

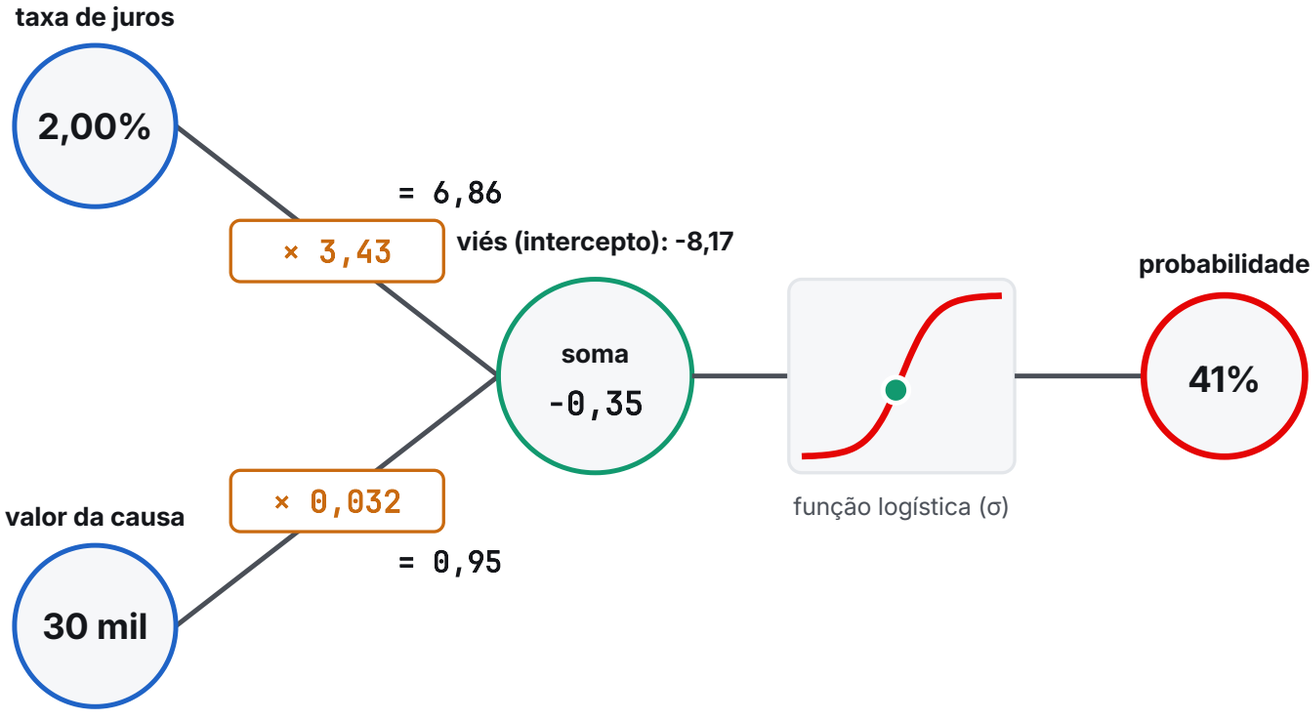
Objetivos de aprendizagem

Ao final da aula, você será capaz de:

1. **explicar** como um neurônio refaz a conta da regressão logística, e como camadas de neurônios aprendem formas que uma reta não aprende;
2. **descrever** o treino de uma rede: passo para frente, erro, gradientes e atualização dos pesos;
3. **explicar** o que é um embedding e como ele transforma um texto em números comparáveis;
4. **usar** embeddings para buscar e comparar ementas, reconhecendo os seus limites e vieses.

Da regressão logística a um neurônio

```
P(favorável) = σ( -8,17 + 3,43 × juros + 0,032 × valor da causa )
```

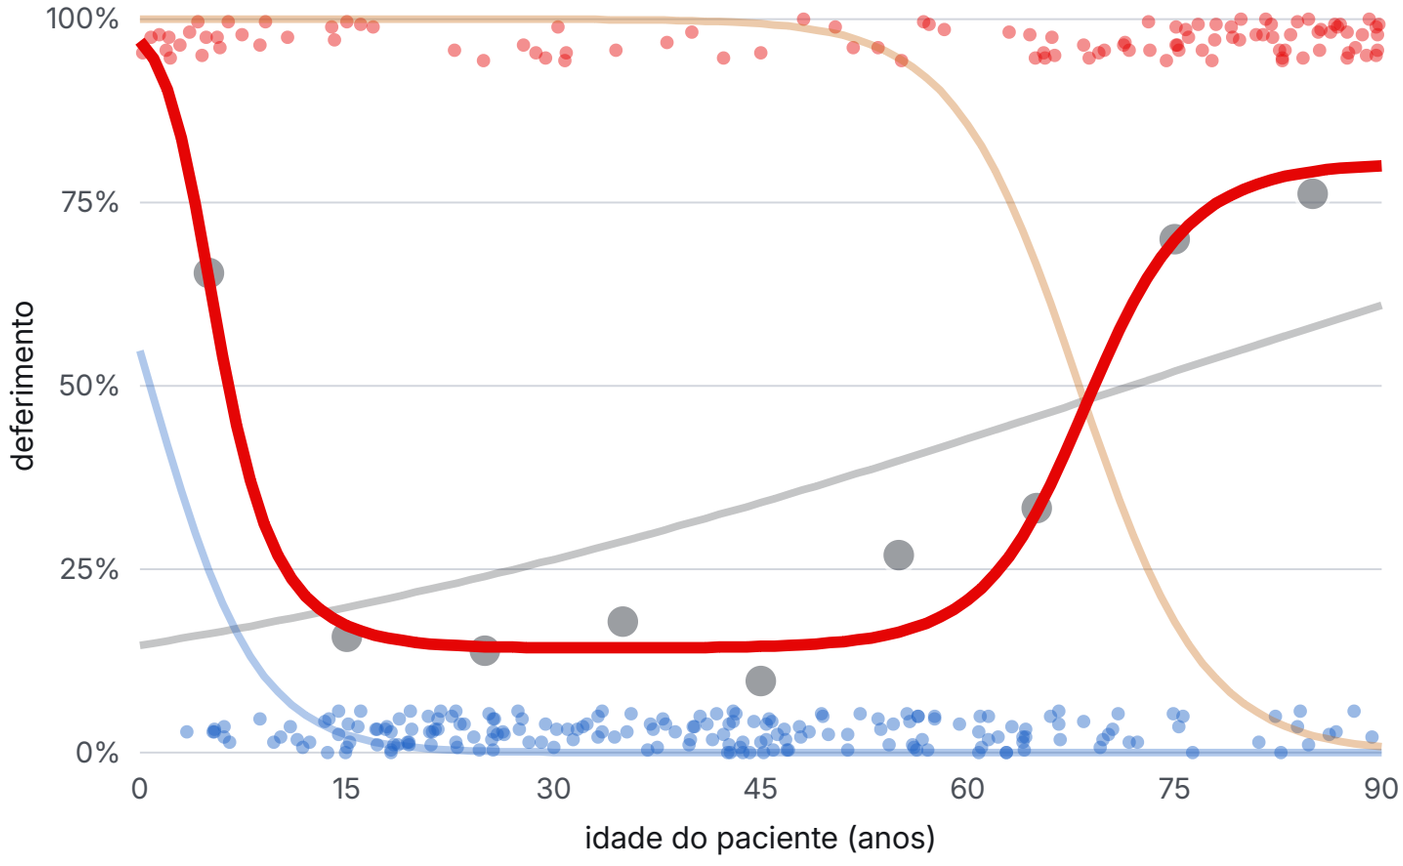


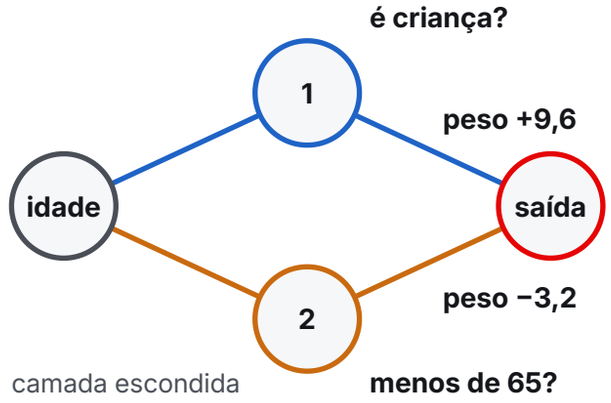
taxa de juros: **2,00% ao mês**

valor da causa: **R$ 30 mil**

A **função logística** transforma a soma numa probabilidade. Isso é **um neurônio**: a mesma regressão logística, desenhada como rede. Mexa nos controles.

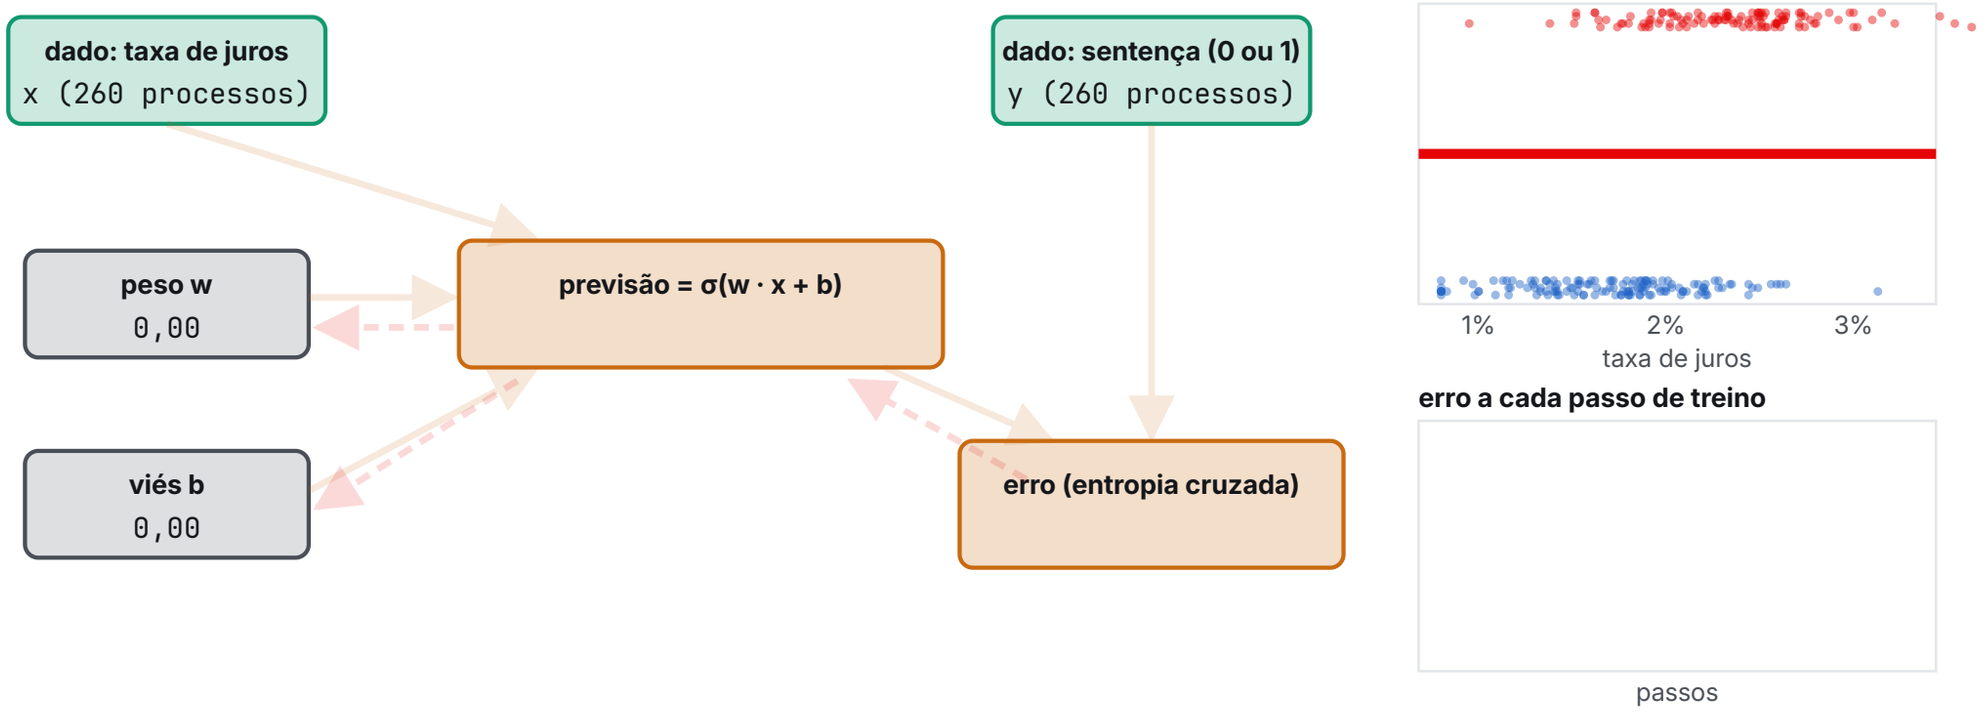
Com uma camada escondida, a rede aprende que crianças e idosos têm mais liminares





O **neurônio de saída** combina os dois: alto se é criança, alto se já passou dos 65. É o U. Ninguém disse à rede onde estavam as faixas de idade: ela as achou nos dados.

O treino da rede, passo a passo



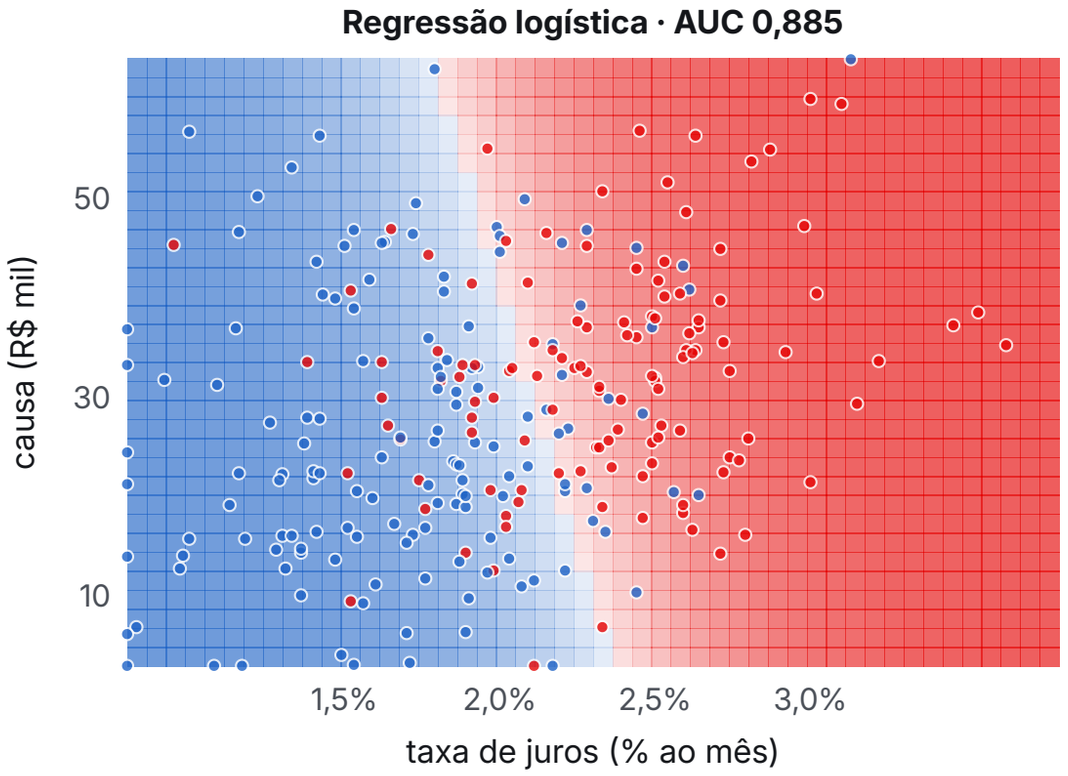
próximo passo | treinar sozinho | recomeçar

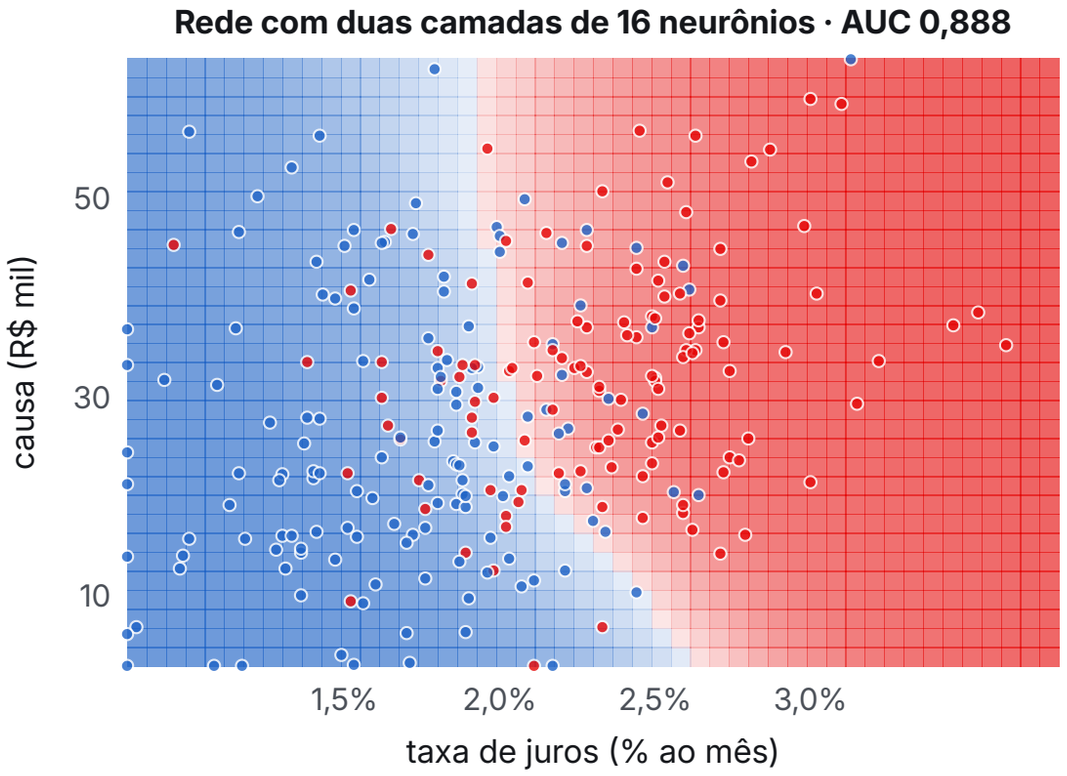
Os pesos começam em zero: a previsão é 50% para todo processo.

DO NEURÔNIO À REDE

Verde: **dados**; cinza: **pesos**; laranja: **contas**. Numa rede com várias camadas, o passo para trás atravessa todas elas, do erro até os primeiros pesos: é a **retropropagação** (*backpropagation*).

Rede e regressão logística empatam em juros e causa





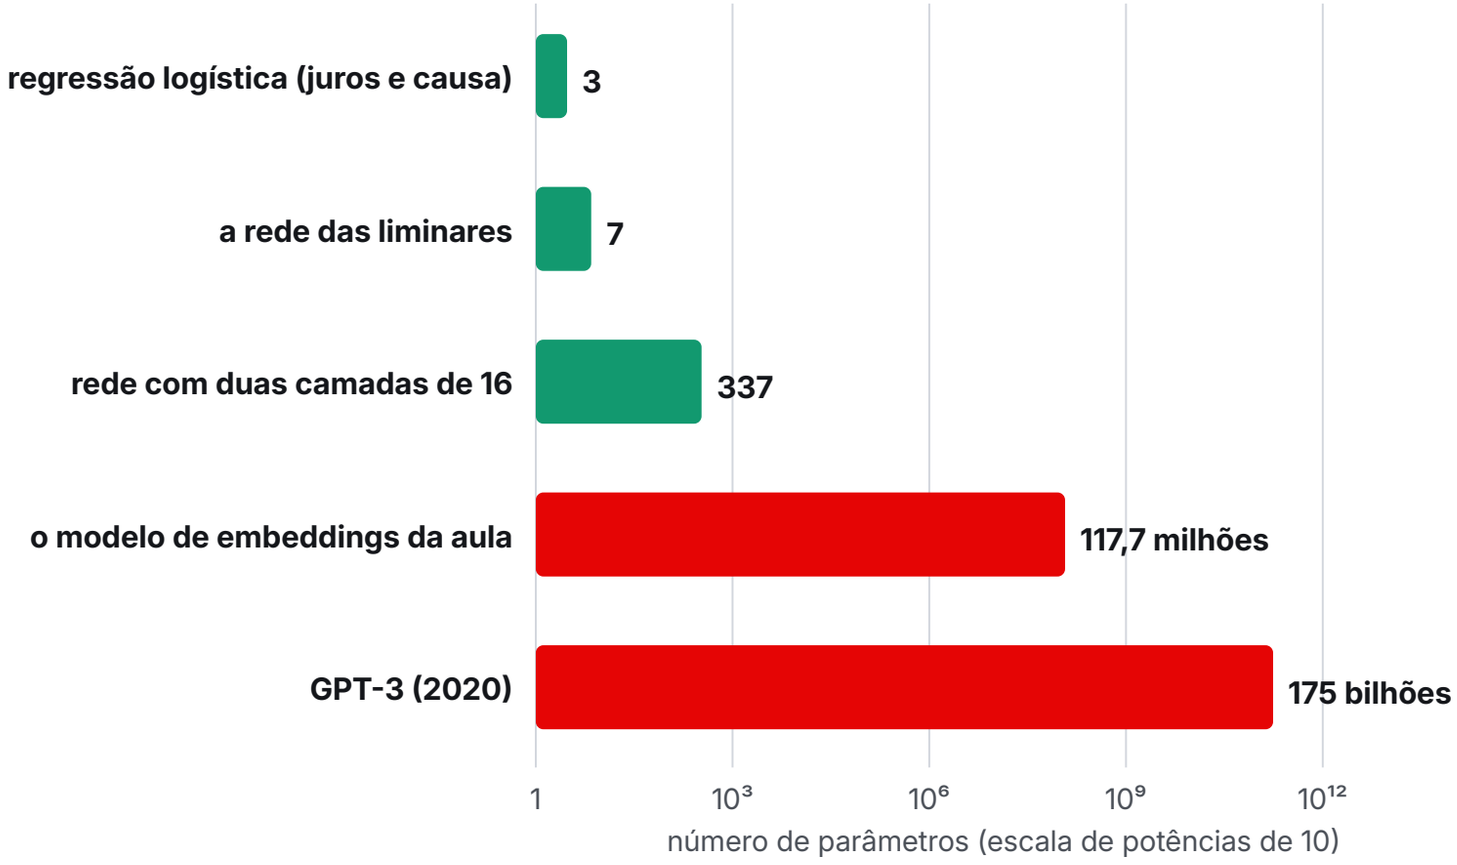
COMO LER OS MAPAS

A probabilidade de sentença favorável em cada ponto: **vermelho** acima de 50%, **azul** abaixo. AUC na validação cruzada: logística **0,885**, rede com duas camadas de 16 neurônios **0,888**.

QUANDO A REDE VALE A PENA

Em tabelas com poucas colunas, a rede raramente ganha de uma logística ou de uma floresta, e é mais difícil de explicar. Ela brilha em **texto, imagem e som**, com muitos dados.

O tamanho dos modelos, em número de parâmetros



APRENDIZADO PROFUNDO

Redes com **muitas camadas**: cada camada transforma a saída da anterior. Um **parâmetro** é um peso ajustado no treino. A escala do gráfico é de potências de 10: cada marca é **dez vezes** a anterior.

MODELOS DE LINGUAGEM

O ChatGPT e parecidos são redes desse tamanho, treinadas para **prever a próxima palavra** em quantidades enormes de texto.

Texto vira número: cada palavra recebe um código

o	réu	pagou	a	dívida
1	2	3	4	5

o	réu	quitou	a	dívida
1	2	6	4	5

o	autor	pagou	a	multa
1	7	3	4	8

vocabulário

1	o
2	réu
3	pagou
4	a
5	dívida
6	quitou
7	autor
8	multa

pagou (3) e quitou (6): longe, mas querem dizer o mesmo



> **O problema:** o número é só um código. “Pagou” é 3 e “quitou” é 6, mas querem dizer quase o mesmo; e a conta 3 + 3 = 6 não tem sentido nenhum.

One-hot e embedding: de códigos a vetores com significado

one-hot: uma coluna por palavra do vocabulário

pagou	quitou	multa
0	0	0
0	0	0
1	0	0
0	0	0
0	0	0
0	1	0
0	0	0
0	0	1

todas a mesma distância umas das outras

embedding: cada palavra, uma linha de números aprendidos

	d1	d2	d3
o	0,1	0,0	0,2
réu	0,7	0,1	-0,3
pagou	-0,5	0,8	0,4
a	0,0	0,1	0,1
dívida	-0,2	0,6	0,9
quitou	-0,4	0,9	0,3
autor	0,8	0,0	-0,2
multa	-0,1	0,5	-0,8

números ilustrativos; nos modelos reais, centenas por palavra

"o réu pagou a dívida"

média das linhas das palavras:

0,02 **0,32** **0,26**

um texto vira um vetor;
textos parecidos, vetores parecidos

> Para um texto inteiro, um jeito simples é a **média** das linhas das suas palavras. O texto vira um vetor, e textos parecidos ficam perto.

Nos modelos atuais: pedaços de palavras e um vetor de 384 números

"O plano de saúde negou a cobertura do home care para a paciente idosa."

`O` `plano` `de` `saúde` `nego` `u` `a` `cobertura` `do` `home` `care` `para` `a` `paciente` `idos` `a` `.`

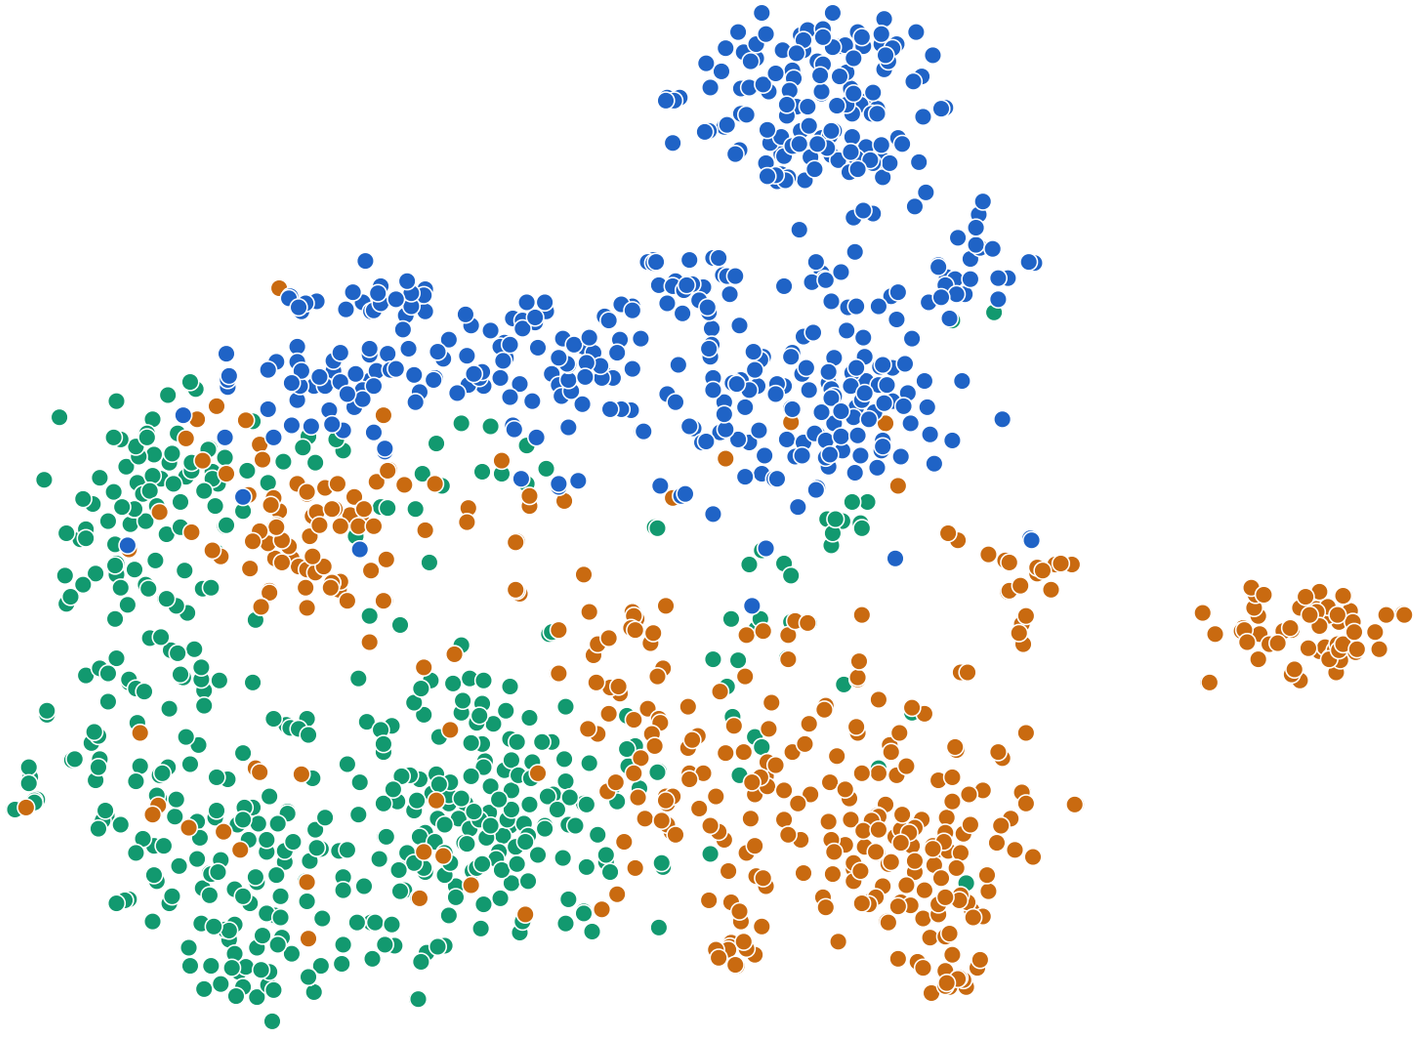
384 números: -0,027; 0,103; -0,051; 0,025; ...

um texto, um ponto



O modelo foi treinado com pares de frases de **mesmo sentido**, para que elas ganhem números parecidos. Por isso cada texto vira um ponto, e textos parecidos ficam perto.

Mapa de 1.423 ementas do TJSP: perto quer dizer parecido



Das cinco vizinhas de cada ementa, **86%** são do mesmo tema. **Clique em um ponto** para ler a ementa e ver as cinco mais parecidas.

Busca por palavra e busca por significado

"a companhia deixou o passageiro em terra e ele perdeu o casamento"

"o convênio não quis pagar o remédio do câncer"

"o banco sujou meu nome por uma conta que eu já tinha pago"

"pegou as coisas da loja e saiu sem pagar"

"vendia droga na esquina perto da escola"

Por palavra: conta as palavras em comum

Atraso de vôo 0,17
APELAÇÃO CÍVEL – Direito Privado – Transporte aéreo internacional – Atraso de voo – Ação de indenização por danos morais – Sentença de improcedência....

Cancelamento de vôo 0,11
APELAÇÃO CÍVEL – Direito Privado – Transporte aéreo nacional – Cancelamento de voo – Ação de indenização por danos morais – Sentença de...

Atraso de vôo 0,11
APELAÇÃO CÍVEL – Direito Privado – Transporte aéreo nacional – Atraso de voo – Ação de indenização por danos morais – Sentença de improcedência. I....

Atraso de vôo 0,10
APELAÇÃO CÍVEL – Direito Privado – Transporte aéreo nacional – Atraso de voo – Ação de indenização por danos morais – Sentença de improcedência. I....

Por significado: compara os embeddings

Bancários 0,43
Apelação Cível. Ação declaratória de inexistência de débito e indenização por danos materiais e morais. Sentença de parcial procedência....

Transporte de Pessoas 0,39
Ação de rescisão contratual e indenização por danos materiais e morais – Transporte interestadual de passageiros – Autor pessoa com deficiência...

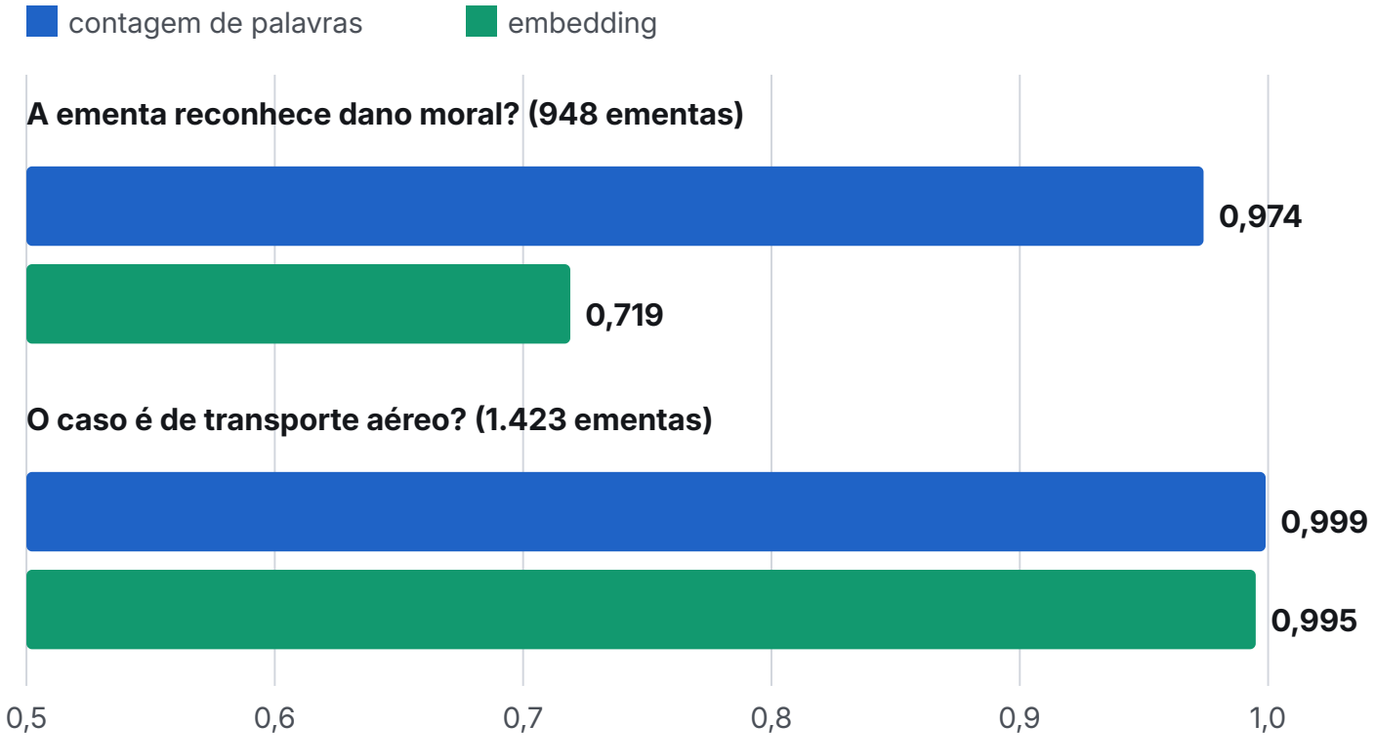
Acidente de Trânsito 0,38
APELAÇÃO CÍVEL. ACIDENTE DE TRÂNSITO. Preliminar. Ilegitimidade passiva da requerida Raquel. Provas que indicam que o veículo foi vendido ao condutor...

Cancelamento de vôo 0,38
AÇÃO INDENIZATÓRIA – TRANSPORTE AÉREO NACIONAL – Sentença de parcial procedência, com condenação solidária das rés – APELAÇÃO DA CORRÉ TAM –...

PERGUNTA PARA A TURMA

Clique nas cinco consultas. Em quais a busca por significado foi melhor, e em quais a busca por palavra bastou? O que as consultas têm de diferente?

Classificar ementas: contar palavras ou usar o embedding



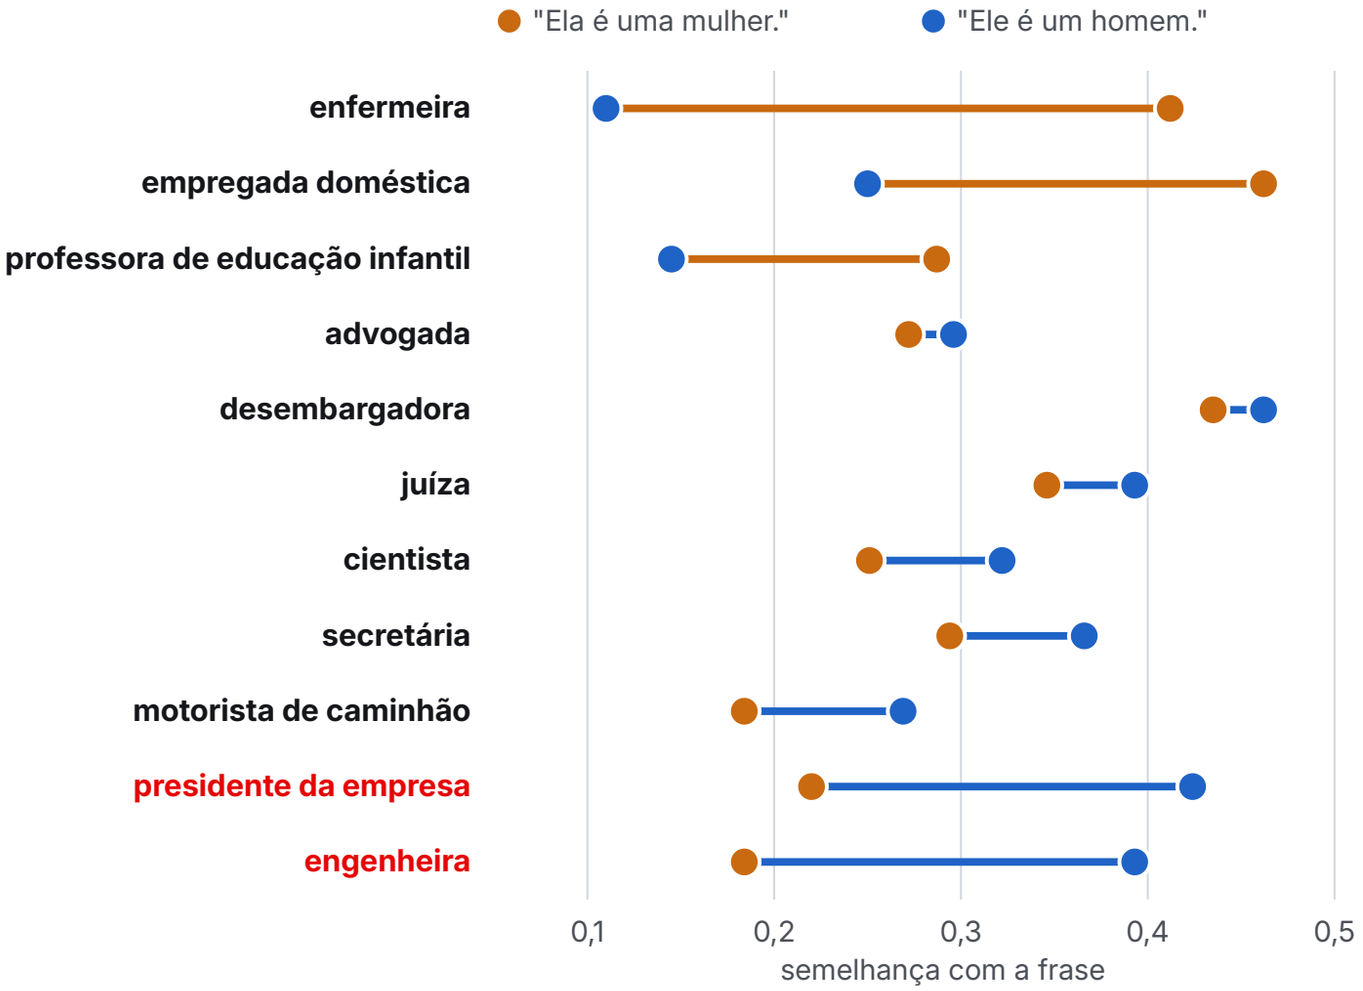
COMO LER O GRÁFICO

Regressão logística com cada representação, AUC na validação cruzada. A resposta costuma estar **escrita com as mesmas palavras** na ementa (“danos morais”, “transporte aéreo”): contar palavras resolve.

EMBEDDING NÃO É MÁGICA

O embedding resume o **assunto** do texto, e perde detalhes. Ele vale mais quando as palavras mudam e o sentido fica, como na busca.

Viés nos embeddings: profissões no feminino



COMO FOI MEDIDO

Frases como “Essa pessoa é engenheira.” comparadas com “Ela é uma mulher.” e “Ele é um homem.”, no mesmo modelo da aula. Quanto mais à direita, mais parecidas.

O QUE O MODELO APRENDEU

Mesmo com a palavra no feminino, **engenheira** e **presidente da empresa** ficam mais perto de “homem”. O modelo repete os padrões dos textos em que foi treinado: o tema da aula 25, agora dentro do vetor.

Aplicações de embeddings no Direito

Busca de jurisprudência

Achar decisões parecidas com o caso, mesmo escritas com outras palavras.

Demandas repetitivas

Agrupar petições quase iguais, para julgar em bloco ou identificar temas de massa.

Triagem de processos

Classificar petições por assunto e encaminhar para a vara ou a equipe certa.

Litigância predatória

Encontrar petições padronizadas, com o mesmo texto e autores diferentes.

Busca com modelo de linguagem

O sistema acha os trechos mais parecidos com a pergunta, e o modelo de linguagem responde só com eles, citando a fonte.

Cuidados

Dados pessoais e sigilo (LGPD), vieses do modelo, e conferir sempre a fonte original.

Exercício no notebook: busca e classificação com embeddings

NOTEBOOK DA AULA 26 · INDIVIDUAL · ATÉ 14:00

As 1.423 ementas do mapa.

1. Ementas em números: palavras e embeddings.
2. Semelhança entre duas ementas.
3. A sua busca por significado.
4. O mapa das ementas.
5. Classificar e comparar.
6. Medir um viés do modelo.

Abrir o notebook no Colab

ANTES DE COMEÇAR

A primeira célula instala o pacote e baixa o modelo (cerca de 470 MB): rode logo ao abrir. Gerar os embeddings das 1.423 ementas leva cerca de um minuto no Colab.

Resumo da aula e próximas aulas

PONTOS PRINCIPAIS DA AULA

- Um **neurônio** faz a conta da regressão logística; **camadas escondidas** fazem formas que uma reta não faz.
- **Treinar** é repetir: passo para frente, erro, gradientes (retropropagação) e atualização dos pesos.
- Em tabelas pequenas, a rede **não costuma ganhar** de modelos simples.
- Um **embedding** transforma um texto em números: textos parecidos ficam perto.
- Embeddings servem para **buscar e agrupar**, e carregam os **vieses** dos textos de treino.

PRÓXIMOS PASSOS

- **14/11:** relatório da Pesquisa de Campo.
- **17 e 19/11:** debates da Pesquisa de Campo.
- **24/11, 12:00:** fim do Projeto 08, com o ranking em aula.