Redes neurais e embeddings

Aula 26 · Ciência de Dados Aplicada ao Direito II

Julio Trecenti

12/11/2026

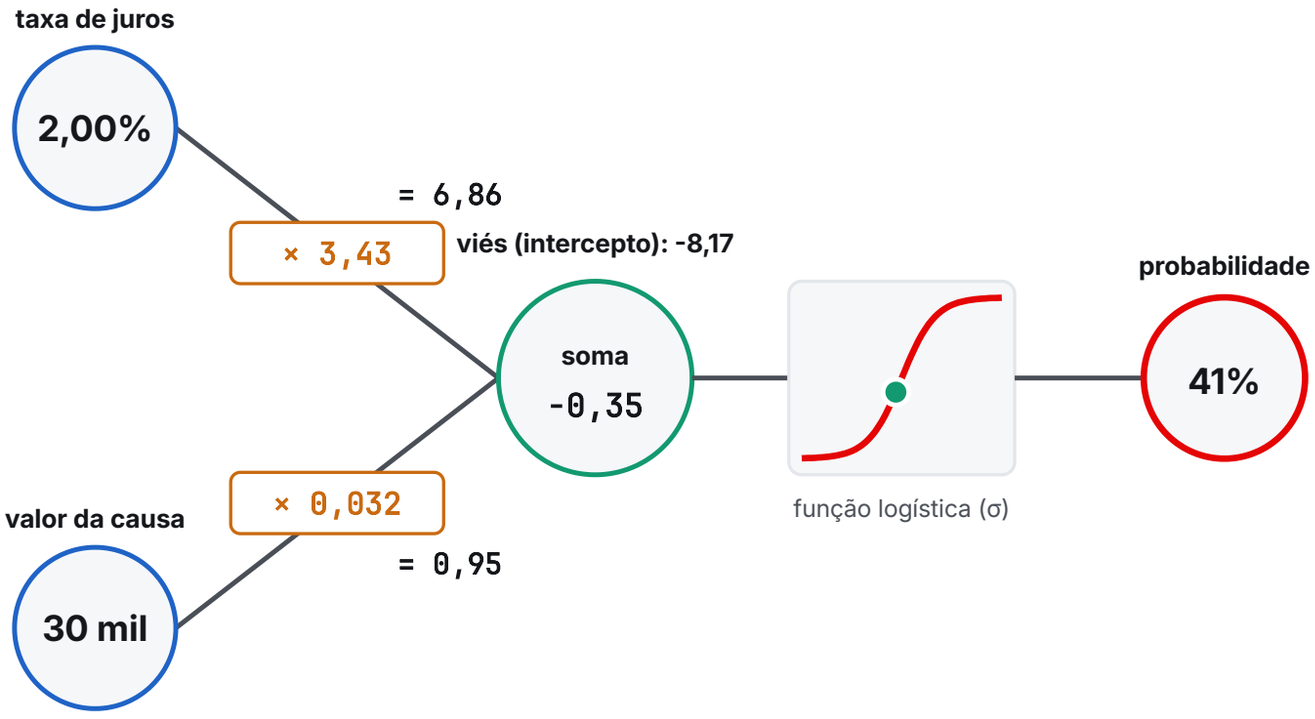
Objetivos de aprendizagem

Ao final da aula, você será capaz de:

1. **explicar** como um neurônio refaz a conta da regressão logística, e como camadas de neurônios aprendem formas que uma reta não aprende;
2. **descrever** o treino de uma rede: passo para frente, erro, gradientes e atualização dos pesos;
3. **explicar** o que é um embedding e como ele transforma um texto em números comparáveis;
4. **usar** embeddings para buscar textos e como **variáveis** de um modelo de previsão, reconhecendo os seus limites e vieses.

Da regressão logística a um neurônio

$$p = \sigma(-8{,}17 + 3{,}43 \times \text{juros} + 0{,}032 \times \text{valor da causa})$$

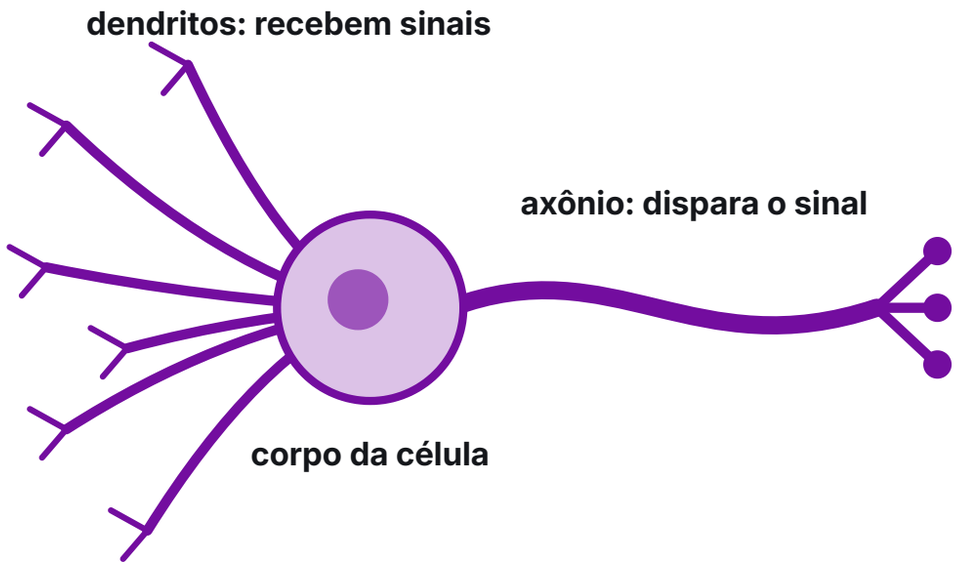


taxa de juros: **2,00% ao mês**

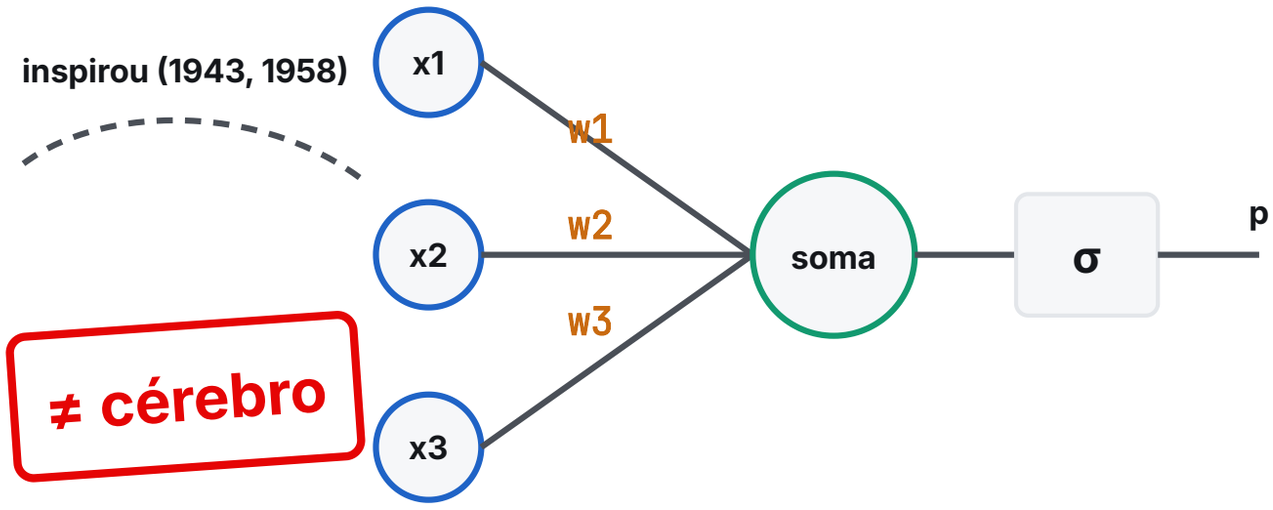
valor da causa: **R$ 30 mil**

A **função logística** transforma a soma numa probabilidade. Isso é **um neurônio**: a mesma regressão logística, desenhada como rede. Mexa nos controles.

Por que “neurônio”? Uma inspiração, não uma cópia do cérebro



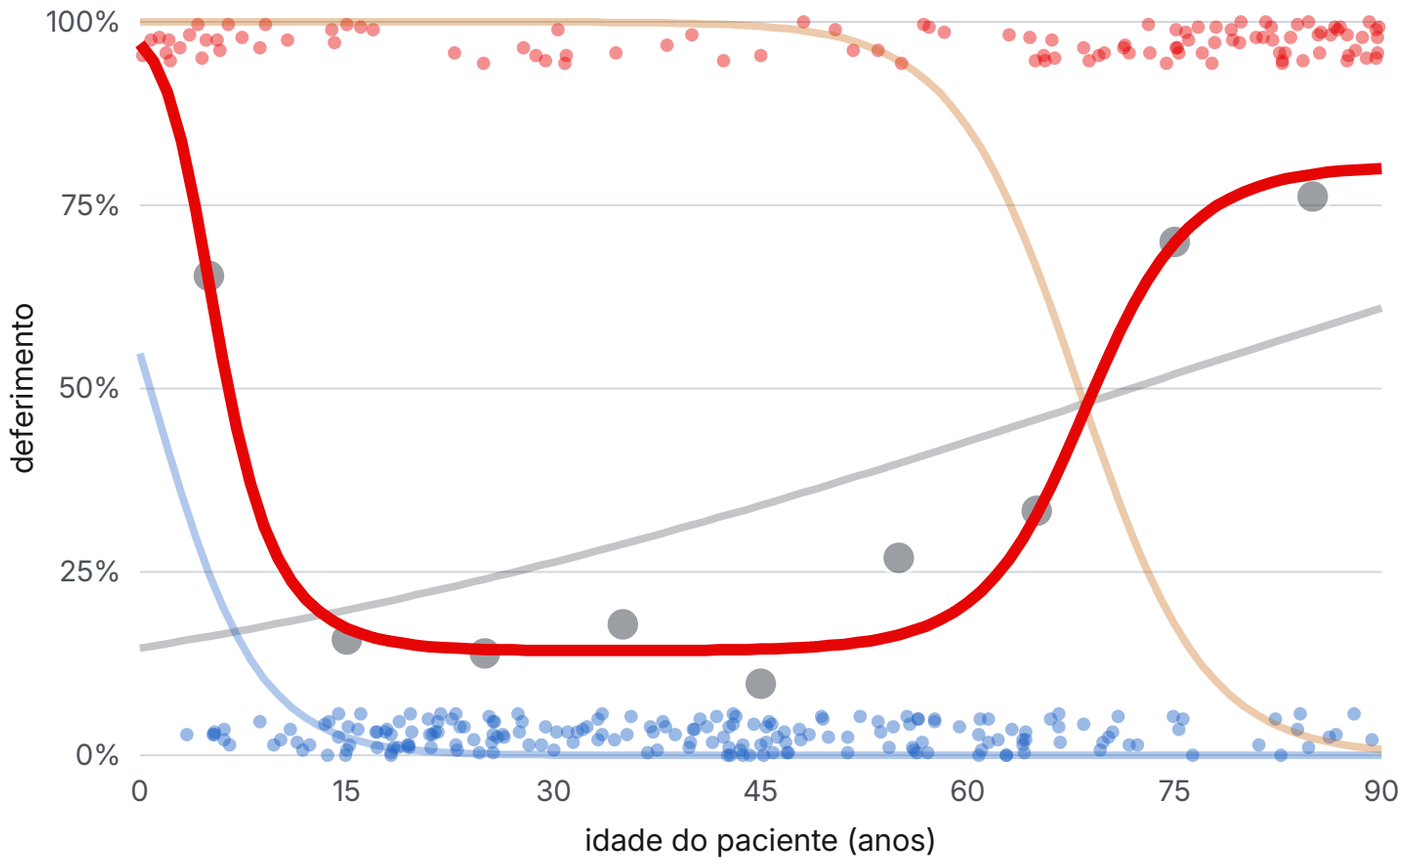
neurônio de verdade (esquema)

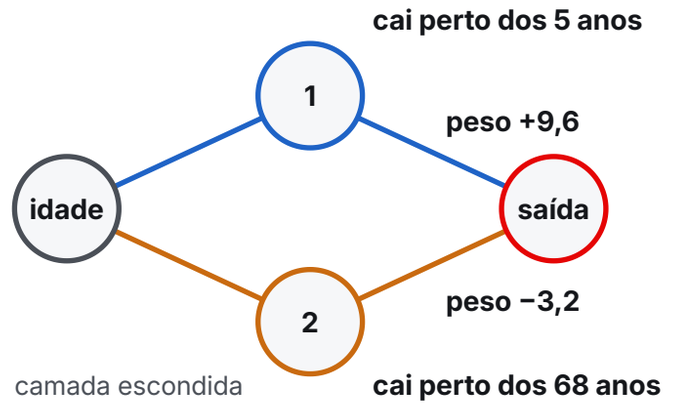


"neurônio" da rede: uma conta

O nome ficou, a semelhança não. Um neurônio real é uma célula, com química, tempo e milhares de conexões; até onde se sabe, o cérebro não aprende ajustando pesos por gradiente. Uma “rede neural” é uma **função com muitos parâmetros**, ajustados com os dados. Nada nela “pensa”.

Com uma camada escondida, a rede consegue fazer um U

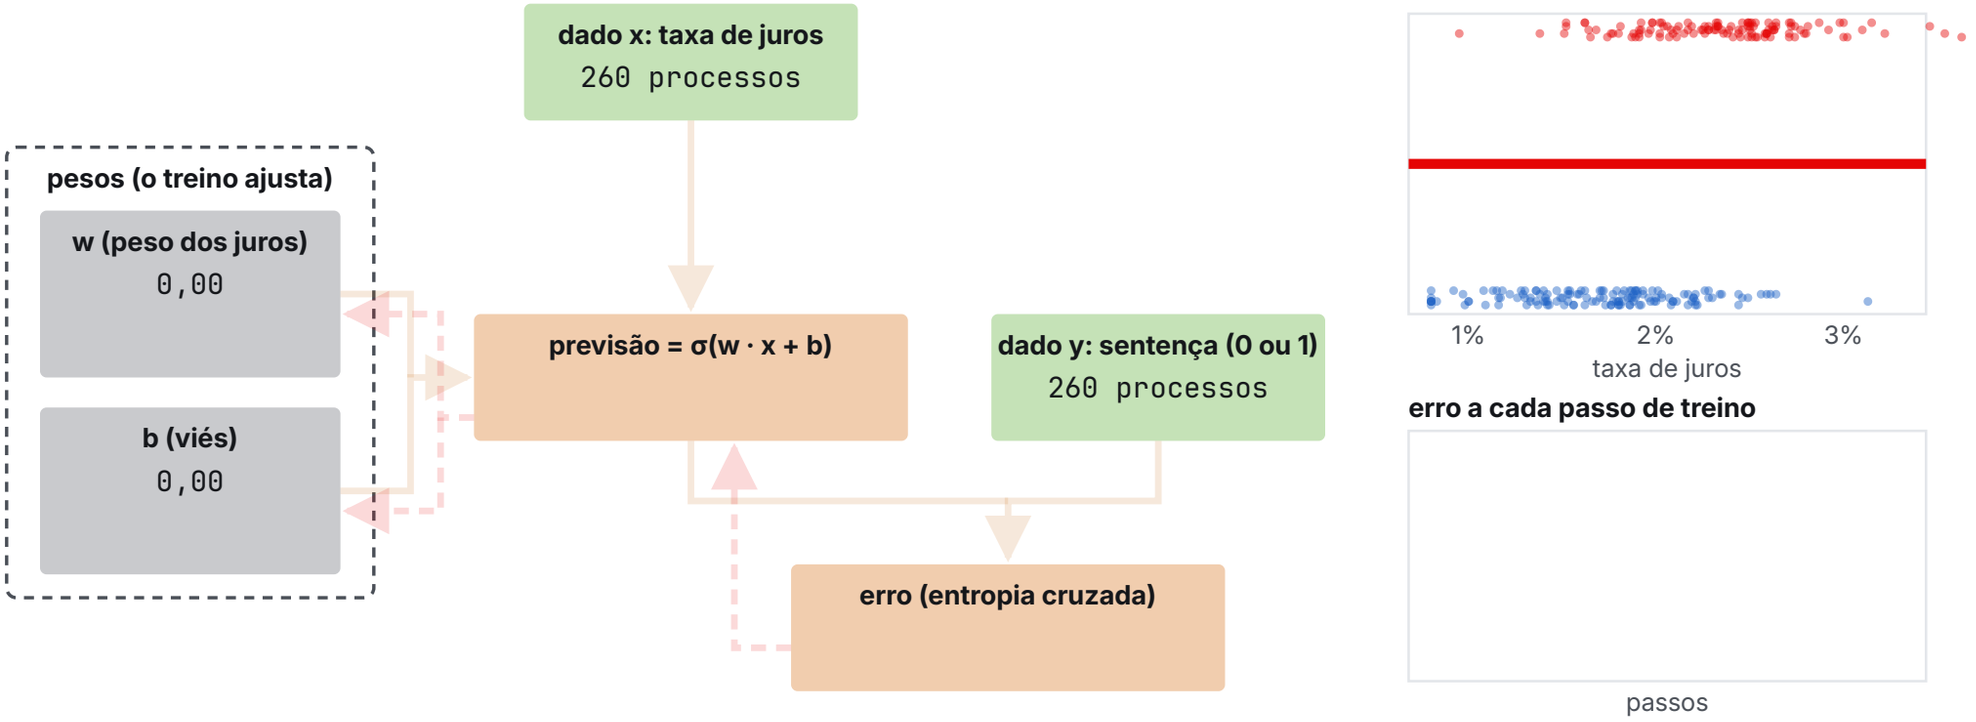




treinar de novo, com outro sorteio

A **saída** combina as duas curvas e faz o U. **Treine de novo:** com outro sorteio inicial, as curvas dividem o trabalho de outro jeito, e às vezes o treino empaca sem achar o U. A camada escondida não tem um significado fixo.

O treino da rede, passo a passo



próximo passo | treinar sozinho | recomeçar

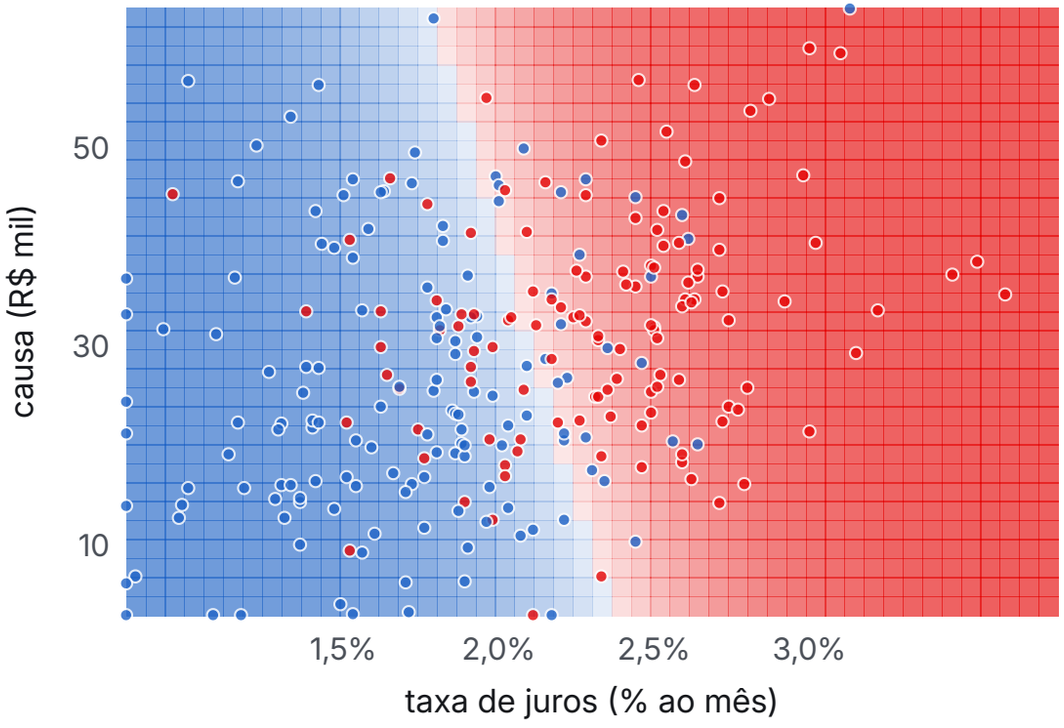
Os pesos começam em zero: a previsão é 50% para todo processo.

DO NEURÔNIO À REDE

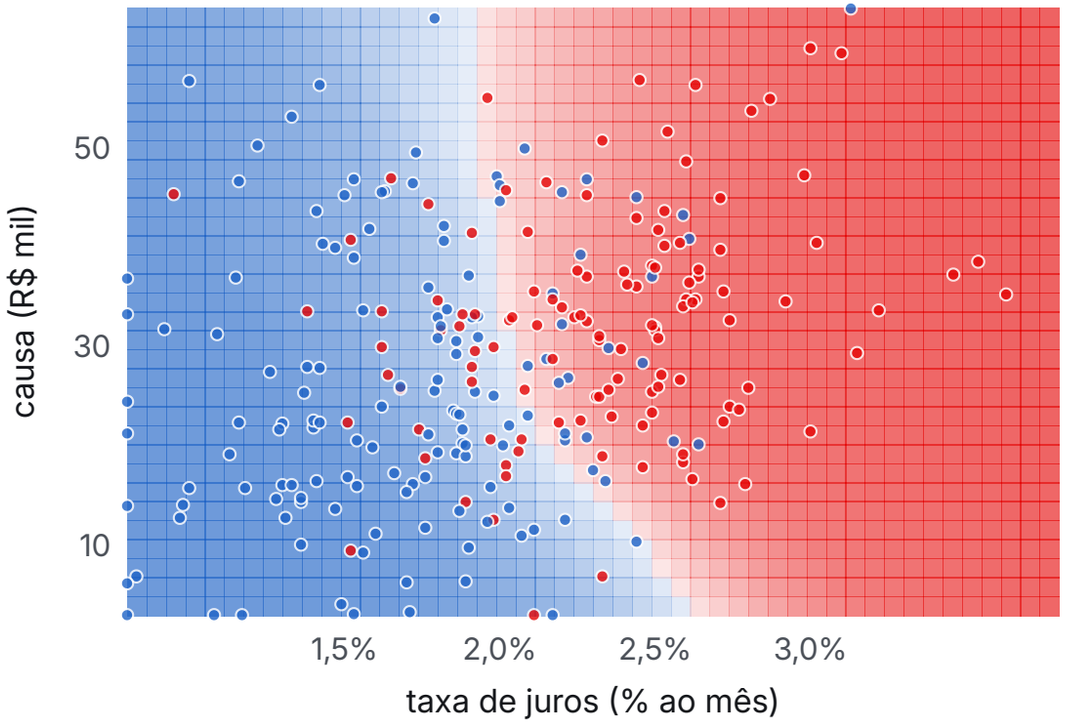
Verde: **dados**; cinza: **pesos**; laranja: **contas**. Numa rede com várias camadas, o passo para trás atravessa todas elas, do erro até os primeiros pesos: é a **retropropagação** (*backpropagation*).

Mais parâmetros nem sempre ajudam: a rede empata com a logística

Regressão logística, 3 parâmetros · AUC 0,885



Rede neural, 337 parâmetros · AUC 0,888



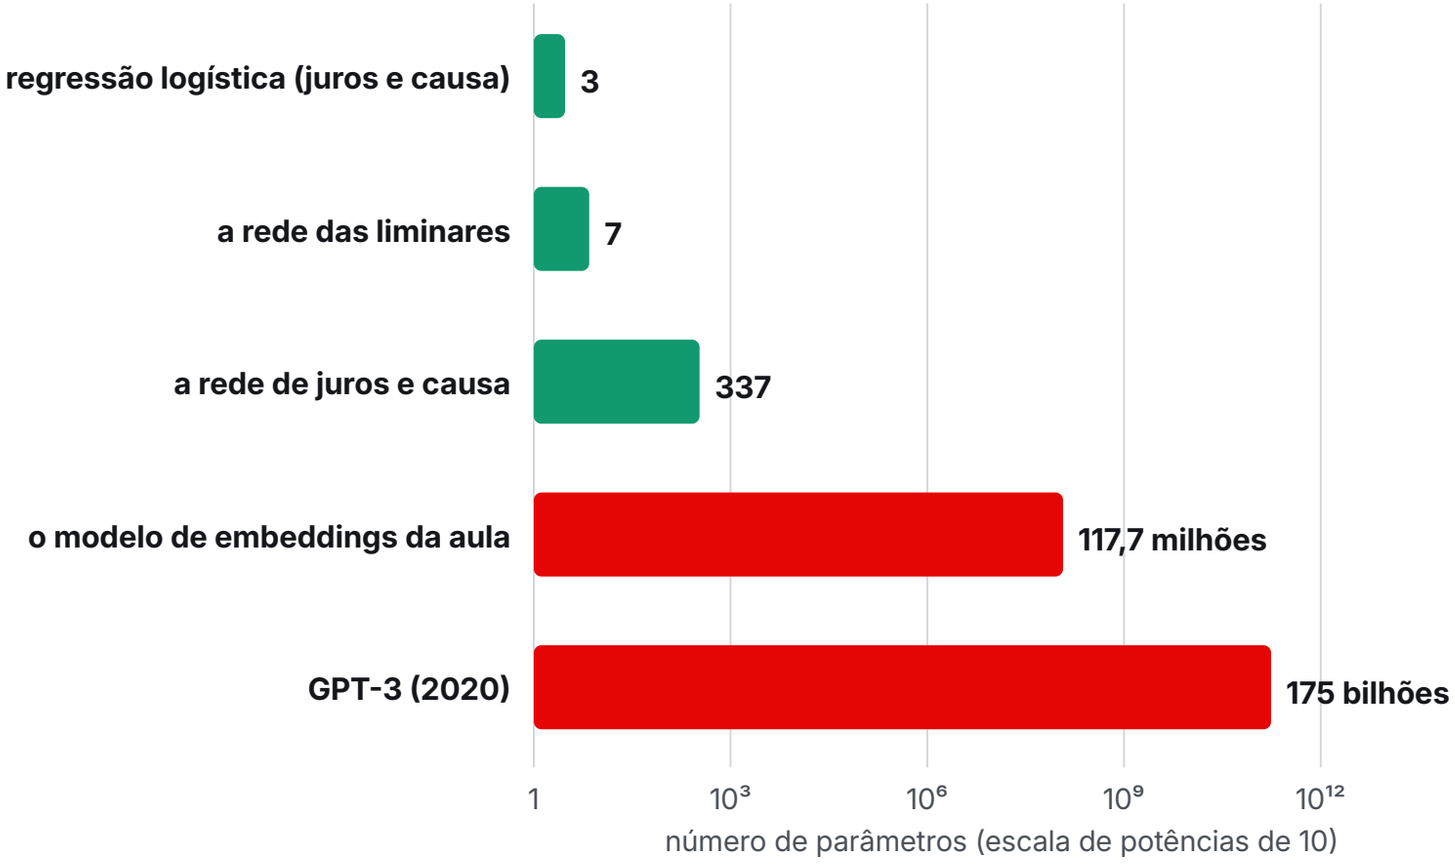
COMO LER OS MAPAS

A probabilidade de sentença favorável em cada ponto: **vermelho** acima de 50%, **azul** abaixo. A logística tem **3 parâmetros**; a rede, **337**. AUC na validação cruzada: **0,885** e **0,888**. Com duas variáveis, não há o que aprender a mais.

QUANDO A REDE VALE A PENA

Quando as variáveis já estão prontas numa tabela, a rede raramente ganha de uma logística ou de uma floresta, e é mais difícil de explicar. Ela brilha quando as variáveis **não existem ainda**: texto, imagem e som. É o que vem a seguir.

O tamanho dos modelos, em número de parâmetros



APRENDIZADO PROFUNDO

Redes com **muitas camadas**: cada camada transforma a saída da anterior. Um **parâmetro** é um peso ajustado no treino. A escala do gráfico é de potências de 10: cada marca é **dez vezes** a anterior.

MODELOS DE LINGUAGEM

O ChatGPT e parecidos são redes desse tamanho, treinadas para **prever a próxima palavra** em quantidades enormes de texto.

Texto vira número: cada palavra recebe um código

o	réu	pagou	a	dívida
1	2	3	4	5

o	réu	quitou	a	dívida
1	2	6	4	5

o	autor	pagou	a	multa
1	7	3	4	8

vocabulário

1	o
2	réu
3	pagou
4	a
5	dívida
6	quitou
7	autor
8	multa

pagou (3) e quitou (6): longe, mas querem dizer o mesmo



> **O problema:** o número é só um código. “Pagou” é 3 e “quitou” é 6, mas querem dizer quase o mesmo; e a conta 3 + 3 = 6 não tem sentido nenhum.

Dummies e embedding: de códigos a vetores com significado

dummies: uma coluna por palavra do vocabulário

pagou	quitou	multa
0	0	0
0	0	0
1	0	0
0	0	0
0	0	0
0	1	0
0	0	0
0	0	1

todas a mesma distância umas das outras

embedding: cada palavra, uma linha de números aprendidos

	d1	d2	d3
o	0,1	0,0	0,2
réu	0,7	0,1	-0,3
pagou	-0,5	0,8	0,4
a	0,0	0,1	0,1
dívida	-0,2	0,6	0,9
quitou	-0,4	0,9	0,3
autor	0,8	0,0	-0,2
multa	-0,1	0,5	-0,8

números ilustrativos; nos modelos reais, centenas por palavra

"o réu pagou a dívida"

média das linhas das palavras:

0,02 **0,32** **0,26**

um texto vira um vetor;
textos parecidos, vetores parecidos

Para um texto inteiro, um jeito simples é a **média** das linhas das suas palavras. O texto vira um vetor, e textos parecidos ficam perto.

Nos modelos atuais: pedaços de palavras e um vetor de 384 números

"O plano de saúde negou a cobertura do home care para a paciente idosa."

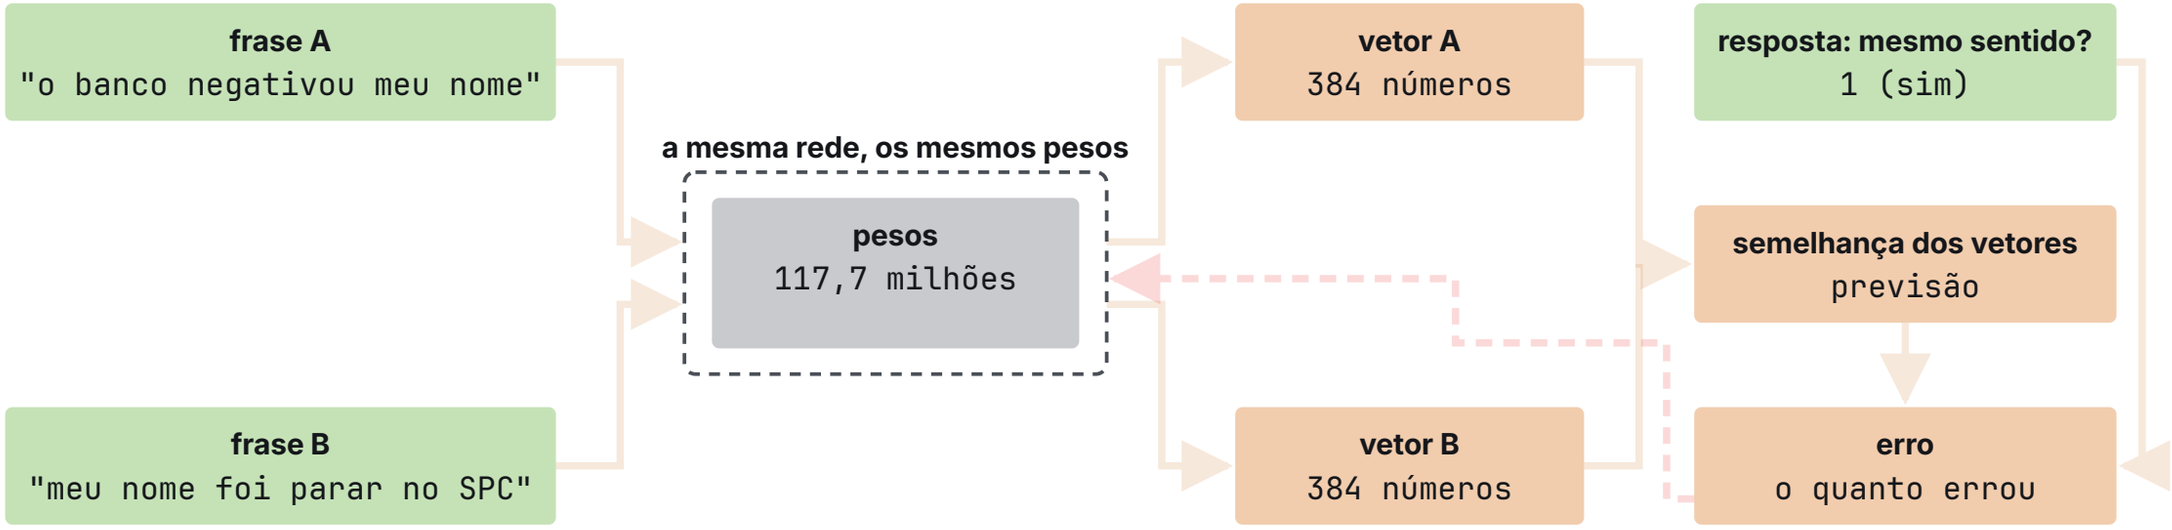
`O` `plano` `de` `saúde` `nego` `u` `a` `cobertura` `do` `home` `care` `para` `a` `paciente` `idos` `a` `.`

384 números: -0,027; 0,103; -0,051; 0,025; ...

um texto, um ponto

3. Um texto, um ponto. Os 384 números são as coordenadas de um ponto. Nenhum número sozinho tem nome: o que importa é a **distância**. Textos parecidos ficam perto, como no mapa daqui a pouco.

O embedding é uma rede neural: treinada para aproximar frases de mesmo sentido

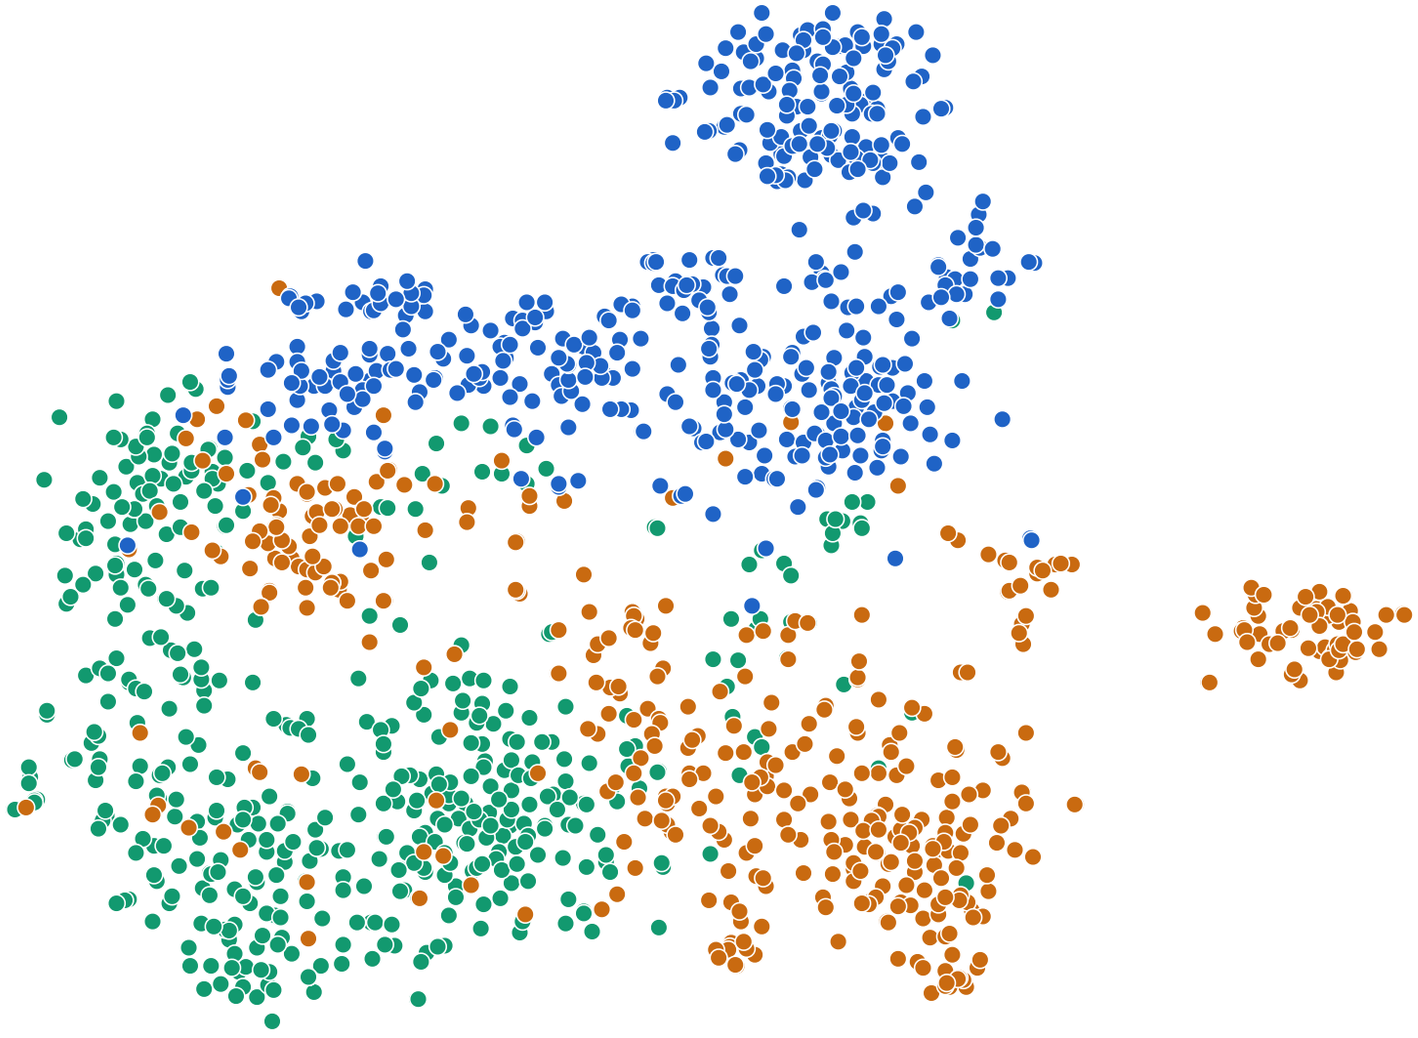


Depois do treino, guardamos só a rede que transforma uma frase em 384 números. É ela que usamos: os números viram **variáveis** para os nossos modelos.

ENGENHARIA DE VARIÁVEIS

Até aqui, as variáveis vinham prontas numa tabela, ou alguém as criava à mão. O embedding cria 384 variáveis de uma vez, a partir do texto, sem ninguém escolher quais. O preço: nenhuma delas tem nome.

Mapa de 1.423 ementas do TJSP: perto quer dizer parecido



plano de saúde (488)
dano moral (460)
criminal (475)

Das cinco vizinhas de cada ementa, **86%** são do mesmo tema. **Clique em um ponto** para ler a ementa e ver as cinco mais parecidas.

Busca por palavra e busca por significado

"a empresa aérea perdeu minha mala"

"o convênio não quis pagar o remédio do câncer"

"comprei um celular que veio quebrado e a loja não trocou"

"entrou na casa e levou a televisão"

"negativa de cobertura de home care"

Por palavra: conta as palavras em comum

Vícios de Construção 0,18
APELAÇÃO CÍVEL. Ação de obrigação de fazer cumulada com indenização por danos materiais e morais. Sentença de procedência parcial. Insurgência...

Vícios de Construção 0,14
AÇÃO DE INDENIZAÇÃO. Vícios construtivos. Sentença de procedência parcial. Recurso da instituição financeira ré. Não convencimento. Imóvel adquirido...

Transporte de Pessoas 0,14
APELAÇÃO - AÇÃO DE INDENIZAÇÃO POR DANOS MORAIS JULGADA PROCEDENTE – TRANSPORTE TERRESTRE - TROCA DE MALA ENTRE PASSAGEIROS NO DESEMBARQUE – fato...

Atraso de vôo 0,12
APELAÇÃO – Ação de indenização por danos morais – Transporte aéreo internacional - Atraso de voo e extravio temporário de bagagem - Aplicação do...

Por significado: compara os embeddings

Transporte Aéreo 0,58
APELAÇÃO CÍVEL – Direito Privado – Transporte aéreo nacional – Impossibilidade de embarque e restituição da bagagem no dia seguinte ao desembarque –...

Cancelamento de vôo 0,56
AÇÃO INDENIZATÓRIA – TRANSPORTE AÉREO NACIONAL – Sentença de parcial procedência, com condenação solidária das rés – APELAÇÃO DA CORRÉ TAM –...

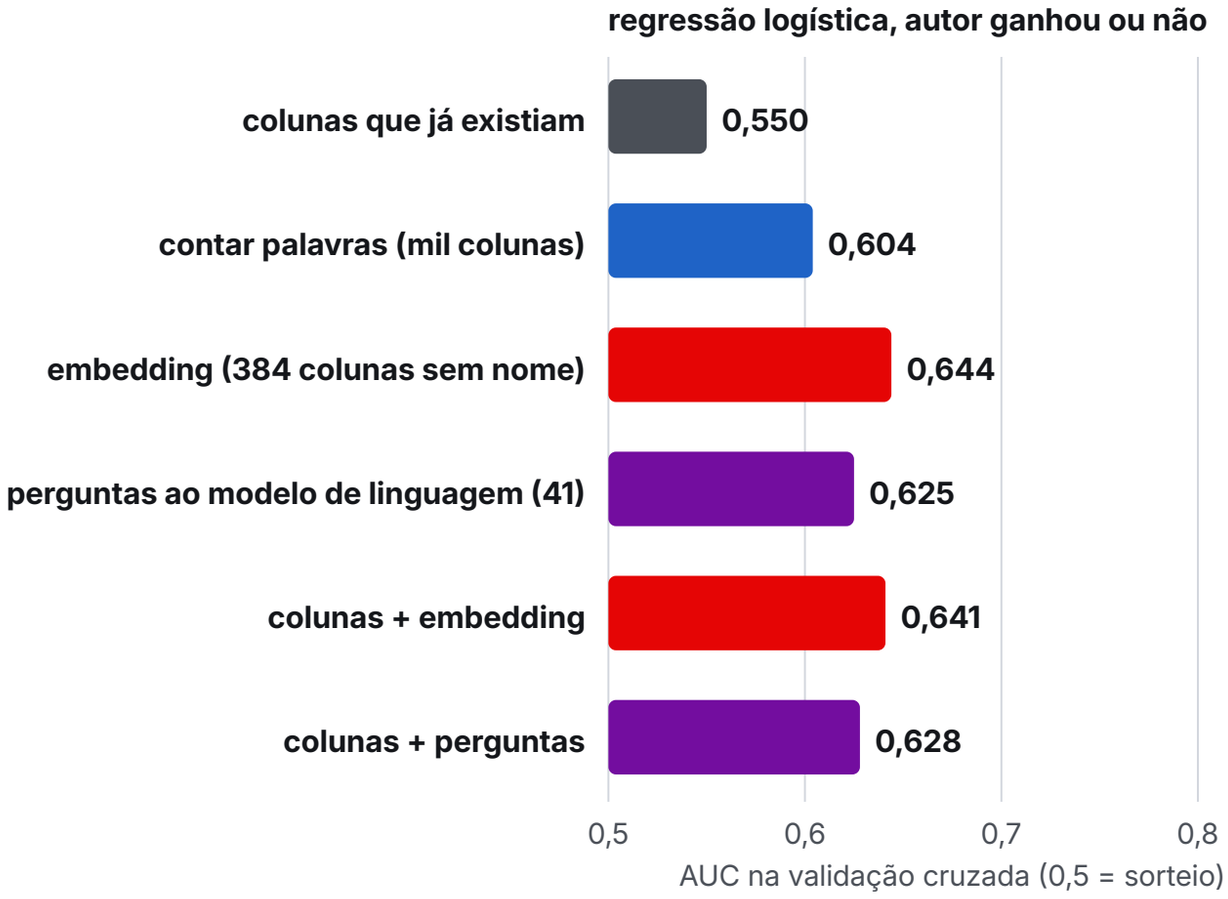
Atraso de vôo 0,56
APELAÇÃO – Transporte aéreo internacional - Ação de indenização por danos morais e materiais – Atraso do primeiro voo, com perda da conexão e chegada...

Atraso de vôo 0,54
APELAÇÃO – Transporte aéreo nacional - Ação de indenização por danos materiais e morais – Atraso do primeiro trecho do voo, com perda da conexão e...

PERGUNTA PARA A TURMA

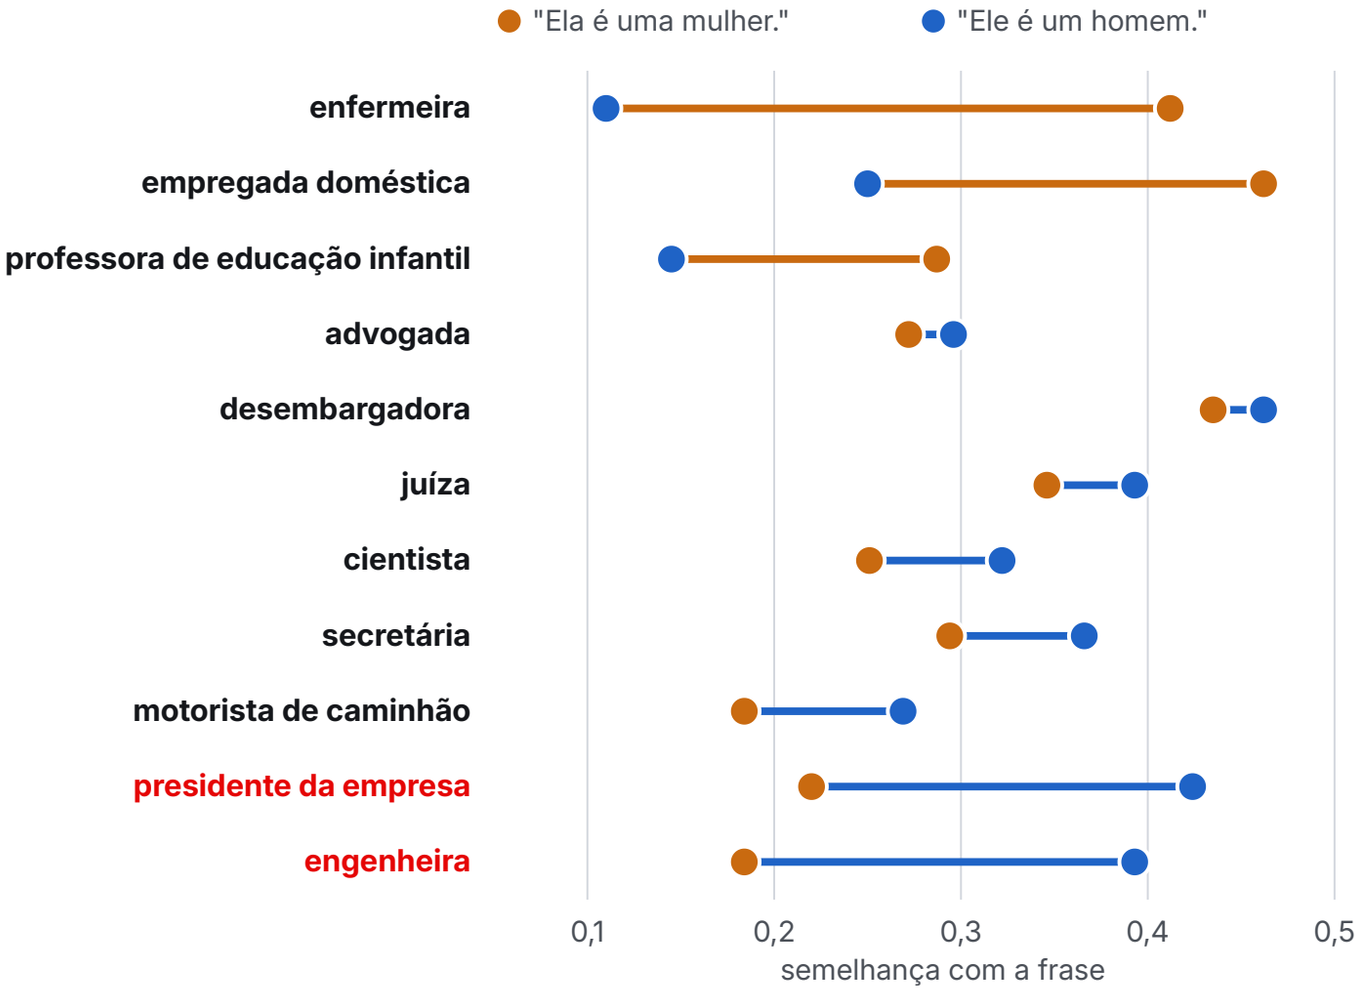
Clique nas cinco consultas: quatro escritas como um cliente falaria, uma com termos jurídicos. Em quais a busca por significado ganhou, e em qual a busca por palavra bastou? Por quê?

Embeddings como variáveis: o resultado de ações por erro médico



Terceiro jeito: perguntas. Um modelo de linguagem leu cada resumo e respondeu 41 perguntas de jurista: houve óbito? sequela? erro de diagnóstico? A AUC é parecida, com uma vantagem: são **poucas variáveis, cada uma com sentido jurídico**, que dá para explicar e auditar. As AUCs são modestas: antes da instrução (perícia, testemunhas), boa parte do resultado ainda não está nos autos.

Viés nos embeddings: profissões no feminino



COMO FOI MEDIDO

Frases como “Essa pessoa é engenheira.” comparadas com “Ela é uma mulher.” e “Ele é um homem.”, no mesmo modelo da aula. Quanto mais à direita, mais parecidas.

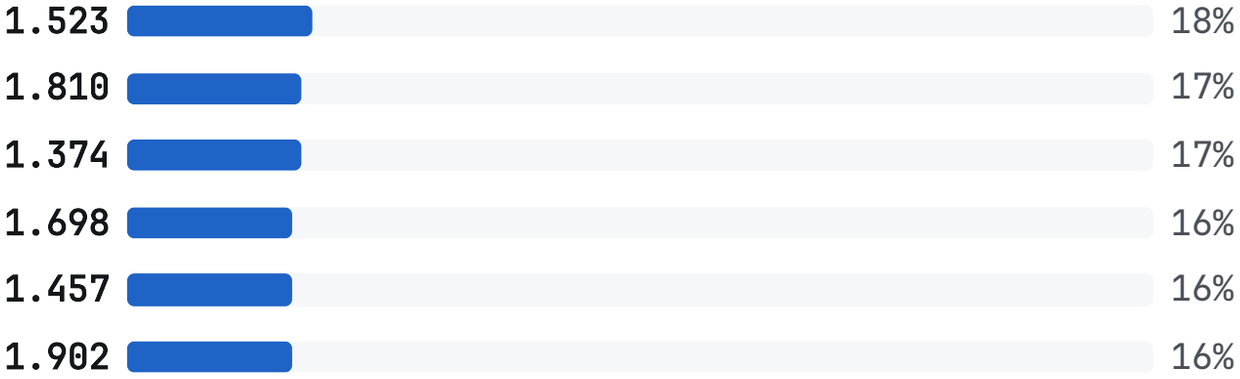
O QUE O MODELO APRENDEU

Mesmo com a palavra no feminino, **engenheira** e **presidente da empresa** ficam mais perto de “homem”. O modelo repete os padrões dos textos em que foi treinado: o tema da aula 25, agora dentro do vetor.

Um modelo de linguagem escreve uma palavra por vez

frase de sentença | pedir um precedente

Nesse sentido, decidiu o STJ no REsp nº



sortear a próxima palavra | recomeçar | temperatura **1,0**

Agora o texto pede um **precedente do STJ**. Vários números parecem certos, e o modelo **não consulta** um banco de decisões: escreve o que é **provável**, não o que é **verdadeiro**. Mesmo com temperatura baixa, sai um número com cara de real. É assim que nasce a **alucinação**.

Probabilidades ilustrativas, para mostrar a ideia.

Jurisprudência que não existe

Nova York, 2023 · Mata v. Avianca. Advogados citaram seis decisões inventadas pelo ChatGPT, com número e trecho. Multa de US$ 5 mil.

~~*Varghese v. China Southern Airlines*, 11th Cir., 2019~~

NÃO EXISTE

Justiça Federal da 1ª Região, 2023. Uma sentença citou precedentes do STJ que não existem. O juiz atribuiu o texto a um servidor e à sobrecarga; o CNJ abriu apuração.

NÃO EXISTE

TSE, 2025. Um recurso citou julgados produzidos com IA, que não estão no repositório do tribunal. Multa de cinco salários mínimos por litigância de má-fé (CPC, arts. 80 e 81) e ofício à OAB.

NÃO EXISTE

O QUE DIZEM AS REGRAS

- **Juízes** (Resolução CNJ 615/2025, art. 19): a IA generativa é **apoio**, nunca decisão autônoma, e o juiz permanece "integralmente responsável" pelo que assina.
- É vedado pôr **dados sigilosos ou em segredo de justiça** numa ferramenta privada, salvo anonimizados. O uso na redação fica **registrado** no tribunal; citar na decisão é opcional.
- **Advogados** (OAB, Recomendação 1/2024): revisar tudo o que a IA produz e proteger o **sigilo** do cliente.

PARA DEBATER

Um juiz cola a petição inicial no ChatGPT para resumir o caso. Pode? E se o processo correr em **segredo de justiça**? Ele deveria **avisar as partes**?

Busca com modelo de linguagem: responder citando a fonte

1 A pergunta

"o convênio não quis pagar o remédio do câncer"

2 Busca por significado

[1] Fornecimento de medicamentos 0,57
1007710-34.2025.8.26.0566
PLANO DE SAÚDE - Negativa de custeio de medicamento para tratamento de neoplasia maligna neuroendócrina, do subtipo tumor neuroendócrino primário de...

[2] Tratamento médico-hospitalar 0,55
1010457-03.2024.8.26.0562
DIREITO DO CONSUMIDOR. APELAÇÃO CÍVEL. PLANO DE SAÚDE . COBERTURA. DOENÇA PREEXISTENTE. MÁ-FÉ DO BENEFICIÁRIO. LIPOMA. DANOS MORAIS. Apelação de...

[3] Planos de saúde 0,55
1004461-41.2022.8.26.0191
DIREITO CIVIL. APELAÇÕES. OBRIGAÇÃO DE FAZER. PARCIAL PROVIMENTO DO RECURSO DA RÉ. NEGADO PROVIMENTO AO RECURSO DA AUTORA. Plano de saúde . Recusa ao...

3 Instrução ao modelo

Responda à pergunta **só com base nas ementas [1] a [3]**. Cite o número entre colchetes em cada frase. Se a resposta não estiver nas ementas, diga que não sabe.
+ a pergunta e as três ementas

4 Resposta, com as fontes

Nas três decisões, o TJSP considerou indevida a recusa do plano: a operadora não pode interferir na indicação do médico, mesmo fora do rol da ANS [1] [3]. Houve dano moral de R$ 8 mil [1] e R$ 5 mil [2] [3]. Atenção: só [1] trata de remédio para câncer; [2] e [3] são cirurgias.

Resposta escrita para ilustrar, a partir das ementas.

POR QUE ISSO AJUDA, E O QUE NÃO RESOLVE

O modelo responde **a partir de ementas reais**, achadas pelo embedding, e cada frase aponta para a fonte. Ainda pode resumir mal, mas agora **dá para conferir**. É a ideia por trás das ferramentas jurídicas com IA. Os embeddings também servem para agrupar **demandas repetitivas**, fazer **triagem** e achar **petições padronizadas**.

Exercício no notebook: busca e embeddings como variáveis

NOTEBOOK DA AULA 26 · INDIVIDUAL · ATÉ 14:00

Em aula: 1, 2, 3 e 5. Para casa: 4 e 6.

1. Ementas em números: palavras e embeddings.
2. Semelhança entre duas ementas.
3. A sua busca por significado.
4. O mapa das ementas.
5. Embeddings como variáveis: erro médico.
6. Medir um viés do modelo.

Abrir o notebook no Colab

ANTES DE COMEÇAR

A primeira célula instala o pacote e baixa o modelo (cerca de 470 MB): rode logo ao abrir. Gerar os embeddings das 1.423 ementas leva cerca de um minuto no Colab.

Resumo da aula e próximas aulas

PONTOS PRINCIPAIS DA AULA

- Um **neurônio** é a regressão logística; com camadas escondidas, a rede faz formas que uma reta não faz.
- **Treinar** é repetir: passo para frente, erro, gradientes e atualização.
- O **embedding** é uma rede treinada para aproximar textos de mesmo sentido: transforma texto em **variáveis**.
- Texto vira variável de três jeitos: contar palavras, embedding ou perguntas a um modelo de linguagem. As perguntas dão poucas variáveis, cada uma com sentido jurídico.
- Um **modelo de linguagem** escreve o provável, não o verdadeiro: conferir a fonte é dever de quem assina.

PRÓXIMOS PASSOS

- **14/11:** relatório da Pesquisa de Campo.
- **17 e 19/11:** debates da Pesquisa de Campo.
- **24/11, 12:00:** fim do Projeto 08, com o ranking em aula.