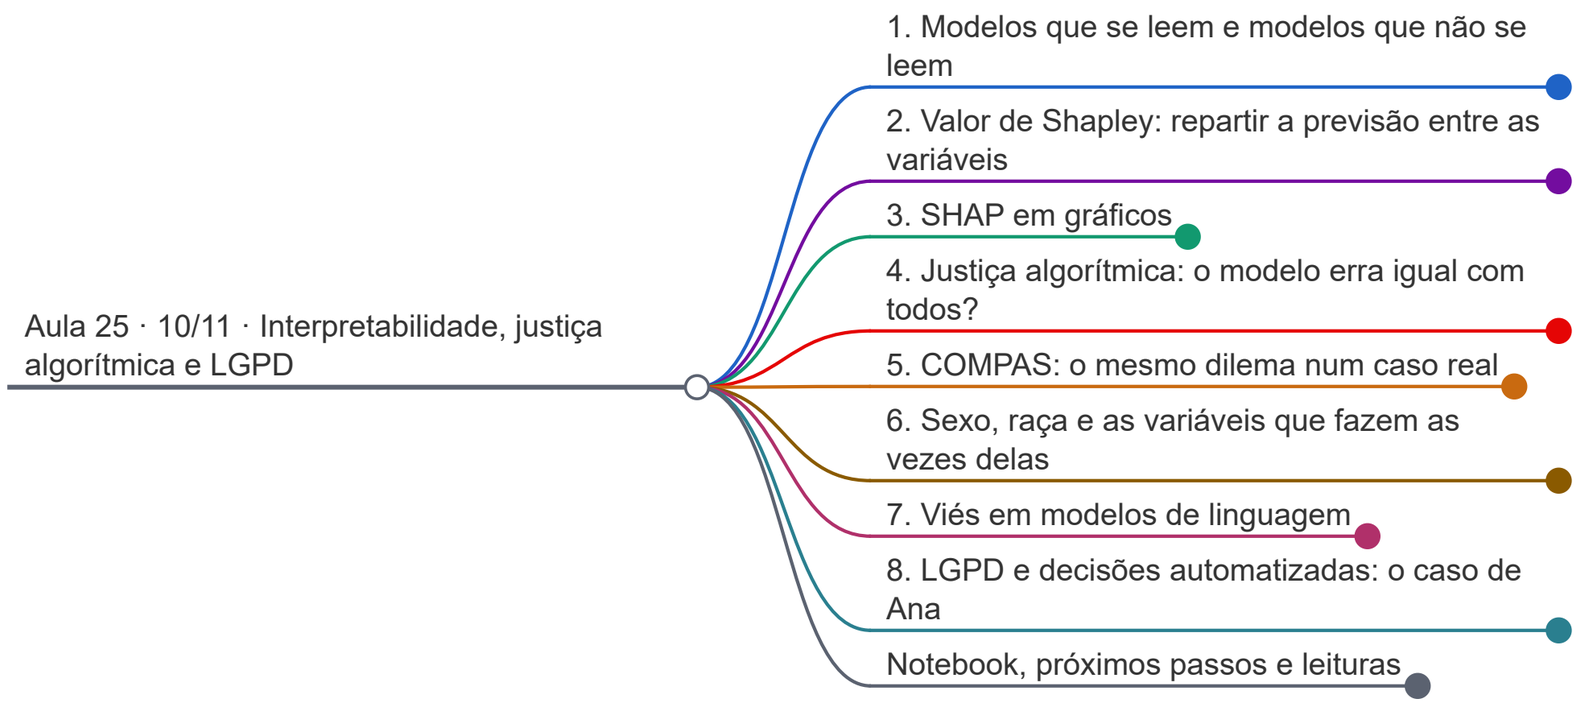

Aula 25 · 10/11 · Interpretabilidade, justiça algorítmica e LGPD
1. Modelos que se leem e modelos que não se leem
2. Valor de Shapley: repartir a previsão entre as variáveis
3. SHAP em gráficos
4. Justiça algorítmica: o modelo erra igual com todos?
5. COMPAS: o mesmo dilema num caso real
6. Sexo, raça e as variáveis que fazem as vezes delas
7. Viés em modelos de linguagem
8. LGPD e decisões automatizadas: o caso de Ana
Notebook, próximos passos e leituras

- 1. Modelos que se leem e modelos que não se leem
  - O mesmo processo: juros de **2,3% ao mês** e valor da causa de **R$ 30 mil** (base simulada das aulas 21 e 22)
  - **Regressão logística**: uma conta
    - logit = −8,11 + 3,47 × juros + 0,027 × causa
    - Previsão para o processo: **66%**
    - Dá para ver quanto cada variável soma e qual pesa mais
  - **Árvore** de profundidade 2: uma regra
    - Juros acima de 2,24 e até 2,56: folha com **79%**
    - A regra cabe numa frase; o valor da causa nem é perguntado
  - **Floresta** de 300 árvores: a média das árvores
    - Previsão para o processo: **88%**
    - Ninguém lê 300 caminhos
    - Para saber o que pesou, é preciso outra ferramenta: o **SHAP**

2. Valor de Shapley: repartir a previsão entre as variáveis

- A pergunta: dos 88%, quanto se deve aos **juros** e quanto ao **valor da causa**?
- Ponto de partida: sem saber nada do processo, a floresta prevê em média **43%**
- "Não saber" uma variável: usar os valores dela em outros processos da base e tirar a média das previsões
- Ordem 1: juros primeiro
  - Só os juros: 73% (**juros +30**)
  - Depois a causa: 88% (**causa +15**)
- Ordem 2: valor da causa primeiro
  - Só a causa: 48% (**causa +5**)
  - Depois os juros: 88% (**juros +40**)
- A mesma informação vale mais ou menos conforme o que já se sabe: as variáveis **interagem**
- Média das duas ordens = **valor de Shapley**
  - Juros: **+34,6 pontos**
  - Valor da causa: **+9,6 pontos**
  - A soma fecha: 43 + 35 + 10 = 88
- O **SHAP** faz a mesma conta com todas as variáveis (o shap.TreeExplainer confere a conta à mão)

- 3. SHAP em gráficos
  - **Cascata**: a explicação de um processo
    - Começa na média da floresta (**40%**) e soma uma variável por vez
    - Barra vermelha empurra para a sentença favorável; azul, contra
    - Processo A: 99%
    - Processo B: 1%
    - Processo C: 50%, porque juros (+34) e escritório de massa (−14) se anulam em parte
  - **Enxame**: as explicações de muitos processos
    - Floresta com todas as variáveis (AUC de 0,932 na validação cruzada) e 300 processos
    - Cada ponto é o SHAP de um processo numa variável
    - A cor é o valor da variável: vermelho, alto; azul, baixo
    - Juros altos ficam à direita: aumentam a chance de sentença favorável
    - A média do tamanho dos pontos (sem sinal) é a **importância geral** da aula 24, agora com a direção
  - Importância pelo SHAP (média sem sinal, em pontos)
    - Juros: 18,3
    - Escritório de massa: 9,4
    - Perícia: 9,2
    - Valor da causa: 4,4
    - Juizado: 2,2
    - Valor financiado, idade e tribunal: menos de 1
  - No Projeto 08: se uma variável pesa muito mais do que o esperado, desconfie de **vazamento** antes de comemorar a AUC

4. Justiça algorítmica: o modelo erra igual com todos?

- O caso: a triagem do **NatJus** (Projeto 06)
  - O NatJus não consegue analisar todos os processos de saúde
  - O modelo dá a cada processo a probabilidade de precisar de análise; à direita do **corte**, recebe análise
  - Erro grave: o paciente precisava da análise e **ficou sem**
- Separar por réu: **poder público** (SUS) ou **plano de saúde**; o modelo não usa essa informação
- **Sensibilidade** por grupo, com o mesmo corte (exemplo ilustrativo, corte 0,5)
  - Poder público: acha **8 de cada 10** que precisavam
  - Planos: só **5 de cada 10**
  - Nos planos, os casos que precisavam ganharam probabilidades mais baixas: o modelo os reconhece pior
- Uma saída: **um corte por grupo**
  - O corte dos planos desce para 0,35: 8 de cada 10 nos dois grupos
  - Custo: 10 análises a mais
- Mas a **precisão** se desiguala
  - Poder público: **2 de cada 3** analisados precisavam
  - Planos: só **2 de cada 5**
- Por quê? Os grupos são diferentes: precisam **20 de 100** contra **10 de 100**
- Com proporções diferentes, um modelo que erra não consegue igualar os erros e a precisão ao mesmo tempo
- **Qual igualdade importa é uma decisão normativa**
- No notebook, com a base real (corte 0,20): sensibilidade de 44% no poder público e 39% nos planos

5. COMPAS: o mesmo dilema num caso real

- Nota de **risco de reincidência** usada nos EUA em decisões de fiança e de pena
- O mesmo desenho com outros nomes: réus, voltar a ser preso em dois anos, alto risco
- ProPublica (2016): cerca de 7 mil réus da Flórida
- Voltaram a ser presos: **51 de 100** réus negros e **39 de 100** brancos (proporções diferentes, como no NatJus)
- Acusar a mais: entre quem **não** voltou, alto risco para **45%** dos negros e **23%** dos brancos
- Aliviar a mais: entre quem voltou, baixo risco para cerca de **1 em 4** negros e **1 em 2** brancos
- A resposta da empresa: precisão parecida (dos marcados de alto risco, voltaram 63% dos negros e 59% dos brancos)
- As duas análises estão certas, e não dá para igualar as duas coisas

- 6. Sexo, raça e as variáveis que fazem as vezes delas
  - Tirar raça e sexo do modelo parece resolver: o modelo não "vê" o grupo
  - Variáveis **substitutas**: bairro, escola, profissão, até o nome
    - Elas carregam a mesma informação, e o modelo reconstrói o grupo
    - O COMPAS não usava raça
  - Sem a variável, não dá para **auditar** a sensibilidade por grupo
  - Para debater: um modelo de risco para **audiências de custódia** pode usar raça? E o bairro? E o sexo, se na base os homens reincidem mais?
  - Base normativa
    - Constituição, arts. 3º, IV, e 5º, I
    - LGPD, art. 5º, II: origem racial é **dado sensível**
    - LGPD, art. 6º, IX: **não discriminação** (sexo não é dado sensível, mas o princípio vale)

7. Viés em modelos de linguagem

- Modelos de linguagem representam cada palavra como um **vetor** (aula 26)
- A diferença entre dois vetores carrega uma relação: de homem a mulher
- A mesma seta aplicada a "programador" chegou a "dona de casa" (Bolukbasi e coautores, 2016)
- Tradução de pronome neutro como "ele é médico" e "ela é enfermeira" (Caliskan e coautores, 2017)
- Jurisprudência **inventada** por chatbot numa peça (Mata v. Avianca, Nova York, 2023)
- Um modelo treinado em decisões passadas aprende os padrões delas, **inclusive os injustos**, e os repete em escala

- 8. LGPD e decisões automatizadas: o caso de Ana
  - Ana pede um empréstimo; o **score** do modelo nega o pedido sem que ninguém olhe o caso
  - **Art. 20**: quem é afetado por decisão tomada só por máquina pode pedir **revisão**
    - § 1º: informação clara sobre os **critérios e procedimentos**
    - Ressalva da própria lei: **segredo comercial**
    - § 2º: diante do segredo, a **ANPD** pode auditar se há discriminação (por exemplo, negar mais a quem mora na periferia)
  - STJ, **Súmula 550**: o score dispensa consentimento, mas o consumidor pode pedir esclarecimentos sobre os dados e as fontes
  - Dá para explicar sem abrir o código: a **cascata** do caso de Ana mostra o que pesou contra ela
  - Limites
    - A revisão **por pessoa natural** foi vetada em 2019 (Lei 13.853/2019): pode ser feita por outro sistema
    - No Judiciário, a **Resolução CNJ 615/2025** (que substituiu a 332/2020) exige supervisão humana e classificação de risco das soluções de IA

- Notebook, próximos passos e leituras
  - Notebook da aula 25
    - Ajustar a floresta e calcular o SHAP
    - Ler a cascata de um processo
    - Ler o enxame e comparar com a importância da aula 24
    - Medir a sensibilidade por grupo na triagem do NatJus (base real)
    - A explicação basta para o art. 20 da LGPD?
  - Próximos passos
    - Aula 26 (12/11): redes neurais e embeddings
    - 14/11: relatório da Pesquisa de Campo
    - Projeto 08 até 24/11, 12:00
  - Para consultar depois
    - Interpretable Machine Learning, de Christoph Molnar
    - Documentação do SHAP
    - Machine Bias, a reportagem da ProPublica
    - Fairness and Machine Learning, de Barocas, Hardt e Narayanan
    - LGPD, Lei 13.709/2018
    - Resolução CNJ 615/2025